

UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA
DEPARTAMENTO DE INFORMÁTICA
SANTIAGO - CHILE



“MODELACIÓN DE FLUJOS DE TRANSPORTE PÚBLICO
EN SANTIAGO DE CHILE MEDIANTE DEEP GRAVITY:
SENSIBILIDAD A LA DISCRETIZACIÓN ESPACIAL Y
EVALUACIÓN COMPLEMENTARIA DE ATRIBUCIONES
PREDICTIVAS”

PABLO ALBERTO CAMPOS ÁVILA

MEMORIA PARA OPTAR AL TÍTULO DE
INGENIERO CIVIL EN INFORMÁTICA

Profesor Guía: Daniela Opitz
Profesor Correferente: Nombre del correferente

Octubre - 2026

DEDICATORIA

A mis padres, Emilio y Carolina, y a mi hermano Benjamín, por estar siempre a mi lado, por hacerme sentir querido y acompañado en todo momento. A mis tías Darma y Poly, y a mi abuelita Bárbara, por velar siempre por mi bienestar, sus consejos y su cercanía.
A mi tata Emilio Campos, con todo mi cariño.

AGRADECIMIENTOS

A mi querido hermano Benjamín, por demostrarme siempre su cariño. No alcanzan las palabras para expresar cuánto te quiero.

A mis padres, Emilio y Carolina, por los innumerables sacrificios que han hecho por mí y por confiar siempre en mis capacidades. Les estaré infinitamente agradecido.

A mi prima Fernanda, por sus enseñanzas, sus palabras de aliento y por acompañarme en los momentos importantes.

A mis amigos Hernán y Diego, por hacer de esta etapa universitaria un camino mucho más llevadero.

A mi pareja, Susana Durán, por su compañía y por compartir conmigo este proceso. Tuve la suerte de coincidir contigo y de tenerte a mi lado durante esta etapa.

A todas las personas que conocí en la universidad, en la selección de atletismo y en el fútbol, por las experiencias y los momentos compartidos.

A mi profesora guía, Daniela Opitz, por su constante disposición en cada reunión, por sus correcciones y por orientarme durante el desarrollo de este proyecto.

Gracias a todos quienes fueron parte de este camino.

RESUMEN

Resumen— Esta memoria evalúa si *Deep Gravity*, que usa distancia y atributos territoriales para distribuir entre destinos un total conocido de viajes que sale de cada origen, sirve para modelar flujos de transporte público observables en Santiago de Chile y si su desempeño depende de la discretización espacial. Se analizaron 60.511.977 viajes reconstruidos desde DTPM, observados en 34 comunas entre el 1 y el 29 de noviembre de 2024, mediante tres representaciones: Zona 777 (793 unidades), H3-r7 (223 celdas) y H3-r8 (1.210 celdas). El desempeño se midió con el *Common Part of Commuters* (CPC), que cuantifica la fracción de viajes que el modelo coloca en los destinos correctos al comparar los flujos agregados observados y estimados. *Deep Gravity* superó las referencias uniforme y de gravedad exponencial en las tres representaciones. Sin embargo, no superó la atracción entrenada, que distribuye el total saliente según las llegadas observadas en entrenamiento: su CPC fue 14,68 % menor en Zona 777, 0,46 % menor en H3-r7 y 11,48 % menor en H3-r8. Frente a atracción, el mejor resultado ocurrió en H3-r7, la representación más agregada, donde casi la igualó; en las dos representaciones con más unidades todavía quedó entre 11,48 % y 14,68 % por debajo. Dentro del alcance evaluado, el modelo sirve para distribuir un flujo saliente conocido y estudiar su sensibilidad a la representación espacial; la configuración actual todavía no sustituye a atracción cuando existen llegadas observadas. Ninguna de las tres configuraciones XAI superó todos sus controles, aunque algunas aprobaron controles individuales, por lo que sus atribuciones todavía no constituyen explicaciones validadas.

Palabras Clave— modelación de flujos; transporte público; *Deep Gravity*; discretización espacial; inteligencia artificial explicable.

ABSTRACT

Abstract— This thesis evaluates whether *Deep Gravity*, which uses distance and territorial attributes to distribute a known number of trips leaving each origin across destinations, can model observable public transport flows in Santiago, Chile, and whether its performance depends on spatial discretization. The analysis used 60,511,977 trips reconstructed from DTPM and observed in 34 municipalities between November 1 and 29, 2024, under three representations: Zone 777 (793 units), H3-r7 (223 cells), and H3-r8 (1,210 cells). Performance was measured with the *Common Part of Commuters* (CPC), which quantifies the fraction of trips placed in the correct destinations when observed and estimated aggregate flows are compared. *Deep Gravity* outperformed the uniform and exponential-gravity baselines in all three representations. However, it did not outperform the trained attraction baseline, which distributes the known outbound total according to destination arrivals observed during training: its CPC was 14.68 % lower in Zone 777, 0.46 % lower in H3-r7, and 11.48 % lower in H3-r8. Relative to attraction, its best result occurred in H3-r7, the most aggregated representation, where it nearly matched the baseline; in the two representations with more units, it remained 11.48 % to 14.68 % lower. Within the evaluated scope, the model can distribute a known outbound flow and examine sensitivity to spatial representation; the current configuration does not yet replace attraction when observed arrivals are available. None of the three XAI configurations passed all their controls, although some individual controls passed, so their attributions do not yet constitute validated explanations.

Keywords— flow modelling; public transport; *Deep Gravity*; spatial discretization; explainable artificial intelligence.

GLOSARIO

Sigla	Nombre completo
CPC	Componente común de viajeros (<i>Common Part of Commuters</i>); medida de solapamiento entre flujos observados y predichos.
CRS	Sistema de referencia de coordenadas (<i>Coordinate Reference System</i>).
DPA	División político-administrativa.
DTPM	Directorio de Transporte Público Metropolitano.
EOD	Encuesta Origen-Destino.
EPSG	Identificador del registro de sistemas de referencia geodésicos originado por el <i>European Petroleum Survey Group</i> .
GAT	Red de atención en grafos (<i>Graph Attention Network</i>).
H3	Sistema jerárquico de indexación geoespacial utilizado para definir unidades de origen y destino.
INE	Instituto Nacional de Estadísticas.
MAUP	Problema de la unidad espacial modificable (<i>Modifiable Areal Unit Problem</i>); sensibilidad del análisis a la agregación y delimitación de unidades.
MLP	Perceptrón multicapa (<i>Multilayer Perceptron</i>).
OD	Origen-destino.
OSM	OpenStreetMap.
POI	Punto de interés (<i>Point of Interest</i>).
RMSE	Raíz del error cuadrático medio (<i>Root Mean Squared Error</i>).
SECTRA	Secretaría de Planificación del Transporte.
SHAP	<i>SHapley Additive exPlanations</i> ; enfoque de atribución de predicciones basado en valores de Shapley.
UTM	Proyección universal transversal de Mercator (<i>Universal Transverse Mercator</i>).
WGS 84	Sistema Geodésico Mundial de 1984 (<i>World Geodetic System 1984</i>).
XAI	Inteligencia artificial explicable (<i>eXplainable Artificial Intelligence</i>).

ÍNDICE DE CONTENIDOS

RESUMEN	IV
ABSTRACT	V
GLOSARIO	VI
ÍNDICE DE FIGURAS	X
ÍNDICE DE TABLAS	XI
INTRODUCCIÓN	1
CAPÍTULO 1: DEFINICIÓN DEL PROBLEMA	2
1.1 Fuentes de datos actuales y sus limitaciones	2
1.2 Limitaciones de los modelos vigentes	3
1.3 Especificidad del contexto latinoamericano	3
1.4 Síntesis del problema	4
1.5 Árbol del problema	5
1.6 Objetivo General	6
1.7 Objetivos Específicos	6
CAPÍTULO 2: MARCO CONCEPTUAL	7
2.1 Movilidad urbana y flujos origen-destino	7
2.2 Modelos clásicos de generación de flujos	8
2.2.1 Modelo gravitatorio	8
2.2.2 Modelo de oportunidades intervinientes	9
2.2.3 Modelo de radiación	10
2.3 Aprendizaje profundo aplicado a la movilidad	11
2.4 Deep Gravity	12
2.4.1 Formulación matemática	12
2.4.2 Arquitectura de la red neuronal	13
2.4.3 Vector de características geoespaciales	13
2.4.4 Resultados y desempeño	14
2.4.5 Síntesis comparativa de modelos	15
2.5 Explicabilidad en modelos de inteligencia artificial (XAI)	16
2.5.1 Valores SHAP	16
2.5.2 Gradientes integrados	16
2.6 OpenStreetMap como fuente de datos geoespaciales	17
2.7 Contexto de la movilidad en Santiago de Chile	18
CAPÍTULO 3: TRABAJO RELACIONADO	19
3.1 Descubrimiento de patrones en la movilidad individual	19
3.2 Unificación de modelos clásicos y enfoques continuos	19

3.3	Evolución de los modelos de oportunidades intervinientes	20
3.3.1	Modelo de oportunidades ponderadas por población	20
3.3.2	Modelos exploratorios: más allá de la selección secuencial	21
3.3.3	Modelo Unificado de Oportunidades	22
3.4	Deep Learning y modelos espacio-temporales en movilidad	23
3.5	Generación de flujos mediante datos no convencionales	23
3.6	En Resumen	24
CAPÍTULO 4: PROPUESTA DE SOLUCIÓN		26
4.1	Diseño general y trazabilidad	26
4.2	Datos de movilidad y reconstrucción del viaje	27
4.3	Delimitación territorial y cohorte común	28
4.4	Adaptadores espaciales, unidades y <i>tiles</i>	30
4.5	Construcción de atributos y vector de entrada	34
4.6	Modelo, muestreo y evaluación	36
4.6.1	Relación con el modelo gravitatorio	36
4.6.2	Arquitectura, soporte y pérdida	36
4.6.3	Modelos de referencia, particiones y métricas	37
4.6.4	Piloto y experimento mensual	38
4.7	Análisis complementario de atribuciones predictivas	39
4.8	Reproducibilidad, alcances y limitaciones	39
CAPÍTULO 5: VALIDACIÓN DE LA SOLUCIÓN		41
5.1	Piloto como validación preliminar	41
5.2	Soporte de prueba y caracterización espacial	41
5.3	Presencia espacial de los atributos OSM	43
5.4	Resultados globales en prueba	45
5.5	Trayectorias y selección por validación	48
5.6	Discusión del desempeño frente a la atracción	50
5.7	Sensibilidad al peso de evaluación	51
5.8	Recursos de ejecución	53
5.9	Resultado del análisis complementario de atribuciones predictivas	54
5.10	Discusión y amenazas a la validez	56
CAPÍTULO 6: CONCLUSIONES		57
6.1	Cumplimiento de objetivos	58
6.2	Contribuciones	59
6.3	Limitaciones	60
6.4	Trabajo futuro	61
6.5	Reflexión final	62
ANEXOS		63
Anexo A. Diccionario de atributos territoriales		63
Anexo B. Trazabilidad de las corridas mensuales		65

Anexo C. Controles de soporte, conservación de masa y ejecución	66
REFERENCIAS BIBLIOGRÁFICAS	68

ÍNDICE DE FIGURAS

1	Árbol del problema: causas, problema central y efectos. Fuente: Elaboración propia.	5
2	Procedimiento de Santiago: un núcleo común de viajes precede a los adaptadores espaciales y a la evaluación. Fuente: elaboración propia.	26
3	Delimitación del área de estudio: núcleo urbano referencial de 34 comunas dentro de la Región Metropolitana. El recorte territorial retiene 60.513.881 viajes (99,72 % de la cohorte) y 85.777.662,9386 de masa expandida (99,69 %); las 18 comunas rurales excluidas reúnen el 0,28 % de los viajes. El sistema de coordenadas es EPSG:32719 (WGS 84/UTM 19S). Estas cifras corresponden al filtro territorial previo a la exclusión común posterior de tres zonas sin polígono oficial verificable. Fuente: elaboración propia.	28
4	Viajes y masa expandida diarios de la cohorte final. Los puntos distinguen el tipo de día; el OD diario ya está restringido al dominio de 34 comunas y se aplican las exclusiones comunes 848, 849 y 852 en ambos extremos. Se muestran las 29 fechas procesables, del 1 al 29 de noviembre de 2024. Fuente: elaboración propia a partir de los viajes canónicos DTPM.	30
5	Escalas físicas y soporte de las tres representaciones sobre la misma cohorte final. El panel izquierdo muestra $\log_{10}$ del área de cada unidad en km^2 ; el derecho distingue unidades totales y orígenes con salida observada. Las diferencias de área, agregación y soporte sitúan la comparación del CPC dentro de cada rama. Fuente: elaboración propia con el contrato territorial y de atributos aprobado y el soporte del experimento mensual.	32
6	Escalas espaciales del procedimiento. Cada rama representa el mismo dominio mediante sus propias unidades OD; el <i>tile</i> cumple una función de partición, mientras las zonas y celdas forman las unidades OD. Esquema simplificado. Fuente: elaboración propia.	32
7	Ubicación de los diez <i>tiles</i> de 15 km sobre el área de estudio y rol de cada bloque en la partición de orígenes. Las etiquetas $E\{e\}_N\{n\}$ codifican los índices Este y Norte de cada bloque en la cuadrícula UTM. El bloque de prueba $E23_N420$ se destaca en rojo; los destinos de todo el dominio permanecen disponibles en las tres particiones. Fuente: elaboración propia a partir del dominio territorial aprobado y la agenda congelada de particiones.	33
8	Escalas de flujo, distancia y densidad poblacional en H3-r7. Los flujos corresponden a pares OD positivos y se expresan en $\log_{10}$ de viajes por par; las distancias entre centroides se agregan con masa expandida; y la densidad poblacional corresponde a personas por km^2 antes de la normalización del modelo. Fuente: elaboración propia con la cohorte y los atributos territoriales aprobados.	35
9	Concentración mensual de la masa expandida que sale y llega por km^2 en Zona 777. Cada panel usa la cohorte final de 60.511.977 viajes, del 1 al 29 de noviembre de 2024; los colores muestran $\log_{10}$ de masa expandida por km^2 . Fuente: elaboración propia con datos DTPM y geometría oficial Zona 777.	43

10	Presencia espacial de los atributos OSM usados por <i>Deep Gravity</i> en las tres representaciones. La densidad total de POI suma las cinco familias incluidas en el vector de entrada y se muestra como $\log_{10}(1 + \text{POI}/\text{km}^2)$; las unidades grises corresponden a valores cero de POI cartografiados. La presencia OSM corresponde a la fracción de los 18 atributos OSM con valor físico positivo. Los polígonos H3 se conservan completos según la política de borde del experimento. Fuente: elaboración propia a partir de los atributos <i>paper19</i> aprobados.	44
11	CPC de prueba expandida por semilla y modelos de referencia. Cada panel corresponde a una representación y mantiene su propio soporte de destinos; los cuadrados son referencias deterministas y los círculos son las semillas 20260909, 20260910 y 20260911 de <i>Deep Gravity</i> . Fuente: elaboración propia a partir de las métricas globales del experimento mensual.	47
12	Trayectorias mensuales de pérdida de entrenamiento y CPC global de validación para las tres semillas de cada rama. La pérdida se expresa como NLL por viaje expandido; los puntos destacados marcan los <i>checkpoints</i> seleccionados por CPC de validación y la línea discontinua señala la época 200. Fuente: elaboración propia a partir de las trayectorias del experimento mensual.	49
13	Sensibilidad del CPC de prueba al peso de evaluación. El eje horizontal usa masa expandida y el vertical conteos OD sin expansión; los círculos corresponden a las tres semillas de <i>Deep Gravity</i> y los cuadrados a los modelos de referencia. Cada punto reutiliza probabilidades congeladas y conserva los parámetros de las referencias ajustadas con peso expandido. La diagonal discontinua representa igualdad entre ambas métricas. Fuente: elaboración propia a partir de la evaluación de sensibilidad mensual.	52

ÍNDICE DE TABLAS

1	Comparación bibliográfica de modelos de flujos. Fuente: elaboración propia a partir de las referencias indicadas.	15
2	Fuentes de datos y función de las variables usadas por el procedimiento. Fuente: elaboración propia.	27
3	Cascada de filtros desde la entrega DTPM hasta la cohorte comparativa final. El porcentaje retenido usa como denominador los 86.327.914 viajes de los días 1-29; la columna de exclusión se calcula respecto de la fila anterior. Fuente: elaboración propia a partir de las auditorías F2-B-F2-D y del contrato aprobado F2-I.	29
4	Factibilidad de las resoluciones H3-r3 a H3-r8 sobre la cohorte territorial. Todas las filas conservan 60.513.881 viajes y 85.777.662,9386 de masa expandida. La densidad OD corresponde a pares observados sobre pares posibles entre unidades activas. Fuente: elaboración propia a partir del análisis F2-E con asignación directa de cada coordenada mediante <code>latlng_to_cell</code>	31

5	Representaciones espaciales operativas después de la exclusión común. Fuente: elaboración propia.	31
6	Soporte de las particiones del experimento mensual. Los orígenes son unidades con flujo saliente positivo; los viajes y la masa corresponden al origen de cada flujo. El número de <i>tiles</i> describe la agenda común de las tres ramas. Fuente: elaboración propia a partir de las particiones aprobadas de la cohorte final.	42
7	Soporte de prueba por representación. Los pares positivos y su densidad se calculan sobre los pares candidatos indicados. La masa observada usa el factor de expansión; los orígenes activos e inactivos se refieren a la partición de prueba. Fuente: elaboración propia a partir de la tabla de soporte del experimento mensual.	42
8	Presencia de atributos OSM y distancia al centroide del área de estudio. “Interior/periferia” compara el 75 % de unidades más cercanas con el cuartil más distante dentro de cada representación; ρ es la correlación de Spearman con la distancia. Fuente: elaboración propia a partir de los atributos físicos <i>paper19</i>	45
9	CPC global de prueba con peso expandido y salida condicionada al flujo saliente observado. Deep Gravity se resume con tres inicializaciones independientes; DE es la desviación estándar muestral. Uniforme, atracción entrenada y gravedad exponencial se calculan una vez por rama sobre el mismo soporte de prueba. Fuente: elaboración propia a partir de los resultados mensuales congelados.	45
10	Diferencia relativa del CPC medio de Deep Gravity frente a cada modelo de referencia, calculada dentro de cada rama. Fuente: elaboración propia a partir de los resultados mensuales congelados.	46
11	Recursos observados para las nueve corridas mensuales. Las horas corresponden a entrenamiento y validación; la memoria es el máximo registrado en las corridas de cada fila; el tamaño de artefactos se convierte de bytes a GiB (2^{30} bytes) y se redondea a dos decimales. Fuente: elaboración propia a partir del registro de costos e incidencias del experimento mensual.	53
12	Controles decisivos del análisis complementario de explicabilidad en Zona 777. En las filas con varios valores, el orden corresponde a los orígenes de referencia, semillas o tamaños indicados. Fuente: elaboración propia a partir de los registros de ejecución del análisis.	55
A.1	Atributos de población, uso de suelo y red vial del vector de entrada.	63
A.2	Atributos de puntos de interés y superficie por familia temática.	64
B.1	Corridas del experimento mensual y selección por validación.	65
C.1	Controles de soporte, repetición independiente y conservación de masa.	66
C.2	Tiempo de entrenamiento, memoria RAM y tamaño de artefactos por corrida.	66
C.3	Incidencias técnicas y efecto sobre los resultados reportados.	67

INTRODUCCIÓN

Los flujos de movilidad origen-destino (OD) cuantifican el número de personas que se desplazan entre dos ubicaciones geográficas en un período de tiempo definido. Constituyen un insumo para la planificación del transporte, la gestión de emergencias y el diseño de políticas urbanas [Rong *et al.*, 2024]. Obtenerlos mediante observación directa es costoso y poco frecuente, lo que ha motivado modelos que relacionan la distribución de destinos con características observables del territorio. El alcance y la transferibilidad de estos modelos requieren evaluación empírica en cada aplicación.

La estimación de flujos OD cuenta con una tradición extensa en la geografía cuantitativa. Modelos clásicos como el gravitacional [Zipf, 1946], el de oportunidades intervinientes [Stouffer, 1940] y el de radiación [Simini *et al.*, 2012] han dominado históricamente esta área. Estos modelos dependen de la especificación de sus variables y relaciones. El Marco Conceptual de esta memoria detalla sus formulaciones y restricciones. Las redes neuronales profundas permiten evaluar relaciones no lineales entre el tejido urbano y los flujos observados, dando origen a modelos como *Deep Gravity* [Simini *et al.*, 2021], cuya arquitectura y antecedentes se describen en el Marco Conceptual.

Esta memoria adapta y evalúa *Deep Gravity* para estimar la distribución de destinos del flujo saliente observado desde cada origen del transporte público de Santiago de Chile. A partir de datos DTPM y de atributos territoriales de Censo 2024 y OpenStreetMap, mediante la biblioteca *scikit-mobility* [Pappalardo *et al.*, 2023], se construye una cohorte común y se comparan Zona 777, H3-r7 y H3-r8 frente a referencias uniforme, de atracción y de gravedad exponencial. El diseño controla semillas, particiones espaciales, *checkpoints* y la liberación única de la prueba. *Deep Gravity* supera las referencias uniforme y gravitacional dentro de cada rama. Frente a la atracción, la brecha relativa de la red cambia de $-14,7\%$ en Zona 777 a $-0,5\%$ en H3-r7 y $-11,5\%$ en H3-r8, lo que muestra sensibilidad del desempeño a la discretización. Como análisis complementario, se evaluaron tres aproximaciones de XAI con controles de completitud y estabilidad. Los resultados situaron este componente en una evaluación de viabilidad; las atribuciones se reservan para configuraciones que superen esos controles.

El resto del documento se organiza en seis capítulos. El Capítulo 1 (Definición del Problema) diagnostica las brechas actuales en la estimación de flujos de movilidad en Santiago y establece los objetivos de la memoria. El Capítulo 2 (Marco Conceptual) presenta los fundamentos teóricos de los modelos de movilidad y detalla la arquitectura de *Deep Gravity*. El Capítulo 3 (Trabajo Relacionado) sitúa esta memoria respecto a la literatura existente sobre generación de flujos de movilidad. El Capítulo 4 (Propuesta de Solución) describe la construcción del conjunto de datos, la adaptación del modelo, el diseño experimental y el alcance del análisis complementario de explicabilidad. El Capítulo 5 (Validación de la Solución) presenta los resultados predictivos, su comparación con las referencias y el desenlace del análisis XAI. Finalmente, el Capítulo 6 (Conclusiones) sintetiza los hallazgos, sus limitaciones y las líneas de trabajo futuro.

CAPÍTULO 1

DEFINICIÓN DEL PROBLEMA

El transporte público de Santiago integra buses, Metro y tren suburbano. Durante 2024, el sistema registró un promedio de 5,0 millones de transacciones en un día laboral [Directorio de Transporte Público Metropolitano, 2025]. La cifra describe validaciones del conjunto del sistema; el número de personas y de viajes reconstruidos para esta memoria surge de definiciones y filtros distintos.

Comprender la distribución espacial de los desplazamientos en esta red, representada mediante flujos origen-destino (OD), es un insumo esencial para la planificación del transporte. También lo es para el diseño de infraestructura vial y la formulación de políticas urbanas basadas en evidencia [Rong *et al.*, 2024].

1.1. Fuentes de datos actuales y sus limitaciones

La planificación del transporte en Santiago se apoya actualmente en dos fuentes principales de datos de movilidad. La primera es la *Encuesta Origen-Destino* (EOD) de SECTRA¹. Su última versión fue levantada en 2012, con actualizaciones parciales en 2017. Esta encuesta constituye la referencia canónica de flujos de movilidad en la ciudad. Su periodicidad de siete a diez años introduce un desfase respecto de la movilidad actual. Esto es especialmente relevante tras la reconfiguración de patrones de desplazamiento producida por la pandemia de COVID-19. Su elevado costo de levantamiento agrava además esta desactualización.

La segunda fuente son los datos anonimizados de validación de la *tarjeta bip*², administrados por el DTPM³. Estos datos registran validaciones en Metro y buses con alta resolución temporal. El alcance empírico se concentra, por tanto, en esas etapas: caminata, taxi o colectivo pagados en efectivo y modos no motorizados quedan fuera de la fuente.

El análisis utiliza los viajes reconstruibles a partir de la entrega DTPM y el dominio territorial definido para la comparación. Los registros de validación, las etapas y los viajes reconstruidos son unidades distintas. La tarea estima la distribución de destinos del flujo saliente observado de cada origen dentro de la movilidad cubierta por la fuente.

La disponibilidad de estos registros permite evaluar modelos de distribución de flujos a partir de características observables del territorio. En esta memoria se estudia esa distribución condicionada al flujo saliente conocido; las limitaciones de las fuentes delimitan el alcance

¹Secretaría de Planificación del Transporte, organismo dependiente del Ministerio de Transportes y Telecomunicaciones de Chile.

²Nombre oficial del sistema de tarificación electrónica del transporte público de Santiago.

³Directorio de Transporte Público Metropolitano.

de las conclusiones.

1.2. Limitaciones de los modelos vigentes

Los modelos gravitatorios clásicos constituyen un antecedente para la estimación de flujos [Simini *et al.*, 2012, Rong *et al.*, 2024]. Las formulaciones basadas únicamente en población y distancia imponen una relación paramétrica entre esas variables y el flujo; por ello, su capacidad para representar subcentros de empleo u otras diferencias territoriales depende de la especificación elegida. La estimación de sus parámetros requiere datos observados y su transferencia a otro contexto necesita evaluación. El uso del suelo, los equipamientos y la infraestructura de transporte requieren variables adicionales.

Modelos basados en aprendizaje profundo, como *Deep Gravity* [Simini *et al.*, 2021], incorporan variables geoespaciales de OpenStreetMap (OSM) para representar relaciones no lineales. Su arquitectura y los resultados publicados se detallan en el Marco Conceptual. La evaluación empírica en Santiago establece el desempeño de esta adaptación.

1.3. Especificidad del contexto latinoamericano

La evaluación en Santiago requiere considerar que las ciudades latinoamericanas presentan características estructurales que las diferencian de los contextos donde estos modelos han sido desarrollados y evaluados. La segregación socio-espacial severa, la existencia de periferias urbanas de bajos ingresos con infraestructura de transporte deficitaria y la coexistencia de sistemas formales e informales de movilidad motivan examinar la transferencia de las funciones de disuasión por distancia calibradas en otros contextos [Vecchio *et al.*, 2020]. A esto se suma la heterogeneidad en la completitud de los datos geoespaciales abiertos: estudios recientes demuestran que la cobertura de OpenStreetMap en ciudades latinoamericanas alcanza apenas un 10 a 20 % en datos de edificaciones, frente a más del 50 % en Europa y Norteamérica, con un sesgo intra-ciudad correlacionado con el nivel de desarrollo humano subnacional [Herfort *et al.*, 2023, Barrington-Leigh y Millard-Ball, 2017].

En el caso específico de Santiago, evidencia empírica reciente basada en datos de telefonía móvil y enrutamiento multimodal demuestra que la proximidad espacial no se traduce en accesibilidad equitativa [Marín-Flores *et al.*, 2026]. Las poblaciones periféricas de menores ingresos enfrentan penalizaciones estructurales de accesibilidad y un conjunto restringido de opciones de destino, lo que implica que modelos que asumen un comportamiento uniforme de proximidad-a-oportunidad pueden producir errores sistemáticos que requieren evaluación empírica en este contexto. Estas condiciones motivan evaluar el desempeño de *Deep Gravity* en Santiago y examinar la estabilidad de las atribuciones predictivas con datos y condiciones locales.

La publicación original incorpora atribuciones mediante SHAP (*SHapley Additive exPlanations*) [Simini *et al.*, 2021]. En Santiago, la interpretación de las predicciones requiere examinar los atributos, la discretización y el soporte utilizados en esta adaptación. Por ello, la memoria evalúa como componente complementario la viabilidad de obtener atribuciones predictivas estables sobre modelos congelados, con una salida, referencias y controles explícitos. El análisis caracteriza contribuciones predictivas y no estima efectos causales.

La estimación de flujos requiere definir las unidades espaciales de origen y destino. En esta memoria se consideran la zonificación operativa Zona 777 del DTPM y las celdas del sistema jerárquico de indexación geoespacial H3. Al agrupar los mismos viajes de maneras diferentes, cambian el soporte de los flujos y la agregación de los atributos territoriales. Por ello, la elección de la discretización forma parte de la evaluación del modelo y de la interpretación de sus predicciones. El procedimiento de comparación se desarrolla en el Capítulo 4.

1.4. Síntesis del problema

En síntesis, el problema que aborda esta memoria se formula de la siguiente manera:

En la aplicación de Deep Gravity al transporte público de Santiago, falta evidencia sobre la sensibilidad del desempeño predictivo de los modelos de flujos a la discretización espacial. La zonificación Zona 777 y las celdas H3 producen representaciones distintas de los viajes y de los atributos urbanos. Una cohorte DTPM común permite contrastar la sensibilidad del desempeño dentro de cada representación frente a sus modelos de referencia. De manera complementaria, el análisis de explicabilidad examina la estabilidad de las atribuciones predictivas.

1.5. Árbol del problema

A continuación se presenta el diagrama del árbol del problema (Figura 1):




Figura 1: Árbol del problema: causas, problema central y efectos. Fuente: Elaboración propia.

La Figura 1 sitúa como problema central la falta de evidencia sobre la sensibilidad del desempeño predictivo de los modelos de flujos a la discretización espacial. En esta memoria, dicha sensibilidad se examina para el transporte público de Santiago mediante la comparación entre Zona 777 y H3.

Las causas representadas son la cobertura limitada de las fuentes de movilidad observada, la sensibilidad de los viajes a la agregación definida por las unidades espaciales, la variación en la construcción de atributos territoriales según la zonificación y la transferibilidad incierta de los modelos entre contextos geográficos.

Como efectos, la falta de evidencia puede llevar a atribuir a una mejora predictiva diferencias originadas por la agregación espacial, generalizar resultados a patrones de movilidad no observados en la fuente, interpretar atribuciones predictivas como evidencia de efectos causales o transferir resultados o modelos a otros territorios sin validación previa. Estos efectos describen riesgos metodológicos para la interpretación de resultados. Su posible utilidad para la planificación depende de la evidencia obtenida.

1.6. Objetivo General

Evaluar la sensibilidad de *Deep Gravity* y de sus modelos de referencia frente a la discretización espacial Zona 777-H3, a partir de una cohorte DTPM común, trazable y reproducible para Santiago de Chile.

1.7. Objetivos Específicos

1. Auditar y adaptar el código de referencia para verificar su funcionamiento y asegurar la trazabilidad de las ejecuciones.
2. Reconstruir viajes canónicos desde las tablas DTPM de viajes y etapas, definir una cohorte común y delimitar el núcleo urbano de Santiago mediante reglas espaciales reproducibles.
3. Construir representaciones comparables mediante Zona 777 y H3, evaluar la factibilidad de las resoluciones H3-r3 a H3-r8 y seleccionar candidatas para la evaluación experimental.
4. Construir atributos de población y de OpenStreetMap con fuentes, unidades y procedimientos de agregación y normalización explícitos.
5. Entrenar y evaluar *Deep Gravity* frente a los modelos de referencia uniforme, de atracción de entrenamiento y de gravedad exponencial, mediante una medida de solapamiento de flujos observados y predichos, el componente común de viajeros (*Common Part of Commuters*, CPC), sobre particiones espaciales comparables.
6. Evaluar, como análisis complementario, la viabilidad de obtener atribuciones predictivas estables de las características territoriales mediante técnicas de inteligencia artificial explicable (XAI), documentando la configuración, los controles y el alcance efectivo del análisis.

CAPÍTULO 2

MARCO CONCEPTUAL

Este capítulo presenta los fundamentos de la modelación de flujos origen-destino. Describe los modelos clásicos como antecedentes teóricos y expone la formulación de *Deep Gravity*, distinguiendo la publicación original de la adaptación utilizada en Santiago. Luego introduce los métodos de atribución de predicciones, las fuentes geoespaciales y el contexto de movilidad. El procedimiento experimental de esta memoria se especifica en el Capítulo 4.

2.1. Movilidad urbana y flujos origen-destino

La movilidad urbana comprende el conjunto de desplazamientos que realizan las personas entre distintas ubicaciones de la ciudad en un período de tiempo determinado [Rong *et al.*, 2024]. Comprender estos desplazamientos es un insumo fundamental para la planificación del transporte, el diseño de infraestructura vial y la formulación de políticas públicas basadas en evidencia.

Una representación sintética y cuantitativa de la movilidad urbana es la matriz origen-destino (matriz OD). Formalmente, dado un conjunto de n zonas geográficas $\mathcal{Z} = \{z_1, z_2, \dots, z_n\}$ que particionan el área de estudio, el flujo T_{ij} representa el número de viajes que se realizan desde la zona de origen z_i hasta la zona de destino z_j en un intervalo de tiempo fijo:

$$\mathbf{T} \in \mathbb{R}^{n \times n}, \quad T_{ij} \geq 0 \quad \forall i, j \in \{1, \dots, n\} \quad (1)$$

La colección de todos los flujos posibles entre pares de zonas conforma la matriz OD. Cada fila i representa los flujos salientes desde una zona de origen, y cada columna j los flujos entrantes hacia una zona de destino.

Obtener la matriz OD mediante observación directa, a través de encuestas domiciliarias, aforos de tráfico o registros de tarjetas de pago, es costoso y poco frecuente. Esta limitación ha motivado el desarrollo de modelos generativos de flujos, capaces de estimar $\mathbf{T}$ a partir de características observables del territorio, como la distribución de la población o la presencia de equipamientos urbanos, sin depender exclusivamente de mediciones directas [Simini *et al.*, 2021].

El problema de generación de flujos se formula de la siguiente manera: dado un conjunto de zonas $\mathcal{Z}$, sus características geoespaciales y los flujos totales salientes por zona $O_i = \sum_j T_{ij}$, estimar los flujos por par origen-destino $\hat{T}_{ij}$ para todos los pares (i, j) .

2.2. Modelos clásicos de generación de flujos

La estimación de flujos origen-destino cuenta con una tradición extensa en la geografía cuantitativa. Los modelos que se describen a continuación constituyen antecedentes teóricos de esta memoria. Los modelos de referencia utilizados en la evaluación de Santiago se especifican en el Capítulo 4.

2.2.1. Modelo gravitatorio

El modelo gravitatorio de movilidad establece una analogía con la ley de gravitación universal de Newton. La aplicación de este principio a los fenómenos sociales cuenta con antecedentes desde el siglo XIX. Posteriormente, Zipf [Zipf, 1946] lo formalizó en 1946 para la predicción de flujos. Su formulación postula que el volumen de desplazamientos entre dos zonas es directamente proporcional al producto de sus masas (habitualmente la población) e inversamente proporcional a la distancia que las separa:

$$T_{ij} = k \cdot \frac{P_i^\alpha \cdot P_j^\beta}{d_{ij}^\gamma} \quad (2)$$

donde P_i y P_j son las poblaciones de las zonas de origen y destino, d_{ij} es la distancia entre sus centroides, k es una constante de proporcionalidad, y α, β, γ son parámetros que deben calibrarse con datos observados. Zipf verificó empíricamente esta relación mediante datos de tráfico de buses, ferrocarriles y llamadas telefónicas entre ciudades de Estados Unidos. Los coeficientes obtenidos se aproximan a la unidad en todos los casos.

La formulación de la ecuación (2) recibe el nombre de *modelo de gravedad no restringido*. En la práctica, para garantizar que los flujos generados sean consistentes con los totales salientes observados, se utiliza la versión *restringida en origen* (*singly-constrained*), que normaliza los flujos de cada origen sobre todos sus destinos posibles:

$$\hat{T}_{ij} = O_i \cdot \frac{P_j^\beta f(d_{ij})}{\sum_k P_k^\beta f(d_{ik})} \quad (3)$$

donde $O_i = \sum_j T_{ij}$ es el flujo total saliente de la zona i y $f(d_{ij})$ es una función de disuasión por distancia, que puede adoptar una forma exponencial, $f(d_{ij}) = e^{-\lambda d_{ij}}$, con $\lambda > 0$, o una ley de potencia, $f(d_{ij}) = d_{ij}^{-\gamma}$, con $\gamma > 0$ y $d_{ij} > 0^4$.

Las limitaciones de un modelo gravitatorio dependen de su especificación [Rong et al., 2024]. La versión presentada relaciona población, distancia y flujo mediante parámetros calibrados con observaciones. Los usos del suelo, los equipamientos y

⁴Existe también la versión *doblemente restringida* (*doubly-constrained*), que impone conservación tanto de los flujos salientes O_i como de los flujos entrantes $D_j = \sum_i T_{ij}$. *Deep Gravity* utiliza exclusivamente la versión restringida en origen.

la infraestructura de transporte quedan fuera de su vector explicativo. Esta caracterización corresponde a esa formulación; otras extensiones de la familia gravitatoria incorporan atributos diferentes. Su adecuación y la transferencia de sus parámetros requieren evaluación empírica.

2.2.2. Modelo de oportunidades intervinientes

Stouffer [Stouffer, 1940] propuso en 1940 una perspectiva alternativa al modelo gravitatorio, en la que la distancia funciona como un contenedor espacial de oportunidades. Su hipótesis central es que el número de personas que se desplazan a una zona de destino es directamente proporcional al número de oportunidades en ese destino e inversamente proporcional al número de oportunidades intervinientes entre el origen y el destino.

Formalmente, sea y el número de personas que se desplazan desde un origen hasta una banda circular de anchura Δs , y sea x el número acumulado de oportunidades entre el origen y la distancia s . Stouffer postula:

$$\Delta y = a \cdot \frac{\Delta x}{x} \quad (4)$$

Integrando esta expresión diferencial, el número total de personas que se detienen dentro de un círculo de radio s desde el origen es:

$$y = a \cdot \ln f(s) + c \quad (5)$$

donde $f(s)$ es el número acumulado de oportunidades dentro de ese radio y c es una constante de integración. Stouffer verificó empíricamente esta formulación con datos de movilidad residencial en Cleveland, Ohio (1933-1935). Los resultados muestran una buena correspondencia entre los flujos observados y los predichos por el modelo.

Liu y Yan [Liu y Yan, 2020] formalizaron y extendieron esta familia de modelos de manera rigurosa. Para describir su funcionamiento, es necesario precisar tres conceptos fundamentales:

- **Oportunidades de un lugar (m_l):** cantidad de oportunidades que ofrece el lugar l para satisfacer el propósito del desplazamiento. En la práctica se asume que m_l es proporcional a la población del lugar.
- **Oportunidades intervinientes (s_{ij}):** suma de oportunidades de todos los lugares cuya distancia al origen i es menor que d_{ij} , excluyendo el propio origen i y el destino j . Si se incluyen origen y destino se utiliza la notación $S_{ij} = m_i + s_{ij} + m_j$.
- **Valor de beneficio de una oportunidad (z):** utilidad o recompensa que una oportunidad reporta al viajero. Se modela como variable aleatoria continua con distribución $p(z)$.

El modelo de Stouffer establece que cada individuo que parte del origen i ordena todos los destinos potenciales por distancia creciente y se detiene en cada lugar con una probabilidad fija proporcional al parámetro α . Bajo este mecanismo, la probabilidad de que un individuo en i elija el destino j adopta la forma [Stouffer, 1940, Liu y Yan, 2020]:

$$P_{ij} = \frac{e^{-\alpha(S_{ij}-m_j)} - e^{-\alpha S_{ij}}}{1 - e^{-\alpha M}} \quad (6)$$

donde m_j es la cantidad de oportunidades del destino j , S_{ij} es el total de oportunidades en el círculo de radio d_{ij} centrado en i (incluyendo origen y destino), α es el parámetro de absorción a calibrar con datos históricos, y $M = \sum_k m_k$ es el total de oportunidades del sistema. La ecuación (6) muestra que la probabilidad de elegir j crece con las oportunidades del destino m_j y decrece con el número de oportunidades intervinientes s_{ij} : cuanto mayor es la competencia en el camino, menor la probabilidad de alcanzar el destino.

La principal limitación del modelo original de Stouffer es que contiene el parámetro α , que debe calibrarse mediante datos históricos de flujo observado. Esta dependencia paramétrica restringe su aplicabilidad cuando no se dispone de matrices OD previas, y motivó el desarrollo de modelos libres de parámetros basados en el mismo concepto de oportunidades intervinientes.

2.2.3. Modelo de radiación

Simini et al. [Simini et al., 2012] propusieron en 2012 el modelo de radiación como una alternativa libre de parámetros al modelo gravitatorio. El modelo establece una analogía con los procesos de radiación y absorción en física de partículas. Su mecanismo se basa en un proceso estocástico de toma de decisiones locales: cada individuo en un origen busca la mejor oportunidad disponible dentro de radios geográficos crecientes y se desplaza hacia el destino donde la encuentra.

El mecanismo es el siguiente. Se asigna a cada oportunidad un valor de beneficio z extraído de una distribución de probabilidad $p(z)$. La probabilidad de que un individuo en la zona i elija la zona j como destino es la probabilidad de que el mejor beneficio dentro de j supere al mejor beneficio disponible dentro del círculo de radio d_{ij} centrado en i (excluyendo i y j). Esta probabilidad es:

$$p(n_j | m_i, s_{ij}) = \frac{m_i n_j}{(m_i + s_{ij})(m_i + n_j + s_{ij})} \quad (7)$$

donde m_i es la población de la zona de origen i , n_j es la población de la zona de destino j , y s_{ij} es la población total dentro de un círculo de radio d_{ij} centrado en i , excluyendo las poblaciones de i y de j . El flujo esperado entre i y j es entonces:

$$\langle T_{ij} \rangle = T_i \cdot \frac{m_i n_j}{(m_i + s_{ij})(m_i + n_j + s_{ij})} \quad (8)$$

donde $T_i = \sum_j T_{ij}$ es el flujo total saliente de la zona i . Una propiedad destacable del modelo de radiación es que satisface automáticamente la restricción de conservación de flujos: $\sum_j \langle T_{ij} \rangle = T_i$, sin necesidad de calibración de parámetros adicionales.

Simini et al. [Simini et al., 2012] validaron el modelo sobre datos de *commuting* del censo de Estados Unidos (2000). Los resultados muestran que el modelo de radiación supera al modelo gravitatorio en la reproducción de flujos observados, especialmente en viajes de corta distancia, que el modelo gravitatorio tiende a sobreestimar.

Variantes del modelo de radiación. La solidez del modelo original motivó diversas extensiones para adaptar su mecanismo a diferentes contextos. Ren et al. [Ren et al., 2014] propusieron una versión basada en tiempo de viaje en lugar de distancia euclidiana, incorporando así la resistencia real de la red de transporte. Kang et al. [Kang et al., 2015] formularon un modelo de radiación generalizado que introduce parámetros de escala y restricciones explícitas de producción y atracción, mejorando la precisión en contextos con heterogeneidad espacial marcada. Yang et al. [Yang et al., 2014] extendieron el modelo para incorporar la distribución no homogénea de oportunidades en el espacio, relevante en regiones con alta segregación funcional del suelo.

Limitación del modelo de radiación a escala intraurbana. A pesar de su éxito en la predicción de *commuting* interurbano, el modelo de radiación presenta una limitación estructural cuando se aplica a la escala intraurbana [Yan et al., 2014, Liu y Yan, 2020]. Su supuesto central, que cada individuo elige el destino más cercano cuyo beneficio supera al del origen, refleja adecuadamente el comportamiento en la búsqueda de empleo a larga distancia (donde la proximidad es costosa), pero no captura la lógica real de los desplazamientos dentro de una ciudad. En entornos urbanos, las personas consideran simultáneamente el conjunto de destinos disponibles en toda la ciudad, sin restringirse a los más cercanos. Estudios empíricos sobre datos de transporte público en diversas ciudades confirman que el modelo de radiación subestima sistemáticamente los flujos intraurbanos de largo alcance [Yan et al., 2014]. Adicionalmente, el modelo utiliza exclusivamente la población como *proxy*⁵ de oportunidades, sin incorporar características del tejido urbano como el uso de suelo o la distribución de actividades económicas. Estas limitaciones fueron el punto de partida para el desarrollo del modelo de oportunidades ponderadas por población, descrito en la Sección 3.3, y justifican el uso de modelos basados en aprendizaje profundo capaces de representar el tejido urbano más allá de la simple distribución poblacional, como *Deep Gravity*.

⁵Una variable *proxy* es una medida indirecta que se emplea en sustitución de una variable inobservable, asumiendo que existe una fuerte correlación estadística entre ambas.

2.3. Aprendizaje profundo aplicado a la movilidad

El aprendizaje profundo (*deep learning*) es un subcampo del aprendizaje automático que utiliza redes neuronales con múltiples capas de transformaciones no lineales para aprender representaciones jerárquicas de los datos [Rong *et al.*, 2024]. Su aplicación a la predicción de flujos de movilidad ha permitido incorporar un conjunto amplio de variables geoespaciales y capturar relaciones no lineales que los modelos clásicos no pueden representar.

Una red neuronal *feedforward* (de propagación hacia adelante) con L capas ocultas transforma un vector de entrada $\mathbf{x} \in \mathbb{R}^d$ mediante una secuencia de transformaciones afines seguidas de funciones de activación no lineales:

$$\mathbf{z}^{(0)} = \sigma(W^{(0)} \mathbf{x}), \quad \mathbf{z}^{(\ell)} = \sigma(W^{(\ell)} \mathbf{z}^{(\ell-1)}), \quad \ell = 1, \dots, L-1 \quad (9)$$

donde $W^{(\ell)}$ es la matriz de pesos de la capa ℓ y $\sigma(\cdot)$ es la función de activación, comúnmente ReLU ($\max(0, x)$) o su variante LeakyReLU ($\max(\alpha x, x)$ con α pequeño), que mitiga el problema del gradiente desvanecido en redes profundas.

En el contexto de la generación de flujos, el aprendizaje profundo ha sido aplicado de múltiples formas: como extensión no lineal del modelo gravitatorio [Simini *et al.*, 2021], mediante redes neuronales de grafos que modelan la estructura espacial de las zonas, y mediante modelos de series de tiempo que capturan la evolución temporal de los flujos [Luca *et al.*, 2024]. Esta memoria se enfoca en el primero de estos enfoques, implementado a través del modelo *Deep Gravity*.

2.4. Deep Gravity

Deep Gravity es un modelo de generación de flujos de movilidad propuesto por Simini *et al.* [Simini *et al.*, 2021] en 2021. Su contribución central es demostrar que el modelo gravitatorio clásico restringido en origen (ecuación 3) es formalmente equivalente a una red neuronal lineal de una sola capa con salida *softmax*, y que reemplazar esa capa lineal por una red neuronal profunda permite capturar relaciones no lineales entre las características del territorio y los flujos observados.

2.4.1. Formulación matemática

El modelo gravitatorio restringido en origen puede reescribirse como un modelo lineal generalizado con distribución multinomial. Para un origen i , la probabilidad de que un viaje se dirija al destino j es:

$$p_{ij} = \frac{\exp(\beta^\top \mathbf{x}(l_i, l_j))}{\sum_k \exp(\beta^\top \mathbf{x}(l_i, l_k))} \quad (10)$$

donde $\mathbf{x}(l_i, l_j) = [\ln P_j, d_{ij}]$ es el vector de características del par (i, j) , y $\beta = [\beta_1, \beta_2]$ son los parámetros del modelo.

Con distancia sin transformar, el numerador es proporcional a $P_j^{\beta_1} e^{\beta_2 d_{ij}}$; la disuasión exponencial corresponde a $\beta_2 < 0$. Una ley de potencia se obtiene incorporando $\ln d_{ij}$ en lugar de d_{ij} , para distancias positivas. Ambas son formulaciones gravitatorias, con funciones de disuasión distintas.

La formulación publicada utiliza la siguiente entropía cruzada entre distribuciones de destino normalizadas por origen, para orígenes con $O_i > 0$:

$$H = - \sum_i \sum_j \frac{T_{ij}}{O_i} \ln p_{ij} \quad (11)$$

Esta expresión asigna el mismo peso a cada origen. La pérdida efectiva de Santiago pondera las contribuciones por la masa observada, $-\sum_i \sum_j T_{ij} \ln p_{ij}$, como se especifica en la ecuación (24). Por tanto, las dos expresiones definen objetivos de entrenamiento distintos. *Deep Gravity* reemplaza el producto interno lineal $\beta^\top \mathbf{x}(l_i, l_j)$ por una red neuronal profunda $f_\theta(\mathbf{x}(l_i, l_j))$ que produce un *score* escalar. Las probabilidades de destino se obtienen mediante *softmax* sobre los *scores* de todos los destinos candidatos desde el origen i :

$$p_{ij} = \frac{\exp(f_\theta(\mathbf{x}(l_i, l_j)))}{\sum_k \exp(f_\theta(\mathbf{x}(l_i, l_k)))} \quad (12)$$

El flujo estimado desde i hacia j es entonces $\hat{T}_{ij} = O_i \cdot p_{ij}$. El total O_i se considera conocido; la tarea predictiva consiste en estimar la distribución de ese flujo entre destinos.

2.4.2. Arquitectura de la red neuronal

En la arquitectura descrita por Simini et al. [Simini et al., 2021], la función f_θ se implementa como una red neuronal *feedforward* de 15 capas ocultas con activación LeakyReLU. Las primeras 6 capas tienen dimensión 256 y las 9 restantes dimensión 128. La capa de salida produce un escalar:

$$\begin{aligned} \mathbf{z}^{(0)} &= \text{LeakyReLU}(W^{(0)} \mathbf{x}(l_i, l_j)) \\ \mathbf{z}^{(\ell)} &= \text{LeakyReLU}(W^{(\ell)} \mathbf{z}^{(\ell-1)}), \quad \ell = 1, \dots, 14 \\ f_\theta(\mathbf{x}(l_i, l_j)) &= \mathbf{w}^\top \mathbf{z}^{(14)} \end{aligned} \quad (13)$$

Esta distribución de anchos corresponde a la arquitectura descrita en la publicación. La implementación utilizada en Santiago tiene cinco capas ocultas de 256 unidades y diez de 128; su configuración efectiva se documenta en la Sección 4.6. El protocolo publicado emplea RMSprop, con momento 0,9, tasa de aprendizaje 5×10^{-6} , lotes de 64 orígenes y hasta 512

destinos muestreados por origen. El muestreo calcula la normalización sobre un subconjunto de candidatos durante el entrenamiento. La configuración de Santiago, documentada en la Sección 4.6, usa lotes de ocho orígenes y el soporte completo de destinos para entrenar y evaluar. Los parámetros de los experimentos finales se fijan en su diseño específico.

2.4.3. Vector de características geoespaciales

En la formulación de referencia [Simini *et al.*, 2021], el vector de entrada reúne atributos del origen y del destino, población y distancia. Su estructura puede representarse mediante el siguiente esquema de 39 componentes:

$$\mathbf{x}(l_i, l_j) = [\mathbf{f}(l_i), \mathbf{f}(l_j), \ln P_i, \ln P_j, d_{ij}] \quad (14)$$

donde $\mathbf{f}(l) \in \mathbb{R}^{18}$ reúne atributos geoespaciales de la ubicación l , P_i y P_j representan la población asociada a ambos extremos y d_{ij} es la distancia entre sus representantes espaciales. La procedencia de las variables y sus transformaciones deben identificarse en cada aplicación.

En Santiago se utiliza un conjunto de 19 atributos por ubicación y 39 componentes por par. Incluye densidad de población censal, coberturas de suelo, densidades viales y atributos de equipamientos y servicios. Su construcción, orden y transformación se definen en la Sección 4.5. El vector conserva 39 componentes por par, pero su contenido corresponde a fuentes y transformaciones distintas. La población de Santiago procede del Censo 2024 y se expresa como densidad después de la interpolación areal; su especificación difiere de las que usan logaritmos de población total o flujo saliente observado.

La agregación espacial depende de la magnitud del atributo. En Santiago, la densidad de población se expresa en personas por km^2 , la densidad de puntos de interés en puntos por km^2 y la densidad vial en km de vías por km^2 . La cobertura corresponde al área de la unión de polígonos de una categoría dividida por el área de la unidad, por lo que es una proporción adimensional entre cero y uno. Estas operaciones se distinguen de las transformaciones y la estandarización previas al entrenamiento, descritas en la Sección 4.5.

2.4.4. Resultados y desempeño

Simini *et al.* [Simini *et al.*, 2021] evaluaron *Deep Gravity* sobre flujos censales de *commuting* en Inglaterra e Italia y flujos derivados de telefonía móvil en el estado de Nueva York, utilizando la métrica *Common Part of Commuters* (CPC), definida como:

$$\text{CPC}(\hat{\mathbf{T}}, \mathbf{T}) = \frac{2 \sum_{i,j} \min(\hat{T}_{ij}, T_{ij})}{\sum_{i,j} \hat{T}_{ij} + \sum_{i,j} T_{ij}} \quad (15)$$

Cuando la masa del denominador es positiva, la métrica CPC toma valores en $[0, 1]$, donde 1 indica coincidencia exacta entre flujos generados y reales. Es equivalente al índice de Sørensen-Dice aplicado a flujos. En los experimentos publicados, *Deep Gravity* supera al modelo gravitatorio clásico en todos los contextos evaluados. Las mejoras en CPC global alcanzan hasta un 190 % en Inglaterra y un 1.066 % en el estado de Nueva York. El estudio también evaluó la transferencia geográfica. Entrenado en algunas ciudades del Reino Unido, mantuvo un desempeño similar al evaluarse en ciudades no vistas durante el entrenamiento. En el caso de Nueva York, la publicación aproxima la población mediante flujo saliente observado; Santiago utiliza otra definición de atributos. La auditoría técnica verifica la compatibilidad de la implementación y la evaluación de Santiago examina su desempeño empírico bajo el protocolo de esta memoria.

2.4.5. Síntesis comparativa de modelos

La Tabla 1 sintetiza antecedentes bibliográficos. La calibración, los atributos y el comportamiento intraurbano dependen de la variante; la evidencia latinoamericana se limita a las fuentes revisadas.

Tabla 1: Comparación bibliográfica de modelos de flujos. Fuente: elaboración propia a partir de las referencias indicadas.

Modelo	Atributos considerados	Calibración	Escala intraurbana	Interpretación de la predicción	Evidencia latinoamericana
Gravitatorio clásico [Zipf, 1946, Rong <i>et al.</i> , 2024]	Población y distancia	Exponentes y disuasión	Evaluación según contexto	Formulación explícita	—
Oportunidades intervinientes [Stouffer, 1940, Liu y Yan, 2020]	Oportunidades y su distribución	Parámetro de absorción	Depende de la formulación	Formulación explícita	—
Radiación original [Simini <i>et al.</i> , 2012, Yan <i>et al.</i> , 2014]	Población como aproximación de oportunidades	Sin parámetros de forma	Limitaciones documentadas	Formulación explícita	—
Variantes de oportunidades intervinientes [Yan <i>et al.</i> , 2014, Liu y Yan, 2019]	Oportunidades, habitualmente aproximadas por población	Depende de la variante	Evaluadas en los contextos citados	Formulación explícita	—
<i>Deep Gravity</i> [Simini <i>et al.</i> , 2021]	Población, atributos territoriales y distancia	Pesos de la red	Evaluación según contexto	Atribución posterior, como SHAP	—

Las celdas con — registran la ausencia de aplicaciones latinoamericanas en el corpus bibliográfico revisado. Las formulaciones explícitas permiten inspeccionar supuestos; las explicaciones causales exigen un diseño de evaluación específico. SHAP reúne aproximaciones agnósticas aplicables a modelos diversos, incluidas redes profundas [Lundberg y Lee, 2017]. El artículo original de *Deep Gravity* ya incorpora un análisis SHAP; esta memoria evaluó complementariamente la viabilidad de trasladar atribuciones a Santiago.

Estas características justifican la evaluación de *Deep Gravity* en Santiago. Los capítulos siguientes establecen su desempeño bajo el diseño experimental de esta memoria y evalúan la viabilidad de las atribuciones.

2.5. Explicabilidad en modelos de inteligencia artificial (XAI)

La explicabilidad de la inteligencia artificial (*eXplainable Artificial Intelligence*, XAI) se refiere al conjunto de técnicas que permiten comprender e interpretar las predicciones de modelos de aprendizaje automático complejos [Lundberg y Lee, 2017]. En el contexto de la planificación del transporte, la explicabilidad es relevante no solo desde el punto de vista académico, para estudiar cómo las variables de entrada contribuyen a las predicciones, sino también desde el punto de vista institucional, ya que permite a los planificadores auditar las predicciones del modelo.

2.5.1. Valores SHAP

SHAP (*SHapley Additive exPlanations*), propuesto por Lundberg y Lee [Lundberg y Lee, 2017], es un método de explicabilidad que fundamenta la importancia de cada variable en la teoría de juegos cooperativos de Shapley. La contribución de la característica i a la predicción del modelo para una instancia $\mathbf{x}$ se define como:

$$\phi_i(f, \mathbf{x}) = \sum_{S \subseteq \mathcal{F} \setminus \{i\}} \frac{|S|! (|\mathcal{F}| - |S| - 1)!}{|\mathcal{F}|!} [f(S \cup \{i\}) - f(S)] \quad (16)$$

donde $\mathcal{F}$ es el conjunto de todas las características, S es una coalición de características que no incluye a i , y $f(S)$ es la predicción del modelo usando solo las características en S . El valor ϕ_i representa la contribución marginal promedio de la característica i sobre todas las posibles coaliciones de características.

Los valores SHAP satisfacen tres propiedades deseables: *eficiencia* (la suma de todos los valores SHAP es igual a la diferencia entre la predicción y el valor base), *simetría* (características con igual contribución marginal reciben igual valor SHAP) y *dummy* (características sin influencia reciben valor cero). En conjunto, estas propiedades garantizan una atribución justa y consistente de importancias.

Los valores SHAP permiten estudiar la contribución de los atributos a una predicción con respecto a una referencia. En esta memoria, el análisis complementario incluyó aproximaciones de Shapley con referencias de entrenamiento y controles de estabilidad predefinidos. Los controles situaron este componente en una evaluación metodológica del procedimiento. Las atribuciones describen propiedades de las predicciones.

2.5.2. Gradientes integrados

Los *Integrated Gradients* [Sundararajan et al., 2017] son un método de atribución basado en el gradiente de la función del modelo con respecto a las variables de entrada. A diferencia de SHAP, que se fundamenta en la teoría de juegos cooperativos, los *Integrated Gradients* derivan las atribuciones directamente de la estructura diferencial de la red neuronal. Para una predicción $f(\mathbf{x})$ y una entrada de referencia $\mathbf{x}'$, la atribución de la característica i se define como:

$$\text{IG}_i(\mathbf{x}) = (x_i - x'_i) \cdot \int_0^1 \frac{\partial f(\mathbf{x}' + \alpha(\mathbf{x} - \mathbf{x}'))}{\partial x_i} d\alpha \quad (17)$$

El método satisface dos propiedades axiomáticas que lo distinguen de otras técnicas de atribución: *sensibilidad* (si la entrada y la referencia difieren en una sola característica y producen predicciones distintas, esa característica recibe atribución no nula) e *invariancia a la implementación* (la atribución depende únicamente de la función matemática que computa la red, no de su arquitectura interna). Estas propiedades lo hacen complementario a SHAP, que satisface eficiencia, simetría y dummy.

La elección de la entrada de referencia $\mathbf{x}'$ es un aspecto crítico del método. El vector nulo ($\mathbf{x}' = \mathbf{0}$) es una convención habitual en clasificación de imágenes, pero su significado depende de las variables y de su preprocesamiento. Una densidad cartografiada puede ser cero; después de estandarizar, el valor cero representa la media de entrenamiento. La referencia debe definirse en el espacio de entrada del modelo y su elección requiere un análisis de sensibilidad. En Santiago, las referencias ensayadas se construyeron con orígenes de entrenamiento de cada rama para conservar la coherencia con las transformaciones del modelo.

Los gradientes integrados pueden considerarse una técnica complementaria para atribuir una salida diferenciable del modelo a sus entradas. En Santiago, la consulta crítica cubrió solo parte de la cobertura requerida aun al aumentar la cuadratura. Por ello, el método quedó en etapa de evaluación metodológica.

2.6. OpenStreetMap como fuente de datos geospaciales

OpenStreetMap (OSM) es una base de datos geoespacial colaborativa y de libre acceso, construida y mantenida por una comunidad global de voluntarios desde su creación en 2004 [Haklay y Weber, 2008]. Su modelo de datos se articula en tres tipos de objetos geométricos: *nodos* (puntos), *vías* (secuencias de nodos que representan líneas o polígonos) y *relaciones* (agrupaciones de nodos y vías con un significado semántico compartido). Cada objeto puede llevar asociados pares clave-valor denominados *etiquetas* (*tags*), que codifican su naturaleza (por ejemplo, *amenity=hospital* o *landuse=residential*).

Para modelar flujos de movilidad, OpenStreetMap aporta atributos de uso del suelo, vialidad, equipamientos y servicios. En esta memoria, el término *amenities* se refiere a equipamientos y servicios urbanos; los atributos de OSM abarcan también información que no pertenece a ese conjunto. Los puntos de interés son una representación de algunas de estas entidades, mientras que otras se describen mediante áreas o líneas. La selección y construcción de los atributos empleados en Santiago se describe en la Sección 4.5.

Una limitación reconocida de OSM es la heterogeneidad espacial de su cobertura. Estudios previos [Barrington-Leigh y Millard-Ball, 2017] documentan variaciones de densidad y completitud asociadas, entre otros factores, al nivel socioeconómico y la accesibilidad; el patrón de Santiago se mide en esta memoria. El diagnóstico mide la presencia espacial de los atributos OSM que entraron a la red, tanto mediante su densidad como mediante la proporción de variables con valor positivo por unidad (Sección 5.3). Un valor cero registra ausencia cartografiada bajo las reglas de construcción. Estimar completitud externa o disponibilidad física de servicios requiere una fuente independiente de contraste.

2.7. Contexto de la movilidad en Santiago de Chile

El sistema integrado de transporte público de Santiago reúne buses, Metro y el servicio ferroviario Nos-Estación Central [Directorio de Transporte Público Metropolitano, 2025]. El área de estudio es un núcleo urbano referencial de 34 comunas y se diferencia de la cobertura operativa y de las delimitaciones estadísticas de la ciudad. La delimitación utilizada se describe en la Sección 4.3.

Las limitaciones de las fuentes de datos de movilidad disponibles para Santiago (la EOD de SECTRA y los registros de validación de la tarjeta bip!) se detallan en la Sección 1.1.

Esta memoria utiliza la entrega DTPM disponible entre el 1 y el 29 de noviembre de 2024. La unidad de análisis se reconstruye al unir viajes y etapas: las zonas y el factor de expansión principal provienen de viajes, mientras que las coordenadas UTM de subida y bajada se obtienen de etapas. La fuente permite construir matrices OD diarias y por período horario; el archivo del día 30 presentó errores de origen. Esta entrega constituye la principal fuente de flujos observados para el entrenamiento y la evaluación de *Deep Gravity* en Santiago.

CAPÍTULO 3

TRABAJO RELACIONADO

Este capítulo contrasta los supuestos, las necesidades de datos y las limitaciones de los enfoques de predicción de flujos origen-destino (OD) revisados en la literatura. El análisis fundamenta la elección de *Deep Gravity* como arquitectura para evaluar el desempeño predictivo con atributos geoespaciales y su sensibilidad a la discretización en Santiago.

3.1. Descubrimiento de patrones en la movilidad individual

Durante mucho tiempo, la falta de datos de trayectoria masivos obligó a los investigadores a extrapolar los patrones de movilidad humana a partir de la dispersión de billetes de banco [Brockmann *et al.*, 2006], asumiendo que los desplazamientos individuales seguían trayectorias puramente aleatorias y no acotadas, similares a los vuelos de Lévy (*Lévy flights*).

Este paradigma fue refutado por González *et al.* [González *et al.*, 2008], quienes utilizaron registros masivos de telefonía móvil (CDR, por sus siglas en inglés) de 100.000 usuarios durante seis meses para analizar la movilidad humana a nivel microscópico. Su trabajo demostró que, a diferencia del movimiento browniano o de los vuelos de Lévy, las trayectorias humanas son altamente predecibles, regulares y están fuertemente confinadas espacialmente. Los autores introdujeron el concepto de *radio de giro* para cuantificar la distancia típica recorrida por un individuo. Su análisis demostró que la aparente distribución pesada de saltos poblacionales es, en realidad, el resultado de agregar trayectorias individuales acotadas con una gran heterogeneidad en los radios de giro.

Esta contribución fue clave porque estableció que la movilidad urbana no es un fenómeno caótico, sino un sistema gobernado por rutinas (hogar-trabajo) y patrones espaciales predecibles. Esta previsibilidad estadística es la premisa fundamental que justifica el desarrollo de modelos matemáticos y algorítmicos para la predicción de flujos agregados.

3.2. Unificación de modelos clásicos y enfoques continuos

Con la confirmación de la regularidad en la movilidad humana, los esfuerzos se centraron en predecir los volúmenes de viaje entre distintas zonas de una ciudad o país. Tradicionalmente, este problema se abordó mediante el modelo gravitatorio [Zipf, 1946] y el modelo de oportunidades intervinientes [Stouffer, 1940]. Más tarde, el modelo de radiación [Simini *et al.*, 2012] ofreció una solución libre de parámetros que superaba varias limitaciones empíricas de la formulación gravitatoria.

Estos modelos presentaban un problema matemático estructural: dependían fuertemente de la partición espacial utilizada (comunas, distritos, censos), lo que generaba inconsistencias espaciales. Además, salvo casos triviales, las formulaciones discretas como el modelo gravitatorio violaban la propiedad de *aditividad*: el flujo hacia una región compuesta difería de la suma de los flujos hacia sus subregiones.

Para resolver esto, Simini, Maritan y Néda [Simini *et al.*, 2013] propusieron un marco unificado en el continuo. Los autores formularon un principio estocástico general de selección de beneficios laborales que preserva estrictamente la aditividad de los flujos. Además, demostraron que la gravedad, las oportunidades intervinientes y la radiación son, matemáticamente, casos particulares de una misma familia de procesos de selección espacial continua. Asimismo, introdujeron un parámetro de selección (λ) que flexibilizó el modelo de radiación para adaptarlo a diferentes escalas geográficas.

A pesar de su solidez teórica y elegancia matemática, este paradigma continuo arrastra una limitación fundamental de representación: asume que la cantidad de oportunidades en una región es estrictamente proporcional a su masa poblacional. En la realidad urbana, existe una profunda segregación funcional del suelo (zonas industriales, distritos financieros, áreas puramente residenciales) que rompe esta proporcionalidad lineal, exigiendo modelos capaces de entender el tejido urbano más allá de la simple aglomeración de personas.

3.3. Evolución de los modelos de oportunidades intervinientes

El concepto de oportunidades intervinientes de Stouffer [Stouffer, 1940] inspiró, a lo largo de las décadas siguientes, una familia de modelos cada vez más sofisticados que buscaron superar las limitaciones paramétricas y escalares del modelo original. Liu y Yan [Liu y Yan, 2020] ofrecen una revisión sistemática de esta evolución, identificando una línea de progresión que va desde el modelo de radiación hasta un marco unificado de comportamiento de destino. Esta sección sigue esa trayectoria, enfatizando los modelos más relevantes para el contexto intraurbano de la presente memoria.

3.3.1. Modelo de oportunidades ponderadas por población

Yan *et al.* [Yan *et al.*, 2014] identificaron en sus experimentos que el modelo de radiación falla sistemáticamente al predecir flujos dentro de una ciudad: sobreestima los flujos de corto alcance y subestima los de largo alcance intraurbano. Los autores argumentaron que el supuesto de selección secuencial por proximidad no refleja la realidad del viajero urbano, quien considera simultáneamente el conjunto completo de destinos disponibles en la ciudad.

Para corregir esto, Yan *et al.* [Yan *et al.*, 2014] propusieron el *Modelo de Oportunidades Ponderadas por Población* (Population-Weighted Opportunity, PWO), en el que la probabilidad

de elegir el destino j desde el origen i es proporcional a las oportunidades del destino e inversamente proporcional a las oportunidades totales dentro de un círculo centrado en el destino j con radio d_{ij} :

$$P_{ij} = \frac{m_j}{S_{ji}} \quad (18)$$

donde m_j es la cantidad de oportunidades (población) del destino j , y $S_{ji} = m_j + s_{ji} + m_i$ es el total de oportunidades dentro del círculo de radio d_{ij} centrado en j , incluyendo origen y destino. El cambio conceptual respecto al modelo de radiación es fundamental: en lugar de evaluar la competencia desde el origen, el modelo PWO evalúa la competencia desde el destino, capturando la lógica de atracción de un lugar sobre su entorno geográfico inmediato.

Al igual que el modelo de radiación, el modelo PWO es libre de parámetros: requiere únicamente la distribución de población de las zonas para generar predicciones, sin necesidad de calibración con datos históricos. Validado sobre datos de transporte público en múltiples ciudades chinas, el modelo PWO supera consistentemente al modelo de radiación en la predicción de viajes intraurbanos [Yan et al., 2014]. Yan et al. [Yan et al., 2017] extendieron posteriormente este modelo combinándolo con un proceso de caminata aleatoria con memoria, logrando reproducir simultáneamente los patrones de movilidad a nivel individual y los flujos agregados a nivel poblacional.

3.3.2. Modelos exploratorios: más allá de la selección secuencial

Tanto el modelo de radiación como el modelo PWO comparten un supuesto implícito sobre el comportamiento del viajero. Según la terminología introducida retrospectivamente por Liu y Yan [Liu y Yan, 2020] para clasificar los mecanismos de selección de destino, el modelo de radiación asume una *tendencia cautelosa*: el individuo elige el destino más cercano que supera el beneficio del origen. El modelo PWO también incorpora una lógica de competencia local. En ambos casos, la distancia juega un papel restrictivo en la selección.

Investigaciones posteriores identificaron una tendencia exploratoria. En el ámbito de los procesos de evaluación y selección social, Sim et al. [Sim et al., 2015] describieron que, ante un beneficio suficientemente alto, los individuos consideran destinos más distantes. Liu y Yan [Liu y Yan, 2019] trasladaron formalmente este concepto al dominio de la movilidad espacial y propusieron el *Modelo de Selección Prioritaria de Oportunidades* (Opportunity Priority Selection), en el que un individuo en i elige el destino j si su beneficio supera tanto al del origen como al de todas las oportunidades intervinientes:

$$P_{ij} = \frac{m_j}{S_{ij}} = \frac{m_j}{m_i + s_{ij} + m_j} \quad (19)$$

donde $S_{ij} = m_i + s_{ij} + m_j$ es el total de oportunidades en el círculo de radio d_{ij} centrado en el origen i . Este modelo, al igual que el PWO, es libre de parámetros y fue validado con buenos resultados tanto para viajes intraurbanos como interurbanos.

3.3.3. Modelo Unificado de Oportunidades

La existencia de modelos con supuestos comportamentales tan distintos, el cauteloso modelo de radiación y el exploratorio modelo de selección prioritaria, planteó una pregunta natural: ¿qué modelo aplicar en cada contexto? Liu y Yan [Liu y Yan, 2020] respondieron esta pregunta proponiendo el *Modelo Unificado de Oportunidades* (Universal Opportunity Model), un marco general con dos parámetros que engloba a los modelos anteriores como casos especiales. La probabilidad de que un individuo en i elija el destino j se formula como:

$$P_{ij} = \frac{(m_i + \alpha s_{ij}) m_j}{[m_i + (\alpha + \beta) s_{ij}] [m_i + (\alpha + \beta) s_{ij} + m_j]} \quad (20)$$

donde $\alpha \geq 0$ es el parámetro de *tendencia exploratoria* (cuán dispuesto está el individuo a alejarse buscando mayor beneficio) y $\beta \geq 0$ es el parámetro de *tendencia cautelosa* (preferencia por destinos cercanos), sujetos a $\alpha + \beta \leq 1$. Los modelos previos emergen como casos particulares de esta formulación:

- Si $\alpha = 0, \beta = 1$: la ecuación (20) se reduce a la ecuación (7) del modelo de radiación (comportamiento puramente cauteloso).
- Si $\alpha = 1, \beta = 0$: la ecuación (20) se reduce a la ecuación (19) del modelo de selección prioritaria (comportamiento puramente exploratorio).

Liu y Yan [Liu y Yan, 2020] validaron el modelo sobre 14 conjuntos de datos de movilidad a distintas escalas: carga de mercancías, *commuting* interurbano (EE.UU., Italia, Hungría), búsqueda de empleo, migración, viajes entre ciudades y viajes intraurbanos (Berlín, Londres, Beijing, Shenzhen, Suzhou). Sus resultados revelan un patrón sistemático: los flujos de *commuting* y carga exhiben alta tendencia cautelosa (los individuos priorizan destinos cercanos de alto beneficio), mientras que los desplazamientos intraurbanos presentan valores bajos de ambos parámetros, indicando que la masa poblacional por sí sola es insuficiente para capturar la complejidad de la elección de destino en la ciudad. Este hallazgo es particularmente relevante para la presente memoria: sugiere que las variables de oportunidad basadas en población deben complementarse con atributos del tejido urbano para modelar adecuadamente los flujos en Santiago de Chile.

Aplicaciones colaterales. Más allá de la movilidad de transporte, esta familia de modelos ha demostrado versatilidad en otros dominios. En el campo de la epidemiología, modelos como el de radiación y el PWO han sido utilizados para estimar probabilidades de contacto entre poblaciones y parametrizar la difusión espacial de enfermedades infecciosas, incluyendo estudios sobre la propagación de COVID-19 [Liu y Yan, 2020]. Esta amplitud de aplicación evidencia la robustez conceptual del marco de oportunidades intervinientes.

3.4. Deep Learning y modelos espacio-temporales en movilidad

Para superar las limitaciones lineales y la dependencia exclusiva de la densidad poblacional, la literatura reciente ha migrado hacia el aprendizaje automático (*Machine Learning*) y el aprendizaje profundo (*Deep Learning*) [Rong et al., 2024]. Las arquitecturas neuronales han demostrado una capacidad superior para capturar la no linealidad del entorno urbano.

Un avance significativo en esta línea es la incorporación explícita de Puntos de Interés (POIs) y características del entorno construido como variables condicionantes. Por ejemplo, Luca et al. [Luca et al., 2024] propusieron el *framework* TS-Mob, que combina modelos fundacionales de series de tiempo (*TimesFM*) con un módulo de atractividad gravitacional basado en perceptrones multicapa (MLP). Este modelo integra 16 categorías de POIs extraídas de bases de datos abiertas. Ello permite modular la probabilidad de atracción estructural de un destino en función de la oferta de servicios comerciales, educativos o de salud y de la población. Es importante distinguir este enfoque del de *Deep Gravity*: mientras TS-Mob integra estas categorías en un módulo de atractividad temporal, la adaptación de *Deep Gravity* de esta memoria utiliza un vector estático de atributos territoriales y distancia. Su composición y preprocesamiento se describen en la Sección 4.5.

La transición hacia arquitecturas profundas introdujo requisitos de datos para controlar sobreajuste y dificultades de interpretación asociadas a sus arquitecturas de caja negra [Rong et al., 2024]. Los estudios citados reportan menores errores y mayor CPC que los modelos clásicos; explicar una predicción individual sigue siendo una condición relevante para la adopción institucional.

3.5. Generación de flujos mediante datos no convencionales

En el estado del arte más reciente (2024-2025), la investigación ha explorado métodos para mitigar la dependencia de datos socioeconómicos hiperlocales o de costosas encuestas de transporte. Destaca el paradigma de inferencia mediante imágenes satelitales y modelos generativos de grafos.

Un estudio fundacional en esta línea metodológica es el de Xu et al. [Xu et al., 2025], quienes desarrollaron *Imagery2Flow*, un modelo que emplea aprendizaje contrastivo y Redes de Atención en Grafos (GAT) para predecir flujos a partir de imágenes satelitales. Su investigación utiliza a *Deep Gravity* como arquitectura de referencia en la literatura. Los autores demuestran que la versión con atributos espaciales (*Deep Gravity-V*) supera con claridad a la versión puramente poblacional (*Deep Gravity-P*). Este resultado respalda la utilidad predictiva de esos atributos en las condiciones evaluadas por los autores.

Posteriormente, Rong et al. [Rong et al., 2026] extendieron este paradigma de inferencia satelital mediante *GIODGen*, un generador global de flujos OD basado en modelos de difusión (*Denoising Diffusion Networks*). Este *framework* utiliza un codificador visual multimodal (*Re-*

moteCLIP) para extraer un *embedding* semántico de 1.024 dimensiones directamente desde imágenes satelitales de alta resolución. Los autores reportan que el aspecto visual del entorno urbano y un mapa global de población poseen una expresividad superior al 98 % respecto al uso de datos multisectoriales complejos (catastros, POIs, atributos socioeconómicos). Su modelo, entrenado en Estados Unidos, demostró transferibilidad a ciudades de Europa, China, Brasil y África.

Estos modelos presentan barreras prácticas para su aplicación. Pueden conservar sesgos geográficos de los contextos donde fueron entrenados y su desempeño es, además, sensible a la calidad de las imágenes satelitales. La representación del territorio mediante *embeddings* puede dificultar la asociación directa entre los componentes aprendidos y categorías urbanas explícitas. Relacionar una predicción con equipamientos concretos requiere procedimientos de interpretación adicionales y validación; esa dificultad depende de la arquitectura, los datos y el método de explicación utilizado. El estudio de intervenciones urbanas con estas representaciones requiere una validación diseñada para vincular predicciones y efectos de intervención.

En el contexto latinoamericano, los antecedentes de aplicación de modelos computacionales para la generación de flujos son escasos. Spadon et al. [Spadon et al., 2019] reconstruyeron redes de *commuting* en la región metropolitana de São Paulo utilizando *random forests* e indicadores urbanos municipales, demostrando la viabilidad de enfoques basados en aprendizaje automático para ciudades de la región. Su trabajo emplea arquitecturas de baja complejidad e indicadores urbanos municipales. Esta memoria evalúa empíricamente la adaptación de *Deep Gravity* al transporte público de Santiago con atributos OSM y controles de explicabilidad.

3.6. En Resumen

La revisión permite comparar los supuestos, las necesidades de datos y las posibilidades de interpretación de los modelos:

- Los modelos físicos y estadísticos clásicos (Secciones 3.1 y 3.2) ofrecen formulaciones explícitas; algunos marcos continuos incorporan propiedades de aditividad [Simini et al., 2013]. Las versiones basadas en población y distancia restringen de antemano la relación entre esas variables y el flujo, mientras que otras formulaciones amplían sus atributos y supuestos.
- Los modelos de oportunidades intervinientes (Sección 3.3) han dado lugar a formulaciones con distintos supuestos de selección de destino y requisitos de calibración. En las variantes revisadas, la población suele utilizarse como aproximación de las oportunidades, lo que limita la descripción de actividades urbanas específicas.
- Los modelos basados en aprendizaje profundo, series de tiempo e imágenes satelitales

(Secciones 3.4 y 3.5) han mostrado capacidad predictiva en los contextos y protocolos evaluados por los estudios citados. Sus necesidades de cómputo y la interpretación de sus salidas dependen de la arquitectura, de los atributos y del método de explicación.

En este contexto metodológico, el uso del modelo *Deep Gravity* [Simini *et al.*, 2021], alimentado con datos de OpenStreetMap (OSM), motiva una evaluación conjunta de capacidad predictiva y representación espacial en Santiago de Chile. La memoria también evaluó, como componente complementario, la viabilidad de atribuir predicciones mediante métodos inspirados en SHAP [Lundberg y Lee, 2017] y gradientes integrados.

Por un lado, *Deep Gravity* reemplaza la rigidez heurística de los exponentes gravitacionales por una red neuronal profunda capaz de capturar relaciones no lineales entre el territorio y los flujos. A diferencia de los *embeddings* satelitales, utiliza variables explícitas y semánticamente interpretables provistas por OSM: centros de salud, red vial, escuelas y comercio. Por otro lado, su arquitectura permite aplicar métodos de explicabilidad como SHAP. Esta combinación permite analizar predicciones y atributos de entrada. Los capítulos siguientes presentan la evaluación predictiva y los controles de estabilidad del componente de atribuciones.

CAPÍTULO 4

PROPUESTA DE SOLUCIÓN

Este capítulo especifica el procedimiento reproducible para estudiar la sensibilidad de *Deep Gravity* frente a la discretización espacial en Santiago. El diseño compara las ramas Zona 777, H3-r7 y H3-r8 a partir de una cohorte común, con atributos, particiones y protocolo de evaluación explícitos. Se distinguen un piloto de un día, destinado a comprobar la factibilidad del recorrido, y un experimento mensual agregado, destinado a la evaluación principal. Ambos comparten decisiones estructurales, pero difieren en su escenario, normalización, presupuesto y regla de liberación de prueba.

4.1. Diseño general y trazabilidad

La solución parte de registros DTPM de viajes y etapas, reconstruye extremos válidos a nivel de viaje y aplica una delimitación territorial común. A continuación, dos adaptadores espaciales asignan esos mismos viajes a zonas operativas DTPM o a celdas H3. Cada rama recibe atributos externos, forma pares origen-destino y utiliza la misma familia de modelos y reglas de evaluación. La Figura 2 resume esta separación entre núcleo común y adaptadores.




Figura 2: Procedimiento de Santiago: un núcleo común de viajes precede a los adaptadores espaciales y a la evaluación. Fuente: elaboración propia.

La variable de respuesta es el flujo observado agregado entre una unidad de origen i y una unidad de destino j . La población censal, el flujo saliente observado, el factor de expansión y los atributos de OSM cumplen funciones distintas: el flujo saliente reconstruye la masa predicha condicionada al origen, mientras la red utiliza atributos territoriales del origen y del destino junto con la distancia geodésica.

4.2. Datos de movilidad y reconstrucción del viaje

La entrega DTPM disponible comprende 29 fechas procesables, desde el 1 al 29 de noviembre de 2024. El archivo del día 30 presentó errores de origen. La unidad observacional utilizada en la comparación es un viaje canónico, una unidad distinta de una validación aislada. La unión diaria validada vincula viajes.(id_tarjeta, id_viaje) con etapas.(id_etapa, correlativo_viajes). El origen se reconstruye desde la primera etapa y el destino desde una bajada válida de la etapa final; las coordenadas UTM de ambos extremos residen en etapas.

La cohorte primaria exige una secuencia completa y sin duplicados de etapas, numeradas desde uno hasta el número declarado para el viaje. El origen corresponde a la primera etapa y el destino a la bajada de la última; esta debe tener tiene_bajada=1 y el viaje debe indicar ultimaetapaconbajada=1. Se requieren zonas de origen y destino disponibles y factor_expansion no negativo. Como control técnico previo al recorte territorial, las coordenadas de ambos extremos deben satisfacer $100,000 \leq X \leq 900,000$ y $5,000,000 \leq Y \leq 10,000,000$, en metros. Estos rangos no definen el área de estudio.

El factor de expansión de viajes es el peso principal para los flujos expandidos; el conteo sin expansión se conserva para el análisis de sensibilidad. La Tabla 2 distingue procedencia y función de los insumos para evitar confundir pesos, coordenadas y variables explicativas.

Tabla 2: Fuentes de datos y función de las variables usadas por el procedimiento. Fuente: elaboración propia.

Insumo	Contenido o unidad	Uso y regla de trazabilidad
viajes DTPM	Identificadores del viaje, zonas consolidadas, secuencia y factor_expansion.	Aporta la identidad del viaje, las zonas de la rama zonal y la masa expandida; las coordenadas UTM de los extremos proceden de etapas.
etapas DTPM	Identificadores de etapa y viaje; coordenadas UTM de subida y bajada.	Permite reconstruir origen y destino válidos y asignar H3 tras transformar EPSG:32719 a WGS84.
ShapeZona 777 DTPM	Geometría oficial de zonas y sus identificadores.	Sustenta área, centroides y atributos de las zonas; los IDs sin geometría verificable quedan fuera de esa construcción.
Censo 2024 (INE)	Población de manzanas y entidades de la Región Metropolitana.	Se interpola por fracción de área en EPSG:32719 y se expresa por unidad espacial como atributo territorial; la generación observada procede de DTPM.
OSM Chile 2024-01-01	Polígonos, vías y puntos del extracto histórico.	Aporta coberturas y densidades utilizadas como atributos territoriales; un cero registra ausencia cartografiada bajo las reglas de construcción.

Para un escenario temporal dado, el flujo expandido se agrega como

$$T_{ij} = \sum_{v \in \mathcal{V}_{ij}} w_v, \quad (21)$$

donde $\mathcal{V}_{ij}$ reúne los viajes canónicos entre i y j , y w_v es el peso expandido del viaje v . Las tablas OD operativas conservan, por separado, `trip_count` y `expanded_mass`; no incluyen identificadores personales.

4.3. Delimitación territorial y cohorte común

El dominio de estudio es el núcleo urbano referencial de 34 comunas. Cada extremo UTM debe estar estrictamente contenido en una de las geometrías comunales DPA 2023 proyectadas a EPSG:32719; los puntos ubicados en un límite se excluyen por la regla `contains`. El filtro territorial retiene 60.513.881 viajes de la cohorte primaria y 85.777.662,9386 de masa expandida. La Figura 3 documenta esa decisión territorial.




Figura 3: Delimitación del área de estudio: núcleo urbano referencial de 34 comunas dentro de la Región Metropolitana. El recorte territorial retiene 60.513.881 viajes (99,72 % de la cohorte) y 85.777.662,9386 de masa expandida (99,69 %); las 18 comunas rurales excluidas reúnen el 0,28 % de los viajes. El sistema de coordenadas es EPSG:32719 (WGS 84/UTM 19S). Estas cifras corresponden al filtro territorial previo a la exclusión común posterior de tres zonas sin polígono oficial verificable. Fuente: elaboración propia.

Después del recorte territorial se excluyen, en las tres ramas, los 1.904 viajes que tienen al menos un extremo en las zonas 848, 849 o 852, cuyas geometrías oficiales verificables

no están disponibles para construir atributos. La cohorte comparativa resultante contiene 60.511.977 viajes y 85.774.522,4070 de masa expandida. Esta exclusión se aplica antes de agregar OD.

La Tabla 3 resume la reducción desde la entrega DTPM hasta la cohorte comparativa. De los 86.327.914 viajes entregados para las 29 fechas procesables, 25.325.042 (29,34 %) tienen `ultimaetapaconbajada=0` y se excluyen porque el destino de la etapa final no puede reconstruirse bajo el contrato adoptado. Los filtros posteriores reúnen las condiciones de consistencia canónica, el recorte territorial y la disponibilidad de geometría zonal.

Tabla 3: Cascada de filtros desde la entrega DTPM hasta la cohorte comparativa final. El porcentaje retenido usa como denominador los 86.327.914 viajes de los días 1-29; la columna de exclusión se calcula respecto de la fila anterior. Fuente: elaboración propia a partir de las auditorías F2-B-F2-D y del contrato aprobado F2-I.

Etapas	Viajes retenidos	Excluidos	Retención
Entrega DTPM procesable, días 1-29	86.327.914	—	100,00 %
Indicador de bajada en etapa final igual a uno	61.002.872	25.325.042	70,66 %
Cohorte canónica primaria	60.682.293	320.579	70,29 %
Ambos extremos dentro de las 34 comunas	60.513.881	168.412	70,10 %
Cohorte comparativa final	60.511.977	1.904	70,10 %

La Figura 4 muestra la cobertura diaria de esta cohorte final. Las 29 fechas disponibles se mantienen con su tipo de día observado.




Figura 4: Viajes y masa expandida diarios de la cohorte final. Los puntos distinguen el tipo de día; el OD diario ya está restringido al dominio de 34 comunas y se aplican las exclusiones comunes 848, 849 y 852 en ambos extremos. Se muestran las 29 fechas procesables, del 1 al 29 de noviembre de 2024. Fuente: elaboración propia a partir de los viajes canónicos DTPM.

4.4. Adaptadores espaciales, unidades y tiles

La rama Zona 777 usa las zonas de origen y destino auditadas en el viaje canónico y la geometría oficial publicada por DTPM. La rama H3 transforma las coordenadas válidas desde EPSG:32719 a WGS84 con `always_xy=True` y asigna cada extremo mediante `latlng_to_cell`. La política de borde conserva la huella completa de cada celda H3 observada y asigna cada viaje a la celda de sus extremos después del recorte territorial.

H3 es un sistema jerárquico de índices geoespaciales. Sus áreas y distancias varían geográficamente, incluye pentágonos y presenta relaciones de vecindad diferenciadas. La comparación examina la discretización espacial como una fuente de sensibilidad empírica.

La factibilidad se evaluó sobre los 60.513.881 viajes del recorte territorial, antes de la exclusión común posterior de 1.904 viajes. Para cada resolución se exigió conservar esa cohorte

y su masa expandida, disponer de al menos 100 unidades de origen activas y requerir como máximo 128 MiB para una matriz densa de puntajes de una pasada. La Tabla 4 muestra que H3-r7 y H3-r8 cumplen los umbrales de soporte y memoria; H3-r3 a H3-r6 quedan bajo el umbral de 100 unidades de origen activas.

Tabla 4: Factibilidad de las resoluciones H3-r3 a H3-r8 sobre la cohorte territorial. Todas las filas conservan 60.513.881 viajes y 85.777.662,9386 de masa expandida. La densidad OD corresponde a pares observados sobre pares posibles entre unidades activas. Fuente: elaboración propia a partir del análisis F2-E con asignación directa de cada coordenada mediante `latlng_to_cell`.

Resolución	Orígenes activos	Pares OD	Densidad OD	Masa intraunidad	Área mediana (km ²)	Matriz (MiB)	Decisión
H3-r3	1	1	100,00 %	100,00 %	10.691,59	< 0,01	Descartada
H3-r4	4	16	100,00 %	69,85 %	1.529,98	< 0,01	Descartada
H3-r5	9	81	100,00 %	52,20 %	218,89	< 0,01	Descartada
H3-r6	44	1.760	90,91 %	18,63 %	31,24	< 0,01	Descartada
H3-r7	220	37.196	76,16 %	5,06 %	4,46	0,19	Seleccionada
H3-r8	1.194	617.070	43,76 %	0,80 %	0,64	5,38	Seleccionada

H3-r7 y H3-r8 pasaron al piloto junto con Zona 777. La Tabla 5 presenta las representaciones operativas de la cohorte común después de la exclusión compartida.

Tabla 5: Representaciones espaciales operativas después de la exclusión común. Fuente: elaboración propia.

Rama	Unidades	Rol	Regla de asignación y alcance
Zona 777	793 zonas	Referencia zonal	Zonas de origen y destino del viaje canónico; atributos calculados desde la geometría oficial verificable.
H3-r7	223 celdas	Candidata de escala más agregada	Ambos extremos válidos se asignan directamente a celdas H3; mantiene celdas completas en el borde.
H3-r8	1.210 celdas	Candidata de mayor detalle	Misma regla de asignación H3 y misma cohorte fuente; su mayor desagregación modifica el soporte OD.

La Figura 5 complementa esta descripción con las áreas físicas de las unidades y el número de unidades que tienen salida observada en la cohorte completa. Estas diferencias cambian los pares OD evaluables y la masa asignada a prueba; por ello, el análisis usa el CPC dentro del soporte de cada rama.




Figura 5: Escalas físicas y soporte de las tres representaciones sobre la misma cohorte final. El panel izquierdo muestra $\log_{10}$ del área de cada unidad en km^2 ; el derecho distingue unidades totales y orígenes con salida observada. Las diferencias de área, agregación y soporte sitúan la comparación del CPC dentro de cada rama. Fuente: elaboración propia con el contrato territorial y de atributos aprobado y el soporte del experimento mensual.

Una zona o celda es una unidad OD. Un *tile* es un bloque mayor, de 15.000 m de lado en EPSG:32719. Cada bloque se identifica como $E\{e\}_N\{n\}$, donde E y N indican los índices Este y Norte de la cuadrícula, calculados mediante $e = \text{floor}(x/15000)$ y $n = \text{floor}(y/15000)$. Sus límites se obtienen multiplicando cada índice por 15 km; por ejemplo, E23_N420 abarca 345–360 km Este y 6.300–6.315 km Norte. Se fijaron diez *tiles* comunes y una agenda determinista con semilla 20260909: siete para entrenamiento, dos para validación y uno para prueba. La partición se aplica al origen; todos los destinos del dominio de estudio, incluidos los de otros *tiles* o particiones, permanecen candidatos y los flujos cruzados se conservan. La Figura 6 distingue estos objetos y evita equiparar un *tile* con una unidad OD.



Figura 6: Escalas espaciales del procedimiento. Cada rama representa el mismo dominio mediante sus propias unidades OD; el *tile* cumple una función de partición, mientras las zonas y celdas forman las unidades OD. Esquema simplificado. Fuente: elaboración propia.

La Figura 7 sitúa la agenda sobre las 34 comunas. El único bloque de prueba es E23_N420.

Intersecta sectores de Santiago, Conchalí, Huechuraba, Independencia, La Reina, Las Condes, Lo Barnechea, Providencia, Recoleta y Vitacura. Las tres representaciones comparten esta agenda de *tiles*; cambian las unidades asignadas y, por ello, los orígenes y la masa de cada partición.




Figura 7: Ubicación de los diez *tiles* de 15 km sobre el área de estudio y rol de cada bloque en la partición de orígenes. Las etiquetas $E\{e\}_N\{n\}$ codifican los índices Este y Norte de cada bloque en la cuadrícula UTM. El bloque de prueba E23_N420 se destaca en rojo; los destinos de todo el dominio permanecen disponibles en las tres particiones. Fuente: elaboración propia a partir del dominio territorial aprobado y la agenda congelada de particiones.

4.5. Construcción de atributos y vector de entrada

La configuración principal utiliza 19 variables por ubicación y, para un par OD, forma un vector de 39 entradas: 19 del origen, 19 del destino y una distancia. Incluye densidad de población censal, cinco coberturas de uso de suelo, tres densidades de longitud vial y cinco familias de servicios, cada una medida mediante densidad de puntos y cobertura de áreas. Se conserva una configuración alternativa para diagnóstico, con 20 variables por ubicación y 41 entradas por par, evaluada como una configuración separada del piloto.

$$\mathbf{x}_{ij} = [\mathbf{a}_i^{(19)}, \mathbf{a}_j^{(19)}, d_{ij}], \quad (22)$$

donde $\mathbf{a}_i$ y $\mathbf{a}_j$ contienen los atributos externos de origen y destino, respectivamente, y d_{ij} es la distancia geodésica calculada desde representantes espaciales en WGS84. La población se interpola desde Censo 2024 a las unidades y se divide por su área para construir la densidad de entrada a la red.

Los polígonos y las vías se recortan y unen dentro de cada categoría antes de calcular cobertura o longitud. Los puntos requieren pertenencia estricta a la unidad. Para densidades y tasas se aplica $\log_{1p}$; las coberturas mantienen su escala física antes de estandarizar. Media y desviación estándar se estiman solo con orígenes activos de entrenamiento de cada rama y escenario, y luego se aplican a validación y prueba. Esta regla impide que el conjunto de prueba intervenga en la normalización.

El piloto ajustó esta transformación con los orígenes activos del 5 de noviembre de 2024. En contraste, el experimento principal recalculó y verificó independientemente la normalización mensual a partir de los atributos físicos y de sus propios orígenes de entrenamiento. Las variables constantes reciben escala uno. Aunque los escenarios comparten diccionario de atributos, sus transformaciones numéricas se estiman por separado.

El Anexo A detalla las variables territoriales, sus fuentes, unidades, reglas de construcción y transformaciones.

La Figura 8 sitúa las escalas de tres magnitudes en H3-r7 antes de la normalización del modelo. El primer histograma condiciona explícitamente en pares OD positivos; el segundo pondera por masa expandida la separación geodésica entre centroides; el tercero usa densidad poblacional física antes de las transformaciones de entrada. Los recorridos de la red requieren información adicional de infraestructura y operación.

Escalas de flujo, distancia y atributo en H3-r7




Figura 8: Escalas de flujo, distancia y densidad poblacional en H3-r7. Los flujos corresponden a pares OD positivos y se expresan en log₁₀ de viajes por par; las distancias entre centroides se agregan con masa expandida; y la densidad poblacional corresponde a personas por km² antes de la normalización del modelo. Fuente: elaboración propia con la cohorte y los atributos territoriales aprobados.

4.6. Modelo, muestreo y evaluación

4.6.1. Relación con el modelo gravitatorio

El *softmax* de una utilidad sistemática V_{ij} define la probabilidad de destino

$$p_{ij} = \frac{\exp(V_{ij})}{\sum_{k \in \mathcal{D}_i} \exp(V_{ik})}, \quad (23)$$

donde $\mathcal{D}_i$ es el soporte de destinos permitido para el origen i . Si $V_{ij} = \beta_1 \ln(P_j) + \beta_2 \ln(d_{ij})$, el *softmax* induce una forma de potencia $P_j^{\beta_1} d_{ij}^{\beta_2}$; no induce una disuasión exponencial. Una forma gravitatoria exponencial requiere, por ejemplo, una utilidad coherente $V_{ij} = \alpha \ln(P_j) - \beta d_{ij}$ [McFadden, 1974, Ortúzar y Willumsen, 2011].

Deep Gravity reemplaza la utilidad lineal por una función no lineal aprendida $f_\theta(\mathbf{x}_{ij})$. El teorema de aproximación universal respalda una capacidad de representación bajo sus supuestos; con datos finitos, el desempeño de una arquitectura concreta requiere comprobar optimización, generalización y brecha respecto de las referencias [Hornik, 1991].

4.6.2. Arquitectura, soporte y pérdida

La implementación efectiva conserva 15 capas ocultas: cinco de ancho 256 y diez de ancho 128, con activaciones LeakyReLU. BatchNorm está desactivado y el *dropout* efectivo es 0,0 en la ruta vigente. La capa final produce un *score* por destino candidato. La arquitectura heredada y la corrida técnica de Nueva York se mantienen como antecedentes de compatibilidad; el desempeño para Santiago se evalúa con el protocolo descrito en este capítulo.

El muestreador general permite limitar el número de destinos por origen, sin reposición, y reservar una fracción de candidatos con flujo positivo. Los candidatos restantes se eligen uniformemente entre los disponibles, por lo que pueden incluir otros destinos con flujo positivo. El piloto y el experimento mensual utilizaron el soporte completo de destinos de cada representación; los destinos de todo el dominio metropolitano permanecieron disponibles aunque correspondieran a otro *tile* o partición.

La pérdida es la log-verosimilitud multinomial negativa ponderada por la masa elegida:

$$\mathcal{L} = - \sum_i \sum_{j \in \mathcal{D}_i} y_{ij} \log p_{ij}. \quad (24)$$

Para conteos enteros, minimizar esta expresión equivale a maximizar la log-verosimilitud multinomial, salvo constantes independientes del modelo. Con masa expandida fraccionaria, se interpreta como una pérdida multinomial ponderada, con el soporte de destinos y los pesos definidos para el análisis. Su relación con la formulación de entropía de Wilson es conceptual y requiere restricciones adicionales; no se identifica automáticamente con maximizar la entropía de Wilson [Wilson, 1970].

4.6.3. Modelos de referencia, particiones y métricas

Las tres referencias se ajustan solamente con los flujos cuyos orígenes pertenecen a entrenamiento y se evalúan sobre los mismos orígenes, destinos y masa que la red dentro de cada rama. La referencia uniforme asigna $1/|\mathcal{D}|$ a cada destino del soporte. La referencia de atracción, definida operacionalmente para esta memoria, usa la masa expandida recibida durante entrenamiento:

$$\hat{y}_{ij} = O_i \frac{A_j^{\text{train}} + \lambda}{\sum_{k \in \mathcal{D}} A_k^{\text{train}} + \lambda |\mathcal{D}|}, \quad \lambda = 1. \quad (25)$$

donde A_j^{train} es la masa que llega a j desde los orígenes de entrenamiento, $\mathcal{D}$ es el soporte completo de destinos de la rama y O_i es el flujo saliente observado del origen que se evalúa. El pseudoconteo λ corresponde a una unidad de masa por destino. Por construcción, A_j^{train} resume una marginal de la variable objetivo observada. La red estima sus puntajes a partir de las características territoriales del origen y el destino y de su distancia, mientras la referencia incorpora la marginal observada de llegadas de entrenamiento. La referencia permite evaluar cuánto se conserva el perfil empírico de destinos al cambiar los orígenes; su ventaja informativa debe considerarse al compararla con la red.

En el modelo gravitatorio exponencial, la utilidad se calcula como

$$V_{ij} = \alpha \ln(1 + P_j) + \beta d_{ij}, \quad \alpha \geq 0, \quad \beta \leq 0, \quad (26)$$

donde P_j es la población total interpolada, recuperada multiplicando la densidad censal por el área de la unidad, y d_{ij} es la distancia esférica en kilómetros. Los parámetros se ajustan exclusivamente con los flujos de entrenamiento mediante una pérdida multinomial ponderada y L-BFGS-B, inicializado en $(1, -0, 1)$, con un máximo de 500 iteraciones, $ftol = 10^{-12}$ y $gtol = 10^{-8}$; se imponen $\alpha \geq 0$ y $\beta \leq 0$. Esta variable del modelo de referencia se distingue de la densidad de población transformada y estandarizada que recibe la red. La distancia intrazonal o intracelda es cero, valor admisible en la disuasión exponencial.

El piloto verificó la comparación contra estas tres referencias en el mismo soporte de cada rama. El *checkpoint* se selecciona por CPC de validación y la prueba evalúa el modelo ya fijado. La configuración del piloto usa RMSprop, tasa de aprendizaje 5×10^{-6} , momento 0,9, lotes de ocho orígenes y 15 épocas. Estos valores registran una configuración de piloto; el experimento mensual adopta sus parámetros según el protocolo siguiente.

La métrica principal es

$$\text{CPC} = \frac{2 \sum_{ij} \min(T_{ij}, \hat{T}_{ij})}{\sum_{ij} T_{ij} + \sum_{ij} \hat{T}_{ij}}. \quad (27)$$

Se guardan numerador y ambas masas por origen para agregar CPC global y por *tile* sobre el mismo soporte. Las medias por origen, por todos los *tiles* y condicionadas a CPC positivo se reportan separadamente. El piloto de Santiago confirma que el procedimiento se puede ejecutar y repetir con tres semillas. Como la agregación, los representantes espaciales y la

masa de prueba cambian entre ramas, el CPC se compara con las referencias dentro de cada representación.

4.6.4. Piloto y experimento mensual

El piloto utilizó el martes 5 de noviembre de 2024. Incluyó diagnósticos en una muestra, en el día completo y en tres ventanas horarias, y nueve corridas estables del día completo: tres ramas y las semillas 20260909, 20260910 y 20260911. Cada corrida estable se entrenó durante 15 épocas; el mejor *checkpoint* de validación se conservó y se evaluó posteriormente en prueba. Esta etapa comprobó la factibilidad y estabilidad iniciales. La convergencia, los hiperparámetros y el comportamiento mensual se evaluaron en el experimento principal.

El experimento principal agrega las 29 fechas disponibles entre el 1 y el 29 de noviembre de 2024; el día 30 se excluye por problemas en los archivos y no se imputa. Se entrenaron nueve modelos desde inicializaciones nuevas: las tres ramas y las mismas tres semillas. La red, el soporte completo y la pérdida fueron los descritos antes. El optimizador fue RMS-prop con tasa 5×10^{-6} , momento 0,9, $\alpha = 0,99$, $\epsilon = 10^{-8}$, sin decaimiento de pesos ni centrado; se usaron lotes de ocho orígenes en orden estable y sin barajado. Las corridas se ejecutaron secuencialmente en CPU con cuatro hilos. Cada época evaluó todos los orígenes de validación.

La selección del *checkpoint* y la parada anticipada obedecieron a reglas diferentes. Se conservó el *checkpoint* con el mayor CPC global de validación entre todas las épocas ejecutadas y, ante un empate exacto, el primero. Para la parada, la primera época de validación inicializó una referencia significativa; esta se actualizó solo si el CPC posterior era estrictamente mayor que la referencia más 0,0001. Tras un mínimo de 50 épocas, la corrida se detenía cuando acumulaba 30 épocas sin esa mejora significativa. El límite inicial fue 200 épocas; una extensión requería autorización previa y mantenía la misma regla de selección.

Dos corridas alcanzaron dicho límite y recibieron una autorización previa a la prueba para continuar con los mismos datos, particiones, arquitectura, optimizador, métrica y regla de selección. La continuación elevó el máximo a 300 épocas para Zona 777 con semilla 20260909 y H3-r8 con semilla 20260910. Ambas cerraron posteriormente por la misma regla de meseta, en las épocas 226 y 218, respectivamente; sus *checkpoints* seleccionados permanecieron en las épocas 196 y 188. Las demás corridas cerraron con la configuración inicial. La prueba se liberó una sola vez después de congelar las fuentes, las decisiones de validación y los *checkpoints* seleccionados; la selección de época, semilla, parámetros y representación ya estaba cerrada.

Como análisis de sensibilidad de la evaluación, las probabilidades ya congeladas se aplicaron también a los conteos OD sin expansión y se reescalaron por el flujo saliente no expandido de cada origen. Este CPC describe el efecto del peso de evaluación; conserva el entrenamiento, la selección y los parámetros de referencia ajustados con masa expandida.

4.7. Análisis complementario de atribuciones predictivas

Después de congelar los modelos mensuales se evaluó la viabilidad de explicar la log-probabilidad condicional de un destino dentro del soporte completo de cada origen. Los representantes se escogieron por la mediana del CPC de validación de cada rama y la selección se completó antes de acceder a prueba o de producir atribuciones. Las referencias se construyeron exclusivamente con orígenes de entrenamiento de la rama correspondiente; la función explicada, la muestra y los controles se fijaron antes de cada ejecución. Un origen de referencia aporta una entrada de comparación para calcular cuánto cambia la salida del modelo respecto de la predicción analizada. Cuando el método promedia varias referencias, esos orígenes forman un conjunto de referencia. Según el método, la estabilidad se evaluó comparando orígenes individuales o dos conjuntos seleccionados de manera independiente. Se ensayaron gradientes integrados con cuadratura Gauss-Legendre [Sundararajan *et al.*, 2017], SHAP por permutaciones agrupadas y valores de Shapley exactos para grupos jerárquicos [Lundberg y Lee, 2017]. En todos los casos las atribuciones se definieron como sensibilidades predictivas dependientes de la referencia; su lectura se limita al comportamiento del modelo.

Las tres aproximaciones se evaluaron contra controles de integridad, coincidencia entre el adaptador y la salida del modelo, finitud, convergencia o eficiencia según el método, repetibilidad y estabilidad frente a orígenes o conjuntos de referencia independientes. En el caso crítico, los gradientes integrados quedaron fuera del criterio de completitud aun con 4.096 nodos. Las permutaciones agrupadas no alcanzaron el mínimo de Spearman entre conjuntos de referencia en dos de las tres semillas del primer caso evaluado. El método exacto jerárquico cumplió los controles en un primer caso con 24 orígenes por conjunto, pero el segundo caso no superó el criterio conjunto de estabilidad de los atributos de origen, destino y distancia con 24 ni con 48 orígenes por conjunto. La Tabla 12 informa los umbrales, valores obtenidos y veredictos de los controles decisivos. Por ello, el capítulo presenta una evaluación de viabilidad y conserva los registros técnicos como respaldo reproducible; los resultados de atribución, rankings y figuras SHAP se dejan fuera del manuscrito.

4.8. Reproducibilidad, alcances y limitaciones

Cada ejecución conserva configuración efectiva, semillas, versiones, hashes de entradas y código, particiones, métricas y *checkpoint* en un directorio exclusivo. Los productos de datos, las especificaciones de procesamiento y los registros de ejecución permiten verificar la conservación de masa y reconstruir la procedencia de cada corrida. La prueba espacial se mantiene reservada durante la selección; el conjunto de prueba no participa en la normalización ni en el ajuste de hiperparámetros.

El estudio describe movilidad observable en DTPM durante las 29 fechas disponibles de noviembre de 2024 y en el dominio de 34 comunas. Distribuye el flujo saliente conocido de cada

origen; la generación de viajes, las fechas futuras y los otros modos urbanos requieren un diseño distinto. El piloto cumple una función de factibilidad dentro del período mensual: el agregado incluye el 5 de noviembre y reutiliza la misma geografía de prueba. Las tres semillas caracterizan variación de inicialización bajo una sola partición espacial, mientras nuevas particiones permitirían estimar la variación espacial y poblacional. La instantánea OSM antecede a los viajes y registra presencia cartografiada; la presencia física de servicios requiere contraste externo. La interpolación areal del Censo 2024 supone distribución uniforme dentro de cada geometría censal. La exclusión de las zonas sin polígono, la decisión de discretización y las diferencias de agregación espacial delimitan la interpretación comparativa.

El resultado del análisis complementario de explicabilidad queda circunscrito a una evaluación de viabilidad: bajo las configuraciones ensayadas, las atribuciones quedaron fuera del umbral de estabilidad para una interpretación sustantiva. Las métricas predictivas y las comparaciones con referencias se fundamentan en su propio protocolo de evaluación.

CAPÍTULO 5

VALIDACIÓN DE LA SOLUCIÓN

La validación distingue el piloto del 5 de noviembre de 2024 del experimento mensual congelado. Este último agrega las 29 fechas disponibles entre el 1 y el 29 de noviembre, conserva tres inicializaciones por representación y libera la prueba una sola vez después de seleccionar los *checkpoints* con validación. Las métricas se calculan con la definición de CPC de la ecuación (27); la comparación sustantiva se realiza entre modelos que comparten soporte dentro de cada rama.

5.1. Piloto como validación preliminar

El piloto se realizó sobre el martes 5 de noviembre de 2024 para comprobar el recorrido de datos, el entrenamiento, la selección por validación y la evaluación sobre el soporte completo de destinos. Incluyó 15 corridas diagnósticas y nueve entrenamientos estables del día completo, con tres representaciones espaciales y tres inicializaciones por representación. Cada entrenamiento se limitó a 15 épocas. Las ventanas horarias tuvieron un propósito diagnóstico; la comparación entre períodos se concentra en el experimento mensual.

En la prueba del piloto, el CPC medio de Deep Gravity fue 0,4920 en Zona 777, 0,7172 en H3-r7 y 0,5623 en H3-r8. Las desviaciones estándar muestrales entre las tres inicializaciones fueron 0,0045, 0,0021 y 0,0017, respectivamente. Dentro de cada representación, el modelo de atracción entrenado obtuvo los CPC más altos, con 0,6457, 0,7764 y 0,6669. Estos resultados establecen la factibilidad del procedimiento y justifican conservar las referencias en el experimento mensual. La convergencia, el ajuste óptimo y la generalización temporal requieren evidencia adicional.

El experimento mensual amplía el piloto: comparte la geografía de prueba e incluye el 5 de noviembre. La comparación reúne cambios de período, normalización, volumen de datos y presupuesto de entrenamiento, por lo que describe el efecto conjunto de esas diferencias.

5.2. Soporte de prueba y caracterización espacial

El experimento principal agrega la cohorte final de 60.511.977 viajes, con masa expandida de 85.774.522,4070, observados entre el 1 y el 29 de noviembre de 2024. La Tabla 6 muestra los orígenes, viajes y masa de entrenamiento, validación y prueba después de la exclusión común. La agenda de siete, dos y un *tiles*, respectivamente, es idéntica en las tres ramas; algunos bloques no contienen un origen activo en todas las representaciones, pero permanecen en la agenda congelada.

Tabla 6: Soporte de las particiones del experimento mensual. Los orígenes son unidades con flujo saliente positivo; los viajes y la masa corresponden al origen de cada flujo. El número de *tiles* describe la agenda común de las tres ramas. Fuente: elaboración propia a partir de las particiones aprobadas de la cohorte final.

Rama	Partición	Tiles	Orígenes	Viajes	Masa exp. (M)
Zona 777	Entrenamiento	7	507	41.303.960	58,49
Zona 777	Validación	2	185	7.455.614	11,17
Zona 777	Prueba	1	101	11.752.403	16,11
H3-r7	Entrenamiento	7	126	40.097.642	56,86
H3-r7	Validación	2	60	7.706.503	11,52
H3-r7	Prueba	1	32	12.707.832	17,39
H3-r8	Entrenamiento	7	701	41.789.595	59,18
H3-r8	Validación	2	299	7.203.738	10,80
H3-r8	Prueba	1	189	11.518.644	15,80

El único bloque de prueba es E23_N420, identificado espacialmente en la Figura 7. La Tabla 7 detalla los denominadores utilizados al calcular las métricas de prueba. Aunque la cohorte fuente es común, cada adaptador espacial asigna unidades, pares candidatos y masa de prueba propios. La evaluación mantiene el soporte completo de destinos para cada origen de prueba; las unidades sin origen asignado no se convierten en observaciones inactivas ni se eliminan del conjunto de destinos.

Tabla 7: Soporte de prueba por representación. Los pares positivos y su densidad se calculan sobre los pares candidatos indicados. La masa observada usa el factor de expansión; los orígenes activos e inactivos se refieren a la partición de prueba. Fuente: elaboración propia a partir de la tabla de soporte del experimento mensual.

Rama	Unid.	Orígenes	Sin asignar	Destinos	Pares candidatos	Masa exp.
Zona 777	793	101 (101/0)	0	793	80.093 (61.132; 76,3 %)	16,11 M
H3-r7	223	32 (32/0)	5	223	7.136 (5.552; 77,8 %)	17,39 M
H3-r8	1.210	189 (189/0)	21	1.210	228.690 (99.374; 43,5 %)	15,80 M

En la columna de orígenes, el par entre paréntesis corresponde a activos/inactivos; en la columna de pares, el paréntesis contiene pares OD positivos y su densidad. La masa expandida se expresa en millones de unidades de masa observada. Los desgloses por origen y *tile* se conservan como respaldo reproducible. La densidad de pares OD positivos fue 76,33 % en Zona 777, 77,80 % en H3-r7 y 43,45 % en H3-r8.

Las representaciones se construyen a partir de la misma cohorte y generan tareas de prueba distintas después de asignar cada viaje a una unidad espacial. Cambian el número de destinos

por origen, los pares candidatos, la densidad OD y la masa de prueba. Los CPC absolutos describen esas tareas; por ello, la comparación principal contrasta modelos dentro de cada representación y sobre el mismo soporte.

La Figura 9 caracteriza la distribución espacial de la masa expandida en la rama zonal. Sus dos paneles usan la misma cohorte final y expresan concentración por superficie.




Figura 9: Concentración mensual de la masa expandida que sale y llega por km^2 en Zona 777. Cada panel usa la cohorte final de 60.511.977 viajes, del 1 al 29 de noviembre de 2024; los colores muestran $\log_{10}$ de masa expandida por km^2 . Fuente: elaboración propia con datos DTPM y geometría oficial Zona 777.

5.3. Presencia espacial de los atributos OSM

La Figura 10 examina los atributos físicos de la configuración *paper19* que efectivamente alimentó las corridas mensuales. El panel izquierdo suma las densidades de puntos de interés de transporte, alimentación, salud, educación y comercio minorista. El derecho muestra, para cada unidad, la proporción de los 18 atributos OSM con valor mayor que cero. Esta proporción resume la presencia cartografiada de atributos por unidad.




Figura 10: Presencia espacial de los atributos OSM usados por *Deep Gravity* en las tres representaciones. La densidad total de POI suma las cinco familias incluidas en el vector de entrada y se muestra como $\log_{10}(1 + \text{POI}/\text{km}^2)$; las unidades grises corresponden a valores cero de POI cartografiados. La presencia OSM corresponde a la fracción de los 18 atributos OSM con valor físico positivo. Los polígonos H3 se conservan completos según la política de borde del experimento. Fuente: elaboración propia a partir de los atributos *paper19* aprobados.

Para cuantificar el patrón centro–borde, se definió operacionalmente como periferia el cuartil de unidades más distante del centroide del área de 34 comunas, por separado para cada representación. La periferia operacional, considerada en conjunto, contiene POI y atributos OSM en las tres representaciones, aunque presenta menores medianas de densidad de POI y presencia de atributos que el interior (Tabla 8). Los vacíos de POI son parciales: en H3-r8, el 14,85 % de las celdas periféricas registra cero POI cartografiados, frente al 6,28 % de las celdas interiores. Las correlaciones de Spearman con la distancia son negativas en las tres ramas.

Tabla 8: Presencia de atributos OSM y distancia al centroide del área de estudio. “Interior/periferia” compara el 75 % de unidades más cercanas con el cuartil más distante dentro de cada representación; ρ es la correlación de Spearman con la distancia. Fuente: elaboración propia a partir de los atributos físicos *paper19*.

Rama	Sin POI, total	Sin POI, int./per.	POI/km ² , int./per.	Presencia OSM, int./per.	ρ POI	ρ presencia
Zona 777	0 (0,00 %)	0,00 % / 0,00 %	43,40 / 31,24	72,22 % / 61,11 %	−0,239	−0,340
H3-r7	8 (3,59 %)	3,59 % / 3,57 %	28,95 / 3,69	83,33 % / 55,56 %	−0,409	−0,374
H3-r8	102 (8,43 %)	6,28 % / 14,85 %	32,96 / 7,87	66,67 % / 44,44 %	−0,319	−0,362

El patrón muestra menor presencia cartografiada hacia el borde del dominio. Distinguir entre ausencia de servicios y omisión en OSM requeriría una fuente externa. Para la interpretación predictiva, estas zonas ofrecen a la red menos señales positivas para diferenciar la atraktividad de los destinos; esta condición se considera junto con la información observada que utiliza la referencia de atracción.

5.4. Resultados globales en prueba

La Tabla 9 reúne el CPC global de prueba con peso expandido. Deep Gravity se resume mediante media, desviación estándar muestral y rango de las tres inicializaciones; los modelos de referencia son deterministas y se ajustan solamente con los flujos de entrenamiento de la rama correspondiente.

Tabla 9: CPC global de prueba con peso expandido y salida condicionada al flujo saliente observado. Deep Gravity se resume con tres inicializaciones independientes; DE es la desviación estándar muestral. Uniforme, atracción entrenada y gravedad exponencial se calculan una vez por rama sobre el mismo soporte de prueba. Fuente: elaboración propia a partir de los resultados mensuales congelados.

Rama	Deep Gravity	Rango	Uniforme	Atracción	Gravedad exp.
Zona 777	0,5609 $\pm$ 0,0062	0,5537–0,5647	0,2992	0,6574	0,3819
H3-r7	0,7722 $\pm$ 0,0060	0,7671–0,7787	0,3702	0,7757	0,6153
H3-r8	0,6079 $\pm$ 0,0047	0,6046–0,6133	0,2611	0,6867	0,3777

Para comparar el desempeño de la red con cada referencia dentro de una misma rama, se calculó la diferencia relativa $100 (CPC_{DG} - CPC_{ref}) / CPC_{ref}$. La Tabla 10 presenta este contraste; un valor positivo indica una ventaja de Deep Gravity y uno negativo, una desventaja.

Tabla 10: Diferencia relativa del CPC medio de Deep Gravity frente a cada modelo de referencia, calculada dentro de cada rama. Fuente: elaboración propia a partir de los resultados mensuales congelados.

Rama	Uniforme	Atracción	Gravedad exp.
Zona 777	+87,45 %	-14,68 %	+46,89 %
H3-r7	+108,59 %	-0,46 %	+25,49 %
H3-r8	+132,81 %	-11,48 %	+60,97 %

La Figura 11 muestra los CPC que originan estas brechas y conserva las tres inicializaciones. Los cuadrados corresponden a los modelos de referencia y los círculos a inicializaciones de Deep Gravity.




Figura 11: CPC de prueba expandida por semilla y modelos de referencia. Cada panel corresponde a una representación y mantiene su propio soporte de destinos; los cuadrados son referencias deterministas y los círculos son las semillas 20260909, 20260910 y 20260911 de Deep Gravity. Fuente: elaboración propia a partir de las métricas globales del experimento mensual.

Deep Gravity superó las referencias uniforme y de gravedad exponencial en las tres representaciones, pero la magnitud de la ventaja dependió de la discretización: frente a la uniforme varió entre 87,45 % y 132,81 %, y frente a la gravitacional entre 25,49 % y 60,97 %. La atracción entrenada obtuvo el mayor CPC medio en las tres ramas, aunque su ventaja también

cambió: Deep Gravity quedó 14,68 % por debajo en Zona 777 y 11,48 % en H3-r8, mientras que en H3-r7 la diferencia se redujo a 0,46 %. En esta última rama, una inicialización alcanzó 0,7787 y superó individualmente el CPC de atracción de 0,7757; el resumen principal conserva la media de las tres inicializaciones.

Por tanto, la respuesta experimental a la pregunta central no consiste en ordenar los CPC absolutos de las representaciones, sino en observar cómo cambia el desempeño relativo de la red frente a referencias comunes a cada tarea. La cercanía con atracción en H3-r7 y las brechas mayores en Zona 777 y H3-r8 muestran que el desempeño relativo de Deep Gravity es sensible a la discretización espacial.

La conservación de masa se verificó para todos los orígenes de prueba. El mayor error absoluto por origen fue $1,863 \times 10^{-9}$. Este control confirma que la conversión de probabilidades en flujos preserva el flujo saliente observado.

El Anexo C conserva el detalle del soporte de prueba, la repetición independiente y la conservación de masa.

5.5. Trayectorias y selección por validación

La Figura 12 conserva las trayectorias de las nueve corridas y permite distinguir la pérdida de entrenamiento del CPC de validación utilizado para elegir los *checkpoints*. La línea vertical discontinua marca el límite inicial de 200 épocas; solo Zona 777-20260909 y H3-r8-20260910 continuaron mediante extensiones autorizadas.




Figura 12: Trayectorias mensuales de pérdida de entrenamiento y CPC global de validación para las tres semillas de cada rama. La pérdida se expresa como NLL por viaje expandido; los puntos destacados marcan los *checkpoints* seleccionados por CPC de validación y la línea discontinua señala la época 200. Fuente: elaboración propia a partir de las trayectorias del experimento mensual.

Todas las corridas cerraron por meseta de validación. Las dos extensiones mantuvieron los datos, las particiones, la arquitectura, el optimizador y la regla de selección. La corrida de Zona 777 con semilla 20260909 cerró en la época 226 y mantuvo como *checkpoint* seleccionado la época 196. La corrida de H3-r8 con semilla 20260910 cerró en la época 218 y mantuvo la época 188. Las restantes siete corridas cerraron con el límite inicial.

El Anexo B documenta las nueve corridas, sus épocas seleccionadas y sus condiciones de cierre.

Los rangos de CPC de prueba entre las tres inicializaciones fueron 0,0110 en Zona 777, 0,0117 en H3-r7 y 0,0087 en H3-r8. Los tres rangos permanecieron bajo la alerta protocolaria de 0,05. Esta dispersión describe la variación asociada a la inicialización y al entrenamiento bajo una partición espacial fija. Estimar incertidumbre poblacional, variación entre particiones y significación estadística requeriría réplicas espaciales adicionales.

Una verificación independiente volvió a evaluar un *checkpoint* seleccionado por validación en cada representación. Las diferencias absolutas de CPC fueron inferiores a 10^{-6} , con soporte completo de destinos. Esta comprobación confirma que la evaluación congelada se reproduce técnicamente dentro de cada representación. Una validación científica requiere otro período, ciudad o partición espacial.

5.6. Discusión del desempeño frente a la atracción

La primera diferencia está en la información utilizada. La referencia de atracción, definida para esta memoria en la Ecuación 25, calcula la participación de cada destino directamente desde las llegadas observadas cuyos orígenes pertenecen a entrenamiento. Ambos modelos distribuyen el mismo flujo saliente observado O_i y se ajustan con los mismos flujos OD. En cambio, *Deep Gravity* aproxima la atractividad mediante atributos territoriales y distancia, mientras la referencia incorpora la marginal A_j^{train} . La comparación es, por tanto, informativamente asimétrica. Los CPC de atracción, entre 0,6574 y 0,7757, muestran que el perfil empírico de destinos se conserva en grado importante al pasar de los orígenes de entrenamiento al *tile* de prueba. Esto la convierte en una referencia supervisada exigente dentro de Santiago, condicionada por la disponibilidad previa de flujos OD.

Las trayectorias aportan una segunda explicación posible. Después de la época seleccionada, la NLL de entrenamiento disminuyó otro 0,33–1,24 % en las nueve corridas, mientras el CPC de validación terminó 0,0017–0,0189 por debajo de su máximo. Esta divergencia es compatible con sobreajuste o con un desajuste entre la pérdida optimizada y la métrica de selección; ambas explicaciones permanecen abiertas porque se comparan particiones y métricas distintas. La arquitectura tiene 15 capas ocultas, *dropout* igual a cero y decaimiento de pesos igual a cero, sin una búsqueda de profundidad, ancho o regularización. Elegir el mejor *checkpoint* por validación contuvo el deterioro posterior; la búsqueda de arquitectura y regularización queda como siguiente evaluación.

La tercera explicación concierne a los 19 atributos. La familia OSM de transporte incluye estaciones, paradas, andenes y accesos de Metro, y los resume en densidad de POI y cobertura de áreas. Representar la oferta de transporte requeriría incorporar jerarquía modal, conectividad, frecuencia, capacidad y transbordos, además de empleo, matrícula, horarios o intensidad de actividad. La Sección 5.3 encontró además menores medianas de densidad de

POI y presencia OSM hacia la periferia; en H3-r8, el 14,85 % de las celdas periféricas registró cero POI, frente al 6,28 % del resto. En esas celdas la red dispone de menos señales positivas, mientras la referencia se apoya en la marginal de llegadas con independencia de la presencia OSM. En conjunto, la asimetría informativa está establecida por el diseño, y las trayectorias y la cobertura sostienen como hipótesis las otras dos explicaciones. Comparar regularización, realizar ablaciones e incorporar oferta y conectividad permitiría estimar la contribución de cada una.

5.7. Sensibilidad al peso de evaluación

La Figura 13 contrasta el CPC calculado con masa expandida y con conteos sin expansión. En ambos ejes se aplican las mismas probabilidades ya congeladas y cada origen se reescala con su respectivo flujo saliente. La figura mide el efecto del peso de evaluación sobre esas predicciones y conserva los modelos ya seleccionados. La diagonal indica igualdad entre ambas evaluaciones.

Sensibilidad de evaluación al peso




Figura 13: Sensibilidad del CPC de prueba al peso de evaluación. El eje horizontal usa masa expandida y el vertical conteos OD sin expansión; los círculos corresponden a las tres semillas de Deep Gravity y los cuadrados a los modelos de referencia. Cada punto reutiliza probabilidades congeladas y conserva los parámetros de las referencias ajustadas con peso expandido. La diagonal discontinua representa igualdad entre ambas métricas. Fuente: elaboración propia a partir de la evaluación de sensibilidad mensual.

El cambio de ponderación mantuvo la lectura comparativa principal. Los CPC medios de Deep Gravity fueron 0,5623 en Zona 777, 0,7711 en H3-r7 y 0,6077 en H3-r8 al usar conteos sin expansión, frente a 0,5609, 0,7722 y 0,6079 con masa expandida. La atracción entrenada siguió sobre la media de la red en las tres representaciones. Esta figura corresponde a una sensibilidad de evaluación al uso del peso; evaluar otra función de pérdida requeriría reentrenar los modelos.

5.8. Recursos de ejecución

La Tabla 11 registra los recursos observados durante las épocas de entrenamiento y validación. El cómputo de horas considera esas fases; la carga inicial y la escritura de *checkpoints* quedan fuera de la medida. Por ello, el total corresponde a una cota inferior del costo operativo.

Tabla 11: Recursos observados para las nueve corridas mensuales. Las horas corresponden a entrenamiento y validación; la memoria es el máximo registrado en las corridas de cada fila; el tamaño de artefactos se convierte de bytes a GiB (2^{30} bytes) y se redondea a dos decimales. Fuente: elaboración propia a partir del registro de costos e incidencias del experimento mensual.

Rama	Corridas	Horas	Memoria máx. (GiB)	Artefactos (GiB)
Zona 777	3	2,62	0,53	2,33
H3-r7	3	0,19	0,53	1,99
H3-r8	3	6,65	0,83	2,95
Total de nueve corridas	9	9,46	0,83	7,27

Las nueve corridas acumularon 9,46 horas de entrenamiento y validación. El desglose fue 0,19 horas en H3-r7, 2,62 horas en Zona 777 y 6,65 horas en H3-r8. El máximo de memoria de proceso observado fue 0,834 GiB. Estas cifras describen los recursos medidos en las fases reportadas.

Se registraron dos incidencias, resueltas antes de afectar los resultados de prueba. Antes de la primera época, una corrida de Zona 777 requirió corregir un parámetro de hilos de CPU; la corrección se aplicó antes del entrenamiento. Más tarde, un intento de verificación encontró una ruta relativa no serializable después de crear archivos parciales de reproducción; la verificación final se ejecutó en un directorio nuevo. El Anexo C conserva la bitácora técnica y las verificaciones correspondientes.

El Anexo C reúne el desglose de recursos por corrida, las verificaciones de soporte y conservación de masa, y la bitácora de incidencias técnicas resueltas.

5.9. Resultado del análisis complementario de atribuciones predictivas

El análisis complementario evaluó tres aproximaciones para atribuir cambios en la log-probabilidad condicional de un destino dentro del soporte completo de cada origen. Las explicaciones se definieron como sensibilidades predictivas dependientes de la salida, de la muestra y de las referencias de entrenamiento. El estudio caracteriza contribuciones predictivas del comportamiento del modelo.

La Tabla 12 presenta los umbrales y valores obtenidos en los controles que determinaron la decisión de cada método. Los casos se ejecutaron en Zona 777; por tanto, describen la viabilidad de esas configuraciones y no un resultado para las tres representaciones. En gradientes integrados se exigió que los dos orígenes de referencia cumplieran el criterio de completitud; su residuo mide cuánto difiere la suma de las atribuciones del cambio total que deben explicar. En permutaciones agrupadas, las tres semillas del estimador debían superar los controles entre dos conjuntos independientes de orígenes de referencia. Spearman compara el orden de las magnitudes de atribución y Jaccard mide la coincidencia entre los diez atributos con mayor magnitud. En el método exacto jerárquico se comparó cómo se repartía la atribución entre los atributos de origen, de destino y la distancia. La diferencia máxima identifica el mayor cambio entre esas participaciones y la similitud coseno mide cuán parecida es su distribución; ambos criterios debían cumplirse simultáneamente.

Tabla 12: Controles decisivos del análisis complementario de explicabilidad en Zona 777. En las filas con varios valores, el orden corresponde a los orígenes de referencia, semillas o tamaños indicados. Fuente: elaboración propia a partir de los registros de ejecución del análisis.

Método	Control y caso	Umbral	Valor obtenido	¿Pasó?
Gradientes integrados	Residuo relativo de completitud en el caso crítico, 4.096 nodos y dos orígenes de referencia	$\leq 1\%$ en ambos	1,052843 %; 0,153752 %	No; 1 de 2
Permutaciones agrupadas	Spearman de $ \phi $ entre dos conjuntos de referencia, tres semillas del estimador	$\geq 0,80$ en las tres	0,776316; 0,814575; 0,783603	No; 1 de 3
Permutaciones agrupadas	Jaccard top-10 entre los mismos conjuntos y semillas	$\geq 0,60$ en las tres	0,666667 en las tres	Sí; 3 de 3
Shapley exacto jerárquico	Diferencia máxima entre dos conjuntos de referencia, con 24 y 48 orígenes por conjunto	$\leq 0,10$	0,107741; 0,130261	No; 0 de 2
Shapley exacto jerárquico	Similitud coseno entre los mismos conjuntos, con 24 y 48 orígenes por conjunto	$\geq 0,95$	0,978649; 0,970355	Sí; 2 de 2
Shapley exacto jerárquico	Similitud coseno al aumentar cada conjunto de 24 a 48 orígenes	$\geq 0,95$	0,903762; 0,930160	No; 0 de 2

En gradientes integrados, uno de los dos orígenes de referencia excedió el límite de completitud por 0,052843 puntos porcentuales; el otro sí pasó. En permutaciones agrupadas, la primera y la tercera semilla del estimador quedaron 0,023684 y 0,016397 bajo el mínimo de Spearman, aunque las tres pasaron Jaccard. En Shapley exacto jerárquico, la diferencia máxima entre los conjuntos de referencia excedió el límite por 0,007741 con 24 orígenes y por 0,030261 con 48; además, las similitudes al aumentar el tamaño de cada conjunto quedaron 0,046238 y 0,019840 bajo el mínimo. El primer caso de este último método había cumplido sus controles con 24 orígenes por conjunto, pero el segundo no superó el criterio conjunto de estabilidad.

Ninguna de las tres configuraciones superó todos los controles exigidos por su protocolo. Por ello, el resultado se reporta como una evaluación de viabilidad y las atribuciones, rankings, figuras SHAP y casos locales quedan fuera del manuscrito. Las métricas predictivas y las comparaciones con referencias proceden de un protocolo de evaluación distinto.

5.10. Discusión y amenazas a la validez

La evaluación muestra que Deep Gravity puede ejecutarse de forma trazable sobre la cohorte DTPM y producir una distribución de destinos que supera las referencias uniforme y de gravedad exponencial en las tres representaciones examinadas. La atracción entrenada obtiene un CPC medio mayor, pero su ventaja pasa de 14,68 % en Zona 777 y 11,48 % en H3-r8 a sólo 0,46 % en H3-r7. Este perfil de brechas constituye la evidencia principal de sensibilidad del desempeño a la discretización espacial.

La reproducción técnica previa del código con datos de Nueva York se conserva como antecedente de compatibilidad de implementación. Sus métricas pertenecen a otro contexto empírico y se mantienen separadas de los CPC de Santiago.

La discretización espacial modifica los destinos disponibles, la densidad de pares OD positivos, la masa de prueba y la agregación de atributos. En ese contexto, las brechas relativas frente a referencias evaluadas sobre el mismo soporte caracterizan la sensibilidad observada. Los CPC absolutos permanecen asociados a tareas con soporte diferente.

El experimento aporta evidencia para las 29 fechas disponibles de noviembre de 2024, una partición de origen concentrada en un *tile* de prueba y las 34 comunas del dominio definido. El piloto comparte la geografía de prueba e incluye una de las fechas del agregado mensual; una validación temporal y espacial independiente requeriría nuevos períodos y particiones.

La fuente DTPM cubre viajes reconstruibles de transporte público. El modelo distribuye el flujo saliente observado; modelar la generación de viajes por origen requeriría otra formulación. Además, la cobertura de OpenStreetMap corresponde a una instantánea anterior a los viajes y la interpolación del Censo 2024 supone distribución uniforme dentro de cada geometría censal. Las decisiones de reconstrucción de viajes, exclusión de zonas sin polígono y asignación a unidades espaciales también condicionan el resultado.

Las tres inicializaciones describen la variación de entrenamiento dentro de una partición fija. Cuantificar la variación entre particiones o la incertidumbre poblacional exigiría réplicas espaciales adicionales. El análisis de atribuciones queda circunscrito a la evaluación de viabilidad descrita en la Sección 5.9. Una extensión futura debería separar explícitamente la validación temporal y espacial, incorporar particiones adicionales y definir un protocolo explicativo con controles de estabilidad antes de interpretar atribuciones.

CAPÍTULO 6

CONCLUSIONES

El objetivo principal de esta memoria fue determinar si *Deep Gravity* puede distribuir los viajes de transporte público de Santiago entre destinos y si su desempeño cambia con la discretización espacial.

La respuesta depende de la referencia. *Deep Gravity* sí superó las referencias uniforme y de gravedad exponencial en las tres representaciones evaluadas. No superó la referencia de atracción entrenada. El *Common Part of Commuters* (CPC) mide, en términos simples, qué fracción de los viajes el modelo coloca en los destinos correctos al comparar los flujos agregados observados y estimados; vale 1 cuando ambas distribuciones coinciden por completo.

En números, *Deep Gravity* obtuvo un CPC medio de prueba de 0,5609 en Zona 777, 0,7722 en H3-r7 y 0,6079 en H3-r8, con desviaciones estándar muestrales inferiores a 0,007 entre las tres inicializaciones. Su CPC fue 14,68 % menor que el de atracción en Zona 777, 0,46 % menor en H3-r7 y 11,48 % menor en H3-r8. Medido por esta comparación con atracción, el modelo funcionó mejor en H3-r7, la representación más agregada: allí distinguió 223 destinos y casi igualó a la referencia, mientras que Zona 777 y H3-r8 distinguieron 793 y 1.210 destinos, respectivamente, y mostraron diferencias mayores.

Una explicación posible es que H3-r7 reúne más viajes y atributos territoriales dentro de cada celda y reduce el número de destinos que la red debe distinguir. Esa agregación puede suavizar variaciones locales y facilitar el aprendizaje de patrones generales. En las dos representaciones más detalladas, los viajes y los atributos se reparten entre más unidades, por lo que diferenciar destinos cercanos puede resultar más difícil. Esta es una hipótesis compatible con los resultados, pues el experimento no aisló el efecto del tamaño de las unidades ni demuestra que las celdas grandes sean siempre mejores. El valor de este resultado está en identificar que la escala espacial cambia de forma sustantiva la evaluación del modelo; con una sola representación, esa sensibilidad habría quedado oculta.

Hay tres hipótesis para explicar por qué *Deep Gravity* no supera a la atracción. Primero, la atracción calcula la popularidad de cada destino directamente a partir de las llegadas observadas desde los orígenes de entrenamiento, mientras la red debe inferirla mediante distancia y atributos territoriales. Segundo, las trayectorias son compatibles con sobreajuste o con un desajuste entre la pérdida de entrenamiento y el CPC, porque la pérdida continuó disminuyendo después de que el CPC de validación alcanzara su máximo. Tercero, los 19 atributos pueden representar de forma incompleta aquello que atrae viajes en transporte público: aunque incluyen estaciones, paradas, andenes y accesos de Metro, los resumen en variables agregadas y no incorporan jerarquía modal, conectividad, frecuencia, capacidad ni transbordos.

La primera hipótesis es la mejor sustentada porque el uso directo de llegadas observadas es

una diferencia comprobada del diseño y el perfil aprendido por atracción mantuvo capacidad predictiva al evaluar otros orígenes. El experimento no aisló cuánto de su ventaja proviene de esa información, por lo que las tres explicaciones conservan carácter hipotético.

Con la evidencia de esta memoria, *Deep Gravity* sirve para distribuir entre destinos un total conocido de viajes que salen de cada origen y para estudiar cómo esa distribución cambia con la representación espacial. Como aplicación potencial, podría evaluarse para estimar patrones de destino en áreas o períodos donde se conozca ese total saliente, pero no se disponga de llegadas observadas para construir la referencia de atracción; esa transferencia requiere una validación independiente. La configuración actual todavía no justifica sustituir la atracción cuando esas llegadas están disponibles, pues esta referencia obtuvo un CPC medio mayor en las tres representaciones.

En explicabilidad, ninguna de las tres configuraciones superó todos sus controles, aunque algunas aprobaron controles individuales; por ello, sus atribuciones todavía no constituyen explicaciones validadas (Tabla 12).

Esta conclusión se obtuvo a partir de una cohorte común de 60.511.977 viajes canónicos DTPM, observados entre el 1 y el 29 de noviembre de 2024 en 34 comunas. Se construyeron tres representaciones espaciales, Zona 777 (793 unidades), H3-r7 (223 celdas) y H3-r8 (1.210 celdas), y se entrenaron nueve modelos mensuales, tres por representación. La prueba se liberó una sola vez después de seleccionar por validación los modelos que se evaluarían.

6.1. Cumplimiento de objetivos

A continuación se examina el cumplimiento de cada uno de los seis objetivos específicos formulados en la Sección 1.7.

Objetivo 1: Auditar y adaptar el código de referencia. Se completó una auditoría técnica de la implementación de *scikit-mobility* y se verificó su funcionamiento mediante una corrida de compatibilidad con datos de Nueva York. Esta corrida verificó compatibilidad de implementación; la evaluación de desempeño corresponde al experimento de Santiago. El pipeline resultante registra configuración efectiva, semillas, versiones, hashes de entradas, particiones, métricas y *checkpoints* en un directorio exclusivo por corrida, lo que permite verificar la procedencia de cada resultado.

Objetivo 2: Reconstruir viajes canónicos, definir una cohorte común y delimitar el núcleo urbano. Se reconstruyeron los viajes canónicos mediante la unión de las tablas DTPM de viajes y etapas, exigiendo secuencia completa de etapas, bajada válida en la etapa final y coordenadas dentro de los rangos UTM de control. De los 86.327.914 viajes de la entrega procesable, 25.325.042 (29,34 %) se excluyeron porque no registraban bajada en la etapa final. El dominio de estudio se delimitó a 34 comunas, con exclusión posterior de las zonas 848, 849 y 852 por carecer de polígono oficial verificable. La cascada completa de la Tabla 3

conduce a una cohorte comparativa de 60.511.977 viajes con 85.774.522,4070 de masa expandida, compartida por las tres ramas.

Objetivo 3: Construir representaciones comparables y seleccionar candidatas. La Tabla 4 documenta la evaluación de H3-r3 a H3-r8 con conservación de cohorte y masa, un mínimo de 100 orígenes activos y un límite de 128 MiB para la matriz densa de puntajes de una pasada. H3-r3 a H3-r6 aportaron entre 1 y 44 orígenes activos y se descartaron por representar el territorio con muy pocas unidades; H3-r7 y H3-r8 aportaron 220 y 1.194, respectivamente, por lo que pasaron al piloto junto con Zona 777 y se mantuvieron en el experimento mensual. Las tres representaciones finales usan adaptadores espaciales explícitos sobre la misma cohorte fuente.

Objetivo 4: Construir atributos con fuentes, unidades y procedimientos explícitos. Se construyó un vector de 19 atributos por ubicación: una densidad de población censal (Censo 2024, interpolada por fracción de área), cinco coberturas de uso de suelo, tres densidades de longitud vial y diez variables de servicios. Cada par OD se representa con los 19 atributos del origen, los 19 del destino y la distancia geodésica, sumando 39 entradas. La normalización se estimó exclusivamente con orígenes activos de entrenamiento de cada rama y escenario; el conjunto de prueba quedó fuera de la estandarización.

Objetivo 5: Entrenar y evaluar *Deep Gravity* frente a tres referencias. Se ejecutaron nueve corridas mensuales con tres representaciones y tres inicializaciones, evaluando todos los destinos de cada representación. *Deep Gravity* superó las referencias uniforme y de gravedad exponencial en los tres casos, pero no superó la atracción entrenada. La magnitud de esta diferencia cambió entre representaciones: fue mínima en H3-r7 y mayor en Zona 777 y H3-r8. Con ello, el objetivo se cumplió y mostró que la evaluación depende de la discretización espacial. La Sección 5.6 relaciona la ventaja de atracción con su acceso directo a las llegadas observadas de entrenamiento y examina dos explicaciones adicionales: una señal de sobreajuste en las trayectorias y la representación incompleta de atractividad mediante los atributos territoriales.

Objetivo 6: Evaluar la viabilidad de obtener atribuciones predictivas estables. Se implementaron y evaluaron tres aproximaciones de XAI con controles predefinidos de completitud, convergencia y estabilidad. Los gradientes integrados excedieron en 0,052843 puntos porcentuales el límite de completitud con uno de dos orígenes de referencia; las permutaciones agrupadas quedaron bajo el mínimo de Spearman en dos de tres semillas; y el método exacto jerárquico cumplió el primer caso, pero falló los controles conjuntos de estabilidad del segundo. Así, ninguna configuración superó todos sus controles y las atribuciones, los rankings y las figuras XAI se reservan para configuraciones que sí los cumplan.

6.2. Contribuciones

Las contribuciones de esta memoria se enumeran a continuación.

1. **Evaluación reproducible de Deep Gravity para transporte público observable en Santiago.** El trabajo adapta y evalúa el modelo con viajes reconstruibles desde DTPM y atributos territoriales de Censo 2024 y OpenStreetMap. La evaluación se realizó sobre tres representaciones espaciales y con un protocolo de prueba congelado.
2. **Metodología de comparación entre discretizaciones con cohorte común.** El diseño experimental separa el núcleo común de viajes de los adaptadores espaciales y mantiene diferenciados los cambios de datos y de representación. Su adaptación a otras ciudades o modelos requiere una verificación independiente de sus supuestos y resultados.
3. **Pipeline con trazabilidad integral.** Cada corrida conserva semillas, hashes de entradas, versiones de código, particiones deterministas, métricas por origen y *checkpoints* en un directorio exclusivo. La prueba se libera una sola vez después de congelar las decisiones de validación, las semillas y las representaciones. La conservación de masa se verifica explícitamente.
4. **Resultado metodológico sobre los límites de XAI.** La evaluación sistemática de tres aproximaciones de explicabilidad mostró que ninguna configuración superó todos los controles predefinidos de completitud y estabilidad. Esta contribución sitúa la verificación de controles antes de cualquier uso sustantivo de atribuciones.
5. **Caracterización de la referencia de atracción.** Entre las referencias evaluadas, la atracción entrenada alcanzó el mayor CPC medio en las tres representaciones. Su desempeño muestra que el perfil de llegadas aprendido desde los orígenes de entrenamiento conserva capacidad predictiva sobre orígenes espacialmente separados y establece un punto de comparación exigente para modelos basados en atributos territoriales.

6.3. Limitaciones

Estos resultados valen para los viajes de transporte público observables en DTPM dentro de las 34 comunas del área de estudio de Santiago, entre el 1 y el 29 de noviembre de 2024. Describen la distribución de destinos bajo esas condiciones y no se extienden directamente a otros modos, territorios o períodos.

Reconstrucción de viajes y flujo saliente. El análisis incluye únicamente viajes cuyo destino final pudo reconstruirse. La exclusión de 25.325.042 registros sin bajada en la etapa final, equivalentes al 29,34 % de la entrega procesable, mide el efecto de este requisito sobre el tamaño de la cohorte; no permite establecer cómo habrían cambiado los patrones si esos destinos estuvieran disponibles. Además, el modelo recibe como entrada el total observado que sale de cada origen (O_i). Si ese total no se conoce, el modelo no puede aplicarse directamente y cualquier estimación previa de O_i introduciría una incertidumbre que esta memoria no evaluó.

Atributos territoriales. La instantánea OSM corresponde al 1 de enero de 2024 y un valor cero indica ausencia cartografiada, que puede representar ausencia física u omisión en la fuente. El estudio midió menores medianas de presencia OSM hacia la periferia y, en H3-r8, un 14,85 % de celdas periféricas sin POI frente a un 6,28 % en el interior. Si parte de esos zeros corresponde a omisiones, la red recibe menos señales para diferenciar destinos; este efecto sobre el CPC es plausible, pero no fue aislado causalmente. La interpolación del Censo 2024 supone distribución uniforme dentro de cada geometría censal; si la población se concentra dentro de esas geometrías, las densidades asignadas a las unidades pueden quedar suavizadas.

Diseño experimental. Las tres inicializaciones miden variación de entrenamiento bajo una sola partición espacial fija y un único período de 29 días. Si la relación entre orígenes y destinos cambia en otra partición o período, también podrían cambiar el CPC y la comparación con las referencias. Esta memoria no cuantificó esa variación espacial y temporal, por lo que las tres inicializaciones no representan incertidumbre entre períodos ni entre zonas de prueba.

Alcance predictivo y explicabilidad. El alcance predictivo se limita a distribuir entre destinos un flujo saliente conocido por origen. Por ello, los resultados no abarcan la generación total de viajes ni la optimización de rutas, frecuencias o capacidad, que corresponden a problemas distintos. En el análisis XAI, ninguna configuración cumplió todos los controles exigidos por su protocolo. En consecuencia, las atribuciones se consideran todavía insuficientemente validadas para explicar las decisiones del modelo. Esta restricción corresponde al componente explicativo, mientras que el desempeño predictivo se evaluó mediante un protocolo independiente.

6.4. Trabajo futuro

Lo primero que haría es repetir la comparación entre *Deep Gravity* y atracción con varias particiones espaciales y un período que no comparta fechas con noviembre de 2024. Esta prueba respondería si el casi empate de H3-r7 y las diferencias mayores de Zona 777 y H3-r8 se mantienen fuera de la partición y las fechas utilizadas. Si el patrón es estable, se esperaría conservar la cercanía con atracción en H3-r7 y una diferencia mayor en las otras dos representaciones; si cambia, el resultado indicaría que parte de la comparación depende del lugar o del período evaluado.

Después compararía la red actual con variantes menos profundas y con regularización mediante *dropout* y decaimiento de pesos, manteniendo los mismos datos, particiones y protocolo de evaluación. Esta prueba respondería si el sobreajuste contribuye a la desventaja frente a atracción. Si esa hipótesis es correcta, se esperaría menor separación entre la mejora de la pérdida de entrenamiento y la evolución del CPC de validación, junto con una mejora del CPC de prueba; si las variantes no mejoran, la hipótesis perdería respaldo.

Si hubiera tiempo, incorporaría frecuencia, conectividad, capacidad y transbordos del transporte público y realizaría ablaciones por familias de atributos. La comparación entre el vector actual, el vector ampliado y las versiones sin cada familia respondería si falta información relevante para representar la atracción de viajes. Si esa información es importante, se esperaría que el vector ampliado mejore el CPC y que retirar sus variables reduzca el desempeño; la ausencia de esos cambios debilitaría esta explicación.

Las mejoras de XAI quedan para una fase posterior porque requieren ajustar el método y volver a validar completitud y estabilidad antes de interpretar atribuciones. La transferencia a otra ciudad requiere datos equivalentes, una estrategia para obtener o estimar el flujo saliente y un protocolo específico de transferencia. Una GNN requiere otra arquitectura y una comparación experimental propia. Los modelos de oportunidades intervinientes también quedan como extensión, pues deben implementarse y calibrarse bajo el mismo protocolo antes de compararlos. Estas tareas amplían el alcance de la investigación y no son necesarias para cerrar la evaluación realizada en esta memoria.

6.5. Reflexión final

La principal conclusión de esta memoria es que la representación espacial modifica el desempeño comparado de *Deep Gravity*. El modelo ofrece una mejora consistente frente a las referencias uniforme y gravitacional, mientras que la atracción entrenada sigue siendo la comparación más exigente bajo el protocolo aplicado. La trazabilidad del pipeline, desde la reconstrucción de la cohorte hasta la liberación de la prueba, permite inspeccionar y contrastar este resultado con otras particiones, períodos y configuraciones. El componente XAI permanece como una evaluación de viabilidad hasta que alguna configuración supere conjuntamente sus controles de completitud y estabilidad.

Anexo A. Diccionario de atributos territoriales

Este anexo documenta los 19 atributos de localización que integran el vector de entrada aprobado para el modelo. Las variables diagnósticas se reportan por separado y el flujo observado constituye la variable objetivo. Las transformaciones se ajustan únicamente con los orígenes activos del conjunto de entrenamiento de cada rama y escenario.

Tabla A.1: Atributos de población, uso de suelo y red vial del vector de entrada.

Atributo	Fuente y construcción	Unidad y transformación
population_census_2024_per_km2	Censo 2024 del INE; asignación areal de población y división por el área métrica de la unidad.	personas/km ² ; $\log(1+x)$ y estandarización z .
landuse_residential_share	OpenStreetMap (corte 2024-01-01); unión de polígonos residenciales recortados y división por el área de la unidad.	km ² /km ² ; estandarización z .
landuse_commercial_share	OpenStreetMap (corte 2024-01-01); unión de polígonos comerciales recortados y división por el área de la unidad.	km ² /km ² ; estandarización z .
landuse_industrial_share	OpenStreetMap (corte 2024-01-01); unión de polígonos industriales recortados y división por el área de la unidad.	km ² /km ² ; estandarización z .
landuse_retail_share	OpenStreetMap (corte 2024-01-01); unión de polígonos de comercio minorista recortados y división por el área de la unidad.	km ² /km ² ; estandarización z .
landuse_natural_share	OpenStreetMap (corte 2024-01-01); unión de polígonos naturales recortados y división por el área de la unidad.	km ² /km ² ; estandarización z .
road_residential_km_per_km2	OpenStreetMap; unión de líneas residenciales recortadas y división por el área de la unidad.	km/km ² ; $\log(1+x)$ y estandarización z .
road_main_km_per_km2	OpenStreetMap; unión de líneas principales recortadas y división por el área de la unidad.	km/km ² ; $\log(1+x)$ y estandarización z .
road_other_km_per_km2	OpenStreetMap; unión de las demás líneas viales recortadas y división por el área de la unidad.	km/km ² ; $\log(1+x)$ y estandarización z .

Tabla A.2: Atributos de puntos de interés y superficie por familia temática.

Atributo	Fuente y construcción	Unidad y transformación
transport_poi_per_km2	OpenStreetMap; nodos estrictamente interiores, deduplicados por homónimos nodo-área, categoría y coincidencia espacial, divididos por el área de la unidad.	objetos/km ² ; $\log(1 + x)$ y estandarización z .
transport_area_share	OpenStreetMap; unión de las superficies de transporte recortadas y división por el área de la unidad.	km ² /km ² ; estandarización z .
food_poi_per_km2	OpenStreetMap; nodos estrictamente interiores, deduplicados por homónimos nodo-área, categoría y coincidencia espacial, divididos por el área de la unidad.	objetos/km ² ; $\log(1 + x)$ y estandarización z .
food_area_share	OpenStreetMap; unión de las superficies de alimentación recortadas y división por el área de la unidad.	km ² /km ² ; estandarización z .
health_poi_per_km2	OpenStreetMap; nodos estrictamente interiores, deduplicados por homónimos nodo-área, categoría y coincidencia espacial, divididos por el área de la unidad.	objetos/km ² ; $\log(1 + x)$ y estandarización z .
health_area_share	OpenStreetMap; unión de las superficies de salud recortadas y división por el área de la unidad.	km ² /km ² ; estandarización z .
education_poi_per_km2	OpenStreetMap; nodos estrictamente interiores, deduplicados por homónimos nodo-área, categoría y coincidencia espacial, divididos por el área de la unidad.	objetos/km ² ; $\log(1 + x)$ y estandarización z .
education_area_share	OpenStreetMap; unión de las superficies educacionales recortadas y división por el área de la unidad.	km ² /km ² ; estandarización z .
retail_poi_per_km2	OpenStreetMap; nodos estrictamente interiores, deduplicados por homónimos nodo-área, categoría y coincidencia espacial, divididos por el área de la unidad.	objetos/km ² ; $\log(1 + x)$ y estandarización z .
retail_area_share	OpenStreetMap; unión de las superficies de comercio minorista recortadas y división por el área de la unidad.	km ² /km ² ; estandarización z .

La distancia d_{ij} se calcula como distancia geodésica esférica WGS84 entre los centroides representativos de los pares origen-destino y se incorpora al vector como medida de separación espacial. Una ruta por la red requiere información adicional de infraestructura y operación. Las capas territoriales pueden superponerse, por lo que sus proporciones se analizan por familia. Para OpenStreetMap, un valor cero registra ausencia de objetos mapeados conforme a la regla aplicada.

Anexo B. Trazabilidad de las corridas mensuales

Este anexo individualiza las nueve corridas del experimento mensual: tres inicializaciones independientes en cada representación. La época seleccionada corresponde al mayor CPC global de validación de la trayectoria, conservando la primera época ante empate; la época final indica cuándo se detuvo la corrida. Las dos continuaciones autorizadas partieron del límite inicial de 200 épocas y conservaron datos, particiones, atributos, arquitectura, optimizador y regla de selección. Todas las corridas cerraron por meseta de validación.

Tabla B.1: Corridas del experimento mensual y selección por validación.

Representación	Semilla	Época seleccionada	Época final	CPC validación	Extensión	Cierre
Zona 777	20260909	196	226	0,532453	200–226	Meseta
Zona 777	20260910	94	124	0,525924	—	Meseta
Zona 777	20260911	74	104	0,517290	—	Meseta
H3-r7	20260909	72	97	0,737286	—	Meseta
H3-r7	20260910	162	192	0,734555	—	Meseta
H3-r7	20260911	69	99	0,732907	—	Meseta
H3-r8	20260909	158	188	0,600163	—	Meseta
H3-r8	20260910	188	218	0,594110	200–218	Meseta
H3-r8	20260911	137	167	0,589980	—	Meseta

La prueba se evaluó después de fijar y congelar los *checkpoints* seleccionados por validación. Los resultados de las tres semillas se presentan completos en el Capítulo 5; esta tabla conserva la trazabilidad de la selección.

Anexo C. Controles de soporte, conservación de masa y ejecución

Este anexo reúne los controles de reproducibilidad y el detalle de los recursos medidos junto con los denominadores de la repetición independiente, la conservación del flujo por origen, el detalle por corrida y las incidencias técnicas resueltas.

Soporte de prueba, repetición independiente y conservación de masa

Tabla C.1: Controles de soporte, repetición independiente y conservación de masa.

Representación	Orígenes/destinos prueba	Unidades sin origen	CPC congelado	CPC repetido	Diferencia CPC	Máx. error por origen
Zona 777	101/793	0	0,5647245226	0,5647245225	$9,576 \times 10^{-11}$	$9,313 \times 10^{-10}$
H3-r7	32/223	5	0,7670518160	0,7670518160	$3,483 \times 10^{-11}$	$1,863 \times 10^{-9}$
H3-r8	189/1210	21	0,6132965073	0,6132965073	$9,350 \times 10^{-12}$	$1,630 \times 10^{-9}$

Nota. El error máximo corresponde al máximo entre las tres semillas y los dos esquemas de ponderación. La repetición independiente usa la semilla 20260909 y el conjunto completo de destinos. El soporte de prueba comprende los orígenes asignados al bloque de prueba; las unidades sin origen se registran por separado y se excluyen del cálculo del CPC.

La repetición independiente recuperó el CPC congelado de cada representación, con diferencias inferiores a 10^{-6} . Las nueve corridas preservaron el flujo por origen; el mayor error observado fue $1,863 \times 10^{-9}$. Estos controles verifican la consistencia técnica de la ejecución; la evaluación espacial y temporal se desarrolla mediante el protocolo del Capítulo 5.

Recursos medidos por corrida

Tabla C.2: Tiempo de entrenamiento, memoria RAM y tamaño de artefactos por corrida.

Representación	Semilla	Entrenamiento (h)	RAM máx. (GiB)	Artefactos (GiB)
Zona 777	20260909	1,30	0,53	1,16
Zona 777	20260910	0,72	0,53	0,64
Zona 777	20260911	0,60	0,53	0,53
H3-r7	20260909	0,05	0,53	0,50
H3-r7	20260910	0,10	0,53	0,99
H3-r7	20260911	0,05	0,53	0,51
H3-r8	20260909	2,19	0,78	0,97
H3-r8	20260910	2,50	0,83	1,12
H3-r8	20260911	1,95	0,78	0,86
Suma/máximo (9 corridas)	—	9,46	0,83	7,27

Las horas corresponden a las épocas de entrenamiento y validación. La carga inicial y la escritura de *checkpoints* se registran fuera de esa medida, por lo que las horas son una cota inferior del tiempo total de ejecución. La RAM se informa como máximo observado y el tamaño corresponde a los artefactos conservados de cada corrida. Las condiciones de ejecución difieren entre ramas, por lo que la tabla reporta tiempo de entrenamiento y validación en vez de tiempo calendario.

Incidencias técnicas resueltas

Tabla C.3: Incidencias técnicas y efecto sobre los resultados reportados.

Alcance	Incidencia y resolución	Efecto
Zona 777, semilla 20260909	Se detectó la ausencia del parámetro de hilos de CPU antes de iniciar el entrenamiento. Se corrigió antes de entrenar y evaluar la corrida.	La corrección se realizó antes del entrenamiento y la evaluación; la corrida conservó su plan y sus resultados.
Cierre y repetición independiente	Una ruta relativa de serialización se detectó luego de generar productos parciales. La repetición se ejecutó en un directorio nuevo y se excluyeron los productos parciales.	Los <i>checkpoints</i> congelados y la evaluación de prueba conservaron los resultados reportados.

REFERENCIAS BIBLIOGRÁFICAS

- [Barrington-Leigh y Millard-Ball, 2017] Barrington-Leigh, C. y Millard-Ball, A. (2017). The world's user-generated road map is more than 80 % complete. *PLOS ONE*, 12(8):e0180698.
- [Brockmann *et al.*, 2006] Brockmann, D., Hufnagel, L., y Geisel, T. (2006). The scaling laws of human travel. *Nature*, 439(7075):462–465.
- [Directorio de Transporte Público Metropolitano, 2025] Directorio de Transporte Público Metropolitano (2025). Informe de gestión 2024. Informe institucional sobre el año 2024, Ministerio de Transportes y Telecomunicaciones, Gobierno de Chile. Sección 2.2, p. 33. Consultado el 19 de septiembre de 2026.
- [González *et al.*, 2008] González, M. C., Hidalgo, C. A., y Barabási, A.-L. (2008). Understanding individual human mobility patterns. *Nature*, 453(7196):779–782.
- [Haklay y Weber, 2008] Haklay, M. y Weber, P. (2008). OpenStreetMap: User-generated street maps. *IEEE Pervasive Computing*, 7(4):12–18.
- [Herfort *et al.*, 2023] Herfort, B., Lautenbach, S., Porto de Albuquerque, J., Anderson, J., y Zipf, A. (2023). A spatio-temporal analysis investigating completeness and inequalities of global urban building data in OpenStreetMap. *Nature Communications*, 14(1):3985.
- [Hornik, 1991] Hornik, K. (1991). Approximation capabilities of multilayer feedforward networks. *Neural Networks*, 4(2):251–257.
- [Kang *et al.*, 2015] Kang, C., Liu, Y., Guo, D., y Qin, K. (2015). Generalized radiation model for human mobility: spatial scale, searching direction and trip constraint. *PLOS ONE*, 10(11):e0143500.
- [Liu y Yan, 2019] Liu, E.-J. y Yan, X.-Y. (2019). Opportunity priority selection model for human mobility. *Physica A: Statistical Mechanics and its Applications*, 526:121023.
- [Liu y Yan, 2020] Liu, E.-J. y Yan, X.-Y. (2020). Research advances in intervening opportunity class models for predicting human mobility. *Acta Physica Sinica*, 69(24):248901.
- [Luca *et al.*, 2024] Luca, M., Beneduce, C., y Lepri, B. (2024). TS-Mob: Social and geographical-aware time series foundation-model framework for human mobility prediction. *arXiv preprint arXiv:2412.09180*.
- [Lundberg y Lee, 2017] Lundberg, S. M. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems*, volumen 30. Curran Associates, Inc.
- [Marín-Flores *et al.*, 2026] Marín-Flores, C., Ferres, L., y Tenkanen, H. (2026). When proximity falls short: Inequalities in commuting and accessibility by public transport in Santiago, Chile. *Geographical Analysis*, 58(2):e70039.

- [McFadden, 1974] McFadden, D. (1974). Conditional logit analysis of qualitative choice behavior. En Zarembka, P., editor, *Frontiers in Econometrics*, pp. 105–142. Academic Press, New York.
- [Ortúzar y Willumsen, 2011] Ortúzar, J. d. D. y Willumsen, L. G. (2011). *Modelling Transport*. John Wiley & Sons, Chichester, 4 edición.
- [Pappalardo et al., 2023] Pappalardo, L., Simini, F., Barlacchi, G., y Pellungrini, R. (2023). scikit-mobility: a python library for the analysis, generation and risk assessment of mobility data. *Journal of Statistical Software*, 103(4):1–38.
- [Ren et al., 2014] Ren, Y., Ercsey-Ravasz, M., Wang, P., González, M. C., y Toroczkai, Z. (2014). Predicting commuter flows in spatial networks using a radiation model based on temporal ranges. *Nature Communications*, 5(1):5347.
- [Rong et al., 2024] Rong, C., Ding, J., y Li, Y. (2024). An interdisciplinary survey on origin-destination flows modeling: Theory and techniques. *ACM Computing Surveys*, 57(1):1–38.
- [Rong et al., 2026] Rong, C., Zhang, X., Xi, Y., SUI, H., Ding, J., y Li, Y. (2026). Satellites reveal mobility: A commuting origin-destination flow generator for global cities. En *The Thirty-ninth Annual Conference on Neural Information Processing Systems Datasets and Benchmarks Track*.
- [Sim et al., 2015] Sim, A., Yaliraki, S. N., Barahona, M., y Stumpf, M. P. (2015). Modelling the effects of subjective and objective decision making in scientific peer review. *Journal of The Royal Society Interface*, 12(107):20150315.
- [Simini et al., 2021] Simini, F., Barlacchi, G., Luca, M., y Pappalardo, L. (2021). A deep gravity model for mobility flows generation. *Nature Communications*, 12(1):6576.
- [Simini et al., 2012] Simini, F., González, M. C., Maritan, A., y Barabási, A.-L. (2012). A universal model for mobility and migration patterns. *Nature*, 484(7392):96–100.
- [Simini et al., 2013] Simini, F., Maritan, A., y Néda, Z. (2013). Human mobility in a continuum approach. *PloS one*, 8(3):e60069.
- [Spadon et al., 2019] Spadon, G., de Carvalho, A. C. P. L. F., Rodrigues-Jr, J. F., y Alves, L. G. A. (2019). Reconstructing commuters network using machine learning and urban indicators. *Scientific Reports*, 9:11801.
- [Stouffer, 1940] Stouffer, S. A. (1940). Intervening opportunities: a theory relating mobility and distance. *American Sociological Review*, 5(6):845–867.
- [Sundararajan et al., 2017] Sundararajan, M., Taly, A., y Yan, Q. (2017). Axiomatic attribution for deep networks. En *Proceedings of the 34th International Conference on Machine Learning*, volumen 70, pp. 3319–3328. PMLR.

- [Vecchio *et al.*, 2020] Vecchio, G., Tiznado-Aitken, I., y Hurtubia, R. (2020). Transport and equity in Latin America: a critical review of socially oriented accessibility assessments. *Transport Reviews*, 40(3):354–381.
- [Wilson, 1970] Wilson, A. G. (1970). *Entropy in Urban and Regional Modelling*. Pion, London.
- [Xu *et al.*, 2025] Xu, Y., Gao, S., Huang, Q., Göçmen, A., Zhu, Q., y Zhang, F. (2025). Predicting human mobility flows in cities using deep learning on satellite imagery. *Nature Communications*, 16:10372.
- [Yan *et al.*, 2017] Yan, X.-Y., Wang, W.-X., Gao, Z.-Y., y Lai, Y.-C. (2017). Universal model of individual and population mobility on diverse spatial scales. *Nature Communications*, 8(1):1639.
- [Yan *et al.*, 2014] Yan, X.-Y., Zhao, C., Fan, Y., Di, Z., y Wang, W.-X. (2014). Universal predictability of mobility patterns in cities. *Journal of The Royal Society Interface*, 11(100):20140834.
- [Yang *et al.*, 2014] Yang, Y.-X., Herrera, C., Eagle, N., y González, M. C. (2014). Limits of predictability in human mobility. *Scientific Reports*, 4(1):5662.
- [Zipf, 1946] Zipf, G. K. (1946). The P1 P2/D hypothesis: on the intercity movement of persons. *American Sociological Review*, 11(6):677–686.