

UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA
DEPARTAMENTO DE INFORMÁTICA
SANTIAGO - CHILE



“GENERACIÓN DE FLUJOS DE MOVILIDAD EN
SANTIAGO DE CHILE MEDIANTE DEEP GRAVITY:
EVALUACIÓN DEL IMPACTO DE LAS AMENITIES DE
OPENSTREETMAP Y ANÁLISIS MEDIANTE XAI”

PABLO ALBERTO CAMPOS ÁVILA

MEMORIA PARA OPTAR AL TÍTULO DE
INGENIERO CIVIL EN INFORMÁTICA

Profesor Guía: Daniela Opitz W
Profesor Correferente: Nombre del correferente NN2

Julio - 2026

DEDICATORIA

Considerando la importancia de este trabajo para los alumnos, este apartado es para que el autor entregue palabras personales para dedicar este documento. La extensión puede ser de máximo una hoja y se deben mantener este formato, tipo y tamaño de letra.

AGRADECIMIENTOS

Considerando la importancia de este trabajo para los alumnos, este apartado se podrá incluir en el caso de que el autor desee agradecer a las personas que facilitaron alguna ayuda relevante en su trabajo para la realización de este documento. La extensión puede ser de máximo una hoja y se deben mantener este formato, tipo y tamaño de letra.

RESUMEN

Resumen— El resumen y las palabras clave no deben superar la mitad de la página, donde debe precisarse brevemente: 1) lo que el autor ha hecho, 2) cómo lo hizo (sólo si es importante detallarlo), 3) los resultados principales, 4) la relevancia de los resultados. El resumen es una representación abreviada, pero comprensiva de la memoria y debe informar sobre el objetivo, la metodología y los resultados del trabajo realizado.

Palabras Clave— Cinco es el máximo de palabras clave para describir los temas tratados en la memoria, ponerlas separadas por punto y comas.

ABSTRACT

Abstract— Corresponde a la traducción al idioma inglés del Resumen anterior. Sujeto a la misma regla de extensión del Resumen.

Keywords— Corresponde a la traducción al idioma inglés de Palabras Clave anteriores.

GLOSARIO

Aquí se deben colocar las siglas mencionadas en el trabajo y su explicación, por orden alfabético. Por ejemplo:

DI: Departamento de Informática.

UTFSM: Universidad Técnica Federico Santa María.

ÍNDICE DE CONTENIDOS

RESUMEN	IV
ABSTRACT	IV
GLOSARIO	V
ÍNDICE DE FIGURAS	VIII
ÍNDICE DE TABLAS	VIII
INTRODUCCIÓN	1
CAPÍTULO 1: DEFINICIÓN DEL PROBLEMA	2
1.1 Fuentes de datos actuales y sus limitaciones	2
1.2 Limitaciones de los modelos vigentes	3
1.3 Especificidad del contexto latinoamericano	3
1.4 Síntesis del problema	3
1.5 Árbol del problema	4
1.6 Objetivo General	4
1.7 Objetivos Específicos	4
CAPÍTULO 2: MARCO CONCEPTUAL	6
2.1 Movilidad urbana y flujos origen-destino	6
2.2 Modelos clásicos de generación de flujos	7
2.2.1 Modelo gravitatorio	7
2.2.2 Modelo de oportunidades intervinientes	8
2.2.3 Modelo de radiación	8
2.3 Aprendizaje profundo aplicado a la movilidad	9
2.4 Deep Gravity	10
2.4.1 Formulación matemática	10
2.4.2 Arquitectura de la red neuronal	10
2.4.3 Vector de características geoespaciales	11
2.4.4 Resultados y desempeño	11
2.5 Explicabilidad en modelos de inteligencia artificial (XAI)	12
2.5.1 Valores SHAP	12
2.5.2 Gradientes integrados	12
2.6 OpenStreetMap como fuente de datos geoespaciales	13
2.7 Contexto de la movilidad en Santiago de Chile	13
CAPÍTULO 3: PROPUESTA DE SOLUCIÓN	15
3.1 EJEMPLO DE COMO CITAR FIGURAS E ILUSTRACIONES	15
CAPÍTULO 4: VALIDACIÓN DE LA SOLUCIÓN	16

4.1 EJEMPLO DE COMO CITAR TABLAS	16
CAPÍTULO 5: CONCLUSIONES	17
ANEXOS	18
REFERENCIAS BIBLIOGRÁFICAS	19

ÍNDICE DE FIGURAS

1	Diagrama del árbol del problema. En la parte inferior se presentan las causas que originan el problema central: la planificación del transporte en Santiago opera con datos desactualizados y modelos que ignoran la complejidad del tejido urbano, sin capacidad de explicar sus predicciones. En la parte superior se muestran los efectos que estas limitaciones generan sobre la toma de decisiones en infraestructura y planificación. Fuente: Elaboración propia. . .	4
2	Malla Curricular Ingeniería Civil Informática.	15

ÍNDICE DE TABLAS

1	Coloquios del Ciclo de Charlas Informática.	16
---	---	----

INTRODUCCIÓN

Los flujos de movilidad origen-destino (OD) cuantifican el número de personas que se desplazan entre dos ubicaciones geográficas en un período de tiempo definido. Constituyen un insumo central para la planificación del transporte, la gestión de emergencias y el diseño de políticas urbanas [Rong *et al.*, 2024]. Obtener estos datos mediante observación directa es costoso y poco frecuente. Esta limitación ha motivado el desarrollo de modelos generativos capaces de estimar flujos OD a partir de características observables del territorio, permitiendo extrapolar predicciones a contextos donde no existen datos de encuesta.

La estimación de flujos OD cuenta con una tradición extensa en la geografía cuantitativa. Modelos clásicos como el gravitacional [Zipf, 1946], el de oportunidades intermedias [Stouffer, 1940] y el de radiación [Simini *et al.*, 2012] han dominado históricamente esta área. Estos modelos comparten limitaciones conocidas: dependen de un conjunto reducido de variables explicativas y no capturan relaciones no lineales entre el tejido urbano y los flujos observados. El Marco Conceptual de esta memoria detalla la formulación de estos modelos y sus restricciones. Más recientemente, la incorporación de redes neuronales profundas ha permitido superar parte de estas limitaciones, dando origen a modelos como Deep Gravity [Simini *et al.*, 2021], cuya arquitectura y validación también se describen en el Marco Conceptual.

Deep Gravity ha sido validado sobre ciudades del Norte Global, pero no existe evidencia de su aplicación en una metrópolis latinoamericana. Tampoco ha sido evaluado sobre datos posteriores a la pandemia de COVID-19. Esta memoria aplica Deep Gravity para generar flujos de movilidad en Santiago de Chile a partir de datos abiertos de OpenStreetMap, implementándolo sobre la biblioteca *scikit-mobility* [Pappalardo *et al.*, 2023]. El trabajo evalúa el impacto de las categorías de *amenities* de OpenStreetMap sobre la precisión de las predicciones. Además, aplica la técnica SHAP (*SHapley Additive exPlanations*) [Lundberg y Lee, 2017] para interpretar la contribución de las características urbanas a los flujos estimados. Con ello, la memoria aporta la primera aplicación conocida de Deep Gravity a una ciudad latinoamericana, junto con un análisis de explicabilidad de sus predicciones sobre el tejido urbano de Santiago.

El resto del documento se organiza en cinco capítulos. El Capítulo 1 (Definición del Problema) diagnostica las brechas actuales en la estimación de flujos de movilidad en Santiago y establece los objetivos de la memoria. El Capítulo 2 (Marco Conceptual) presenta los fundamentos teóricos de los modelos de movilidad y detalla la arquitectura de Deep Gravity. El Capítulo 3 (Propuesta de Solución) describe la construcción del dataset, la adaptación del modelo y el diseño experimental. El Capítulo 4 (Validación de la Solución) presenta los resultados obtenidos y su comparación con los modelos baseline. Finalmente, el Capítulo 5 (Conclusiones) discute los hallazgos y propone líneas de trabajo futuro.

CAPÍTULO 1

DEFINICIÓN DEL PROBLEMA

Santiago posee uno de los sistemas de transporte público más avanzados de América Latina. Se caracteriza por la integración de buses, metro y tren suburbano. Este sistema registra más de tres millones de transacciones diarias solo en el modo bus [DPTM, 2025]. La red de movilidad de la ciudad conecta a una población metropolitana que supera los siete millones de habitantes, distribuida en más de cuarenta comunas.

Comprender la distribución espacial de los desplazamientos en esta red, representada mediante flujos origen-destino (OD), es un insumo esencial para la planificación del transporte. También lo es para el diseño de infraestructura vial y la formulación de políticas urbanas basadas en evidencia [Rong *et al.*, 2024].

1.1. Fuentes de datos actuales y sus limitaciones

La planificación del transporte en Santiago se apoya actualmente en dos fuentes principales de datos de movilidad. La primera es la *Encuesta Origen-Destino* (EOD) de SECTRA¹. Su última versión fue levantada en 2012, con actualizaciones parciales en 2017. Esta encuesta constituye la referencia canónica de flujos de movilidad en la ciudad. Sin embargo, su periodicidad de siete a diez años implica que los datos disponibles pueden no reflejar la movilidad actual. Esto es especialmente relevante tras la reconfiguración de patrones de desplazamiento producida por la pandemia de COVID-19. Su elevado costo de levantamiento agrava además esta desactualización.

La segunda fuente son los datos anonimizados de validación de la *tarjeta bip*², administrados por el DTPM³. Estos datos registran validaciones en Metro y buses con alta resolución temporal. No obstante, no cubren etapas caminadas. Tampoco cubren viajes en taxi o colectivo pagados en efectivo, ni modos no motorizados.

Esta brecha entre la necesidad de datos actualizados y su disponibilidad real motiva el desarrollo de modelos generativos. Dichos modelos deben ser capaces de estimar flujos OD a partir de características observables del territorio, sin depender exclusivamente de encuestas o registros transaccionales.

¹Secretaría de Planificación del Transporte, organismo dependiente del Ministerio de Transportes y Telecomunicaciones de Chile.

²Nombre oficial del sistema de tarificación electrónica del transporte público de Santiago.

³Directorio de Transporte Público Metropolitano.

1.2. Limitaciones de los modelos vigentes

Los modelos utilizados en la práctica para la estimación de flujos en Santiago corresponden a modelos de gravedad clásicos. Estos modelos presentan limitaciones ampliamente documentadas en la literatura [Zipf, 1946, Simini *et al.*, 2012, Rong *et al.*, 2024]. Imponen relaciones paramétricas monótonas entre población, distancia y flujo, lo que genera un ajuste deficiente ante fenómenos no lineales, como la existencia de subcentros de empleo o corredores de transporte masivo. Requieren además calibración manual para cada contexto geográfico, lo que limita su transferibilidad. Finalmente, no incorporan como variables explicativas el tejido urbano: puntos de interés, uso de suelo ni infraestructura de transporte.

Modelos basados en aprendizaje profundo, como Deep Gravity [Simini *et al.*, 2021], han demostrado superar estas limitaciones incorporando variables geoespaciales de OpenStreetMap. Su arquitectura y su desempeño reportado se detallan en el Marco Conceptual de esta memoria. Sin embargo, su aplicación en ciudades latinoamericanas no ha sido explorada.

1.3. Especificidad del contexto latinoamericano

Esta ausencia de validación es relevante porque las ciudades latinoamericanas presentan características estructurales que las diferencian de los contextos donde estos modelos han sido desarrollados y evaluados. Entre ellas se cuentan la segregación socioeconómica, la coexistencia de sistemas de transporte formales e informales y diferencias en la completitud de los datos geoespaciales de OpenStreetMap entre regiones del mundo [Barrington-Leigh y Millard-Ball, 2017]. Estas diferencias impiden anticipar si un modelo como Deep Gravity mantendría su desempeño al ser aplicado sobre Santiago.

Más allá del contexto geográfico, el modelo carece de una capa de explicabilidad que permita a los planificadores comprender qué factores del tejido urbano impulsan cada predicción.

1.4. Síntesis del problema

En síntesis, el problema que aborda esta memoria se formula de la siguiente manera:

La planificación del transporte en Santiago de Chile opera con estimaciones de flujos OD basadas en datos desactualizados y modelos paramétricos que no capturan la complejidad del tejido urbano. Modelos basados en aprendizaje profundo, como Deep Gravity, han demostrado superar estas limitaciones, pero su aplicación en ciudades latinoamericanas no ha sido explorada. Se desconoce tanto su capacidad predictiva en este contexto como la contribución de las amenities

urbanas a la generación de flujos. Asimismo, la ausencia de técnicas de explicabilidad sobre estos modelos impide que los planificadores comprendan los factores que determinan las predicciones.

1.5. Árbol del problema

A continuación se presenta el diagrama del árbol del problema (Figura 1), el cual sintetiza de manera visual las relaciones causales identificadas. En la parte inferior se ubican las causas que originan el problema central: la desactualización y alto costo de la EOD, las limitaciones de los modelos de gravedad clásicos, la ausencia de variables geoespaciales en los modelos vigentes, la falta de explicabilidad en los modelos de distribución de viajes, y la inexistencia de validación de modelos de aprendizaje profundo en metrópolis latinoamericanas. En la parte superior se presentan los efectos derivados del problema: decisiones de inversión en infraestructura basadas en datos obsoletos, incapacidad de anticipar el impacto de intervenciones urbanas sobre los flujos, opacidad en la decisión pública, rezago metodológico frente al estado del arte internacional, y subutilización de datasets administrativos de alta resolución.

Figura 1: Diagrama del árbol del problema. En la parte inferior se presentan las causas que originan el problema central: la planificación del transporte en Santiago opera con datos desactualizados y modelos que ignoran la complejidad del tejido urbano, sin capacidad de explicar sus predicciones. En la parte superior se muestran los efectos que estas limitaciones generan sobre la toma de decisiones en infraestructura y planificación. Fuente: Elaboración propia.

1.6. Objetivo General

Generar flujos de movilidad origen-destino en Santiago de Chile mediante el modelo Deep Gravity, evaluando el impacto de las *amenities* de OpenStreetMap sobre la precisión de las predicciones y analizando la contribución de las variables geoespaciales mediante técnicas de Inteligencia Artificial Explicable (XAI).

1.7. Objetivos Específicos

1. Reproducir y adaptar el modelo Deep Gravity sobre el dataset de referencia del repositorio original, validando el pipeline y las métricas reportadas, para garantizar la trazabilidad y reproducibilidad del proceso.

2. Caracterizar el dataset de viajes y etapas de noviembre de 2024 del DTPM y construir una tessellation cuadrada para el Gran Santiago, evaluando la sensibilidad de los resultados ante distintas resoluciones de grilla (**500 m, 1 km, 2 km y 5 km**).
3. Extraer las *amenities* de OpenStreetMap para el área de estudio, utilizando el conjunto de categorías del paper original y evaluando la pertinencia de un conjunto extendido adaptado a las características del tejido urbano latinoamericano.
4. Entrenar y evaluar el modelo Deep Gravity sobre Santiago, comparando cuantitativamente su desempeño con el de los modelos de gravedad clásico y de radiación mediante la métrica CPC (*Common Part of Commuters*) y su descomposición espacial por *tile*.
5. Cuantificar el impacto de las *amenities* de OSM sobre el desempeño del modelo mediante la técnica SHAP (*SHapley Additive exPlanations*), determinando la importancia global y local de cada categoría de *amenity* en la generación de flujos.
6. *Analizar la sensibilidad de las explicaciones obtenidas (valores SHAP) frente a la escala de agregación espacial de la grilla y a las distintas temporalidades del flujo (períodos punta y fuera de punta), discutiendo la coherencia de las amenities identificadas con las dinámicas socioespaciales de Santiago.*

CAPÍTULO 2

MARCO CONCEPTUAL

Este capítulo presenta los fundamentos teóricos y técnicos en que se apoya esta memoria. Se introducen, en primer lugar, los conceptos centrales de movilidad urbana y flujos origen-destino. Luego se describen los modelos clásicos de generación de flujos, que constituyen la base histórica del problema y los *baselines* de esta investigación. A continuación se expone cómo el aprendizaje profundo ha permitido superar las limitaciones de esos modelos, culminando en la arquitectura *Deep Gravity*. El capítulo continúa con los fundamentos de la explicabilidad de modelos de inteligencia artificial mediante SHAP, la descripción de OpenStreetMap como fuente de datos geospaciales, y concluye con el contexto de la movilidad en Santiago de Chile.

2.1. Movilidad urbana y flujos origen-destino

La movilidad urbana comprende el conjunto de desplazamientos que realizan las personas entre distintas ubicaciones de la ciudad en un período de tiempo determinado [Rong *et al.*, 2024]. Comprender estos desplazamientos es un insumo fundamental para la planificación del transporte, el diseño de infraestructura vial y la formulación de políticas públicas basadas en evidencia.

Una representación sintética y cuantitativa de la movilidad urbana es la **matriz origen-destino** (matriz OD). Formalmente, dado un conjunto de n zonas geográficas $\mathcal{Z} = \{z_1, z_2, \dots, z_n\}$ que particionan el área de estudio, el flujo T_{ij} representa el número de viajes que se realizan desde la zona de origen z_i hasta la zona de destino z_j en un intervalo de tiempo fijo:

$$\mathbf{T} \in \mathbb{R}^{n \times n}, \quad T_{ij} \geq 0 \quad \forall i, j \in \{1, \dots, n\} \quad (1)$$

La colección de todos los flujos posibles entre pares de zonas conforma la matriz OD. Cada fila i representa los flujos salientes desde una zona de origen, y cada columna j los flujos entrantes hacia una zona de destino.

Obtener la matriz OD mediante observación directa —a través de encuestas domiciliarias, aforos de tráfico o registros de tarjetas de pago— es costoso y poco frecuente. Esta limitación ha motivado el desarrollo de **modelos generativos de flujos**, capaces de estimar $\mathbf{T}$ a partir de características observables del territorio, como la distribución de la población o la presencia de equipamientos urbanos, sin depender exclusivamente de mediciones directas [Simini *et al.*, 2021].

El problema de generación de flujos se formula de la siguiente manera: dado un conjunto de zonas $\mathcal{Z}$, sus características geospaciales y los flujos totales salientes por zona $O_i = \sum_j T_{ij}$,

estimar los flujos por par origen-destino $\hat{T}_{ij}$ para todos los pares (i, j) .

2.2. Modelos clásicos de generación de flujos

La estimación de flujos origen-destino cuenta con una tradición extensa en la geografía cuantitativa. Los modelos que se describen a continuación han dominado históricamente esta área y constituyen los *baselines* de referencia en esta memoria.

2.2.1. Modelo gravitatorio

El modelo gravitatorio de movilidad establece una analogía con la ley de gravitación universal de Newton. Propuesto formalmente por Zipf [Zipf, 1946] en 1946, postula que el volumen de desplazamientos entre dos zonas es directamente proporcional al producto de sus masas — representadas habitualmente por la población— e inversamente proporcional a la distancia que las separa:

$$T_{ij} = k \cdot \frac{P_i^\alpha \cdot P_j^\beta}{d_{ij}^\gamma} \quad (2)$$

donde P_i y P_j son las poblaciones de las zonas de origen y destino, d_{ij} es la distancia entre sus centroides, k es una constante de proporcionalidad, y α, β, γ son parámetros que deben calibrarse con datos observados. Zipf verificó empíricamente esta relación mediante datos de tráfico de buses, ferrocarriles y llamadas telefónicas entre ciudades de Estados Unidos, encontrando que los coeficientes se aproximan a la unidad en todos los casos.

La formulación de la ecuación (2) recibe el nombre de *modelo de gravedad no restringido*. En la práctica, para garantizar que los flujos generados sean consistentes con los totales salientes observados, se utiliza la versión *restringida en origen* (*singly-constrained*), que normaliza los flujos de cada origen sobre todos sus destinos posibles:

$$\hat{T}_{ij} = O_i \cdot \frac{P_j^\beta f(d_{ij})}{\sum_k P_k^\beta f(d_{ik})} \quad (3)$$

donde $O_i = \sum_j T_{ij}$ es el flujo total saliente de la zona i y $f(d_{ij})$ es una función de disuasión por distancia, que puede adoptar forma exponencial ($e^{\beta_2 d}$) o de ley de potencia (d^{β_2}).

El modelo gravitatorio presenta limitaciones ampliamente documentadas [Rong et al., 2024]. Impone una relación paramétrica monótona entre población, distancia y flujo, lo que genera un ajuste deficiente ante fenómenos no lineales como la existencia de subcentros de empleo o corredores de transporte masivo. Requiere además calibración manual para cada contexto geográfico, lo que limita su transferibilidad. Finalmente, no incorpora como variables explicativas el tejido urbano: puntos de interés, uso de suelo ni infraestructura de transporte.

2.2.2. Modelo de oportunidades intervinientes

Stouffer [Stouffer, 1940] propuso en 1940 una perspectiva alternativa al modelo gravitatorio, argumentando que la distancia no es en sí misma el factor determinante de la movilidad, sino que actúa como un contenedor espacial de oportunidades. Su hipótesis central es que el número de personas que se desplazan a una zona de destino es directamente proporcional al número de oportunidades en ese destino e inversamente proporcional al número de oportunidades intervinientes entre el origen y el destino.

Formalmente, sea y el número de personas que se desplazan desde un origen hasta una banda circular de anchura Δs , y sea x el número acumulado de oportunidades entre el origen y la distancia s . Stouffer postula:

$$\Delta y = a \cdot \frac{\Delta x}{x} \quad (4)$$

Integrando esta expresión diferencial, el número total de personas que se detienen dentro de un círculo de radio s desde el origen es:

$$y = a \cdot \ln f(s) + c \quad (5)$$

donde $f(s)$ es el número acumulado de oportunidades dentro de ese radio y c es una constante de integración. Stouffer verificó empíricamente esta formulación con datos de movilidad residencial en Cleveland, Ohio (1933-1935), obteniendo una buena correspondencia entre los flujos observados y los predichos por el modelo.

El modelo fue validado originalmente para movilidad intrazonal. Su principal dificultad de aplicación radica en la definición operacional de *oportunidad*, que varía según el tipo de desplazamiento estudiado (empleos, viviendas, comercios). Este concepto fue posteriormente formalizado y generalizado en el modelo de radiación.

2.2.3. Modelo de radiación

Simini et al. [Simini *et al.*, 2012] propusieron en 2012 el **modelo de radiación** como una alternativa libre de parámetros al modelo gravitatorio. El modelo parte de una analogía con los procesos de radiación y absorción en física de partículas: cada individuo en un origen busca la mejor oportunidad disponible dentro de radios geográficos crecientes, y se desplaza hacia el destino donde la encuentra.

El mecanismo es el siguiente. Se asigna a cada oportunidad un valor de beneficio z extraído de una distribución de probabilidad $p(z)$. La probabilidad de que un individuo en la zona i elija la zona j como destino es la probabilidad de que el mejor beneficio dentro de j supere al mejor beneficio disponible dentro del círculo de radio d_{ij} centrado en i (excluyendo i y j). Esta probabilidad es:

$$p(n_j | m_i, s_{ij}) = \frac{m_i n_j}{(m_i + s_{ij})(m_i + n_j + s_{ij})} \quad (6)$$

donde m_i es la población de la zona de origen i , n_j es la población de la zona de destino j , y s_{ij} es la población total dentro de un círculo de radio d_{ij} centrado en i , excluyendo las poblaciones de i y de j . El flujo esperado entre i y j es entonces:

$$\langle T_{ij} \rangle = T_i \cdot \frac{m_i n_j}{(m_i + s_{ij})(m_i + n_j + s_{ij})} \quad (7)$$

donde $T_i = \sum_j T_{ij}$ es el flujo total saliente de la zona i . Una propiedad destacable del modelo de radiación es que satisface automáticamente la restricción de conservación de flujos: $\sum_j \langle T_{ij} \rangle = T_i$, sin necesidad de calibración de parámetros adicionales.

Simini et al. [Simini et al., 2012] validaron el modelo sobre datos de commuting del censo de Estados Unidos (2000), demostrando que supera al modelo gravitatorio en la reproducción de flujos observados, especialmente en la predicción de viajes de corta distancia que el modelo gravitatorio tiende a sobreestimar. A pesar de sus ventajas, el modelo de radiación utiliza exclusivamente la población como *proxy* de oportunidades, sin incorporar características del tejido urbano como el uso de suelo o la distribución de actividades económicas. Esta limitación fue el punto de partida para el desarrollo de modelos basados en aprendizaje profundo.

2.3. Aprendizaje profundo aplicado a la movilidad

El aprendizaje profundo (*deep learning*) es un subcampo del aprendizaje automático que utiliza redes neuronales con múltiples capas de transformaciones no lineales para aprender representaciones jerárquicas de los datos [Rong et al., 2024]. Su aplicación a la predicción de flujos de movilidad ha permitido incorporar un conjunto amplio de variables geoespaciales y capturar relaciones no lineales que los modelos clásicos no pueden representar.

Una red neuronal *feedforward* (de propagación hacia adelante) con L capas ocultas transforma un vector de entrada $\mathbf{x} \in \mathbb{R}^d$ mediante una secuencia de transformaciones afines seguidas de funciones de activación no lineales:

$$\mathbf{z}^{(0)} = \sigma(W^{(0)} \mathbf{x}), \quad \mathbf{z}^{(\ell)} = \sigma(W^{(\ell)} \mathbf{z}^{(\ell-1)}), \quad \ell = 1, \dots, L-1 \quad (8)$$

donde $W^{(\ell)}$ es la matriz de pesos de la capa ℓ y $\sigma(\cdot)$ es la función de activación, comúnmente ReLU ($\max(0, x)$) o su variante LeakyReLU ($\max(\alpha x, x)$ con α pequeño), que mitiga el problema del gradiente desvanecido en redes profundas.

En el contexto de la generación de flujos, el aprendizaje profundo ha sido aplicado de múltiples formas: como extensión no lineal del modelo gravitatorio [Simini et al., 2021], mediante redes neuronales de grafos que modelan la estructura espacial de las zonas, y mediante modelos de series de tiempo que capturan la evolución temporal de los flujos [Luca et al., 2024]. Esta memoria se enfoca en el primero de estos enfoques, implementado a través del modelo *Deep Gravity*.

2.4. Deep Gravity

Deep Gravity es un modelo de generación de flujos de movilidad propuesto por Simini et al. [Simini et al., 2021] en 2021. Su contribución central es demostrar que el modelo gravitatorio clásico restringido en origen (ecuación 3) es formalmente equivalente a una red neuronal lineal de una sola capa con salida *softmax*, y que reemplazar esa capa lineal por una red neuronal profunda permite capturar relaciones no lineales entre las características del territorio y los flujos observados.

2.4.1. Formulación matemática

El modelo gravitatorio restringido en origen puede reescribirse como un modelo lineal generalizado con distribución multinomial. Para un origen i , la probabilidad de que un viaje se dirija al destino j es:

$$p_{ij} = \frac{\exp(\beta^\top \mathbf{x}(l_i, l_j))}{\sum_k \exp(\beta^\top \mathbf{x}(l_i, l_k))} \quad (9)$$

donde $\mathbf{x}(l_i, l_j) = [\ln P_j, d_{ij}]$ es el vector de características del par (i, j) , y $\beta = [\beta_1, \beta_2]$ son los parámetros del modelo. Esta formulación es entrenada maximizando la log-verosimilitud multinomial, cuya función de pérdida es equivalente a la entropía cruzada:

$$H = - \sum_i \sum_j \frac{T_{ij}}{O_i} \ln p_{ij} \quad (10)$$

Deep Gravity reemplaza el producto interno lineal $\beta^\top \mathbf{x}(l_i, l_j)$ por una red neuronal profunda $f_\theta(\mathbf{x}(l_i, l_j))$ que produce un score escalar. Las probabilidades de destino se obtienen mediante *softmax* sobre los scores de todos los destinos candidatos desde el origen i :

$$p_{ij} = \frac{\exp(f_\theta(\mathbf{x}(l_i, l_j)))}{\sum_k \exp(f_\theta(\mathbf{x}(l_i, l_k)))} \quad (11)$$

El flujo estimado desde i hacia j es entonces $\hat{T}_{ij} = O_i \cdot p_{ij}$.

2.4.2. Arquitectura de la red neuronal

La función f_θ es implementada como una red neuronal *feedforward* de 15 capas ocultas con activación LeakyReLU. Las primeras 6 capas tienen dimensión 256 y las 9 restantes dimensión

128. La capa de salida produce un escalar:

$$\begin{aligned} \mathbf{z}^{(0)} &= \text{LeakyReLU}(W^{(0)} \mathbf{x}(l_i, l_j)) \\ \mathbf{z}^{(\ell)} &= \text{LeakyReLU}(W^{(\ell)} \mathbf{z}^{(\ell-1)}), \quad \ell = 1, \dots, 14 \\ f_{\theta}(\mathbf{x}(l_i, l_j)) &= \mathbf{w}^T \mathbf{z}^{(14)} \end{aligned} \quad (12)$$

El modelo se entrena con el optimizador RMSprop (momentum = 0,9; tasa de aprendizaje = 5×10^{-6}), con *batches* de 64 zonas de origen. Para cada origen, se aplica *negative sampling*: se seleccionan hasta 512 destinos candidatos por origen, combinando destinos con flujos observados y destinos aleatorios sin flujos observados, lo que hace computacionalmente tratable la normalización del *softmax* sobre todas las zonas.

2.4.3. Vector de características geoespaciales

El vector de entrada $\mathbf{x}(l_i, l_j) \in \mathbb{R}^{39}$ concatena las características del origen, el destino y la distancia entre ellos:

$$\mathbf{x}(l_i, l_j) = [\mathbf{f}(l_i), \mathbf{f}(l_j), \ln P_i, \ln P_j, d_{ij}] \quad (13)$$

donde $\mathbf{f}(l) \in \mathbb{R}^{18}$ es el vector de 18 características geoespaciales extraídas de OpenStreetMap para la zona l , P_i y P_j son las poblaciones de origen y destino, y d_{ij} es la distancia geodésica entre sus centroides (en kilómetros). Las 18 características se organizan en 7 categorías: uso del suelo (5 features), red vial (3 features), instalaciones de transporte (2 features), alimentación (2 features), salud (2 features), educación (2 features) y comercio (2 features). Todas ellas se normalizan dividiendo por el área de la zona, expresando su valor por kilómetro cuadrado.

2.4.4. Resultados y desempeño

Simini et al. [Simini et al., 2021] evaluaron *Deep Gravity* sobre datos de commuting de Inglaterra, Italia y el estado de Nueva York, utilizando la métrica *Common Part of Commuters* (CPC), definida como:

$$\text{CPC}(\hat{\mathbf{T}}, \mathbf{T}) = \frac{2 \sum_{i,j} \min(\hat{T}_{ij}, T_{ij})}{\sum_{i,j} \hat{T}_{ij} + \sum_{i,j} T_{ij}} \quad (14)$$

La métrica CPC toma valores en $[0, 1]$, donde 1 indica coincidencia exacta entre flujos generados y reales. Es equivalente al índice de Sørensen-Dice aplicado a flujos. Los resultados muestran que *Deep Gravity* supera al modelo gravitatorio clásico en todos los contextos evaluados, con mejoras de hasta un 190 % en CPC global en Inglaterra y del 1.066 % en el estado de Nueva York. El modelo también demostró transferibilidad geográfica: entrenado en algunas ciudades del Reino Unido, mantiene un desempeño similar cuando se evalúa en ciudades no vistas durante el entrenamiento.

2.5. Explicabilidad en modelos de inteligencia artificial (XAI)

La explicabilidad de la inteligencia artificial (*eXplainable Artificial Intelligence*, XAI) se refiere al conjunto de técnicas que permiten comprender e interpretar las predicciones de modelos de aprendizaje automático complejos [Lundberg y Lee, 2017]. En el contexto de la planificación del transporte, la explicabilidad es relevante no solo desde el punto de vista académico —para entender qué variables del territorio impulsan los flujos— sino también desde el punto de vista institucional, ya que permite a los planificadores auditar las predicciones del modelo.

2.5.1. Valores SHAP

SHAP (*SHapley Additive exPlanations*), propuesto por Lundberg y Lee [Lundberg y Lee, 2017], es un método de explicabilidad que fundamenta la importancia de cada variable en la teoría de juegos cooperativos de Shapley. La contribución de la característica i a la predicción del modelo para una instancia $\mathbf{x}$ se define como:

$$\phi_i(f, \mathbf{x}) = \sum_{S \subseteq \mathcal{F} \setminus \{i\}} \frac{|S|! (|\mathcal{F}| - |S| - 1)!}{|\mathcal{F}|!} [f(S \cup \{i\}) - f(S)] \quad (15)$$

donde $\mathcal{F}$ es el conjunto de todas las características, S es una coalición de características que no incluye a i , y $f(S)$ es la predicción del modelo usando solo las características en S . El valor ϕ_i representa la contribución marginal promedio de la característica i sobre todas las posibles coaliciones de características.

Los valores SHAP satisfacen tres propiedades deseables: *eficiencia* (la suma de todos los valores SHAP es igual a la diferencia entre la predicción y el valor base), *simetría* (características con igual contribución marginal reciben igual valor SHAP) y *dummy* (características sin influencia reciben valor cero). En conjunto, estas propiedades garantizan una atribución justa y consistente de importancias.

En esta memoria se utilizan los valores SHAP para cuantificar el impacto de cada categoría de *amenity* de OpenStreetMap sobre la predicción de flujos del modelo *Deep Gravity*. El análisis SHAP permite determinar qué tipos de equipamiento urbano —educación, salud, comercio, transporte, entre otros— son los más determinantes en la generación de flujos para el contexto de Santiago de Chile.

2.5.2. Gradientes integrados

Los *Integrated Gradients* [Sundararajan et al., 2017] son un método de atribución basado en el gradiente de la función del modelo con respecto a las variables de entrada. Para una

predicción $f(\mathbf{x})$ y una entrada de referencia $\mathbf{x}'$ (típicamente el vector nulo), la atribución de la característica i se define como:

$$\text{IG}_i(\mathbf{x}) = (x_i - x'_i) \cdot \int_0^1 \frac{\partial f(\mathbf{x}' + \alpha(\mathbf{x} - \mathbf{x}'))}{\partial x_i} d\alpha \quad (16)$$

En esta memoria, los *Integrated Gradients* se utilizan como técnica complementaria a SHAP para obtener atribuciones a nivel de par origen-destino específico, permitiendo identificar qué características son más relevantes para flujos particulares.

2.6. OpenStreetMap como fuente de datos geospaciales

OpenStreetMap (OSM) es una base de datos geoespacial colaborativa y de libre acceso, construida y mantenida por una comunidad global de voluntarios desde su creación en 2004 [Haklay y Weber, 2008]. Su modelo de datos se articula en tres tipos de objetos geométricos: *nodos* (puntos), *vías* (secuencias de nodos que representan líneas o polígonos) y *relaciones* (agrupaciones de nodos y vías con un significado semántico compartido). Cada objeto puede llevar asociados pares clave-valor denominados *etiquetas* (*tags*), que codifican su naturaleza (por ejemplo, *amenity=hospital* o *landuse=residential*).

Para el modelado de flujos de movilidad, OSM provee información sobre la distribución espacial de equipamientos y servicios urbanos —comúnmente denominados *amenities*— que el modelo *Deep Gravity* utiliza como variables explicativas. Estas incluyen establecimientos de salud, educación, comercio, alimentación, transporte, y áreas de uso de suelo residencial, comercial e industrial, entre otras categorías.

Una limitación reconocida de OSM en el contexto latinoamericano es la **heterogeneidad espacial de su cobertura**. Estudios previos [Barrington-Leigh y Millard-Ball, 2017] han documentado que la densidad y completitud de los datos OSM varía significativamente según el nivel socioeconómico y la accesibilidad de las distintas áreas de una ciudad. En Santiago, esto se manifiesta en una mayor completitud en comunas de ingresos medios y altos —como Providencia, Las Condes y Vitacura— y menor cobertura en comunas periféricas de menores ingresos. Esta heterogeneidad es un factor metodológico relevante que se abordará en el análisis de resultados de esta memoria, dado que puede sesgar la estimación de las características geospaciales de entrada al modelo en las zonas con menor presencia de datos voluntarios.

2.7. Contexto de la movilidad en Santiago de Chile

Santiago de Chile es la capital de la Región Metropolitana y alberga aproximadamente siete millones de habitantes, distribuidos en más de cuarenta comunas. Es una de las ciudades de América Latina con mayor complejidad en su sistema de transporte público, que integra

buses (*Red Metropolitana de Movilidad*), Metro, tren suburbano (Metrotren Nos) y sistemas de transporte activo [DPTM, 2025].

La principal fuente histórica de datos de movilidad en Santiago es la **Encuesta Origen-Destino (EOD)** del SECTRA⁴. Su última versión fue levantada en 2012, con actualizaciones parciales en 2017. Esta encuesta constituye la referencia canónica de flujos de movilidad en la ciudad. Sin embargo, su periodicidad de siete a diez años, combinada con el elevado costo de levantamiento, implica que los datos disponibles pueden no reflejar la movilidad actual, especialmente tras la reconfiguración de los patrones de desplazamiento producida por la pandemia de COVID-19.

Una fuente complementaria, de mayor resolución temporal, son los registros de validación de la **tarjeta bip!**, administrados por el DTPM⁵. Estos datos registran cada validación en Metro y buses con información de paradero, zona y hora, lo que permite construir matrices OD a nivel de viaje individual. No obstante, no cubren etapas caminadas, viajes en taxi o colectivo pagados en efectivo, ni modos no motorizados.

Esta memoria utiliza el **dataset de viajes y etapas de noviembre de 2024 del DTPM**, que comprende aproximadamente 3,6 millones de viajes en un mes completo, con información de zona de inicio, zona de fin, modo de transporte, hora, factor de expansión y coordenadas estimadas de subida y bajada. Este dataset, de mayor resolución temporal y amplitud que la EOD, permite construir matrices OD a escala diaria o por período horario (punta mañana, punta tarde, fuera de punta) y constituye la principal fuente de flujos observados para el entrenamiento y evaluación del modelo *Deep Gravity* en Santiago.

⁴Secretaría de Planificación del Transporte, organismo dependiente del Ministerio de Transportes y Telecomunicaciones de Chile.

⁵Directorio de Transporte Público Metropolitano.

CAPÍTULO 3

PROPUESTA DE SOLUCIÓN

Se debe desarrollar la solución propuesta. Los subcapítulos por poner aquí son propios del autor. Se sugiere mencionar metodología usada. Es conveniente incorporar figuras y tablas para aclarar la solución, que deben indicar el número de la figura, su nombre y su autor o fuente (si las diseñas tú, la fuente es “Elaboración propia”). Ver ejemplos en esta página y en la siguiente.

Cabe mencionar que aquí está la esencia del trabajo en lo que se refiere al aporte creativo del memorista, es el momento de demostrar que usted es un destacado profesional que creó, diseñó y/o llevó a cabo la solución propuesta.

3.1. EJEMPLO DE COMO CITAR FIGURAS E ILUSTRACIONES

Se colocó una imagen que se puede referenciar también desde el texto (Ver figura 2).

Malla Curricular Ingeniería Civil Informática

Plan 73 13

AÑO 1				AÑO 2				AÑO 3				AÑO 4				AÑO 5		AÑO 5 1/2	
SEMESTRE I	SEMESTRE II	SEMESTRE III	SEMESTRE IV	SEMESTRE V	SEMESTRE VI	SEMESTRE VII	SEMESTRE VIII	SEMESTRE IX	SEMESTRE X	SEMESTRE XI		SEMESTRE IX	SEMESTRE X	SEMESTRE XI		SEMESTRE IX	SEMESTRE X	SEMESTRE XI	
IWI-131 Programación 3 5	QUI-010 Química y Sociedad 3 5	INF-134 Estructuras de Datos 1 2	INF-253 Lenguajes de Programación 1 2	INF-239 Bases de Datos 1 2	INF-236 Análisis y Diseño de Software 3 5	INF-225 Ingeniería de Software 3 5	INF-322 Diseño de Interfaces de Usuario 3 5	INF-302 Electivo Informática II 3 5				INF-303 Electivo Informática III 3 5	INF-304 Electivo Informática IV 3 5			INF-311 Electivo I 3 5	INF-313 Electivo III 3 5		
MAT-021 Matemáticas I 5 8	MAT-022 Matemáticas II 5 7	MAT-023 Matemáticas III 4 7	MAT-024 Matemáticas IV 4 6	INF-245 Arquitectura y Organización de Computadores 1 2	INF-246 Sistemas Operativos 3 5	INF-256 Redes de Computadores 3 5	INF-343 Sistemas Distribuidos 3 5	INF-303 Electivo Informática III 3 5	INF-304 Electivo Informática IV 3 5			INF-311 Electivo I 3 5	INF-313 Electivo III 3 5			INF-311 Electivo I 3 5	INF-313 Electivo III 3 5		
FIS-100 Introducción a la Física 3 6	FIS-110 Física General I 3 6	FIS-130 Física General III 4 8	FIS-120 Física General II 4 8	FIS-140 Física General IV 4 8	INF-276 Ingeniería, Informática y Matemáticas Financieras 3 5	ICN-270 Información y Matemáticas Financieras 3 5	INF-301 Electivo Informática I 3 5	INF-311 Electivo I 3 5	INF-313 Electivo III 3 5			INF-311 Electivo I 3 5	INF-313 Electivo III 3 5			INF-311 Electivo I 3 5	INF-313 Electivo III 3 5		
	IWI-101 Introducción a la Ingeniería 2 3	INF-152 Estructuras Discretas 1 2	INF-155 Informática Teórica 1 2	INF-280 Estadística Computacional 1 2	INF-221 Algoritmos y Complejidad 3 5	INF-285 Computación Científica 3 5	INF-295 Inteligencia Artificial 3 5	INF-312 Electivo II 3 5	INF-314 Electivo IV 3 5			INF-312 Electivo II 3 5	INF-314 Electivo IV 3 5			INF-312 Electivo II 3 5	INF-314 Electivo IV 3 5		
HRW-132 Humanístico I 2 3	HRW-133 Humanístico II 2 3	INF-260 Teoría de Sistemas 3 5	INF-170 Economía IA 3 5	INF-270 Organizaciones y Sistemas de Información 3 5	INF-292 Optimización 3 5	INF-293 Investigación de Operaciones 3 6	INF-266 Sistemas de Gestión 3 5	INF-360 Gestión de Proyectos de Ingeniería 3 5	INF-228 Taller de Desarrollo de Proyecto de Ingeniería 6 10			INF-360 Gestión de Proyectos de Ingeniería 3 5	INF-228 Taller de Desarrollo de Proyecto de Ingeniería 6 10			INF-360 Gestión de Proyectos de Ingeniería 3 5	INF-228 Taller de Desarrollo de Proyecto de Ingeniería 6 10		
DEW-100 Educación Física I 1 2	DEW-101 Educación Física II 1 2	INF-1 Libre1/ Actividad co-curricular 1 2	INF-2 Libre2/ Actividad co-curricular 1 2	INF-3 Libre3/ Actividad co-curricular 1 2	INF-4 Libre4/ Actividad co-curricular 1 2	INF-5 Libre5/ Actividad co-curricular 1 2	INF-6 Libre6/ Actividad co-curricular 1 2	INF-7 Libre7/ Actividad co-curricular 1 2	INF-309 Trabajo de Título 1 1 2	INF-310 Trabajo de Título 2 12 20		INF-7 Libre7/ Actividad co-curricular 1 2	INF-309 Trabajo de Título 1 1 2	INF-310 Trabajo de Título 2 12 20		INF-7 Libre7/ Actividad co-curricular 1 2	INF-309 Trabajo de Título 1 1 2	INF-310 Trabajo de Título 2 12 20	
14 24	18 28	18 32	18 31	17 30	16 27	16 28	16 27	16 27	16 27	12 20		16 27	16 27	12 20		16 27	16 27	12 20	

BACHILLER EN CIENCIAS DE LA INGENIERÍA

LICENCIADO EN CIENCIAS DE LA INGENIERÍA

Código asignatura	FIS-110	Número asignatura	010	Nombre asignatura	Física General I
Pre Requisito	Q135	5 11			
Créditos USM SCT	5	11			

- Matemáticas, Física y Química
- Transversal y de Integración
- Humanidades, Educación Física y Libres
- Industrial y Comercial

- Fundamentos de Informática
- Sistemas de Información y de Decisión
- Ingeniería de Software y Datos
- Infraestructura TIC

- Computación Aplicada en Ciencia e Ingeniería
- Electivos Informática y Electivos

Al reverso perfil de egreso, inglés, prácticas, titulación, otros

Departamento de Informática

Figura 2: Malla Curricular Ingeniería Civil Informática.

Fuente: Departamento de Informática.

CAPÍTULO 4

VALIDACIÓN DE LA SOLUCIÓN

Se debe validar la solución propuesta. Esto significa probar o demostrar que la solución propuesta es válida para el entorno donde fue planteada.

Tradicionalmente es una etapa crítica, pues debe comprobarse por algún medio que vuestra propuesta es básicamente válida. En el caso de un desarrollo de software es la construcción y sus pruebas; en el caso de propuestas de modelos, guías o metodologías podrían ser desde la aplicación a un caso real hasta encuestas o entrevistas con especialistas; en el caso de mejoras de procesos u optimizaciones, podría ser comparar la situación actual (previa a la memoria) con la situación final (cuando la memoria está ya implementada) en base a un conjunto cuantitativo de indicadores o criterios.

4.1. EJEMPLO DE COMO CITAR TABLAS

Se colocó una tabla que se puede referenciar también desde el texto (Ver tabla 1).

Tabla 1: Coloquios del Ciclo de Charlas Informática.
Fuente: Elaboración Propia.

Título Coloquio	Presentador, País
"Sensible, invisible, sometimes tolerant, heterogeneous, decentralized and interoperable... and we still need to assure its quality..."	Guilherme Horta Travassos, Brasil.
"Dispersed Multiphase Flow Modeling: From Environmental to Industrial Applications"	Orlando Ayala, EE.UU.
"Líneas de Producto Software Dinámicas para Sistemas atentos el Contexto"	Rafael Capilla, España.
...	...

CAPÍTULO 5

CONCLUSIONES

Las Conclusiones son, según algunos especialistas, el aspecto principal de una memoria, ya que reflejan el aprendizaje final del autor del documento. En ellas se tiende a considerar los alcances y limitaciones de la propuesta de solución, establecer de forma simple y directa los resultados, discutir respecto a la validez de los objetivos formulados, identificar las principales contribuciones y aplicaciones del trabajo realizado, así como su impacto o aporte a la organización o a los actores involucrados. Otro aspecto que tiende a incluirse son recomendaciones para quienes se sientan motivados por el tema y deseen profundizarlo, o lineamientos de una futura ampliación del trabajo.

Todo esto debe sintetizarse en al menos 5 páginas.

ANEXOS

En los Anexos se incluye todo aquel material complementario que no es parte del contenido de los capítulos de la memoria, pero que permiten a un lector contar con un contenido adjunto relacionado con el tema.

REFERENCIAS BIBLIOGRÁFICAS

- [Barrington-Leigh y Millard-Ball, 2017] Barrington-Leigh, C. y Millard-Ball, A. (2017). The world's user-generated road map is more than 80 % complete. *PLOS ONE*, 12(8):e0180698.
- [DPTM, 2025] DPTM (2025). Sistema de transporte público de santiago. <https://www.dtpm.cl/index.php/sistema-de-transporte-publico-de-santiago>. Consultado el 4 de octubre de 2025.
- [Haklay y Weber, 2008] Haklay, M. y Weber, P. (2008). OpenStreetMap: User-generated street maps. *IEEE Pervasive Computing*, 7(4):12–18.
- [Luca et al., 2024] Luca, M., Beneduce, C., y Lepri, B. (2024). TS-Mob: Social and geographical-aware time series foundation-model framework for human mobility prediction. *arXiv preprint arXiv:2412.09180*.
- [Lundberg y Lee, 2017] Lundberg, S. M. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems*, volumen 30. Curran Associates, Inc.
- [Pappalardo et al., 2023] Pappalardo, L., Simini, F., Barlacchi, G., y Pellungrini, R. (2023). scikit-mobility: a python library for the analysis, generation and risk assessment of mobility data. *Journal of Statistical Software*, 103(4):1–38.
- [Rong et al., 2024] Rong, C., Ding, J., y Li, Y. (2024). An interdisciplinary survey on origin-destination flows modeling: Theory and techniques. *ACM Computing Surveys*, 57(1):1–38.
- [Simini et al., 2021] Simini, F., Barlacchi, G., Luca, M., y Pappalardo, L. (2021). A deep gravity model for mobility flows generation. *Nature Communications*, 12(1):6576.
- [Simini et al., 2012] Simini, F., González, M. C., Maritan, A., y Barabási, A.-L. (2012). A universal model for mobility and migration patterns. *Nature*, 484(7392):96–100.
- [Stouffer, 1940] Stouffer, S. A. (1940). Intervening opportunities: a theory relating mobility and distance. *American Sociological Review*, 5(6):845–867.
- [Sundararajan et al., 2017] Sundararajan, M., Taly, A., y Yan, Q. (2017). Axiomatic attribution for deep networks. En *Proceedings of the 34th International Conference on Machine Learning*, volumen 70, pp. 3319–3328. PMLR.
- [Zipf, 1946] Zipf, G. K. (1946). The P1 P2/D hypothesis: on the intercity movement of persons. *American Sociological Review*, 11(6):677–686.