

UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA
DEPARTAMENTO DE INFORMÁTICA
SANTIAGO - CHILE



“GENERACIÓN DE FLUJOS DE MOVILIDAD EN
SANTIAGO DE CHILE MEDIANTE DEEP GRAVITY:
EVALUACIÓN DEL IMPACTO DE LAS AMENITIES DE
OPENSTREETMAP Y ANÁLISIS MEDIANTE XAI”

PABLO ALBERTO CAMPOS ÁVILA

MEMORIA PARA OPTAR AL TÍTULO DE
INGENIERO CIVIL EN INFORMÁTICA

Profesor Guía: Daniela Opitz
Profesor Correferente: Nombre del correferente

Julio - 2026

DEDICATORIA

Considerando la importancia de este trabajo para los alumnos, este apartado es para que el autor entregue palabras personales para dedicar este documento. La extensión puede ser de máximo una hoja y se deben mantener este formato, tipo y tamaño de letra.

AGRADECIMIENTOS

Considerando la importancia de este trabajo para los alumnos, este apartado se podrá incluir en el caso de que el autor desee agradecer a las personas que facilitaron alguna ayuda relevante en su trabajo para la realización de este documento. La extensión puede ser de máximo una hoja y se deben mantener este formato, tipo y tamaño de letra.

RESUMEN

Resumen— El resumen y las palabras clave no deben superar la mitad de la página, donde debe precisarse brevemente: 1) lo que el autor ha hecho, 2) cómo lo hizo (sólo si es importante detallarlo), 3) los resultados principales, 4) la relevancia de los resultados. El resumen es una representación abreviada, pero comprensiva de la memoria y debe informar sobre el objetivo, la metodología y los resultados del trabajo realizado.

Palabras Clave— Cinco es el máximo de palabras clave para describir los temas tratados en la memoria, ponerlas separadas por punto y comas.

ABSTRACT

Abstract— Corresponde a la traducción al idioma inglés del Resumen anterior. Sujeto a la misma regla de extensión del Resumen.

Keywords— Corresponde a la traducción al idioma inglés de Palabras Clave anteriores.

GLOSARIO

Aquí se deben colocar las siglas mencionadas en el trabajo y su explicación, por orden alfabético. Por ejemplo:

DI: Departamento de Informática.

UTFSM: Universidad Técnica Federico Santa María.

ÍNDICE DE CONTENIDOS

RESUMEN	IV
ABSTRACT	IV
GLOSARIO	V
ÍNDICE DE FIGURAS	VIII
ÍNDICE DE TABLAS	VIII
INTRODUCCIÓN	1
CAPÍTULO 1: DEFINICIÓN DEL PROBLEMA	2
1.1 Fuentes de datos actuales y sus limitaciones	2
1.2 Limitaciones de los modelos vigentes	3
1.3 Especificidad del contexto latinoamericano	3
1.4 Síntesis del problema	4
1.5 Árbol del problema	5
1.6 Objetivo General	6
1.7 Objetivos Específicos	6
CAPÍTULO 2: MARCO CONCEPTUAL	7
2.1 Movilidad urbana y flujos origen-destino	7
2.2 Modelos clásicos de generación de flujos	8
2.2.1 Modelo gravitatorio	8
2.2.2 Modelo de oportunidades intervinientes	9
2.2.3 Modelo de radiación	10
2.3 Aprendizaje profundo aplicado a la movilidad	12
2.4 Deep Gravity	12
2.4.1 Formulación matemática	12
2.4.2 Arquitectura de la red neuronal	13
2.4.3 Vector de características geoespaciales	13
2.4.4 Resultados y desempeño	14
2.4.5 Síntesis comparativa de modelos	14
2.5 Explicabilidad en modelos de inteligencia artificial (XAI)	15
2.5.1 Valores SHAP	15
2.5.2 Gradientes integrados	16
2.6 OpenStreetMap como fuente de datos geoespaciales	16
2.7 Contexto de la movilidad en Santiago de Chile	17
CAPÍTULO 3: TRABAJO RELACIONADO	18
3.1 Descubrimiento de patrones en la movilidad individual	18
3.2 Unificación de modelos clásicos y enfoques continuos	18

3.3	Evolución de los modelos de oportunidades intervinientes	19
3.3.1	Modelo de oportunidades ponderadas por población	19
3.3.2	Modelos exploratorios: más allá de la selección secuencial	20
3.3.3	Modelo Unificado de Oportunidades	21
3.4	Deep Learning y modelos espacio-temporales en movilidad	22
3.5	Generación de flujos mediante datos no convencionales	22
3.6	En Resumen	23
CAPÍTULO 4: PROPUESTA DE SOLUCIÓN		25
4.1	Diseño general de la solución	25
4.2	Ingesta y procesamiento de datos de movilidad	26
4.2.1	Descripción del conjunto de datos	26
4.2.2	Factor de expansión	26
4.2.3	Construcción de matrices origen-destino	27
4.3	Delimitación espacial del área de estudio	27
4.4	Unidades espaciales y estrategia comparativa	28
4.4.1	Modelo 1 (Control): Teselación zonal DTPM	28
4.4.2	Modelo 2 (Propuesto): Grilla hexagonal Uber H3	29
4.4.3	Modelo 0 (Baseline comunal)	30
4.5	Justificación teórica de la arquitectura	30
4.5.1	El modelo gravitatorio restringido como modelo Logit multinomial	30
4.5.2	Equivalencia entre la función de pérdida y la maximización de entropía	30
4.5.3	Capacidad de aproximación de la red neuronal	31
4.6	Extracción de características urbanas	31
4.6.1	Ontología de características	31
4.6.2	Normalización y construcción del vector de entrada	32
4.7	Configuración del entrenamiento	33
4.7.1	Arquitectura neuronal	33
4.7.2	Muestreo negativo y función de pérdida	33
4.7.3	Optimizador y hiperparámetros	33
4.7.4	Correcciones sobre el código base	33
4.8	Alcances y limitaciones	34
4.8.1	Alcance del estudio	34
4.8.2	Limitaciones	35
CAPÍTULO 5: VALIDACIÓN DE LA SOLUCIÓN		36
CAPÍTULO 6: CONCLUSIONES		37
ANEXOS		38
REFERENCIAS BIBLIOGRÁFICAS		39

ÍNDICE DE FIGURAS

1	Diagrama del árbol del problema. Fuente: Elaboración propia.	5
---	--	---

ÍNDICE DE TABLAS

1	Comparación de modelos de generación de flujos de movilidad. Fuente: Elaboración propia.	14
2	Ontología de características OSM consolidada en 12 macro-categorías funcionales. Fuente: Elaboración propia.	32

INTRODUCCIÓN

Los flujos de movilidad origen-destino (OD) cuantifican el número de personas que se desplazan entre dos ubicaciones geográficas en un período de tiempo definido. Constituyen un insumo central para la planificación del transporte, la gestión de emergencias y el diseño de políticas urbanas [Rong *et al.*, 2024]. Obtener estos datos mediante observación directa es costoso y poco frecuente. Esta limitación ha motivado el desarrollo de modelos generativos capaces de estimar flujos OD a partir de características observables del territorio, permitiendo extrapolar predicciones a contextos donde no existen datos de encuesta.

La estimación de flujos OD cuenta con una tradición extensa en la geografía cuantitativa. Modelos clásicos como el gravitacional [Zipf, 1946], el de oportunidades intervinientes [Stouffer, 1940] y el de radiación [Simini *et al.*, 2012] han dominado históricamente esta área. Estos modelos comparten limitaciones conocidas: dependen de un conjunto reducido de variables explicativas y no capturan relaciones no lineales entre el tejido urbano y los flujos observados. El Marco Conceptual de esta memoria detalla la formulación de estos modelos y sus restricciones. Más recientemente, la incorporación de redes neuronales profundas ha permitido superar parte de estas limitaciones, dando origen a modelos como Deep Gravity [Simini *et al.*, 2021], cuya arquitectura y validación también se describen en el Marco Conceptual.

Deep Gravity ha sido validado sobre ciudades del Norte Global, pero no existe evidencia de su aplicación en una metrópolis latinoamericana. Tampoco ha sido evaluado sobre datos posteriores a la pandemia de COVID-19. Esta memoria aplica Deep Gravity para generar flujos de movilidad en Santiago de Chile a partir de datos abiertos de OpenStreetMap, implementándolo sobre la biblioteca *scikit-mobility* [Pappalardo *et al.*, 2023]. El trabajo evalúa el impacto de las categorías de *amenities* de OpenStreetMap sobre la precisión de las predicciones. Además, aplica la técnica SHAP (*SHapley Additive exPlanations*) [Lundberg y Lee, 2017] para interpretar la contribución de las características urbanas a los flujos estimados. Con ello, la memoria aporta la primera aplicación conocida de Deep Gravity a una ciudad latinoamericana, junto con un análisis de explicabilidad de sus predicciones sobre el tejido urbano de Santiago.

El resto del documento se organiza en seis capítulos. El Capítulo 1 (Definición del Problema) diagnostica las brechas actuales en la estimación de flujos de movilidad en Santiago y establece los objetivos de la memoria. El Capítulo 2 (Marco Conceptual) presenta los fundamentos teóricos de los modelos de movilidad y detalla la arquitectura de Deep Gravity. El Capítulo 3 (Trabajo Relacionado) sitúa esta memoria respecto a la literatura existente sobre generación de flujos de movilidad. El Capítulo 4 (Propuesta de Solución) describe la construcción del dataset, la adaptación del modelo y el diseño experimental. El Capítulo 5 (Validación de la Solución) presenta los resultados obtenidos y su comparación con los modelos *baseline*. Finalmente, el Capítulo 6 (Conclusiones) discute los hallazgos y propone líneas de trabajo futuro.

CAPÍTULO 1

DEFINICIÓN DEL PROBLEMA

Santiago posee uno de los sistemas de transporte público más masivos y avanzados de América Latina, caracterizado por la integración de buses, metro y tren suburbano. Según registros operativos oficiales, el sistema integrado supera las siete millones de transacciones en un día laboral promedio, de las cuales 5,0 millones corresponden exclusivamente a la red de buses [Directorio de Transporte Público Metropolitano (DTPM), 2025]. La red de movilidad de la ciudad conecta a una población metropolitana que supera los siete millones de habitantes, distribuida en más de cuarenta comunas.

Comprender la distribución espacial de los desplazamientos en esta red, representada mediante flujos origen-destino (OD), es un insumo esencial para la planificación del transporte. También lo es para el diseño de infraestructura vial y la formulación de políticas urbanas basadas en evidencia [Rong *et al.*, 2024].

1.1. Fuentes de datos actuales y sus limitaciones

La planificación del transporte en Santiago se apoya actualmente en dos fuentes principales de datos de movilidad. La primera es la *Encuesta Origen-Destino* (EOD) de SECTRA¹. Su última versión fue levantada en 2012, con actualizaciones parciales en 2017. Esta encuesta constituye la referencia canónica de flujos de movilidad en la ciudad. Sin embargo, su periodicidad de siete a diez años implica que los datos disponibles pueden no reflejar la movilidad actual. Esto es especialmente relevante tras la reconfiguración de patrones de desplazamiento producida por la pandemia de COVID-19. Su elevado costo de levantamiento agrava además esta desactualización.

La segunda fuente son los datos anonimizados de validación de la *tarjeta bip!*², administrados por el DTPM³. Estos datos registran validaciones en Metro y buses con alta resolución temporal. No obstante, no cubren etapas caminadas. Tampoco cubren viajes en taxi o colectivo pagados en efectivo, ni modos no motorizados.

Esta brecha entre la necesidad de datos actualizados y su disponibilidad real motiva el desarrollo de modelos generativos. Dichos modelos deben ser capaces de estimar flujos OD a partir de características observables del territorio, sin depender exclusivamente de encuestas o registros transaccionales.

¹Secretaría de Planificación del Transporte, organismo dependiente del Ministerio de Transportes y Telecomunicaciones de Chile.

²Nombre oficial del sistema de tarificación electrónica del transporte público de Santiago.

³Directorio de Transporte Público Metropolitano.

1.2. Limitaciones de los modelos vigentes

Los modelos utilizados en la práctica para la estimación de flujos en Santiago corresponden a modelos de gravedad clásicos. Estos modelos presentan limitaciones ampliamente documentadas en la literatura [Simini *et al.*, 2012, Rong *et al.*, 2024]. Imponen relaciones paramétricas monótonas entre población, distancia y flujo, lo que genera un ajuste deficiente ante fenómenos no lineales, como la existencia de subcentros de empleo o corredores de transporte masivo. Requieren además calibración manual para cada contexto geográfico, lo que limita su transferibilidad. Finalmente, no incorporan como variables explicativas el tejido urbano: puntos de interés, uso de suelo ni infraestructura de transporte.

Modelos basados en aprendizaje profundo, como Deep Gravity [Simini *et al.*, 2021], han demostrado superar estas limitaciones incorporando variables geoespaciales de OpenStreetMap. Su arquitectura y su desempeño reportado se detallan en el Marco Conceptual de esta memoria. Sin embargo, su aplicación en ciudades latinoamericanas no ha sido explorada.

1.3. Especificidad del contexto latinoamericano

Esta ausencia de validación es relevante porque las ciudades latinoamericanas presentan características estructurales que las diferencian de los contextos donde estos modelos han sido desarrollados y evaluados. La segregación socio-espacial severa, la existencia de periferias urbanas de bajos ingresos con infraestructura de transporte deficitaria y la coexistencia de sistemas formales e informales de movilidad generan patrones de desplazamiento que no responden a las funciones de disuasión por distancia calibradas en ciudades del Norte Global [Vecchio *et al.*, 2020]. A esto se suma la heterogeneidad en la complejidad de los datos geoespaciales abiertos: estudios recientes demuestran que la cobertura de OpenStreetMap en ciudades latinoamericanas alcanza apenas un 10 a 20 % en datos de edificaciones, frente a más del 50 % en Europa y Norteamérica, con un sesgo intra-ciudad correlacionado con el nivel de desarrollo humano subnacional [Herfort *et al.*, 2023, Barrington-Leigh y Millard-Ball, 2017].

En el caso específico de Santiago, evidencia empírica reciente basada en datos de telefonía móvil y enrutamiento multimodal demuestra que la proximidad espacial no se traduce en accesibilidad equitativa [Marín-Flores *et al.*, 2026]. Las poblaciones periféricas de menores ingresos enfrentan penalizaciones estructurales de accesibilidad y un conjunto restringido de opciones de destino, lo que implica que modelos que asumen un comportamiento uniforme de proximidad-a-oportunidad generarán predicciones sesgadas en este contexto. Esta dinámica contrasta con las ciudades europeas y norteamericanas donde *Deep Gravity* fue validado, donde la distribución de oportunidades urbanas es comparativamente más homogénea.

Más allá del contexto geográfico, el modelo carece de una capa de explicabilidad que permita

a los planificadores comprender qué factores del tejido urbano impulsan cada predicción. Esta carencia es especialmente crítica en el contexto latinoamericano, donde la auditoría de las predicciones es un requisito para fundamentar inversiones públicas en un escenario de recursos limitados.

1.4. Síntesis del problema

En síntesis, el problema que aborda esta memoria se formula de la siguiente manera:

La planificación del transporte en Santiago de Chile opera con estimaciones de flujos OD basadas en datos desactualizados y modelos paramétricos que no capturan la complejidad del tejido urbano. Modelos basados en aprendizaje profundo, como Deep Gravity, han demostrado superar estas limitaciones, pero su aplicación en ciudades latinoamericanas no ha sido explorada. Se desconoce tanto su capacidad predictiva en este contexto como la contribución de las amenities urbanas a la generación de flujos. Asimismo, la ausencia de técnicas de explicabilidad sobre estos modelos impide que los planificadores comprendan los factores que determinan las predicciones.

1.5. Árbol del problema

A continuación se presenta el diagrama del árbol del problema (Figura 1):




Figura 1: Diagrama del árbol del problema. Fuente: Elaboración propia.

La Figura 1 presenta el árbol del problema que resume los principales desafíos asociados a la estimación de movilidad en el Gran Santiago. En el centro se sitúa el problema fundamental: la inexactitud y obsolescencia en la estimación de flujos de movilidad urbana.

Este problema se origina por cuatro causas principales: la desactualización y cobertura incompleta de fuentes de datos tradicionales (EOD y bip!), la rigidez de los modelos gravitacionales clásicos al omitir variables del tejido urbano, los supuestos teóricos simplistas basados únicamente en distancia y masa poblacional, y la falta de validación y explicabilidad de modelos de Deep Learning en el contexto regional.

Como consecuencia, se generan cuatro efectos críticos: decisiones de inversión en infraestructura basadas en datos obsoletos, la incapacidad de anticipar el impacto de intervenciones territoriales, la opacidad en la decisión pública junto a la subutilización de datos masivos y abiertos, y una asignación ineficiente de recursos públicos con políticas desalineadas de la dinámica urbana real.

1.6. Objetivo General

Generar flujos de movilidad origen-destino en Santiago de Chile mediante el modelo Deep Gravity, evaluando el impacto de las *amenities* de OpenStreetMap sobre la precisión de las predicciones y analizando la contribución de las variables geoespaciales mediante técnicas de Inteligencia Artificial Explicable (XAI).

1.7. Objetivos Específicos

1. Reproducir y adaptar el modelo Deep Gravity sobre el dataset de referencia del repositorio original, validando el pipeline y las métricas reportadas, para garantizar la trazabilidad y reproducibilidad del proceso.
2. Caracterizar el dataset de viajes y etapas de noviembre de 2024 del DTPM y diseñar la estrategia de unidades espaciales para el Gran Santiago mediante un esquema de doble modelo comparativo: el **Modelo 1** (control) utiliza la teselación zonal DTPM de polígonos irregulares (743 zonas operativas), replicando el enfoque de trabajos previos; el **Modelo 2** (propuesto) utiliza una grilla hexagonal regular *Uber H3* evaluando las resoluciones **3 a 8**, con asignación directa de validaciones a celdas mediante coordenadas UTM.
3. Extraer las *amenities* de OpenStreetMap para el área de estudio, utilizando el conjunto de categorías del paper original y evaluando la pertinencia de un conjunto extendido adaptado a las características del tejido urbano latinoamericano.
4. Entrenar y evaluar el modelo Deep Gravity sobre Santiago, comparando cuantitativamente su desempeño con el de los modelos de gravedad clásico y de radiación mediante la métrica CPC (*Common Part of Commuters*) y su descomposición espacial por *tile*.
5. Cuantificar el impacto de las *amenities* de OSM sobre el desempeño del modelo mediante la técnica SHAP (*SHapley Additive exPlanations*), determinando la importancia global y local de cada categoría de *amenity* en la generación de flujos.
6. Analizar la sensibilidad de las explicaciones obtenidas (valores SHAP) frente a la escala de agregación espacial de la grilla y a las distintas temporalidades del flujo, discutiendo la coherencia de las *amenities* identificadas con las dinámicas socioespaciales de Santiago.

CAPÍTULO 2

MARCO CONCEPTUAL

Este capítulo presenta los fundamentos teóricos y técnicos en que se apoya esta memoria. Se introducen, en primer lugar, los conceptos centrales de movilidad urbana y flujos origen-destino. Luego se describen los modelos clásicos de generación de flujos, que constituyen la base histórica del problema y los *baselines* de esta investigación. A continuación se expone cómo el aprendizaje profundo ha permitido superar las limitaciones de esos modelos, culminando en la arquitectura *Deep Gravity*. El capítulo continúa con los fundamentos de la explicabilidad de modelos de inteligencia artificial mediante SHAP, la descripción de OpenStreetMap como fuente de datos geospaciales, y concluye con el contexto de la movilidad en Santiago de Chile.

2.1. Movilidad urbana y flujos origen-destino

La movilidad urbana comprende el conjunto de desplazamientos que realizan las personas entre distintas ubicaciones de la ciudad en un período de tiempo determinado [Rong *et al.*, 2024]. Comprender estos desplazamientos es un insumo fundamental para la planificación del transporte, el diseño de infraestructura vial y la formulación de políticas públicas basadas en evidencia.

Una representación sintética y cuantitativa de la movilidad urbana es la matriz origen-destino (matriz OD). Formalmente, dado un conjunto de n zonas geográficas $\mathcal{Z} = \{z_1, z_2, \dots, z_n\}$ que particionan el área de estudio, el flujo T_{ij} representa el número de viajes que se realizan desde la zona de origen z_i hasta la zona de destino z_j en un intervalo de tiempo fijo:

$$\mathbf{T} \in \mathbb{R}^{n \times n}, \quad T_{ij} \geq 0 \quad \forall i, j \in \{1, \dots, n\} \quad (1)$$

La colección de todos los flujos posibles entre pares de zonas conforma la matriz OD. Cada fila i representa los flujos salientes desde una zona de origen, y cada columna j los flujos entrantes hacia una zona de destino.

Obtener la matriz OD mediante observación directa, a través de encuestas domiciliarias, aforos de tráfico o registros de tarjetas de pago, es costoso y poco frecuente. Esta limitación ha motivado el desarrollo de modelos generativos de flujos, capaces de estimar $\mathbf{T}$ a partir de características observables del territorio, como la distribución de la población o la presencia de equipamientos urbanos, sin depender exclusivamente de mediciones directas [Simini *et al.*, 2021].

El problema de generación de flujos se formula de la siguiente manera: dado un conjunto de zonas $\mathcal{Z}$, sus características geospaciales y los flujos totales salientes por zona $O_i = \sum_j T_{ij}$, estimar los flujos por par origen-destino $\hat{T}_{ij}$ para todos los pares (i, j) .

2.2. Modelos clásicos de generación de flujos

La estimación de flujos origen-destino cuenta con una tradición extensa en la geografía cuantitativa. Los modelos que se describen a continuación han dominado históricamente esta área y constituyen los *baselines* de referencia en esta memoria.

2.2.1. Modelo gravitatorio

El modelo gravitatorio de movilidad establece una analogía con la ley de gravitación universal de Newton. La aplicación de este principio a los fenómenos sociales cuenta con antecedentes desde el siglo XIX. Posteriormente, Zipf [Zipf, 1946] lo formalizó en 1946 para la predicción de flujos. Su formulación postula que el volumen de desplazamientos entre dos zonas es directamente proporcional al producto de sus masas (habitualmente la población) e inversamente proporcional a la distancia que las separa:

$$T_{ij} = k \cdot \frac{P_i^\alpha \cdot P_j^\beta}{d_{ij}^\gamma} \quad (2)$$

donde P_i y P_j son las poblaciones de las zonas de origen y destino, d_{ij} es la distancia entre sus centroides, k es una constante de proporcionalidad, y α, β, γ son parámetros que deben calibrarse con datos observados. Zipf verificó empíricamente esta relación mediante datos de tráfico de buses, ferrocarriles y llamadas telefónicas entre ciudades de Estados Unidos. Los coeficientes obtenidos se aproximan a la unidad en todos los casos.

La formulación de la ecuación (2) recibe el nombre de *modelo de gravedad no restringido*. En la práctica, para garantizar que los flujos generados sean consistentes con los totales salientes observados, se utiliza la versión *restringida en origen* (*singly-constrained*), que normaliza los flujos de cada origen sobre todos sus destinos posibles:

$$\hat{T}_{ij} = O_i \cdot \frac{P_j^\beta f(d_{ij})}{\sum_k P_k^\beta f(d_{ik})} \quad (3)$$

donde $O_i = \sum_j T_{ij}$ es el flujo total saliente de la zona i y $f(d_{ij})$ es una función de disuasión por distancia, que puede adoptar forma exponencial ($e^{\beta_2 d}$) o de ley de potencia (d^{β_2})⁴.

El modelo gravitatorio presenta limitaciones ampliamente documentadas [Rong et al., 2024]. Su formulación impone una relación paramétrica monótona entre población, distancia y flujo, lo que restringe su capacidad de representar fenómenos no lineales. No incorpora variables del tejido urbano como puntos de interés, uso de suelo

⁴Existe también la versión *doblemente restringida* (*doubly-constrained*), que impone conservación tanto de los flujos salientes O_i como de los flujos entrantes $D_j = \sum_i T_{ij}$. *Deep Gravity* utiliza exclusivamente la versión restringida en origen.

o infraestructura de transporte. Requiere además calibración manual para cada contexto geográfico, lo que limita su transferibilidad. La implicancia concreta de estas restricciones para el caso de Santiago se detalla en la Sección de Definición del Problema de esta memoria.

2.2.2. Modelo de oportunidades intervinientes

Stouffer [Stouffer, 1940] propuso en 1940 una perspectiva alternativa al modelo gravitatorio, argumentando que la distancia no es en sí misma el factor determinante de la movilidad, sino que actúa como un contenedor espacial de oportunidades. Su hipótesis central es que el número de personas que se desplazan a una zona de destino es directamente proporcional al número de oportunidades en ese destino e inversamente proporcional al número de oportunidades intervinientes entre el origen y el destino.

Formalmente, sea y el número de personas que se desplazan desde un origen hasta una banda circular de anchura Δs , y sea x el número acumulado de oportunidades entre el origen y la distancia s . Stouffer postula:

$$\Delta y = a \cdot \frac{\Delta x}{x} \quad (4)$$

Integrando esta expresión diferencial, el número total de personas que se detienen dentro de un círculo de radio s desde el origen es:

$$y = a \cdot \ln f(s) + c \quad (5)$$

donde $f(s)$ es el número acumulado de oportunidades dentro de ese radio y c es una constante de integración. Stouffer verificó empíricamente esta formulación con datos de movilidad residencial en Cleveland, Ohio (1933-1935). Los resultados muestran una buena correspondencia entre los flujos observados y los predichos por el modelo.

Liu y Yan [Liu y Yan, 2020] formalizaron y extendieron esta familia de modelos de manera rigurosa. Para describir su funcionamiento, es necesario precisar tres conceptos fundamentales:

- **Oportunidades de un lugar (m_l):** cantidad de oportunidades que ofrece el lugar l para satisfacer el propósito del desplazamiento. En la práctica se asume que m_l es proporcional a la población del lugar.
- **Oportunidades intervinientes (s_{ij}):** suma de oportunidades de todos los lugares cuya distancia al origen i es menor que d_{ij} , excluyendo el propio origen i y el destino j . Si se incluyen origen y destino se utiliza la notación $S_{ij} = m_i + s_{ij} + m_j$.
- **Valor de beneficio de una oportunidad (z):** utilidad o recompensa que una oportunidad reporta al viajero. Se modela como variable aleatoria continua con distribución $p(z)$.

El modelo de Stouffer establece que cada individuo que parte del origen i ordena todos los destinos potenciales por distancia creciente y se detiene en cada lugar con una probabilidad fija proporcional al parámetro α . Bajo este mecanismo, la probabilidad de que un individuo en i elija el destino j adopta la forma [Stouffer, 1940, Liu y Yan, 2020]:

$$P_{ij} = \frac{e^{-\alpha(S_{ij}-m_j)} - e^{-\alpha S_{ij}}}{1 - e^{-\alpha M}} \quad (6)$$

donde m_j es la cantidad de oportunidades del destino j , S_{ij} es el total de oportunidades en el círculo de radio d_{ij} centrado en i (incluyendo origen y destino), α es el parámetro de absorción a calibrar con datos históricos, y $M = \sum_k m_k$ es el total de oportunidades del sistema. La ecuación (6) muestra que la probabilidad de elegir j crece con las oportunidades del destino m_j y decrece con el número de oportunidades intervinientes s_{ij} : cuanto mayor es la competencia en el camino, menor la probabilidad de alcanzar el destino.

La principal limitación del modelo original de Stouffer es que contiene el parámetro α , que debe calibrarse mediante datos históricos de flujo observado. Esta dependencia paramétrica restringe su aplicabilidad cuando no se dispone de matrices OD previas, y motivó el desarrollo de modelos libres de parámetros basados en el mismo concepto de oportunidades intervinientes.

2.2.3. Modelo de radiación

Simini et al. [Simini et al., 2012] propusieron en 2012 el modelo de radiación como una alternativa libre de parámetros al modelo gravitatorio. El modelo establece una analogía con los procesos de radiación y absorción en física de partículas. Su mecanismo se basa en un proceso estocástico de toma de decisiones locales: cada individuo en un origen busca la mejor oportunidad disponible dentro de radios geográficos crecientes y se desplaza hacia el destino donde la encuentra.

El mecanismo es el siguiente. Se asigna a cada oportunidad un valor de beneficio z extraído de una distribución de probabilidad $p(z)$. La probabilidad de que un individuo en la zona i elija la zona j como destino es la probabilidad de que el mejor beneficio dentro de j supere al mejor beneficio disponible dentro del círculo de radio d_{ij} centrado en i (excluyendo i y j). Esta probabilidad es:

$$p(n_j | m_i, s_{ij}) = \frac{m_i n_j}{(m_i + s_{ij})(m_i + n_j + s_{ij})} \quad (7)$$

donde m_i es la población de la zona de origen i , n_j es la población de la zona de destino j , y s_{ij} es la población total dentro de un círculo de radio d_{ij} centrado en i , excluyendo las poblaciones de i y de j . El flujo esperado entre i y j es entonces:

$$\langle T_{ij} \rangle = T_i \cdot \frac{m_i n_j}{(m_i + s_{ij})(m_i + n_j + s_{ij})} \quad (8)$$

donde $T_i = \sum_j T_{ij}$ es el flujo total saliente de la zona i . Una propiedad destacable del modelo de radiación es que satisface automáticamente la restricción de conservación de flujos: $\sum_j \langle T_{ij} \rangle = T_i$, sin necesidad de calibración de parámetros adicionales.

Simini et al. [Simini et al., 2012] validaron el modelo sobre datos de commuting del censo de Estados Unidos (2000). Los resultados muestran que el modelo de radiación supera al modelo gravitatorio en la reproducción de flujos observados, especialmente en viajes de corta distancia, que el modelo gravitatorio tiende a sobreestimar.

Variantes del modelo de radiación. La solidez del modelo original motivó diversas extensiones para adaptar su mecanismo a diferentes contextos. Ren et al. [Ren et al., 2014] propusieron una versión basada en tiempo de viaje en lugar de distancia euclidiana, incorporando así la resistencia real de la red de transporte. Kang et al. [Kang et al., 2015] formularon un modelo de radiación generalizado que introduce parámetros de escala y restricciones explícitas de producción y atracción, mejorando la precisión en contextos con heterogeneidad espacial marcada. Yang et al. [Yang et al., 2014] extendieron el modelo para incorporar la distribución no homogénea de oportunidades en el espacio, relevante en regiones con alta segregación funcional del suelo.

Limitación del modelo de radiación a escala intraurbana. A pesar de su éxito en la predicción de commuting interurbano, el modelo de radiación presenta una limitación estructural cuando se aplica a la escala intraurbana [Yan et al., 2014, Liu y Yan, 2020]. Su supuesto central, que cada individuo elige el destino más cercano cuyo beneficio supera al del origen, refleja adecuadamente el comportamiento en la búsqueda de empleo a larga distancia (donde la proximidad es costosa), pero no captura la lógica real de los desplazamientos dentro de una ciudad. En entornos urbanos, las personas consideran simultáneamente el conjunto de destinos disponibles en toda la ciudad, sin restringirse a los más cercanos. Estudios empíricos sobre datos de transporte público en diversas ciudades confirman que el modelo de radiación subestima sistemáticamente los flujos intraurbanos de largo alcance [Yan et al., 2014]. Adicionalmente, el modelo utiliza exclusivamente la población como *proxy*⁵ de oportunidades, sin incorporar características del tejido urbano como el uso de suelo o la distribución de actividades económicas. Estas limitaciones fueron el punto de partida para el desarrollo del modelo de oportunidades ponderadas por población, descrito en la Sección 3.3, y justifican el uso de modelos basados en aprendizaje profundo capaces de representar el tejido urbano más allá de la simple distribución poblacional, como *Deep Gravity*.

⁵Una variable proxy es una medida indirecta que se emplea en sustitución de una variable inobservable, asumiendo que existe una fuerte correlación estadística entre ambas.

2.3. Aprendizaje profundo aplicado a la movilidad

El aprendizaje profundo (*deep learning*) es un subcampo del aprendizaje automático que utiliza redes neuronales con múltiples capas de transformaciones no lineales para aprender representaciones jerárquicas de los datos [Rong *et al.*, 2024]. Su aplicación a la predicción de flujos de movilidad ha permitido incorporar un conjunto amplio de variables geoespaciales y capturar relaciones no lineales que los modelos clásicos no pueden representar.

Una red neuronal *feedforward* (de propagación hacia adelante) con L capas ocultas transforma un vector de entrada $\mathbf{x} \in \mathbb{R}^d$ mediante una secuencia de transformaciones afines seguidas de funciones de activación no lineales:

$$\mathbf{z}^{(0)} = \sigma(W^{(0)} \mathbf{x}), \quad \mathbf{z}^{(\ell)} = \sigma(W^{(\ell)} \mathbf{z}^{(\ell-1)}), \quad \ell = 1, \dots, L-1 \quad (9)$$

donde $W^{(\ell)}$ es la matriz de pesos de la capa ℓ y $\sigma(\cdot)$ es la función de activación, comúnmente ReLU ($\max(0, x)$) o su variante LeakyReLU ($\max(\alpha x, x)$ con α pequeño), que mitiga el problema del gradiente desvanecido en redes profundas.

En el contexto de la generación de flujos, el aprendizaje profundo ha sido aplicado de múltiples formas: como extensión no lineal del modelo gravitatorio [Simini *et al.*, 2021], mediante redes neuronales de grafos que modelan la estructura espacial de las zonas, y mediante modelos de series de tiempo que capturan la evolución temporal de los flujos [Luca *et al.*, 2024]. Esta memoria se enfoca en el primero de estos enfoques, implementado a través del modelo *Deep Gravity*.

2.4. Deep Gravity

Deep Gravity es un modelo de generación de flujos de movilidad propuesto por Simini *et al.* [Simini *et al.*, 2021] en 2021. Su contribución central es demostrar que el modelo gravitatorio clásico restringido en origen (ecuación 3) es formalmente equivalente a una red neuronal lineal de una sola capa con salida *softmax*, y que reemplazar esa capa lineal por una red neuronal profunda permite capturar relaciones no lineales entre las características del territorio y los flujos observados.

2.4.1. Formulación matemática

El modelo gravitatorio restringido en origen puede reescribirse como un modelo lineal generalizado con distribución multinomial. Para un origen i , la probabilidad de que un viaje se dirija al destino j es:

$$p_{ij} = \frac{\exp(\beta^\top \mathbf{x}(l_i, l_j))}{\sum_k \exp(\beta^\top \mathbf{x}(l_i, l_k))} \quad (10)$$

donde $\mathbf{x}(l_i, l_j) = [\ln P_j, d_{ij}]$ es el vector de características del par (i, j) , y $\beta = [\beta_1, \beta_2]$ son los parámetros del modelo. Esta formulación es entrenada maximizando la log-verosimilitud multinomial, cuya función de pérdida es equivalente a la entropía cruzada:

$$H = - \sum_i \sum_j \frac{T_{ij}}{O_i} \ln p_{ij} \quad (11)$$

Deep Gravity reemplaza el producto interno lineal $\beta^\top \mathbf{x}(l_i, l_j)$ por una red neuronal profunda $f_\theta(\mathbf{x}(l_i, l_j))$ que produce un score escalar. Las probabilidades de destino se obtienen mediante *softmax* sobre los scores de todos los destinos candidatos desde el origen i :

$$p_{ij} = \frac{\exp(f_\theta(\mathbf{x}(l_i, l_j)))}{\sum_k \exp(f_\theta(\mathbf{x}(l_i, l_k)))} \quad (12)$$

El flujo estimado desde i hacia j es entonces $\hat{T}_{ij} = O_i \cdot p_{ij}$.

2.4.2. Arquitectura de la red neuronal

La función f_θ es implementada como una red neuronal *feedforward* de 15 capas ocultas con activación LeakyReLU. Las primeras 6 capas tienen dimensión 256 y las 9 restantes dimensión 128. La capa de salida produce un escalar:

$$\begin{aligned} \mathbf{z}^{(0)} &= \text{LeakyReLU}(W^{(0)} \mathbf{x}(l_i, l_j)) \\ \mathbf{z}^{(\ell)} &= \text{LeakyReLU}(W^{(\ell)} \mathbf{z}^{(\ell-1)}), \quad \ell = 1, \dots, 14 \\ f_\theta(\mathbf{x}(l_i, l_j)) &= \mathbf{w}^\top \mathbf{z}^{(14)} \end{aligned} \quad (13)$$

El modelo se entrena con el optimizador RMSprop (momentum = 0,9; tasa de aprendizaje = 5×10^{-6}), con *batches* de 64 zonas de origen. Para cada origen, se aplica *negative sampling*: se seleccionan hasta 512 destinos candidatos por origen, combinando destinos con flujos observados y destinos aleatorios sin flujos observados, lo que hace computacionalmente tratable la normalización del *softmax* sobre todas las zonas.

2.4.3. Vector de características geoespaciales

El vector de entrada $\mathbf{x}(l_i, l_j) \in \mathbb{R}^{39}$ concatena las características del origen, el destino y la distancia entre ellos:

$$\mathbf{x}(l_i, l_j) = [\mathbf{f}(l_i), \mathbf{f}(l_j), \ln P_i, \ln P_j, d_{ij}] \quad (14)$$

donde $\mathbf{f}(l) \in \mathbb{R}^{18}$ es el vector de 18 características geoespaciales extraídas de OpenStreetMap para la zona l , P_i y P_j son las poblaciones de origen y destino, y d_{ij} es la distancia geodésica entre sus centroides (en kilómetros). Las 18 características se organizan en 7 categorías:

uso del suelo (5 features), red vial (3 features), instalaciones de transporte (2 features), alimentación (2 features), salud (2 features), educación (2 features) y comercio (2 features). Todas ellas se normalizan dividiendo por el área de la zona, expresando su valor por kilómetro cuadrado.

2.4.4. Resultados y desempeño

Simini et al. [Simini *et al.*, 2021] evaluaron *Deep Gravity* sobre datos de commuting de Inglaterra, Italia y el estado de Nueva York, utilizando la métrica *Common Part of Commuters* (CPC), definida como:

$$\text{CPC}(\hat{\mathbf{T}}, \mathbf{T}) = \frac{2 \sum_{i,j} \min(\hat{T}_{ij}, T_{ij})}{\sum_{i,j} \hat{T}_{ij} + \sum_{i,j} T_{ij}} \quad (15)$$

La métrica CPC toma valores en $[0, 1]$, donde 1 indica coincidencia exacta entre flujos generados y reales. Es equivalente al índice de Sørensen-Dice aplicado a flujos. Los resultados muestran que *Deep Gravity* supera al modelo gravitatorio clásico en todos los contextos evaluados. Las mejoras en CPC global alcanzan hasta un 190 % en Inglaterra y un 1.066 % en el estado de Nueva York. El modelo también demostró transferibilidad geográfica. Entrenado en algunas ciudades del Reino Unido, mantiene un desempeño similar al evaluarse en ciudades no vistas durante el entrenamiento.

2.4.5. Síntesis comparativa de modelos

La Tabla 1 compara los modelos de generación de flujos presentados en este capítulo en cinco dimensiones clave para esta memoria: incorporación de variables del tejido urbano, ausencia de calibración paramétrica, aptitud para la escala intraurbana, compatibilidad con técnicas de explicabilidad (XAI), y existencia de validación empírica en el contexto latinoamericano.

Tabla 1: Comparación de modelos de generación de flujos de movilidad. Fuente: Elaboración propia.

Modelo	Variables urbanas	Libre de parámetros	Escala intraurbana	Explicable (XAI)	Validado en LatAm
Gravitatorio	No	No	<i>Parc.</i>	No	<i>Parc.</i>
IO Model	No	No	<i>Parc.</i>	No	No
Radiación	No	Sí	No	No	No
Mod. avanz. IO	No	Sí	Sí	No	No
Deep Gravity	Sí	No	Sí	Sí	No

Deep Gravity es el único modelo que combina simultáneamente las tres capacidades centrales para esta investigación: incorpora variables geoespaciales del tejido urbano provenientes de OSM, es apto para la escala intraurbana, y admite análisis de explicabilidad mediante SHAP e Integrated Gradients. La ausencia de validación en el contexto latinoamericano constituye precisamente la brecha que esta memoria busca cubrir para el caso del Gran Santiago de Chile.

2.5. Explicabilidad en modelos de inteligencia artificial (XAI)

La explicabilidad de la inteligencia artificial (*eXplainable Artificial Intelligence*, XAI) se refiere al conjunto de técnicas que permiten comprender e interpretar las predicciones de modelos de aprendizaje automático complejos [Lundberg y Lee, 2017]. En el contexto de la planificación del transporte, la explicabilidad es relevante no solo desde el punto de vista académico, para entender qué variables del territorio impulsan los flujos, sino también desde el punto de vista institucional, ya que permite a los planificadores auditar las predicciones del modelo.

2.5.1. Valores SHAP

SHAP (*SHapley Additive exPlanations*), propuesto por Lundberg y Lee [Lundberg y Lee, 2017], es un método de explicabilidad que fundamenta la importancia de cada variable en la teoría de juegos cooperativos de Shapley. La contribución de la característica i a la predicción del modelo para una instancia $\mathbf{x}$ se define como:

$$\phi_i(f, \mathbf{x}) = \sum_{S \subseteq \mathcal{F} \setminus \{i\}} \frac{|S|! (|\mathcal{F}| - |S| - 1)!}{|\mathcal{F}|!} [f(S \cup \{i\}) - f(S)] \quad (16)$$

donde $\mathcal{F}$ es el conjunto de todas las características, S es una coalición de características que no incluye a i , y $f(S)$ es la predicción del modelo usando solo las características en S . El valor ϕ_i representa la contribución marginal promedio de la característica i sobre todas las posibles coaliciones de características.

Los valores SHAP satisfacen tres propiedades deseables: *eficiencia* (la suma de todos los valores SHAP es igual a la diferencia entre la predicción y el valor base), *simetría* (características con igual contribución marginal reciben igual valor SHAP) y *dummy* (características sin influencia reciben valor cero). En conjunto, estas propiedades garantizan una atribución justa y consistente de importancias.

En esta memoria se utilizan los valores SHAP para cuantificar el impacto de cada categoría de *amenity* de OpenStreetMap sobre la predicción de flujos del modelo *Deep Gravity*. El análisis SHAP permite determinar qué tipos de equipamiento urbano, como educación, salud, comercio y transporte, entre otros, son los más determinantes en la generación de flujos para el contexto de Santiago de Chile.

2.5.2. Gradientes integrados

Los *Integrated Gradients* [Sundararajan et al., 2017] son un método de atribución basado en el gradiente de la función del modelo con respecto a las variables de entrada. A diferencia de SHAP, que se fundamenta en la teoría de juegos cooperativos, los *Integrated Gradients* derivan las atribuciones directamente de la estructura diferencial de la red neuronal. Para una predicción $f(\mathbf{x})$ y una entrada de referencia $\mathbf{x}'$, la atribución de la característica i se define como:

$$IG_i(\mathbf{x}) = (x_i - x'_i) \cdot \int_0^1 \frac{\partial f(\mathbf{x}' + \alpha(\mathbf{x} - \mathbf{x}'))}{\partial x_i} d\alpha \quad (17)$$

El método satisface dos propiedades axiomáticas que lo distinguen de otras técnicas de atribución: *sensibilidad* (si la entrada y la referencia difieren en una sola característica y producen predicciones distintas, esa característica recibe atribución no nula) e *invariancia a la implementación* (la atribución depende únicamente de la función matemática que computa la red, no de su arquitectura interna). Estas propiedades lo hacen complementario a SHAP, que satisface eficiencia, simetría y dummy.

La elección de la entrada de referencia $\mathbf{x}'$ es un aspecto crítico del método. El vector nulo ($\mathbf{x}' = \mathbf{0}$) es una convención habitual en clasificación de imágenes, pero puede no ser representativo para variables de densidad urbana, que por definición nunca son cero en zonas habitadas. En esta memoria se evalúa el uso del vector promedio de la distribución de características como referencia alternativa, lo que permite interpretar las atribuciones como desviaciones respecto al comportamiento medio del territorio.

Los *Integrated Gradients* se utilizan como técnica complementaria a SHAP para obtener atribuciones a nivel de par origen-destino específico, permitiendo identificar qué características son más relevantes para flujos particulares.

2.6. OpenStreetMap como fuente de datos geospaciales

OpenStreetMap (OSM) es una base de datos geoespacial colaborativa y de libre acceso, construida y mantenida por una comunidad global de voluntarios desde su creación en 2004 [Haklay y Weber, 2008]. Su modelo de datos se articula en tres tipos de objetos geométricos: *nodos* (puntos), *vías* (secuencias de nodos que representan líneas o polígonos) y *relaciones* (agrupaciones de nodos y vías con un significado semántico compartido). Cada objeto puede llevar asociados pares clave-valor denominados *etiquetas* (*tags*), que codifican su naturaleza (por ejemplo, *amenity=hospital* o *landuse=residential*).

Para el modelado de flujos de movilidad, OSM provee información sobre la distribución espacial de equipamientos y servicios urbanos, comúnmente denominados *amenities*, que el modelo *Deep Gravity* utiliza como variables explicativas. Estas incluyen establecimientos de salud, educación, comercio, alimentación, transporte, y áreas de uso de suelo residencial,

comercial e industrial, entre otras categorías.

Una limitación reconocida de OSM en el contexto latinoamericano es la heterogeneidad espacial de su cobertura. Estudios previos [Barrington-Leigh y Millard-Ball, 2017] han documentado que la densidad y completitud de los datos OSM varía significativamente según el nivel socioeconómico y la accesibilidad de las distintas áreas de una ciudad. En Santiago, esto se manifiesta en una mayor completitud en comunas de ingresos medios y altos, como Providencia, Las Condes y Vitacura, y menor cobertura en comunas periféricas de menores ingresos. Esta heterogeneidad es un factor metodológico relevante para esta memoria. Puede sesgar la estimación de las características geoespaciales de entrada al modelo en las zonas con menor presencia de datos voluntarios. Este aspecto se aborda en el análisis de resultados.

2.7. Contexto de la movilidad en Santiago de Chile

Santiago de Chile es la capital de la Región Metropolitana y alberga aproximadamente siete millones de habitantes, distribuidos en más de cuarenta comunas. Es una de las ciudades de América Latina con mayor complejidad en su sistema de transporte público, que integra buses (*Red Metropolitana de Movilidad*), Metro, tren suburbano (Metrotren Nos) y sistemas de transporte activo [DTPM, 2025].

Las limitaciones de las fuentes de datos de movilidad disponibles para Santiago (la EOD de SECTRA y los registros de validación de la tarjeta bip!) se detallan en la Sección 1.1 de esta memoria.

Esta memoria utiliza el dataset de viajes y etapas de noviembre de 2024 del DTPM, que comprende aproximadamente 3,6 millones de viajes en un mes completo, con información de zona de inicio, zona de fin, modo de transporte, hora, factor de expansión y coordenadas estimadas de subida y bajada. Este dataset, de mayor resolución temporal y amplitud que la EOD, permite construir matrices OD a escala diaria o por período horario (punta mañana, punta tarde, fuera de punta). Constituye la principal fuente de flujos observados para el entrenamiento y evaluación del modelo *Deep Gravity* en Santiago.

CAPÍTULO 3

TRABAJO RELACIONADO

El estudio de la movilidad humana y la predicción de flujos origen-destino (OD) ha experimentado una evolución metodológica fundamental en las últimas décadas. Este capítulo no busca enumerar exhaustivamente todas las investigaciones previas, sino trazar una línea evolutiva que contraste las fortalezas y debilidades de los distintos enfoques adoptados en la literatura científica. A través de este análisis se fundamentan las decisiones metodológicas que sustentan la presente memoria. Se demuestra por qué la integración de modelos de aprendizaje profundo con datos geospaciales abiertos constituye la alternativa más adecuada para el contexto actual.

3.1. Descubrimiento de patrones en la movilidad individual

Durante mucho tiempo, la falta de datos de trayectoria masivos obligó a los investigadores a extrapolar los patrones de movilidad humana a partir de la dispersión de billetes de banco [Brockmann *et al.*, 2006], asumiendo que los desplazamientos individuales seguían trayectorias puramente aleatorias y no acotadas, similares a los vuelos de Lévy (*Lévy flights*).

Este paradigma fue refutado por González *et al.* [González *et al.*, 2008], quienes utilizaron registros masivos de telefonía móvil (CDR, por sus siglas en inglés) de 100.000 usuarios durante seis meses para analizar la movilidad humana a nivel microscópico. Su trabajo demostró que, a diferencia del movimiento browniano o de los vuelos de Lévy, las trayectorias humanas son altamente predecibles, regulares y están fuertemente confinadas espacialmente. Los autores introdujeron el concepto de *radio de giro* para cuantificar la distancia típica recorrida por un individuo. Su análisis demostró que la aparente distribución pesada de saltos poblacionales es, en realidad, el resultado de agregar trayectorias individuales acotadas con una gran heterogeneidad en los radios de giro.

Esta contribución fue clave porque estableció que la movilidad urbana no es un fenómeno caótico, sino un sistema gobernado por rutinas (hogar-trabajo) y patrones espaciales predecibles. Esta previsibilidad estadística es la premisa fundamental que justifica el desarrollo de modelos matemáticos y algorítmicos para la predicción de flujos agregados.

3.2. Unificación de modelos clásicos y enfoques continuos

Con la confirmación de la regularidad en la movilidad humana, los esfuerzos se centraron en predecir los volúmenes de viaje entre distintas zonas de una ciudad o país. Tradicionalmente, este problema se abordó mediante el modelo gravitatorio [Zipf, 1946] y el mo-

delo de oportunidades intervinientes [Stouffer, 1940]. Más tarde, el modelo de radiación [Simini *et al.*, 2012] ofreció una solución libre de parámetros que superaba varias limitaciones empíricas de la formulación gravitatoria.

Sin embargo, estos modelos presentaban un problema matemático estructural: dependían fuertemente de la partición espacial utilizada (comunas, distritos, censos), lo que generaba inconsistencias espaciales. Además, salvo casos triviales, las formulaciones discretas como el modelo gravitatorio violaban la propiedad de *aditividad* (el flujo hacia una región compuesta no siempre equivalía a la suma de los flujos hacia sus subregiones).

Para resolver esto, Simini, Maritan y Néda [Simini *et al.*, 2013] propusieron un marco unificado en el continuo. Los autores formularon un principio estocástico general de selección de beneficios laborales que preserva estrictamente la aditividad de los flujos. Además, demostraron que la gravedad, las oportunidades intervinientes y la radiación son, matemáticamente, casos particulares de una misma familia de procesos de selección espacial continua. Asimismo, introdujeron un parámetro de selección (λ) que flexibilizó el modelo de radiación para adaptarlo a diferentes escalas geográficas.

A pesar de su solidez teórica y elegancia matemática, este paradigma continuo arrastra una limitación fundamental de representación: asume que la cantidad de oportunidades en una región es estrictamente proporcional a su masa poblacional. En la realidad urbana, existe una profunda segregación funcional del suelo (zonas industriales, distritos financieros, áreas puramente residenciales) que rompe esta proporcionalidad lineal, exigiendo modelos capaces de entender el tejido urbano más allá de la simple aglomeración de personas.

3.3. Evolución de los modelos de oportunidades intervinientes

El concepto de oportunidades intervinientes de Stouffer [Stouffer, 1940] inspiró, a lo largo de las décadas siguientes, una familia de modelos cada vez más sofisticados que buscaron superar las limitaciones paramétricas y escalares del modelo original. Liu y Yan [Liu y Yan, 2020] ofrecen una revisión sistemática de esta evolución, identificando una línea de progresión que va desde el modelo de radiación hasta un marco unificado de comportamiento de destino. Esta sección sigue esa trayectoria, enfatizando los modelos más relevantes para el contexto intraurbano de la presente memoria.

3.3.1. Modelo de oportunidades ponderadas por población

Yan *et al.* [Yan *et al.*, 2014] identificaron en sus experimentos que el modelo de radiación falla sistemáticamente al predecir flujos dentro de una ciudad: sobreestima los flujos de corto alcance y subestima los de largo alcance intraurbano. Los autores argumentaron que el supuesto de selección secuencial por proximidad no refleja la realidad del viajero urbano, quien

considera simultáneamente el conjunto completo de destinos disponibles en la ciudad.

Para corregir esto, Yan et al. [Yan et al., 2014] propusieron el *Modelo de Oportunidades Ponderadas por Población* (Population-Weighted Opportunity, PWO), en el que la probabilidad de elegir el destino j desde el origen i es proporcional a las oportunidades del destino e inversamente proporcional a las oportunidades totales dentro de un círculo centrado en el destino j con radio d_{ij} :

$$P_{ij} = \frac{m_j}{S_{ji}} \quad (18)$$

donde m_j es la cantidad de oportunidades (población) del destino j , y $S_{ji} = m_j + s_{ji} + m_i$ es el total de oportunidades dentro del círculo de radio d_{ij} centrado en j , incluyendo origen y destino. El cambio conceptual respecto al modelo de radiación es fundamental: en lugar de evaluar la competencia desde el origen, el modelo PWO evalúa la competencia desde el destino, capturando la lógica de atracción de un lugar sobre su entorno geográfico inmediato.

Al igual que el modelo de radiación, el modelo PWO es libre de parámetros: requiere únicamente la distribución de población de las zonas para generar predicciones, sin necesidad de calibración con datos históricos. Validado sobre datos de transporte público en múltiples ciudades chinas, el modelo PWO supera consistentemente al modelo de radiación en la predicción de viajes intraurbanos [Yan et al., 2014]. Yan et al. [Yan et al., 2017] extendieron posteriormente este modelo combinándolo con un proceso de caminata aleatoria con memoria, logrando reproducir simultáneamente los patrones de movilidad a nivel individual y los flujos agregados a nivel poblacional.

3.3.2. Modelos exploratorios: más allá de la selección secuencial

Tanto el modelo de radiación como el modelo PWO comparten un supuesto implícito sobre el comportamiento del viajero. Utilizando la terminología introducida retrospectivamente por Liu y Yan [Liu y Yan, 2020] para clasificar los mecanismos de selección de destino, el modelo de radiación asume una *tendencia cautelosa*: el individuo elige el destino más cercano que supera el beneficio del origen. El modelo PWO también incorpora una lógica de competencia local. En ambos casos, la distancia juega un papel restrictivo en la selección.

Investigaciones posteriores mostraron que este supuesto no aplica universalmente. En el ámbito de los procesos de evaluación y selección social, Sim et al. [Sim et al., 2015] identificaron un mecanismo alternativo al que denominaron *tendencia exploratoria*: los individuos que buscan el mejor resultado posible no se restringen a las opciones más cercanas, sino que aceptan recorrer distancias mayores si el destino ofrece un beneficio suficientemente alto. Liu y Yan [Liu y Yan, 2019] trasladaron formalmente este concepto al dominio de la movilidad espacial y propusieron el *Modelo de Selección Prioritaria de Oportunidades* (Opportunity Priority Selection), en el que un individuo en i elige el destino j si su beneficio supera tanto

al del origen como al de todas las oportunidades intervinientes:

$$P_{ij} = \frac{m_j}{S_{ij}} = \frac{m_j}{m_i + s_{ij} + m_j} \quad (19)$$

donde $S_{ij} = m_i + s_{ij} + m_j$ es el total de oportunidades en el círculo de radio d_{ij} centrado en el origen i . Este modelo, al igual que el PWO, es libre de parámetros y fue validado con buenos resultados tanto para viajes intraurbanos como interurbanos.

3.3.3. Modelo Unificado de Oportunidades

La existencia de modelos con supuestos comportamentales tan distintos, el cauteloso modelo de radiación y el exploratorio modelo de selección prioritaria, planteó una pregunta natural: ¿qué modelo aplicar en cada contexto? Liu y Yan [Liu y Yan, 2020] respondieron esta pregunta proponiendo el *Modelo Unificado de Oportunidades* (Universal Opportunity Model), un marco general con dos parámetros que engloba a los modelos anteriores como casos especiales. La probabilidad de que un individuo en i elija el destino j se formula como:

$$P_{ij} = \frac{(m_i + \alpha s_{ij}) m_j}{[m_i + (\alpha + \beta) s_{ij}] [m_i + (\alpha + \beta) s_{ij} + m_j]} \quad (20)$$

donde $\alpha \geq 0$ es el parámetro de *tendencia exploratoria* (cuán dispuesto está el individuo a alejarse buscando mayor beneficio) y $\beta \geq 0$ es el parámetro de *tendencia cautelosa* (preferencia por destinos cercanos), sujetos a $\alpha + \beta \leq 1$. Los modelos previos emergen como casos particulares de esta formulación:

- Si $\alpha = 0, \beta = 1$: la ecuación (20) se reduce a la ecuación (7) del modelo de radiación (comportamiento puramente cauteloso).
- Si $\alpha = 1, \beta = 0$: la ecuación (20) se reduce a la ecuación (19) del modelo de selección prioritaria (comportamiento puramente exploratorio).

Liu y Yan [Liu y Yan, 2020] validaron el modelo sobre 14 conjuntos de datos de movilidad a distintas escalas: carga de mercancías, commuting interurbano (EE.UU., Italia, Hungría), búsqueda de empleo, migración, viajes entre ciudades y viajes intraurbanos (Berlín, Londres, Beijing, Shenzhen, Suzhou). Sus resultados revelan un patrón sistemático: los flujos de commuting y carga exhiben alta tendencia cautelosa (los individuos priorizan destinos cercanos de alto beneficio), mientras que los desplazamientos intraurbanos presentan valores bajos de ambos parámetros, indicando que la masa poblacional por sí sola es insuficiente para capturar la complejidad de la elección de destino en la ciudad. Este hallazgo es particularmente relevante para la presente memoria: sugiere que las variables de oportunidad basadas en población deben complementarse con atributos del tejido urbano para modelar adecuadamente los flujos en Santiago de Chile.

Aplicaciones colaterales. Más allá de la movilidad de transporte, esta familia de modelos ha demostrado versatilidad en otros dominios. En el campo de la epidemiología, modelos como el de radiación y el PWO han sido utilizados para estimar probabilidades de contacto entre poblaciones y parametrizar la difusión espacial de enfermedades infecciosas, incluyendo estudios sobre la propagación de COVID-19 [Liu y Yan, 2020]. Esta amplitud de aplicación evidencia la robustez conceptual del marco de oportunidades intervinientes.

3.4. Deep Learning y modelos espacio-temporales en movilidad

Para superar las limitaciones lineales y la dependencia exclusiva de la densidad poblacional, la literatura reciente ha migrado hacia el aprendizaje automático (*Machine Learning*) y el aprendizaje profundo (*Deep Learning*) [Rong et al., 2024]. Las arquitecturas neuronales han demostrado una capacidad superior para capturar la no linealidad del entorno urbano.

Un avance significativo en esta línea es la incorporación explícita de Puntos de Interés (POIs) y características del entorno construido como variables condicionantes. Por ejemplo, Luca et al. [Luca et al., 2024] propusieron el *framework* TS-Mob, que combina modelos fundacionales de series de tiempo (*TimesFM*) con un módulo de atractividad gravitacional basado en perceptrones multicapa (MLP). Este modelo integra 16 categorías de POIs extraídas de bases de datos abiertas. Ello permite modular la probabilidad de atracción estructural de un destino en función de la oferta real de servicios comerciales, educativos o de salud, y no únicamente de su población. Es importante distinguir este enfoque del de *Deep Gravity*: mientras TS-Mob utiliza 16 categorías de POIs integradas en un módulo de atractividad temporal, *Deep Gravity* opera con 7 categorías agrupadas en 18 características del entorno construido (uso del suelo, red vial, transporte, alimentación, salud, educación y comercio), combinadas con la distancia geodésica y la población en un vector de entrada estático.

No obstante, la transición hacia arquitecturas profundas introdujo nuevos desafíos. Las redes neuronales profundas y espaciales requieren enormes volúmenes de datos para evitar el sobreajuste y, más críticamente, operan como *cajas negras* [Rong et al., 2024]. Estos modelos reducen drásticamente el error absoluto medio (MAE) y mejoran la similitud estructural de flujos (CPC) respecto a los modelos clásicos. Sin embargo, la incapacidad de explicar por qué el modelo predice un flujo determinado limita su adopción institucional. Este aspecto es crítico en la planificación urbana pública.

3.5. Generación de flujos mediante datos no convencionales

En el estado del arte más reciente (2024-2025), la investigación ha explorado métodos para mitigar la dependencia de datos socioeconómicos hiperlocales o de costosas encuestas de transporte. Destaca el paradigma de inferencia mediante imágenes satelitales y modelos generativos de grafos.

Un estudio fundacional en esta línea metodológica es el de Xu et al. [Xu et al., 2025], quienes desarrollaron *Imagery2Flow*, un modelo que emplea aprendizaje contrastivo y Redes de Atención en Grafos (GAT) para predecir flujos a partir de imágenes satelitales. Su investigación valida empíricamente a *Deep Gravity* como arquitectura de referencia en la literatura. Los autores demuestran que la versión con atributos espaciales (*Deep Gravity-V*) supera con claridad a la versión puramente poblacional (*Deep Gravity-P*). Este resultado confirma que las características del entorno construido son determinantes para el aprendizaje profundo aplicado a la movilidad.

Posteriormente, Rong et al. [Rong et al., 2026] extendieron este paradigma de inferencia satelital mediante *GIODGen*, un generador global de flujos OD basado en modelos de difusión (*Denoising Diffusion Networks*). Este *framework* utiliza un codificador visual multimodal (*RemoteCLIP*) para extraer un *embedding* semántico de 1.024 dimensiones directamente desde imágenes satelitales de alta resolución. Los autores reportan que el aspecto visual del entorno urbano y un mapa global de población poseen una expresividad superior al 98 % respecto al uso de datos multisectoriales complejos (catastros, POIs, atributos socioeconómicos). Su modelo, entrenado en Estados Unidos, demostró transferibilidad a ciudades de Europa, China, Brasil y África.

A pesar del salto tecnológico que representan estos modelos, presentan barreras prácticas relevantes. Suelen estar condicionados por sesgos geográficos propios de los contextos donde fueron entrenados. Su desempeño es además sensible a la calidad, iluminación y nubosidad de las imágenes satelitales. La limitación más crítica es de naturaleza interpretativa: la compresión del entorno urbano en *embeddings* altamente dimensionales sacrifica completamente la interpretabilidad semántica. Resulta imposible aislar el impacto de variables específicas como “presencia de escuelas” o “red de hospitales” sobre la predicción del flujo. Estas variables son, sin embargo, fundamentales para simular escenarios de impacto urbano y fundamentar políticas públicas.

En el contexto latinoamericano, los antecedentes de aplicación de modelos computacionales para la generación de flujos son escasos. Spadon et al. [Spadon et al., 2019] reconstruyeron redes de commuting en la región metropolitana de São Paulo utilizando *random forests* e indicadores urbanos municipales, demostrando la viabilidad de enfoques basados en aprendizaje automático para ciudades de la región. Sin embargo, su trabajo emplea arquitecturas de baja complejidad, no incorpora *amenities* de OpenStreetMap como variables explicativas y no incluye técnicas de explicabilidad. No se ha identificado en la literatura ninguna aplicación de modelos de aprendizaje profundo con explicabilidad para la generación de flujos OD en ciudades latinoamericanas, lo que constituye la brecha que la presente memoria busca abordar.

3.6. En Resumen

La revisión de la literatura evidencia un claro *trade-off* en la evolución de los modelos de movilidad:

- Los modelos físicos y estadísticos clásicos (Secciones 3.1 y 3.2) ofrecen transparencia matemática, rigor explicativo y garantías de aditividad. Sin embargo, dependen exclusivamente de la distancia y la masa poblacional como variables *proxy* de oportunidad, lo que les impide modelar las no linealidades del uso de suelo urbano contemporáneo.
- Los modelos de la familia de oportunidades intervinientes (Sección 3.3) avanzaron hacia marcos libres de parámetros y comportamentalmente ricos, revelando que los desplazamientos intraurbanos requieren variables del tejido urbano para ser bien predichos. Sin embargo, continúan dependiendo de la población como único *proxy* de oportunidades.
- Los modelos avanzados basados en aprendizaje profundo, series de tiempo e imágenes satelitales (Secciones 3.4 y 3.5) alcanzan alta precisión predictiva y transferibilidad global. No obstante, operan como *cajas negras* opacas y computacionalmente costosas, lo que limita su utilidad para fundamentar políticas públicas explicables.

En este contexto metodológico, el uso del modelo *Deep Gravity* [Simini *et al.*, 2021] alimentado con datos de OpenStreetMap (OSM) y analizado mediante técnicas de explicabilidad SHAP [Lundberg y Lee, 2017] se posiciona como una solución de equilibrio para el caso de Santiago de Chile.

Por un lado, *Deep Gravity* reemplaza la rigidez heurística de los exponentes gravitacionales por una red neuronal profunda capaz de capturar relaciones no lineales entre el territorio y los flujos. A diferencia de los *embeddings* satelitales, utiliza variables explícitas y semánticamente interpretables provistas por OSM: centros de salud, red vial, escuelas y comercio. Por otro lado, su arquitectura relativamente simple facilita la aplicación de métodos de explicabilidad como SHAP. Ello permite no solo estimar los flujos con alta precisión, sino también auditar *por qué* ocurren, proveyendo evidencia interpretable para la planificación territorial en el Gran Santiago.

CAPÍTULO 4

PROPUESTA DE SOLUCIÓN

Este capítulo describe la solución propuesta para la estimación de flujos de movilidad origen-destino en el Gran Santiago de Chile mediante el modelo *Deep Gravity*. La propuesta se articula en torno a un diseño de doble modelo comparativo: el primero replica la unidad espacial de teselación zonal irregular del sistema DTPM como referencia de control; el segundo introduce una grilla hexagonal regular del sistema *Uber H3* como contribución metodológica original. La estructura del capítulo sigue el flujo de procesamiento integral, desde la ingesta de datos hasta la configuración del entrenamiento, pasando por la delimitación espacial, la extracción de características urbanas y la justificación teórica de la arquitectura.

4.1. Diseño general de la solución

La solución propuesta se organiza en torno a un *pipeline* de procesamiento dual que opera sobre tres fuentes de entrada y produce modelos entrenados para dos tipos de unidades espaciales distintas. El flujo comprende desde la ingesta y recorte territorial hasta la evaluación y explicabilidad de las predicciones.

Las fuentes de entrada son: (1) las transacciones de validación del sistema de transporte público metropolitano administradas por el Directorio de Transporte Público Metropolitano (DTPM), que constituyen la fuente de flujos observados; (2) los datos geoespaciales de OpenStreetMap (OSM), que proveen las características del tejido urbano empleadas como variables explicativas; y (3) los datos de población del Censo INE 2017, utilizados como variable de masa para cada unidad espacial.

El *pipeline* se bifurca tras la delimitación del área de estudio en dos ramas paralelas:

- **Rama Modelo 1 (Control):** agrega los viajes individuales por zona operativa DTPM, utilizando directamente los campos `zona_subida` y `zona_bajada` presentes en los datos. No requiere redistribución espacial.
- **Rama Modelo 2 (Propuesto):** asigna cada validación individual a su celda hexagonal H3 correspondiente mediante reproyección de coordenadas UTM a WGS84 y la función `h3.latlng_to_cell(lat, lon, resolution)` de la librería `h3-py`.

Ambas ramas convergen en la misma arquitectura neuronal *Deep Gravity*, que recibe como entrada el vector de características geoespaciales y produce las probabilidades de destino mediante la función *softmax*. La comparación de desempeño entre modelos, mediante la

métrica CPC (*Common Part of Commuters*), y el análisis de explicabilidad mediante valores SHAP constituyen el núcleo de la validación experimental, descrita en el Capítulo 5.

Adicionalmente, se contempla un **Modelo 0 (Baseline)**, de carácter opcional, que opera a nivel comunal (33 comunas del Gran Santiago). Su propósito es proporcionar un punto de referencia macroscópico e institucional, sin información de alta resolución geoespacial.

4.2. Ingesta y procesamiento de datos de movilidad

4.2.1. Descripción del conjunto de datos

La fuente primaria de flujos observados es el dataset de transacciones de noviembre de 2024 del DTPM, correspondiente al sistema de tarjeta inteligente *bip!*. Este dataset ha sido procesado institucionalmente mediante algoritmos de encadenamiento de etapas (*trip chaining*), que permiten inferir el punto de bajada de cada validación a partir del análisis secuencial de las etapas de un viaje completo [Munizaga y Palma, 2012]. El método infiere la parada de destino de cada etapa como la parada de subida de la etapa inmediatamente siguiente del mismo viajero, o como la parada más cercana al hogar estimado si la etapa es la última del día. Esta inferencia es especialmente relevante para el sistema *bip!*, que registra únicamente las validaciones de subida y no las de bajada.

Los archivos base del dataset son los siguientes:

- `viajes.csv`: aproximadamente 3,6 millones de registros que representan viajes completos consolidados, resultantes del encadenamiento de etapas individuales.
- `etapas.csv`: aproximadamente 1,5 millones de registros de transacciones unitarias por etapa de viaje en buses Red, Metro y Tren Nos.

Los campos espaciales clave son las coordenadas proyectadas UTM del punto de subida y bajada (`x_subida`, `y_subida`, `x_bajada`, `y_bajada`) en el sistema de referencia EPSG:32719 (WGS84 UTM zona 19S), junto con las unidades zonales DTPM (`zona_subida`, `zona_bajada`) y administrativas (`comuna_subida`, `comuna_bajada`).

4.2.2. Factor de expansión

Cada viaje en el dataset lleva asociado un campo `factor_expansion`, que corrige el sesgo de cobertura introducido por la evasión tarifaria en la red de buses. La evasión no es uniformemente distribuida en el espacio ni en el tiempo: varía según la unidad de negocio, el periodo horario y la línea de servicio. El DTPM calcula y aplica institucionalmente factores de

expansión diferenciados por estos estratos, de modo que los flujos expandidos son representativos del universo total de viajes realizados, incluyendo los no registrados electrónicamente [Espinoza *et al.*, 2018]. En el procesamiento de este trabajo se retienen únicamente los registros con `factor_expansion > 0`, descartando aquellos que el sistema institucional ha marcado como inválidos o no expandibles.

4.2.3. Construcción de matrices origen-destino

A partir de los datos filtrados, se construyen las matrices origen-destino **T** (definidas en la Ecuación (1) del Marco Conceptual) para cada unidad espacial y escenario horario. El flujo T_{ij} entre el origen i y el destino j se obtiene como la suma ponderada de los factores de expansión de todos los viajes que conectan esas zonas en el intervalo temporal correspondiente:

$$T_{ij} = \sum_{v \in \mathcal{V}_{ij}} \text{factor_expansion}_v \quad (21)$$

donde $\mathcal{V}_{ij}$ es el conjunto de viajes con origen en i y destino en j dentro del intervalo horario analizado.

4.3. Delimitación espacial del área de estudio

El dataset DTPM cubre técnicamente las 777 zonas operativas de toda la Región Metropolitana. Sin embargo, la cobertura del sistema de transporte público formal (Red Metropolitana de Movilidad y Metro) es heterogénea: en las comunas periféricas y rurales la densidad de validaciones es baja, lo que genera matrices OD con alta esparsidad en esas zonas. Entrenar *Deep Gravity* con unidades espaciales de señal rala introduce ruido que degrada la calidad global del modelo.

El área de estudio se acota por ello al **Gran Santiago urbano**, definido como el conjunto de comunas que integran el continuo urbano metropolitano con cobertura densa de transporte público. El criterio de inclusión combina tres condiciones: pertenencia al continuo urbano del Gran Santiago según la definición del Instituto Nacional de Estadísticas (INE) y SECTRA; existencia de al menos una línea de bus Red o una estación de Metro en operación en el periodo de análisis; y densidad de validaciones *bip!* estadísticamente significativa en noviembre de 2024.

Las comunas nucleares del área de estudio son: Santiago, Providencia, Las Condes, Ñuñoa, Vitacura, Lo Barnechea, La Reina, Peñalolén, Macul, San Joaquín, La Granja, La Florida, Puen-te Alto, San Bernardo, El Bosque, Pedro Aguirre Cerda, Lo Espejo, La Cisterna, San Miguel, Estación Central, Quinta Normal, Independencia, Recoleta, Conchalí, Huechuraba, Pudahuel, Lo Prado, Cerrillos, Maipú, Quilicura, Renca, Cerro Navia y La Pintana. Las comunas limítrofes

se evalúan en función del umbral de densidad de validaciones definido en el piloto exploratorio de datos.

Este enfoque es consistente con investigaciones previas sobre fusión de datos de movilidad en Santiago, donde la delimitación al área metropolitana densa es condición necesaria para la validez estadística de los modelos [Graells-Garrido *et al.*, 2023]. La delimitación también es coherente con el trabajo de referencia de Vicente Mackenzie (2026), quien acotó a 743 de las 777 zonas operativas excluyendo la periferia rural, aunque sin documentar explícitamente el criterio de exclusión.

Técnicamente, el recorte se implementa mediante un polígono de unión geométrica de los límites comunales seleccionados, disponibles en los *shapefiles* oficiales del INE y del Banco Cartográfico Nacional de Chile (BCN). Todas las coordenadas y centroides de viajes se filtran espacialmente mediante intersección con este polígono antes de la asignación a unidades espaciales.

4.4. Unidades espaciales y estrategia comparativa

El núcleo de la contribución metodológica de esta memoria reside en contrastar el impacto de la partición espacial sobre el aprendizaje del modelo. Se implementan dos tipos de unidades espaciales con roles distintos en el diseño experimental.

4.4.1. Modelo 1 (Control): Teselación zonal DTPM

El Modelo 1 utiliza la teselación operativa del DTPM, compuesta por polígonos irregulares diseñados con criterios de gestión del transporte público y no de modelación geoespacial. Dentro del área del Gran Santiago, esta teselación comprende aproximadamente 743 zonas operativas urbanas. La asignación de viajes a zonas se realiza directamente mediante los campos *zona_subida* y *zona_bajada* del dataset, sin redistribución adicional.

El propósito del Modelo 1 es replicar de forma controlada el enfoque metodológico de Vicente (2026), constituyendo la línea de control para cuantificar el efecto intrínseco de la geometría irregular sobre el aprendizaje del modelo. Los resultados reportados en ese trabajo indican que las cinco variables de mayor impacto en el análisis SHAP pertenecen todas al vector del origen (*vías principales_origen*, *vías secundarias_origen*, *transporte público_origen*, entre otras), con las *amenities* del destino relegadas a un impacto marginal. El CPC máximo alcanzado fue 0,2566 en el Periodo Valle. Estos resultados constituyen la referencia cuantitativa de comparación del presente trabajo.

4.4.2. Modelo 2 (Propuesto): Grilla hexagonal Uber H3

El Modelo 2 utiliza el sistema de indexación geoespacial discreta *Uber H3* [Brodsky, 2018], que divide la superficie terrestre en hexágonos regulares jerárquicos con 16 niveles de resolución. Este sistema presenta tres propiedades geométricas relevantes para la modelación de flujos:

1. **Isotropía de vecindad:** cada celda hexagonal posee exactamente seis vecinos equidistantes, con idéntica distancia inter-centroide. Los polígonos cuadrados tienen cuatro vecinos cardinales y cuatro diagonales con distancias distintas; los polígonos irregulares tienen vecindades asimétricas variables.
2. **Invarianza de área:** todas las celdas de una misma resolución comparten idéntica superficie nominal, eliminando el sesgo de agregación espacial introducido por la heterogeneidad de tamaño de las zonas DTPM (Problema de la Unidad de Área Modificable, MAUP).
3. **Indexación eficiente:** la asignación de cualquier par de coordenadas geográficas a su celda H3 correspondiente es una operación de tiempo constante mediante la función `h3.latlng_to_cell(lat, lon, resolution)` de la librería `h3-py`, sin necesidad de operaciones de intersección geométrica.

Las resoluciones H3 evaluadas van del nivel 3 al 8, cubriendo un rango de granularidades desde áreas macrodistritales hasta áreas de aproximadamente $0,74 \text{ km}^2$ (resolución 7) y $0,74 \text{ km}^2$ de radio medio equivalente (resolución 8, con radio de 460 m). La resolución óptima se selecciona en función del equilibrio entre granularidad urbana y esparsidad de la matriz OD resultante, determinado empíricamente en el piloto exploratorio de datos.

La asignación de validaciones individuales a celdas H3 se realiza mediante la **Estrategia A (preferida)**: se reprojectan las coordenadas UTM (`x_subida`, `y_subida`) de cada validación a coordenadas geográficas WGS84 y se invoca directamente `h3.latlng_to_cell()`. Esta estrategia evita completamente el error de redistribución, pues opera a nivel de validación individual. Si los datos solo estuvieran disponibles a nivel de zona agregada, se aplicaría la **Estrategia B (fallback)**: redistribución por proporción de superficie de intersección entre la celda H3 y la zona DTPM.

La hipótesis experimental central de la tesis es que la regularidad geométrica de la grilla H3 permite que las variables de destino recuperen importancia en el ranking de valores SHAP, validando la conjetura de que el sesgo observado en Vicente (2026) es atribuible a la irregularidad de la unidad espacial y no a una incapacidad estructural del modelo para aprender atractores de destino.

4.4.3. Modelo 0 (Baseline comunal)

El Modelo 0 opera a nivel de las comunas del Gran Santiago (33 unidades). Su construcción es directa mediante los campos *comuna_subida* y *comuna_bajada* del dataset. Proporciona un punto de referencia macroscópico que permite cuantificar la pérdida de información al agregar a nivel comunal, en contraste con las granularidades menores del Modelo 1 y el Modelo 2.

4.5. Justificación teórica de la arquitectura

La arquitectura *Deep Gravity* presentada en el Marco Conceptual (Secciones 2.3 y 2.4) puede entenderse como la extensión profunda de un modelo de elección discreta clásico. Esta sección articula el puente teórico entre ambas tradiciones, justificando formalmente cada componente de la arquitectura propuesta.

4.5.1. El modelo gravitatorio restringido como modelo Logit multinomial

El modelo gravitatorio restringido en origen (Ecuación (3)) puede reescribirse como un caso particular del *Modelo Logit Multinomial* de McFadden [McFadden, 1974] bajo el marco de la Teoría de la Utilidad Aleatoria (RUM). En este marco, la probabilidad de que un viajero en la zona de origen i elija la zona de destino j es:

$$p_{ij} = \frac{\exp(V_{ij})}{\sum_k \exp(V_{ik})} \quad (22)$$

donde $V_{ij} = \beta_1 \ln P_j + \beta_2 \ln d_{ij}$ es la componente determinística de la utilidad del par (i, j) . Cuando $\beta_1 = 1$ y $\beta_2 = \gamma$, la Ecuación (22) es algebraicamente equivalente a la Ecuación (3) con función de disuasión exponencial. Esta equivalencia, discutida en profundidad por Ortúzar y Willumsen [Ortúzar y Willumsen, 2011], establece que el modelo gravitatorio clásico es un modelo Logit multinomial con un vector de utilidad de dos dimensiones.

La relación formal con *Deep Gravity* es directa: la red neuronal profunda $f_\theta(\mathbf{x}_{ij})$ reemplaza el producto interno lineal $\beta^\top \mathbf{x}_{ij}$ por una función no lineal aprendida, y la capa *softmax* (Ecuación (12)) implementa precisamente el operador Logit multinomial sobre los *scores* producidos por la red. El modelo no impone forma funcional alguna a la utilidad: la aprende directamente de los datos.

4.5.2. Equivalencia entre la función de pérdida y la maximización de entropía

La función de pérdida de entropía cruzada empleada en el entrenamiento (Ecuación (11)) es formalmente equivalente a la maximización de la log-verosimilitud de una distribución

multinomial de flujos. Wilson [Wilson, 1970] demostró que maximizar la log-verosimilitud multinomial de los viajes observados, bajo las restricciones de conservación de flujos salientes, conduce a las mismas distribuciones que el principio de maximización de entropía. Por lo tanto, minimizar la función de pérdida H equivale a encontrar la distribución de probabilidades de destino que, siendo consistente con los flujos observados, maximiza la entropía del sistema. Esto reinterpreta el entrenamiento de *Deep Gravity* como una instancia del principio variacional de Wilson en el espacio de los modelos neuronales.

4.5.3. Capacidad de aproximación de la red neuronal

La sustitución de la función de disuasión analítica $f(d_{ij})$ (exponencial o ley de potencia) por una red neuronal profunda con 15 capas ocultas está formalmente respaldada por el Teorema de Aproximación Universal [Hornik, 1991]. Este teorema establece que una red neuronal *feedforward* con al menos una capa oculta y una función de activación no polinómica puede aproximar, con precisión arbitraria, cualquier función continua definida sobre un compacto de $\mathbb{R}^d$. Por extensión, una red de 15 capas con activaciones LeakyReLU tiene capacidad suficiente para aproximar cualquier relación funcional compleja entre los descriptores urbanos del par (i, j) y la probabilidad de viaje, sin imponer restricciones sobre la forma matemática de esa relación.

4.6. Extracción de características urbanas

Deep Gravity incorpora la oferta de infraestructura y descriptores del entorno construido como variables explicativas del flujo entre pares de zonas. Estas características se extraen de OpenStreetMap (OSM), cuyo modelo de datos y cobertura en el contexto de Santiago se describen en la Sección 2.6 del Marco Conceptual.

4.6.1. Ontología de características

Para mitigar el problema de esparsidad de etiquetas derivado del exceso de categorías OSM vacías en celdas periféricas del Gran Santiago, se adopta una consolidación en **12 macro-categorías funcionales**, en lugar de las 18 características del paper original [Simini *et al.*, 2021]. La Tabla 2 detalla las entidades OSM representativas de cada categoría.

Tabla 2: Ontología de características OSM consolidada en 12 macro-categorías funcionales.
Fuente: Elaboración propia.

ID	Macro-categoría	Entidades OSM representativas
1	residential_bldg	building=residential, apartments, house
2	commercial_bldg	building=commercial, office
3	industrial_bldg	building=industrial, warehouse
4	leisure	leisure=park, sports_centre, pitch, garden
5	edu	amenity=school, university, college, kindergarten
6	food	amenity=restaurant, cafe, fast_food, bar
7	health	amenity=hospital, clinic, pharmacy, doctors
8	retail	shop=supermarket, mall, convenience; amenity=bank
9	transport	public_transport=platform, stop_position; highway=bus_stop
10	main_roads	highway=motorway, trunk, primary (longitud en km)
11	secondary_roads	highway=secondary, tertiary (longitud en km)
12	other	Equipamientos institucionales y servicios menores

4.6.2. Normalización y construcción del vector de entrada

Para cada celda z (sea zona 777 o celda H3), los conteos brutos de entidades OSM se transforman en densidades por kilómetro cuadrado:

$$X_{k,z} = \frac{\sum_{i \in z} \mathbb{I}_k(\text{POI}_i)}{A_z} \quad (23)$$

donde A_z es el área métrica de la celda calculada tras proyectar sus geometrías a EPSG:32719.

El vector de entrada al Perceptrón Multicapa tiene **27 dimensiones**:

$$\mathbf{x}_{ij} = [\text{Pop}_i, \text{Pop}_j, d_{ij}, \mathbf{X}_i^{(1.,12)}, \mathbf{X}_j^{(1.,12)}] \quad (24)$$

donde Pop_i y Pop_j son las poblaciones del Censo INE 2017 asignadas a origen y destino, d_{ij} es la distancia euclidiana inter-centroides en kilómetros proyectados, y $\mathbf{X}_i^{(1.,12)}$ y $\mathbf{X}_j^{(1.,12)}$ son las 12 densidades funcionales de origen y destino respectivamente.

La reducción de 39 a 27 dimensiones respecto al trabajo original de Simini et al. [Simini et al., 2021] obedece a la consolidación de 18 categorías en 12. Las 6 dimensiones eliminadas corresponden a subcategorías de uso de suelo y vialidad que en el contexto de Santiago presentan tasas de llenado inferiores al 30 % de las celdas del área de estudio.

4.7. Configuración del entrenamiento

4.7.1. Arquitectura neuronal

La función f_θ se implementa como una red neuronal *feedforward* de 15 capas ocultas, idéntica a la descrita en la Sección 2.4.2 del Marco Conceptual. Las primeras 6 capas tienen dimensión 256 y las 9 restantes dimensión 128. Cada capa aplica secuencialmente normalización por lotes (*Batch Normalization*), activación LeakyReLU y regularización por abandono (*Dropout*). La capa de salida produce un escalar por par (i, j) .

El operador *Softmax* se aplica sobre todos los pares de destino candidatos desde cada origen, configurado como *Single Tile* continuo sobre el Gran Santiago, es decir, todos los orígenes compiten dentro del mismo sistema metropolitano sin subdivisión en teselas.

4.7.2. Muestreo negativo y función de pérdida

Para hacer computacionalmente tratable la normalización del *softmax* sobre todas las posibles zonas de destino, se aplica *negative sampling*: por cada origen i se seleccionan hasta 512 destinos candidatos, combinando todos los destinos con flujos observados ($T_{ij} > 0$) y destinos aleatorios sin flujos observados ($T_{ij} = 0$). La función de pérdida minimizada es la entropía cruzada multinomial (Ecuación (11)).

4.7.3. Optimizador y hiperparámetros

El modelo se entrena con el optimizador RMSprop con momento 0,9 y tasa de aprendizaje 5×10^{-6} , en lotes de 64 zonas de origen. Estos hiperparámetros reproducen la configuración original de Simini et al. [Simini et al., 2021] para garantizar la comparabilidad de resultados.

4.7.4. Correcciones sobre el código base

Antes de ejecutar el entrenamiento sobre los datos de Santiago, se aplican las siguientes correcciones sobre el repositorio base original:

1. **Bug de serialización (`utils.py:106`):** el código original almacena la estructura `oa2centroid` dentro del archivo `od2flow.pkl`. La corrección serializa correctamente `od2flow` en su archivo correspondiente.
2. **Reactivación del generador de soporte:** se descomenta la llamada a `_compute_support_files` en `load_data()` para permitir la generación automática de los archivos `.pkl` indexados para las unidades espaciales de Santiago.
3. **Corrección del bucle de evaluación (`main.py`):** se elimina el `break` residual en la iteración sobre `test_loader`, que impedía el cálculo del CPC acumulado completo sobre todas las particiones de prueba.
4. **Integración de dependencias geoespaciales:** se incorporan las librerías `h3-py` y `geopandas` al entorno de ejecución para el soporte de la teselación hexagonal y las operaciones de recorte geométrico.

4.8. Alcances y limitaciones

4.8.1. Alcance del estudio

El alcance de esta propuesta se define en las siguientes dimensiones:

- **Área geográfica:** Gran Santiago urbano, conformado por las comunas del continuo metropolitano con cobertura densa de Red Metropolitana de Movilidad y Metro (Sección 4.3).
- **Período temporal:** noviembre de 2024, que corresponde a un mes de días laborales post-pandemia representativo del patrón de movilidad contemporáneo.
- **Modos de transporte:** todos los presentes en el dataset DTPM: buses Red, Metro y Tren Nos.
- **Modelos implementados:** *Deep Gravity* como modelo principal; modelo gravitatorio clásico exponencial singly-constrained y modelo de radiación como *baselines* de referencia.
- **Características geoespaciales:** 12 macro-categorías funcionales extraídas de OSM (Tabla 2), complementadas con población censal y distancia inter-centroides.
- **Técnicas de explicabilidad:** valores SHAP (*SHapley Additive exPlanations*) aplicados a ambos modelos para el análisis comparativo de importancia de variables.

4.8.2. Limitaciones

Las siguientes limitaciones son inherentes al diseño de la propuesta y deben tenerse en cuenta en la interpretación de los resultados:

- **Cobertura modal parcial:** el dataset DTPM no registra viajes en taxi, colectivo de pago en efectivo, bicicleta ni caminata. Los flujos modelados corresponden exclusivamente al transporte público formal.
- **Exclusión de la periferia regional:** la delimitación al Gran Santiago urbano excluye los viajes de las comunas rurales y periféricas de la Región Metropolitana, lo que reduce la representatividad del modelo para esas zonas. Esta limitación debe documentarse en los reportes de uso institucional del modelo.
- **Cobertura heterogénea de OSM:** la densidad y completitud de los datos OSM varía según el nivel socioeconómico de las comunas, con menor cobertura en las comunas periféricas de menores ingresos, como se describe en la Sección 2.6 del Marco Conceptual. Este sesgo puede afectar la estimación de características geoespaciales en dichas zonas.
- **Instantánea temporal:** el dataset de noviembre de 2024 constituye una fotografía de la movilidad en ese período. El modelo no realiza predicción temporal (*forecasting*) y sus resultados no son necesariamente extrapolables a períodos con condiciones de movilidad distintas (vacaciones, eventos masivos, crisis de transporte).
- **Fuera de alcance:** quedan excluidos del presente trabajo la calibración de políticas públicas, el uso de datos de telecomunicaciones, y la implementación de otras arquitecturas neuronales como redes de grafos (GNN) o transformadores espaciales.

CAPÍTULO 5

VALIDACIÓN DE LA SOLUCIÓN

CAPÍTULO 6

CONCLUSIONES

Las Conclusiones son, según algunos especialistas, el aspecto principal de una memoria, ya que reflejan el aprendizaje final del autor del documento. En ellas se tiende a considerar los alcances y limitaciones de la propuesta de solución, establecer de forma simple y directa los resultados, discutir respecto a la validez de los objetivos formulados, identificar las principales contribuciones y aplicaciones del trabajo realizado, así como su impacto o aporte a la organización o a los actores involucrados. Otro aspecto que tiende a incluirse son recomendaciones para quienes se sientan motivados por el tema y deseen profundizarlo, o lineamientos de una futura ampliación del trabajo.

Todo esto debe sintetizarse en al menos 5 páginas.

ANEXOS

En los Anexos se incluye todo aquel material complementario que no es parte del contenido de los capítulos de la memoria, pero que permiten a un lector contar con un contenido adjunto relacionado con el tema.

REFERENCIAS BIBLIOGRÁFICAS

- [Barrington-Leigh y Millard-Ball, 2017] Barrington-Leigh, C. y Millard-Ball, A. (2017). The world's user-generated road map is more than 80 % complete. *PLOS ONE*, 12(8):e0180698.
- [Brockmann *et al.*, 2006] Brockmann, D., Hufnagel, L., y Geisel, T. (2006). The scaling laws of human travel. *Nature*, 439(7075):462–465.
- [Brodsky, 2018] Brodsky, I. (2018). H3: Uber's hexagonal hierarchical spatial index. <https://eng.uber.com/h3/>. Uber Engineering Blog. Consultado el 1 de septiembre de 2026.
- [Directorio de Transporte Público Metropolitano (DTPM), 2025] Directorio de Transporte Público Metropolitano (DTPM) (2025). Informe de gestión dtpm 2025. Informe institucional, Ministerio de Transportes y Telecomunicaciones, Gobierno de Chile.
- [DTPM, 2025] DTPM (2025). Sistema de transporte público de santiago. <https://www.dtpm.cl/index.php/sistema-de-transporte-publico-de-santiago>. Consultado el 4 de octubre de 2025.
- [Espinoza *et al.*, 2018] Espinoza, F., Munizaga, M., Bustos, B., y Trépanier, M. (2018). Assessing the public transport travel behavior consistency from smartcard data. *Transportation Research Procedia*, 32:44–53.
- [González *et al.*, 2008] González, M. C., Hidalgo, C. A., y Barabási, A.-L. (2008). Understanding individual human mobility patterns. *Nature*, 453(7196):779–782.
- [Graells-Garrido *et al.*, 2023] Graells-Garrido, E., Opitz, D., Rowe, F., y Arriagada, J. (2023). A data fusion approach with mobile phone data for updating travel survey-based mode split estimates. *Transportation Research Part C: Emerging Technologies*, 155:104285.
- [Haklay y Weber, 2008] Haklay, M. y Weber, P. (2008). OpenStreetMap: User-generated street maps. *IEEE Pervasive Computing*, 7(4):12–18.
- [Herfort *et al.*, 2023] Herfort, B., Lautenbach, S., Porto de Albuquerque, J., Anderson, J., y Zipf, A. (2023). A spatio-temporal analysis investigating completeness and inequalities of global urban building data in OpenStreetMap. *Nature Communications*, 14(1):3985.
- [Hornik, 1991] Hornik, K. (1991). Approximation capabilities of multilayer feedforward networks. *Neural Networks*, 4(2):251–257.
- [Kang *et al.*, 2015] Kang, C., Liu, Y., Guo, D., y Qin, K. (2015). Generalized radiation model for human mobility: spatial scale, searching direction and trip constraint. *PLOS ONE*, 10(11):e0143500.
- [Liu y Yan, 2019] Liu, E.-J. y Yan, X.-Y. (2019). Opportunity priority selection model for human mobility. *Physica A: Statistical Mechanics and its Applications*, 526:121023.

- [Liu y Yan, 2020] Liu, E.-J. y Yan, X.-Y. (2020). Research advances in intervening opportunity class models for predicting human mobility. *Acta Physica Sinica*, 69(24):248901.
- [Luca et al., 2024] Luca, M., Beneduce, C., y Lepri, B. (2024). TS-Mob: Social and geographical-aware time series foundation-model framework for human mobility prediction. *arXiv preprint arXiv:2412.09180*.
- [Lundberg y Lee, 2017] Lundberg, S. M. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems*, volumen 30. Curran Associates, Inc.
- [Marín-Flores et al., 2026] Marín-Flores, C., Ferres, L., y Tenkanen, H. (2026). When proximity falls short: Inequalities in commuting and accessibility by public transport in Santiago, Chile. *Geographical Analysis*, 58(2):e70039.
- [McFadden, 1974] McFadden, D. (1974). Conditional logit analysis of qualitative choice behavior. En Zarembka, P., editor, *Frontiers in Econometrics*, pp. 105–142. Academic Press, New York.
- [Munizaga y Palma, 2012] Munizaga, M. A. y Palma, C. (2012). Estimation of a disaggregate multimodal public transport origin–destination matrix from passive smartcard data from Santiago, Chile. *Transportation Research Part C: Emerging Technologies*, 24:9–18.
- [Ortúzar y Willumsen, 2011] Ortúzar, J. d. D. y Willumsen, L. G. (2011). *Modelling Transport*. John Wiley & Sons, Chichester, 4 edición.
- [Pappalardo et al., 2023] Pappalardo, L., Simini, F., Barlacchi, G., y Pellungrini, R. (2023). scikit-mobility: a python library for the analysis, generation and risk assessment of mobility data. *Journal of Statistical Software*, 103(4):1–38.
- [Ren et al., 2014] Ren, Y., Ercsey-Ravasz, M., Wang, P., González, M. C., y Toroczkai, Z. (2014). Predicting commuter flows in spatial networks using a radiation model based on temporal ranges. *Nature Communications*, 5(1):5347.
- [Rong et al., 2024] Rong, C., Ding, J., y Li, Y. (2024). An interdisciplinary survey on origin-destination flows modeling: Theory and techniques. *ACM Computing Surveys*, 57(1):1–38.
- [Rong et al., 2026] Rong, C., Zhang, X., Xi, Y., SUI, H., Ding, J., y Li, Y. (2026). Satellites reveal mobility: A commuting origin-destination flow generator for global cities. En *The Thirty-ninth Annual Conference on Neural Information Processing Systems Datasets and Benchmarks Track*.
- [Sim et al., 2015] Sim, A., Yaliraki, S. N., Barahona, M., y Stumpf, M. P. (2015). Modelling the effects of subjective and objective decision making in scientific peer review. *Journal of The Royal Society Interface*, 12(107):20150315.
- [Simini et al., 2021] Simini, F., Barlacchi, G., Luca, M., y Pappalardo, L. (2021). A deep gravity model for mobility flows generation. *Nature Communications*, 12(1):6576.

- [Simini *et al.*, 2012] Simini, F., González, M. C., Maritan, A., y Barabási, A.-L. (2012). A universal model for mobility and migration patterns. *Nature*, 484(7392):96–100.
- [Simini *et al.*, 2013] Simini, F., Maritan, A., y Neda, Z. (2013). Human mobility in a continuum approach. *PloS one*, 8(3):e60069.
- [Spadon *et al.*, 2019] Spadon, G., de Carvalho, A. C. P. L. F., Rodrigues-Jr, J. F., y Alves, L. G. A. (2019). Reconstructing commuters network using machine learning and urban indicators. *Scientific Reports*, 9:11801.
- [Stouffer, 1940] Stouffer, S. A. (1940). Intervening opportunities: a theory relating mobility and distance. *American Sociological Review*, 5(6):845–867.
- [Sundararajan *et al.*, 2017] Sundararajan, M., Taly, A., y Yan, Q. (2017). Axiomatic attribution for deep networks. En *Proceedings of the 34th International Conference on Machine Learning*, volumen 70, pp. 3319–3328. PMLR.
- [Vecchio *et al.*, 2020] Vecchio, G., Tiznado-Aitken, I., y Hurtubia, R. (2020). Transport and equity in Latin America: a critical review of socially oriented accessibility assessments. *Transport Reviews*, 40(3):354–381.
- [Wilson, 1970] Wilson, A. G. (1970). *Entropy in Urban and Regional Modelling*. Pion, London.
- [Xu *et al.*, 2025] Xu, Y., Gao, S., Huang, Q., Göçmen, A., Zhu, Q., y Zhang, F. (2025). Predicting human mobility flows in cities using deep learning on satellite imagery. *Nature Communications*, 16:10372.
- [Yan *et al.*, 2017] Yan, X.-Y., Wang, W.-X., Gao, Z.-Y., y Lai, Y.-C. (2017). Universal model of individual and population mobility on diverse spatial scales. *Nature Communications*, 8(1):1639.
- [Yan *et al.*, 2014] Yan, X.-Y., Zhao, C., Fan, Y., Di, Z., y Wang, W.-X. (2014). Universal predictability of mobility patterns in cities. *Journal of The Royal Society Interface*, 11(100):20140834.
- [Yang *et al.*, 2014] Yang, Y.-X., Herrera, C., Eagle, N., y González, M. C. (2014). Limits of predictability in human mobility. *Scientific Reports*, 4(1):5662.
- [Zipf, 1946] Zipf, G. K. (1946). The P1 P2/D hypothesis: on the intercity movement of persons. *American Sociological Review*, 11(6):677–686.