

UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA
DEPARTAMENTO DE INFORMÁTICA
SANTIAGO - CHILE



“MODELACIÓN DE FLUJOS DE TRANSPORTE PÚBLICO
EN SANTIAGO DE CHILE MEDIANTE DEEP GRAVITY:
SENSIBILIDAD A LA DISCRETIZACIÓN ESPACIAL Y
EVALUACIÓN COMPLEMENTARIA DE ATRIBUCIONES
PREDICTIVAS”

PABLO ALBERTO CAMPOS ÁVILA

MEMORIA PARA OPTAR AL TÍTULO DE
INGENIERO CIVIL EN INFORMÁTICA

Profesor Guía: Daniela Opitz
Profesor Correferente: Nombre del correferente

Julio - 2026

DEDICATORIA

Considerando la importancia de este trabajo para los alumnos, este apartado es para que el autor entregue palabras personales para dedicar este documento. La extensión puede ser de máximo una hoja y se deben mantener este formato, tipo y tamaño de letra.

AGRADECIMIENTOS

Considerando la importancia de este trabajo para los alumnos, este apartado se podrá incluir en el caso de que el autor desee agradecer a las personas que facilitaron alguna ayuda relevante en su trabajo para la realización de este documento. La extensión puede ser de máximo una hoja y se deben mantener este formato, tipo y tamaño de letra.

RESUMEN

Resumen— El resumen y las palabras clave no deben superar la mitad de la página, donde debe precisarse brevemente: 1) lo que el autor ha hecho, 2) cómo lo hizo (sólo si es importante detallarlo), 3) los resultados principales, 4) la relevancia de los resultados. El resumen es una representación abreviada, pero comprensiva de la memoria y debe informar sobre el objetivo, la metodología y los resultados del trabajo realizado.

Palabras Clave— Cinco es el máximo de palabras clave para describir los temas tratados en la memoria, ponerlas separadas por punto y comas.

ABSTRACT

Abstract— Corresponde a la traducción al idioma inglés del Resumen anterior. Sujeto a la misma regla de extensión del Resumen.

Keywords— Corresponde a la traducción al idioma inglés de Palabras Clave anteriores.

GLOSARIO

CPC Componente común de viajeros (*Common Part of Commuters*); medida de solapamiento entre flujos observados y predichos.

CRS Sistema de referencia de coordenadas (*Coordinate Reference System*).

DPA División político-administrativa.

DTPM Directorio de Transporte Público Metropolitano.

EOD Encuesta Origen-Destino.

EPSG Identificador del registro de sistemas de referencia geodésicos originado por el *European Petroleum Survey Group*.

GAT Red de atención en grafos (*Graph Attention Network*).

H3 Sistema jerárquico de indexación geoespacial utilizado para definir unidades de origen y destino.

INE Instituto Nacional de Estadísticas.

MAUP Problema de la unidad espacial modificable (*Modifiable Areal Unit Problem*); sensibilidad del análisis a la agregación y delimitación de unidades.

MLP Perceptrón multicapa (*Multilayer Perceptron*).

OD Origen-destino.

OSM OpenStreetMap.

POI Punto de interés (*Point of Interest*).

RMSE Raíz del error cuadrático medio (*Root Mean Squared Error*).

SECTRA Secretaría de Planificación del Transporte.

SHAP *SHapley Additive exPlanations*; enfoque de atribución de predicciones basado en valores de Shapley.

UTM Proyección universal transversal de Mercator (*Universal Transverse Mercator*).

WGS 84 Sistema Geodésico Mundial de 1984 (*World Geodetic System 1984*).

XAI Inteligencia artificial explicable (*eXplainable Artificial Intelligence*).

ÍNDICE DE CONTENIDOS

RESUMEN	IV
ABSTRACT	IV
GLOSARIO	V
ÍNDICE DE FIGURAS	VIII
ÍNDICE DE TABLAS	VIII
INTRODUCCIÓN	1
CAPÍTULO 1: DEFINICIÓN DEL PROBLEMA	3
1.1 Fuentes de datos actuales y sus limitaciones	3
1.2 Limitaciones de los modelos vigentes	4
1.3 Especificidad del contexto latinoamericano	4
1.4 Síntesis del problema	5
1.5 Árbol del problema	6
1.6 Objetivo General	6
1.7 Objetivos Específicos	7
CAPÍTULO 2: MARCO CONCEPTUAL	8
2.1 Movilidad urbana y flujos origen-destino	8
2.2 Modelos clásicos de generación de flujos	9
2.2.1 Modelo gravitatorio	9
2.2.2 Modelo de oportunidades intervinientes	10
2.2.3 Modelo de radiación	11
2.3 Aprendizaje profundo aplicado a la movilidad	13
2.4 Deep Gravity	13
2.4.1 Formulación matemática	13
2.4.2 Arquitectura de la red neuronal	14
2.4.3 Vector de características geoespaciales	15
2.4.4 Resultados y desempeño	15
2.4.5 Síntesis comparativa de modelos	16
2.5 Explicabilidad en modelos de inteligencia artificial (XAI)	16
2.5.1 Valores SHAP	16
2.5.2 Gradientes integrados	18
2.6 OpenStreetMap como fuente de datos geoespaciales	19
2.7 Contexto de la movilidad en Santiago de Chile	20
CAPÍTULO 3: TRABAJO RELACIONADO	21
3.1 Descubrimiento de patrones en la movilidad individual	21
3.2 Unificación de modelos clásicos y enfoques continuos	21

3.3	Evolución de los modelos de oportunidades intervinientes	22
3.3.1	Modelo de oportunidades ponderadas por población	22
3.3.2	Modelos exploratorios: más allá de la selección secuencial	23
3.3.3	Modelo Unificado de Oportunidades	24
3.4	Deep Learning y modelos espacio-temporales en movilidad	25
3.5	Generación de flujos mediante datos no convencionales	25
3.6	En Resumen	26
CAPÍTULO 4: PROPUESTA DE SOLUCIÓN		28
4.1	Diseño general y trazabilidad	28
4.2	Datos de movilidad y reconstrucción del viaje	29
4.3	Delimitación territorial y cohorte común	30
4.4	Adaptadores espaciales, unidades y <i>tiles</i>	31
4.5	Construcción de atributos y vector de entrada	32
4.6	Modelo, muestreo y evaluación	33
4.6.1	Relación con el modelo gravitatorio	33
4.6.2	Arquitectura, soporte y pérdida	33
4.6.3	Modelos de referencia, particiones y métricas	34
4.6.4	Piloto y experimento mensual	35
4.7	Análisis complementario de atribuciones predictivas	36
4.8	Reproducibilidad, alcances y limitaciones	36
CAPÍTULO 5: VALIDACIÓN DE LA SOLUCIÓN		38
CAPÍTULO 6: CONCLUSIONES		39
ANEXOS		40
REFERENCIAS BIBLIOGRÁFICAS		41

ÍNDICE DE FIGURAS

1	Diagrama del árbol del problema. Fuente: Elaboración propia.	6
2	Procedimiento de Santiago: un núcleo común de viajes precede a los adaptadores espaciales y a la evaluación. Fuente: elaboración propia.	28
3	Delimitación del área de estudio: núcleo urbano referencial de 34 comunas dentro de la Región Metropolitana. Las cifras de la figura corresponden al filtro territorial previo a la exclusión común posterior de tres zonas sin polígono oficial verificable. Fuente: elaboración propia. Los datos territoriales y el procedimiento se describen en esta sección.	30
4	Escalas espaciales del procedimiento. Cada rama representa el mismo dominio mediante sus propias unidades OD; el <i>tile</i> es un bloque de partición mayor y no reemplaza a una zona o celda. Esquema no a escala. Fuente: elaboración propia.	32

ÍNDICE DE TABLAS

1	Comparación bibliográfica de modelos de flujos. Fuente: elaboración propia a partir de las referencias indicadas.	17
2	Fuentes de datos y función de las variables usadas por el procedimiento. Fuente: elaboración propia.	29
3	Representaciones espaciales operativas después de la exclusión común. Fuente: elaboración propia.	31

INTRODUCCIÓN

Los flujos de movilidad origen-destino (OD) cuantifican el número de personas que se desplazan entre dos ubicaciones geográficas en un período de tiempo definido. Constituyen un insumo central para la planificación del transporte, la gestión de emergencias y el diseño de políticas urbanas [Rong *et al.*, 2024]. Obtener estos datos mediante observación directa es costoso y poco frecuente. Esta limitación ha motivado el desarrollo de modelos generativos capaces de estimar flujos OD a partir de características observables del territorio, permitiendo extrapolar predicciones a contextos donde no existen datos de encuesta.

La estimación de flujos OD cuenta con una tradición extensa en la geografía cuantitativa. Modelos clásicos como el gravitacional [Zipf, 1946], el de oportunidades intervinientes [Stouffer, 1940] y el de radiación [Simini *et al.*, 2012] han dominado históricamente esta área. Estos modelos comparten limitaciones conocidas: dependen de un conjunto reducido de variables explicativas y no capturan relaciones no lineales entre el tejido urbano y los flujos observados. El Marco Conceptual de esta memoria detalla la formulación de estos modelos y sus restricciones. Más recientemente, la incorporación de redes neuronales profundas ha permitido superar parte de estas limitaciones, dando origen a modelos como Deep Gravity [Simini *et al.*, 2021], cuya arquitectura y validación también se describen en el Marco Conceptual.

Deep Gravity ha sido validado principalmente en ciudades del Norte Global, por lo que su aplicación a una metrópolis latinoamericana requiere evidencia empírica propia. Esta memoria adapta y evalúa Deep Gravity para asignar destinos de viajes de transporte público en Santiago de Chile a partir de datos DTPM y atributos territoriales de OpenStreetMap, mediante la biblioteca *scikit-mobility* [Pappalardo *et al.*, 2023]. La evaluación compara Zona 777 y dos resoluciones H3 sobre una cohorte común, frente a referencias uniforme, de atracción y de gravedad exponencial. Como análisis complementario, se implementaron y evaluaron tres aproximaciones de XAI para estudiar atribuciones predictivas. Ninguna acreditó todos los controles de completitud y estabilidad requeridos; por tanto, la memoria informa ese resultado metodológico sin publicar atribuciones, rankings ni figuras SHAP. El aporte principal es una evaluación reproducible del desempeño predictivo y de la sensibilidad a la discretización espacial en Santiago, con límites explícitos para el análisis de explicabilidad.

El resto del documento se organiza en seis capítulos. El Capítulo 1 (Definición del Problema) diagnostica las brechas actuales en la estimación de flujos de movilidad en Santiago y establece los objetivos de la memoria. El Capítulo 2 (Marco Conceptual) presenta los fundamentos teóricos de los modelos de movilidad y detalla la arquitectura de Deep Gravity. El Capítulo 3 (Trabajo Relacionado) sitúa esta memoria respecto a la literatura existente sobre generación de flujos de movilidad. El Capítulo 4 (Propuesta de Solución) describe la construcción del conjunto de datos, la adaptación del modelo, el diseño experimental y el alcance del análisis complementario de explicabilidad. El Capítulo 5 (Validación de la Solución) presenta los resultados predictivos, su comparación con las referencias y el desenlace del análisis XAI.

Finalmente, el Capítulo 6 (Conclusiones) discute los hallazgos y propone líneas de trabajo futuro.

CAPÍTULO 1

DEFINICIÓN DEL PROBLEMA

El transporte público de Santiago integra buses, Metro y tren suburbano. Durante 2024, el sistema registró un promedio de 5,0 millones de transacciones en un día laboral [Directorio de Transporte Público Metropolitano, 2025]. Esta cifra corresponde al conjunto del sistema y no equivale al número de personas ni al de viajes reconstruidos para esta memoria.

Comprender la distribución espacial de los desplazamientos en esta red, representada mediante flujos origen-destino (OD), es un insumo esencial para la planificación del transporte. También lo es para el diseño de infraestructura vial y la formulación de políticas urbanas basadas en evidencia [Rong *et al.*, 2024].

1.1. Fuentes de datos actuales y sus limitaciones

La planificación del transporte en Santiago se apoya actualmente en dos fuentes principales de datos de movilidad. La primera es la *Encuesta Origen-Destino* (EOD) de SECTRA¹. Su última versión fue levantada en 2012, con actualizaciones parciales en 2017. Esta encuesta constituye la referencia canónica de flujos de movilidad en la ciudad. Sin embargo, su periodicidad de siete a diez años implica que los datos disponibles pueden no reflejar la movilidad actual. Esto es especialmente relevante tras la reconfiguración de patrones de desplazamiento producida por la pandemia de COVID-19. Su elevado costo de levantamiento agrava además esta desactualización.

La segunda fuente son los datos anonimizados de validación de la *tarjeta bip*², administrados por el DTPM³. Estos datos registran validaciones en Metro y buses con alta resolución temporal. No obstante, no cubren etapas caminadas. Tampoco cubren viajes en taxi o colectivo pagados en efectivo, ni modos no motorizados.

El análisis de esta memoria se limita a los viajes reconstruibles a partir de la entrega DTPM y al dominio territorial definido para la comparación. Los registros de validación, las etapas y los viajes reconstruidos son unidades distintas. La evaluación distribuye entre destinos el flujo saliente observado de cada origen; su alcance no comprende predecir el total de viajes generados ni los desplazamientos de modos no observables en la fuente.

La disponibilidad de estos registros permite evaluar modelos de distribución de flujos a partir

¹Secretaría de Planificación del Transporte, organismo dependiente del Ministerio de Transportes y Telecomunicaciones de Chile.

²Nombre oficial del sistema de tarificación electrónica del transporte público de Santiago.

³Directorio de Transporte Público Metropolitano.

de características observables del territorio. En esta memoria se estudia esa distribución condicionada al flujo saliente conocido; las limitaciones de las fuentes delimitan el alcance de las conclusiones.

1.2. Limitaciones de los modelos vigentes

Los modelos gravitatorios clásicos constituyen un antecedente para la estimación de flujos [Simini *et al.*, 2012, Rong *et al.*, 2024]. Las formulaciones basadas únicamente en población y distancia imponen una relación paramétrica entre esas variables y el flujo; por ello, su capacidad para representar subcentros de empleo u otras diferencias territoriales depende de la especificación elegida. La estimación de sus parámetros requiere datos observados y su transferencia a otro contexto necesita evaluación. Las versiones que solo usan población y distancia tampoco describen directamente el uso del suelo, los equipamientos o la infraestructura de transporte.

Modelos basados en aprendizaje profundo, como *Deep Gravity* [Simini *et al.*, 2021], incorporan variables geoespaciales de OpenStreetMap (OSM) para representar relaciones no lineales. Su arquitectura y los resultados publicados se detallan en el Marco Conceptual. Esos antecedentes motivan su evaluación en Santiago, pero no permiten anticipar su desempeño en esta aplicación.

1.3. Especificidad del contexto latinoamericano

La evaluación en Santiago requiere considerar que las ciudades latinoamericanas presentan características estructurales que las diferencian de los contextos donde estos modelos han sido desarrollados y evaluados. La segregación socio-espacial severa, la existencia de periferias urbanas de bajos ingresos con infraestructura de transporte deficitaria y la coexistencia de sistemas formales e informales de movilidad motivan examinar la transferencia de las funciones de disuasión por distancia calibradas en otros contextos [Vecchio *et al.*, 2020]. A esto se suma la heterogeneidad en la completitud de los datos geoespaciales abiertos: estudios recientes demuestran que la cobertura de OpenStreetMap en ciudades latinoamericanas alcanza apenas un 10 a 20 % en datos de edificaciones, frente a más del 50 % en Europa y Norteamérica, con un sesgo intra-ciudad correlacionado con el nivel de desarrollo humano subnacional [Herfort *et al.*, 2023, Barrington-Leigh y Millard-Ball, 2017].

En el caso específico de Santiago, evidencia empírica reciente basada en datos de telefonía móvil y enrutamiento multimodal demuestra que la proximidad espacial no se traduce en accesibilidad equitativa [Marín-Flores *et al.*, 2026]. Las poblaciones periféricas de menores ingresos enfrentan penalizaciones estructurales de accesibilidad y un conjunto restringido de opciones de destino, lo que implica que modelos que asumen un comportamiento uniforme de proximidad-a-oportunidad pueden producir errores sistemáticos que requieren evalua-

ción empírica en este contexto. Estas condiciones motivan evaluar el desempeño de *Deep Gravity* en Santiago y examinar de manera complementaria si es posible obtener atribuciones predictivas estables, sin presuponer que los resultados de otros contextos geográficos se transfieran directamente.

La publicación original incorpora atribuciones mediante SHAP (*SHapley Additive exPlanations*) [Simini *et al.*, 2021]. En Santiago, la interpretación de las predicciones requiere examinar los atributos, la discretización y el soporte utilizados en esta adaptación. Por ello, la memoria evalúa como componente complementario la viabilidad de obtener atribuciones predictivas estables sobre modelos congelados, con una salida, referencias y controles explícitos. Ese análisis no se plantea como evidencia causal.

La estimación de flujos requiere definir las unidades espaciales de origen y destino. En esta memoria se consideran la zonificación operativa Zona 777 del DTPM y las celdas del sistema jerárquico de indexación geoespacial H3. Al agrupar los mismos viajes de maneras diferentes, cambian el soporte de los flujos y la agregación de los atributos territoriales. Por ello, la elección de la discretización forma parte de la evaluación del modelo y de la interpretación de sus predicciones. El procedimiento de comparación se desarrolla en el Capítulo 3.6.

1.4. Síntesis del problema

En síntesis, el problema que aborda esta memoria se formula de la siguiente manera:

La aplicación de Deep Gravity al transporte público de Santiago requiere establecer cómo la discretización espacial condiciona su desempeño predictivo y la interpretación de sus resultados. La zonificación Zona 777 y las celdas H3 producen representaciones distintas de los viajes y de los atributos urbanos. Una comparación sustentada en una cohorte DTPM común permite estudiar esa sensibilidad frente a modelos de referencia. El problema de investigación consiste en evaluar estas diferencias dentro de la movilidad observable en la fuente y determinar si un análisis complementario de explicabilidad produce atribuciones predictivas suficientemente estables para su interpretación.

1.5. Árbol del problema

A continuación se presenta el diagrama del árbol del problema (Figura 1):




Figura 1: Diagrama del árbol del problema. Fuente: Elaboración propia.

La Figura 1 organiza el problema alrededor de la necesidad de evaluar cómo la discretización espacial condiciona el desempeño y la interpretación de los modelos de flujos observables en el transporte público de Santiago.

El árbol reúne cuatro factores que requieren control metodológico: la cobertura parcial de las fuentes de movilidad, los cambios en la agregación de viajes al definir unidades espaciales, las diferencias en la construcción de atributos territoriales y la transferencia de modelos entre contextos geográficos.

Si estos factores no se examinan, la comparación puede confundir cambios de agregación con mejoras predictivas, extender sus conclusiones a movilidad no observada o atribuir un alcance causal a explicaciones del modelo. El diagrama presenta riesgos para la interpretación de resultados, no efectos medidos sobre la inversión pública. Su posible utilidad para la planificación depende de la evidencia obtenida.

1.6. Objetivo General

Evaluar la sensibilidad de *Deep Gravity* y de sus modelos de referencia frente a la discretización espacial Zona 777-H3, a partir de una cohorte DTPM común, trazable y reproducible para Santiago de Chile.

1.7. Objetivos Específicos

1. Auditar y adaptar el código de referencia para verificar su funcionamiento y asegurar la trazabilidad de las ejecuciones.
2. Reconstruir viajes canónicos desde las tablas DTPM de viajes y etapas, definir una cohorte común y delimitar el núcleo urbano de Santiago mediante reglas espaciales reproducibles.
3. Construir representaciones comparables mediante Zona 777 y H3, evaluar la factibilidad de las resoluciones H3-r3 a H3-r8 y seleccionar candidatas para la evaluación experimental.
4. Construir atributos de población y de OpenStreetMap con fuentes, unidades y procedimientos de agregación y normalización explícitos.
5. Entrenar y evaluar *Deep Gravity* frente a los modelos de referencia uniforme, de atracción de entrenamiento y de gravedad exponencial, mediante una medida de solapamiento de flujos observados y predichos, el componente común de viajeros (*Common Part of Commuters*, CPC), sobre particiones espaciales comparables.
6. Evaluar, como análisis complementario, la viabilidad de obtener atribuciones predictivas estables de las características territoriales mediante técnicas de inteligencia artificial explicable (XAI), documentando la configuración, los controles y el alcance efectivo del análisis.

CAPÍTULO 2

MARCO CONCEPTUAL

Este capítulo presenta los fundamentos de la modelación de flujos origen-destino. Describe los modelos clásicos como antecedentes teóricos y expone la formulación de *Deep Gravity*, distinguiendo la publicación original de la adaptación utilizada en Santiago. Luego introduce los métodos de atribución de predicciones, las fuentes geoespaciales y el contexto de movilidad. El procedimiento experimental de esta memoria se especifica en el Capítulo 3.6.

2.1. Movilidad urbana y flujos origen-destino

La movilidad urbana comprende el conjunto de desplazamientos que realizan las personas entre distintas ubicaciones de la ciudad en un período de tiempo determinado [Rong *et al.*, 2024]. Comprender estos desplazamientos es un insumo fundamental para la planificación del transporte, el diseño de infraestructura vial y la formulación de políticas públicas basadas en evidencia.

Una representación sintética y cuantitativa de la movilidad urbana es la matriz origen-destino (matriz OD). Formalmente, dado un conjunto de n zonas geográficas $\mathcal{Z} = \{z_1, z_2, \dots, z_n\}$ que particionan el área de estudio, el flujo T_{ij} representa el número de viajes que se realizan desde la zona de origen z_i hasta la zona de destino z_j en un intervalo de tiempo fijo:

$$\mathbf{T} \in \mathbb{R}^{n \times n}, \quad T_{ij} \geq 0 \quad \forall i, j \in \{1, \dots, n\} \quad (1)$$

La colección de todos los flujos posibles entre pares de zonas conforma la matriz OD. Cada fila i representa los flujos salientes desde una zona de origen, y cada columna j los flujos entrantes hacia una zona de destino.

Obtener la matriz OD mediante observación directa, a través de encuestas domiciliarias, aforos de tráfico o registros de tarjetas de pago, es costoso y poco frecuente. Esta limitación ha motivado el desarrollo de modelos generativos de flujos, capaces de estimar $\mathbf{T}$ a partir de características observables del territorio, como la distribución de la población o la presencia de equipamientos urbanos, sin depender exclusivamente de mediciones directas [Simini *et al.*, 2021].

El problema de generación de flujos se formula de la siguiente manera: dado un conjunto de zonas $\mathcal{Z}$, sus características geoespaciales y los flujos totales salientes por zona $O_i = \sum_j T_{ij}$, estimar los flujos por par origen-destino $\hat{T}_{ij}$ para todos los pares (i, j) .

2.2. Modelos clásicos de generación de flujos

La estimación de flujos origen-destino cuenta con una tradición extensa en la geografía cuantitativa. Los modelos que se describen a continuación constituyen antecedentes teóricos de esta memoria. Los modelos de referencia utilizados en la evaluación de Santiago se especifican en el Capítulo 3.6.

2.2.1. Modelo gravitatorio

El modelo gravitatorio de movilidad establece una analogía con la ley de gravitación universal de Newton. La aplicación de este principio a los fenómenos sociales cuenta con antecedentes desde el siglo XIX. Posteriormente, Zipf [Zipf, 1946] lo formalizó en 1946 para la predicción de flujos. Su formulación postula que el volumen de desplazamientos entre dos zonas es directamente proporcional al producto de sus masas (habitualmente la población) e inversamente proporcional a la distancia que las separa:

$$T_{ij} = k \cdot \frac{P_i^\alpha \cdot P_j^\beta}{d_{ij}^\gamma} \quad (2)$$

donde P_i y P_j son las poblaciones de las zonas de origen y destino, d_{ij} es la distancia entre sus centroides, k es una constante de proporcionalidad, y α, β, γ son parámetros que deben calibrarse con datos observados. Zipf verificó empíricamente esta relación mediante datos de tráfico de buses, ferrocarriles y llamadas telefónicas entre ciudades de Estados Unidos. Los coeficientes obtenidos se aproximan a la unidad en todos los casos.

La formulación de la ecuación (2) recibe el nombre de *modelo de gravedad no restringido*. En la práctica, para garantizar que los flujos generados sean consistentes con los totales salientes observados, se utiliza la versión *restringida en origen* (*singly-constrained*), que normaliza los flujos de cada origen sobre todos sus destinos posibles:

$$\hat{T}_{ij} = O_i \cdot \frac{P_j^\beta f(d_{ij})}{\sum_k P_k^\beta f(d_{ik})} \quad (3)$$

donde $O_i = \sum_j T_{ij}$ es el flujo total saliente de la zona i y $f(d_{ij})$ es una función de disuasión por distancia, que puede adoptar una forma exponencial, $f(d_{ij}) = e^{-\lambda d_{ij}}$, con $\lambda > 0$, o una ley de potencia, $f(d_{ij}) = d_{ij}^{-\gamma}$, con $\gamma > 0$ y $d_{ij} > 0$ ⁴.

Las limitaciones de un modelo gravitatorio dependen de su especificación [Rong *et al.*, 2024]. La versión presentada relaciona población, distancia y flujo mediante parámetros calibrados con observaciones. Al no incluir otros atributos, no distingue

⁴Existe también la versión *doblemente restringida* (*doubly-constrained*), que impone conservación tanto de los flujos salientes O_i como de los flujos entrantes $D_j = \sum_i T_{ij}$. *Deep Gravity* utiliza exclusivamente la versión restringida en origen.

de forma directa usos del suelo, equipamientos ni infraestructura de transporte. Estas restricciones corresponden a esa formulación, no a toda extensión posible de la familia gravitatoria. Su adecuación y la transferencia de sus parámetros requieren evaluación empírica.

2.2.2. Modelo de oportunidades intervinientes

Stouffer [Stouffer, 1940] propuso en 1940 una perspectiva alternativa al modelo gravitatorio, argumentando que la distancia no es en sí misma el factor determinante de la movilidad, sino que actúa como un contenedor espacial de oportunidades. Su hipótesis central es que el número de personas que se desplazan a una zona de destino es directamente proporcional al número de oportunidades en ese destino e inversamente proporcional al número de oportunidades intervinientes entre el origen y el destino.

Formalmente, sea y el número de personas que se desplazan desde un origen hasta una banda circular de anchura Δs , y sea x el número acumulado de oportunidades entre el origen y la distancia s . Stouffer postula:

$$\Delta y = a \cdot \frac{\Delta x}{x} \quad (4)$$

Integrando esta expresión diferencial, el número total de personas que se detienen dentro de un círculo de radio s desde el origen es:

$$y = a \cdot \ln f(s) + c \quad (5)$$

donde $f(s)$ es el número acumulado de oportunidades dentro de ese radio y c es una constante de integración. Stouffer verificó empíricamente esta formulación con datos de movilidad residencial en Cleveland, Ohio (1933-1935). Los resultados muestran una buena correspondencia entre los flujos observados y los predichos por el modelo.

Liu y Yan [Liu y Yan, 2020] formalizaron y extendieron esta familia de modelos de manera rigurosa. Para describir su funcionamiento, es necesario precisar tres conceptos fundamentales:

- **Oportunidades de un lugar (m_l):** cantidad de oportunidades que ofrece el lugar l para satisfacer el propósito del desplazamiento. En la práctica se asume que m_l es proporcional a la población del lugar.
- **Oportunidades intervinientes (s_{ij}):** suma de oportunidades de todos los lugares cuya distancia al origen i es menor que d_{ij} , excluyendo el propio origen i y el destino j . Si se incluyen origen y destino se utiliza la notación $S_{ij} = m_i + s_{ij} + m_j$.
- **Valor de beneficio de una oportunidad (z):** utilidad o recompensa que una oportunidad reporta al viajero. Se modela como variable aleatoria continua con distribución $p(z)$.

El modelo de Stouffer establece que cada individuo que parte del origen i ordena todos los destinos potenciales por distancia creciente y se detiene en cada lugar con una probabilidad fija proporcional al parámetro α . Bajo este mecanismo, la probabilidad de que un individuo en i elija el destino j adopta la forma [Stouffer, 1940, Liu y Yan, 2020]:

$$P_{ij} = \frac{e^{-\alpha(S_{ij}-m_j)} - e^{-\alpha S_{ij}}}{1 - e^{-\alpha M}} \quad (6)$$

donde m_j es la cantidad de oportunidades del destino j , S_{ij} es el total de oportunidades en el círculo de radio d_{ij} centrado en i (incluyendo origen y destino), α es el parámetro de absorción a calibrar con datos históricos, y $M = \sum_k m_k$ es el total de oportunidades del sistema. La ecuación (6) muestra que la probabilidad de elegir j crece con las oportunidades del destino m_j y decrece con el número de oportunidades intervinientes s_{ij} : cuanto mayor es la competencia en el camino, menor la probabilidad de alcanzar el destino.

La principal limitación del modelo original de Stouffer es que contiene el parámetro α , que debe calibrarse mediante datos históricos de flujo observado. Esta dependencia paramétrica restringe su aplicabilidad cuando no se dispone de matrices OD previas, y motivó el desarrollo de modelos libres de parámetros basados en el mismo concepto de oportunidades intervinientes.

2.2.3. Modelo de radiación

Simini et al. [Simini et al., 2012] propusieron en 2012 el modelo de radiación como una alternativa libre de parámetros al modelo gravitatorio. El modelo establece una analogía con los procesos de radiación y absorción en física de partículas. Su mecanismo se basa en un proceso estocástico de toma de decisiones locales: cada individuo en un origen busca la mejor oportunidad disponible dentro de radios geográficos crecientes y se desplaza hacia el destino donde la encuentra.

El mecanismo es el siguiente. Se asigna a cada oportunidad un valor de beneficio z extraído de una distribución de probabilidad $p(z)$. La probabilidad de que un individuo en la zona i elija la zona j como destino es la probabilidad de que el mejor beneficio dentro de j supere al mejor beneficio disponible dentro del círculo de radio d_{ij} centrado en i (excluyendo i y j). Esta probabilidad es:

$$p(n_j | m_i, s_{ij}) = \frac{m_i n_j}{(m_i + s_{ij})(m_i + n_j + s_{ij})} \quad (7)$$

donde m_i es la población de la zona de origen i , n_j es la población de la zona de destino j , y s_{ij} es la población total dentro de un círculo de radio d_{ij} centrado en i , excluyendo las poblaciones de i y de j . El flujo esperado entre i y j es entonces:

$$\langle T_{ij} \rangle = T_i \cdot \frac{m_i n_j}{(m_i + s_{ij})(m_i + n_j + s_{ij})} \quad (8)$$

donde $T_i = \sum_j T_{ij}$ es el flujo total saliente de la zona i . Una propiedad destacable del modelo de radiación es que satisface automáticamente la restricción de conservación de flujos: $\sum_j \langle T_{ij} \rangle = T_i$, sin necesidad de calibración de parámetros adicionales.

Simini et al. [Simini et al., 2012] validaron el modelo sobre datos de *commuting* del censo de Estados Unidos (2000). Los resultados muestran que el modelo de radiación supera al modelo gravitatorio en la reproducción de flujos observados, especialmente en viajes de corta distancia, que el modelo gravitatorio tiende a sobreestimar.

Variantes del modelo de radiación. La solidez del modelo original motivó diversas extensiones para adaptar su mecanismo a diferentes contextos. Ren et al. [Ren et al., 2014] propusieron una versión basada en tiempo de viaje en lugar de distancia euclidiana, incorporando así la resistencia real de la red de transporte. Kang et al. [Kang et al., 2015] formularon un modelo de radiación generalizado que introduce parámetros de escala y restricciones explícitas de producción y atracción, mejorando la precisión en contextos con heterogeneidad espacial marcada. Yang et al. [Yang et al., 2014] extendieron el modelo para incorporar la distribución no homogénea de oportunidades en el espacio, relevante en regiones con alta segregación funcional del suelo.

Limitación del modelo de radiación a escala intraurbana. A pesar de su éxito en la predicción de *commuting* interurbano, el modelo de radiación presenta una limitación estructural cuando se aplica a la escala intraurbana [Yan et al., 2014, Liu y Yan, 2020]. Su supuesto central, que cada individuo elige el destino más cercano cuyo beneficio supera al del origen, refleja adecuadamente el comportamiento en la búsqueda de empleo a larga distancia (donde la proximidad es costosa), pero no captura la lógica real de los desplazamientos dentro de una ciudad. En entornos urbanos, las personas consideran simultáneamente el conjunto de destinos disponibles en toda la ciudad, sin restringirse a los más cercanos. Estudios empíricos sobre datos de transporte público en diversas ciudades confirman que el modelo de radiación subestima sistemáticamente los flujos intraurbanos de largo alcance [Yan et al., 2014]. Adicionalmente, el modelo utiliza exclusivamente la población como *proxy*⁵ de oportunidades, sin incorporar características del tejido urbano como el uso de suelo o la distribución de actividades económicas. Estas limitaciones fueron el punto de partida para el desarrollo del modelo de oportunidades ponderadas por población, descrito en la Sección 3.3, y justifican el uso de modelos basados en aprendizaje profundo capaces de representar el tejido urbano más allá de la simple distribución poblacional, como *Deep Gravity*.

⁵Una variable *proxy* es una medida indirecta que se emplea en sustitución de una variable inobservable, asumiendo que existe una fuerte correlación estadística entre ambas.

2.3. Aprendizaje profundo aplicado a la movilidad

El aprendizaje profundo (*deep learning*) es un subcampo del aprendizaje automático que utiliza redes neuronales con múltiples capas de transformaciones no lineales para aprender representaciones jerárquicas de los datos [Rong *et al.*, 2024]. Su aplicación a la predicción de flujos de movilidad ha permitido incorporar un conjunto amplio de variables geoespaciales y capturar relaciones no lineales que los modelos clásicos no pueden representar.

Una red neuronal *feedforward* (de propagación hacia adelante) con L capas ocultas transforma un vector de entrada $\mathbf{x} \in \mathbb{R}^d$ mediante una secuencia de transformaciones afines seguidas de funciones de activación no lineales:

$$\mathbf{z}^{(0)} = \sigma(W^{(0)} \mathbf{x}), \quad \mathbf{z}^{(\ell)} = \sigma(W^{(\ell)} \mathbf{z}^{(\ell-1)}), \quad \ell = 1, \dots, L-1 \quad (9)$$

donde $W^{(\ell)}$ es la matriz de pesos de la capa ℓ y $\sigma(\cdot)$ es la función de activación, comúnmente ReLU ($\max(0, x)$) o su variante LeakyReLU ($\max(\alpha x, x)$ con α pequeño), que mitiga el problema del gradiente desvanecido en redes profundas.

En el contexto de la generación de flujos, el aprendizaje profundo ha sido aplicado de múltiples formas: como extensión no lineal del modelo gravitatorio [Simini *et al.*, 2021], mediante redes neuronales de grafos que modelan la estructura espacial de las zonas, y mediante modelos de series de tiempo que capturan la evolución temporal de los flujos [Luca *et al.*, 2024]. Esta memoria se enfoca en el primero de estos enfoques, implementado a través del modelo *Deep Gravity*.

2.4. Deep Gravity

Deep Gravity es un modelo de generación de flujos de movilidad propuesto por Simini *et al.* [Simini *et al.*, 2021] en 2021. Su contribución central es demostrar que el modelo gravitatorio clásico restringido en origen (ecuación 3) es formalmente equivalente a una red neuronal lineal de una sola capa con salida *softmax*, y que reemplazar esa capa lineal por una red neuronal profunda permite capturar relaciones no lineales entre las características del territorio y los flujos observados.

2.4.1. Formulación matemática

El modelo gravitatorio restringido en origen puede reescribirse como un modelo lineal generalizado con distribución multinomial. Para un origen i , la probabilidad de que un viaje se dirija al destino j es:

$$p_{ij} = \frac{\exp(\beta^\top \mathbf{x}(l_i, l_j))}{\sum_k \exp(\beta^\top \mathbf{x}(l_i, l_k))} \quad (10)$$

donde $\mathbf{x}(l_i, l_j) = [\ln P_j, d_{ij}]$ es el vector de características del par (i, j) , y $\beta = [\beta_1, \beta_2]$ son los parámetros del modelo.

Con distancia sin transformar, el numerador es proporcional a $P_j^{\beta_1} e^{\beta_2 d_{ij}}$; la disuasión exponencial corresponde a $\beta_2 < 0$. Una ley de potencia se obtiene incorporando $\ln d_{ij}$ en lugar de d_{ij} , para distancias positivas. Ambas son formulaciones gravitatorias, con funciones de disuasión distintas.

La formulación publicada utiliza la siguiente entropía cruzada entre distribuciones de destino normalizadas por origen, para orígenes con $O_i > 0$:

$$H = - \sum_i \sum_j \frac{T_{ij}}{O_i} \ln p_{ij} \quad (11)$$

Esta expresión asigna el mismo peso a cada origen. La pérdida efectiva de Santiago pondera las contribuciones por la masa observada, $-\sum_i \sum_j T_{ij} \ln p_{ij}$, como se especifica en la ecuación (24). Las dos expresiones difieren en la ponderación entre orígenes y no se presentan como objetivos de entrenamiento idénticos. *Deep Gravity* reemplaza el producto interno lineal $\beta^\top \mathbf{x}(l_i, l_j)$ por una red neuronal profunda $f_\theta(\mathbf{x}(l_i, l_j))$ que produce un *score* escalar. Las probabilidades de destino se obtienen mediante *softmax* sobre los *scores* de todos los destinos candidatos desde el origen i :

$$p_{ij} = \frac{\exp(f_\theta(\mathbf{x}(l_i, l_j)))}{\sum_k \exp(f_\theta(\mathbf{x}(l_i, l_k)))} \quad (12)$$

El flujo estimado desde i hacia j es entonces $\hat{T}_{ij} = O_i \cdot p_{ij}$. El total O_i se considera conocido; la tarea predictiva consiste en estimar la distribución de ese flujo entre destinos.

2.4.2. Arquitectura de la red neuronal

En la arquitectura descrita por Simini et al. [Simini et al., 2021], la función f_θ se implementa como una red neuronal *feedforward* de 15 capas ocultas con activación LeakyReLU. Las primeras 6 capas tienen dimensión 256 y las 9 restantes dimensión 128. La capa de salida produce un escalar:

$$\begin{aligned} \mathbf{z}^{(0)} &= \text{LeakyReLU}(W^{(0)} \mathbf{x}(l_i, l_j)) \\ \mathbf{z}^{(\ell)} &= \text{LeakyReLU}(W^{(\ell)} \mathbf{z}^{(\ell-1)}), \quad \ell = 1, \dots, 14 \\ f_\theta(\mathbf{x}(l_i, l_j)) &= \mathbf{w}^\top \mathbf{z}^{(14)} \end{aligned} \quad (13)$$

Esta distribución de anchos corresponde a la arquitectura descrita en la publicación. La implementación utilizada en Santiago tiene cinco capas ocultas de 256 unidades y diez de 128; su configuración efectiva se documenta en la Sección 4.6. El protocolo publicado emplea RMSprop, con momento 0,9, tasa de aprendizaje 5×10^{-6} , lotes de 64 orígenes y hasta 512

destinos muestreados por origen. El muestreo permite calcular la normalización sobre un subconjunto de candidatos durante el entrenamiento; no equivale a evaluar todos los destinos. La configuración efectivamente usada en el piloto de Santiago se documenta en la Sección 4.6: emplea lotes de ocho orígenes y el soporte completo de destinos. Los parámetros de los experimentos finales se fijarán en su diseño específico.

2.4.3. Vector de características geoespaciales

En la formulación de referencia [Simini et al., 2021], el vector de entrada reúne atributos del origen y del destino, población y distancia. Su estructura puede representarse mediante el siguiente esquema de 39 componentes:

$$\mathbf{x}(l_i, l_j) = [\mathbf{f}(l_i), \mathbf{f}(l_j), \ln P_i, \ln P_j, d_{ij}] \quad (14)$$

donde $\mathbf{f}(l) \in \mathbb{R}^{18}$ reúne atributos geoespaciales de la ubicación l , P_i y P_j representan la población asociada a ambos extremos y d_{ij} es la distancia entre sus representantes espaciales. La procedencia de las variables y sus transformaciones deben identificarse en cada aplicación.

En Santiago se utiliza un conjunto de 19 atributos por ubicación y 39 componentes por par. Incluye densidad de población censal, coberturas de suelo, densidades viales y atributos de equipamientos y servicios. Su construcción, orden y transformación se definen en la Sección 4.5. La igualdad de dimensión con el vector de referencia no implica equivalencia de los atributos. La población de Santiago procede del Censo 2024 y se expresa como densidad después de la interpolación areal; no se introduce directamente el logaritmo de la población total ni el flujo saliente observado como variable de población.

La agregación espacial depende de la magnitud del atributo. En Santiago, la densidad de población se expresa en personas por km^2 , la densidad de puntos de interés en puntos por km^2 y la densidad vial en km de vías por km^2 . La cobertura corresponde al área de la unión de polígonos de una categoría dividida por el área de la unidad, por lo que es una proporción adimensional entre cero y uno. Estas operaciones se distinguen de las transformaciones y la estandarización previas al entrenamiento, descritas en la Sección 4.5.

2.4.4. Resultados y desempeño

Simini et al. [Simini et al., 2021] evaluaron *Deep Gravity* sobre flujos censales de *commuting* en Inglaterra e Italia y flujos derivados de telefonía móvil en el estado de Nueva York,

utilizando la métrica *Common Part of Commuters* (CPC), definida como:

$$\text{CPC}(\hat{\mathbf{T}}, \mathbf{T}) = \frac{2 \sum_{i,j} \min(\hat{T}_{ij}, T_{ij})}{\sum_{i,j} \hat{T}_{ij} + \sum_{i,j} T_{ij}} \quad (15)$$

Cuando la masa del denominador es positiva, la métrica CPC toma valores en $[0, 1]$, donde 1 indica coincidencia exacta entre flujos generados y reales. Es equivalente al índice de Sørensen-Dice aplicado a flujos. En los experimentos publicados, *Deep Gravity* supera al modelo gravitatorio clásico en todos los contextos evaluados. Las mejoras en CPC global alcanzan hasta un 190 % en Inglaterra y un 1.066 % en el estado de Nueva York. El estudio también evaluó la transferencia geográfica. Entrenado en algunas ciudades del Reino Unido, mantuvo un desempeño similar al evaluarse en ciudades no vistas durante el entrenamiento. En el caso de Nueva York, la publicación aproxima la población mediante flujo saliente observado; esa decisión no se traslada a Santiago. La auditoría técnica del código no acredita por sí sola una reproducción integral de esos resultados.

2.4.5. Síntesis comparativa de modelos

La Tabla 1 resume las formulaciones examinadas en la literatura. Es una comparación bibliográfica, no una tabla de resultados experimentales de esta memoria. La calibración, los atributos y el comportamiento intraurbano dependen de la variante; la evidencia latinoamericana se limita a las fuentes revisadas.

La combinación de atributos territoriales explícitos, una función predictiva no lineal y la posibilidad de aplicar métodos de atribución motiva la evaluación de *Deep Gravity* en esta memoria. La comparación bibliográfica no establece por sí sola su superioridad en Santiago ni demuestra que estas capacidades sean exclusivas de esa arquitectura.

2.5. Explicabilidad en modelos de inteligencia artificial (XAI)

La explicabilidad de la inteligencia artificial (*eXplainable Artificial Intelligence*, XAI) se refiere al conjunto de técnicas que permiten comprender e interpretar las predicciones de modelos de aprendizaje automático complejos [Lundberg y Lee, 2017]. En el contexto de la planificación del transporte, la explicabilidad es relevante no solo desde el punto de vista académico, para estudiar cómo las variables de entrada contribuyen a las predicciones, sino también desde el punto de vista institucional, ya que permite a los planificadores auditar las predicciones del modelo.

Tabla 1: Comparación bibliográfica de modelos de flujos. Fuente: elaboración propia a partir de las referencias indicadas.

Modelo	Atributos considerados	Calibración	Escala intraurbana	Interpretación de la predicción	Evidencia latinoamericana
Gravitatorio clásico [Zipf, 1946, Rong <i>et al.</i> , 2024]	Población y distancia	Exponentes y disuasión	Evaluación según contexto	Formulación explícita	No documentada aquí
Oportunidades intervinientes [Stouffer, 1940, Liu y Yan, 2020]	Oportunidades y su distribución	Parámetro de absorción	Depende de la formulación	Formulación explícita	No documentada aquí
Radiación original [Simini <i>et al.</i> , 2012, Yan <i>et al.</i> , 2014]	Población como aproximación de oportunidades	Sin parámetros de forma	Limitaciones documentadas	Formulación explícita	No documentada aquí
Variantes de oportunidades intervinientes [Yan <i>et al.</i> , 2014, Liu y Yan, 2019]	Oportunidades, habitualmente aproximadas por población	Depende de la variante	Evaluadas en los contextos citados	Formulación explícita	No documentada aquí
Deep Gravity [Simini <i>et al.</i> , 2021]	Población, atributos territoriales y distancia	Pesos de la red	Evaluación según contexto	Atribución posterior, como SHAP	No documentada aquí

La última columna significa que no se documenta una validación de esa formulación en las fuentes utilizadas para esta comparación; no demuestra la inexistencia de otros estudios. Una formulación explícita facilita inspeccionar sus supuestos, pero no garantiza una explicación causal. SHAP incluye aproximaciones agnósticas al modelo y no es exclusivo de las redes profundas [Lundberg y Lee, 2017]. El artículo original de *Deep Gravity* ya incorpora un análisis SHAP; en esta memoria se evaluó de forma complementaria la viabilidad de trasladar análisis de atribuciones a Santiago.

2.5.1. Valores SHAP

SHAP (*SHapley Additive exPlanations*), propuesto por Lundberg y Lee [Lundberg y Lee, 2017], es un método de explicabilidad que fundamenta la importancia de cada variable en la teoría de juegos cooperativos de Shapley. La contribución de la característica i a la predicción del modelo para una instancia $\mathbf{x}$ se define como:

$$\phi_i(f, \mathbf{x}) = \sum_{S \subseteq \mathcal{F} \setminus \{i\}} \frac{|S|! (|\mathcal{F}| - |S| - 1)!}{|\mathcal{F}|!} [f(S \cup \{i\}) - f(S)] \quad (16)$$

donde $\mathcal{F}$ es el conjunto de todas las características, S es una coalición de características que no incluye a i , y $f(S)$ es la predicción del modelo usando solo las características en S . El valor ϕ_i representa la contribución marginal promedio de la característica i sobre todas las posibles coaliciones de características.

Los valores SHAP satisfacen tres propiedades deseables: *eficiencia* (la suma de todos los valores SHAP es igual a la diferencia entre la predicción y el valor base), *simetría* (características con igual contribución marginal reciben igual valor SHAP) y *dummy* (características sin influencia reciben valor cero). En conjunto, estas propiedades garantizan una atribución justa y consistente de importancias.

Los valores SHAP permiten estudiar la contribución de los atributos a una predicción con respecto a una referencia. En esta memoria, el análisis complementario incluyó aproximaciones de Shapley con referencias de entrenamiento y controles de estabilidad predefinidos. Ninguna de ellas produjo atribuciones que superaran todos los controles de publicación; por ello, el resultado se limita a la evaluación metodológica del procedimiento y no a una interpretación de la importancia de los atributos. En cualquier caso, las atribuciones se interpretan como propiedades de predicciones y no como efectos causales de intervenciones urbanas.

2.5.2. Gradientes integrados

Los *Integrated Gradients* [Sundararajan et al., 2017] son un método de atribución basado en el gradiente de la función del modelo con respecto a las variables de entrada. A diferencia de SHAP, que se fundamenta en la teoría de juegos cooperativos, los *Integrated Gradients* derivan las atribuciones directamente de la estructura diferencial de la red neuronal. Para una predicción $f(\mathbf{x})$ y una entrada de referencia $\mathbf{x}'$, la atribución de la característica i se define como:

$$\text{IG}_i(\mathbf{x}) = (x_i - x'_i) \cdot \int_0^1 \frac{\partial f(\mathbf{x}' + \alpha(\mathbf{x} - \mathbf{x}'))}{\partial x_i} d\alpha \quad (17)$$

El método satisface dos propiedades axiomáticas que lo distinguen de otras técnicas de atribución: *sensibilidad* (si la entrada y la referencia difieren en una sola característica y producen predicciones distintas, esa característica recibe atribución no nula) e *invariancia a la implementación* (la atribución depende únicamente de la función matemática que computa

la red, no de su arquitectura interna). Estas propiedades lo hacen complementario a SHAP, que satisface eficiencia, simetría y dummy.

La elección de la entrada de referencia $\mathbf{x}'$ es un aspecto crítico del método. El vector nulo ($\mathbf{x}' = \mathbf{0}$) es una convención habitual en clasificación de imágenes, pero su significado depende de las variables y de su preprocesamiento. Una densidad cartografiada puede ser cero; después de estandarizar, el valor cero representa la media de entrenamiento. La referencia debe definirse en el espacio de entrada del modelo y su elección requiere un análisis de sensibilidad. En Santiago, las referencias ensayadas se construyeron con orígenes de entrenamiento de cada rama para conservar la coherencia con las transformaciones del modelo.

Los gradientes integrados pueden considerarse una técnica complementaria para atribuir una salida diferenciable del modelo a sus entradas. En Santiago, el control de completitud no se acreditó para toda la cobertura requerida, incluso al aumentar la cuadratura en la consulta crítica; por ello, las atribuciones de este método no se interpretan como resultados de la memoria.

2.6. OpenStreetMap como fuente de datos geoespaciales

OpenStreetMap (OSM) es una base de datos geoespacial colaborativa y de libre acceso, construida y mantenida por una comunidad global de voluntarios desde su creación en 2004 [Haklay y Weber, 2008]. Su modelo de datos se articula en tres tipos de objetos geométricos: *nodos* (puntos), *vías* (secuencias de nodos que representan líneas o polígonos) y *relaciones* (agrupaciones de nodos y vías con un significado semántico compartido). Cada objeto puede llevar asociados pares clave-valor denominados *etiquetas* (*tags*), que codifican su naturaleza (por ejemplo, *amenity=hospital* o *landuse=residential*).

Para modelar flujos de movilidad, OpenStreetMap aporta atributos de uso del suelo, vialidad, equipamientos y servicios. En esta memoria, el término *amenities* se refiere a equipamientos y servicios urbanos; los atributos de OSM abarcan también información que no pertenece a ese conjunto. Los puntos de interés son una representación de algunas de estas entidades, mientras que otras se describen mediante áreas o líneas. La selección y construcción de los atributos empleados en Santiago se describe en la Sección 4.5.

Una limitación reconocida de OSM en el contexto latinoamericano es la heterogeneidad espacial de su cobertura. Estudios previos [Barrington-Leigh y Millard-Ball, 2017] han documentado que la densidad y completitud de los datos OSM varía significativamente según el nivel socioeconómico y la accesibilidad de las distintas áreas de una ciudad. En Santiago, esto se manifiesta en una mayor completitud en comunas de ingresos medios y altos, como Providencia, Las Condes y Vitacura, y menor cobertura en comunas periféricas de menores ingresos. Esta heterogeneidad es un factor metodológico relevante para esta memoria. Puede sesgar la estimación de las características geoespaciales de entrada al modelo en las zonas con menor presencia de datos voluntarios. Este aspecto se aborda en el análisis de

resultados.

2.7. Contexto de la movilidad en Santiago de Chile

El sistema integrado de transporte público de Santiago reúne buses, Metro y el servicio ferroviario Nos-Estación Central [Directorio de Transporte Público Metropolitano, 2025]. Su cobertura operativa y las distintas delimitaciones estadísticas de la ciudad no deben confundirse con el área de estudio, definida aquí como un núcleo urbano referencial de 34 comunas. La delimitación utilizada se describe en la Sección 4.3.

Las limitaciones de las fuentes de datos de movilidad disponibles para Santiago (la EOD de SECTRA y los registros de validación de la tarjeta bip!) se detallan en la Sección 1.1.

Esta memoria utiliza la entrega DTPM disponible entre el 1 y el 29 de noviembre de 2024. La unidad de análisis se reconstruye al unir viajes y etapas: las zonas y el factor de expansión principal provienen de viajes, mientras que las coordenadas UTM de subida y bajada se obtienen de etapas. La fuente permite construir matrices OD diarias y por período horario; los archivos del día 30 se excluyen por errores, sin imputación. Esta entrega constituye la principal fuente de flujos observados para el entrenamiento y la evaluación de *Deep Gravity* en Santiago.

CAPÍTULO 3

TRABAJO RELACIONADO

Este capítulo contrasta los supuestos, las necesidades de datos y las limitaciones de los enfoques de predicción de flujos origen-destino (OD) revisados en la literatura. El análisis fundamenta la elección de *Deep Gravity* como arquitectura para evaluar el desempeño predictivo con atributos geoespaciales y su sensibilidad a la discretización en Santiago.

3.1. Descubrimiento de patrones en la movilidad individual

Durante mucho tiempo, la falta de datos de trayectoria masivos obligó a los investigadores a extrapolar los patrones de movilidad humana a partir de la dispersión de billetes de banco [Brockmann *et al.*, 2006], asumiendo que los desplazamientos individuales seguían trayectorias puramente aleatorias y no acotadas, similares a los vuelos de Lévy (*Lévy flights*).

Este paradigma fue refutado por González *et al.* [González *et al.*, 2008], quienes utilizaron registros masivos de telefonía móvil (CDR, por sus siglas en inglés) de 100.000 usuarios durante seis meses para analizar la movilidad humana a nivel microscópico. Su trabajo demostró que, a diferencia del movimiento browniano o de los vuelos de Lévy, las trayectorias humanas son altamente predecibles, regulares y están fuertemente confinadas espacialmente. Los autores introdujeron el concepto de *radio de giro* para cuantificar la distancia típica recorrida por un individuo. Su análisis demostró que la aparente distribución pesada de saltos poblacionales es, en realidad, el resultado de agregar trayectorias individuales acotadas con una gran heterogeneidad en los radios de giro.

Esta contribución fue clave porque estableció que la movilidad urbana no es un fenómeno caótico, sino un sistema gobernado por rutinas (hogar-trabajo) y patrones espaciales predecibles. Esta previsibilidad estadística es la premisa fundamental que justifica el desarrollo de modelos matemáticos y algorítmicos para la predicción de flujos agregados.

3.2. Unificación de modelos clásicos y enfoques continuos

Con la confirmación de la regularidad en la movilidad humana, los esfuerzos se centraron en predecir los volúmenes de viaje entre distintas zonas de una ciudad o país. Tradicionalmente, este problema se abordó mediante el modelo gravitatorio [Zipf, 1946] y el modelo de oportunidades intervinientes [Stouffer, 1940]. Más tarde, el modelo de radiación [Simini *et al.*, 2012] ofreció una solución libre de parámetros que superaba varias limitaciones empíricas de la formulación gravitatoria.

Sin embargo, estos modelos presentaban un problema matemático estructural: dependían fuertemente de la partición espacial utilizada (comunas, distritos, censos), lo que generaba inconsistencias espaciales. Además, salvo casos triviales, las formulaciones discretas como el modelo gravitatorio violaban la propiedad de *aditividad* (el flujo hacia una región compuesta no siempre equivalía a la suma de los flujos hacia sus subregiones).

Para resolver esto, Simini, Maritan y Néda [Simini *et al.*, 2013] propusieron un marco unificado en el continuo. Los autores formularon un principio estocástico general de selección de beneficios laborales que preserva estrictamente la aditividad de los flujos. Además, demostraron que la gravedad, las oportunidades intervinientes y la radiación son, matemáticamente, casos particulares de una misma familia de procesos de selección espacial continua. Asimismo, introdujeron un parámetro de selección (λ) que flexibilizó el modelo de radiación para adaptarlo a diferentes escalas geográficas.

A pesar de su solidez teórica y elegancia matemática, este paradigma continuo arrastra una limitación fundamental de representación: asume que la cantidad de oportunidades en una región es estrictamente proporcional a su masa poblacional. En la realidad urbana, existe una profunda segregación funcional del suelo (zonas industriales, distritos financieros, áreas puramente residenciales) que rompe esta proporcionalidad lineal, exigiendo modelos capaces de entender el tejido urbano más allá de la simple aglomeración de personas.

3.3. Evolución de los modelos de oportunidades intervinientes

El concepto de oportunidades intervinientes de Stouffer [Stouffer, 1940] inspiró, a lo largo de las décadas siguientes, una familia de modelos cada vez más sofisticados que buscaron superar las limitaciones paramétricas y escalares del modelo original. Liu y Yan [Liu y Yan, 2020] ofrecen una revisión sistemática de esta evolución, identificando una línea de progresión que va desde el modelo de radiación hasta un marco unificado de comportamiento de destino. Esta sección sigue esa trayectoria, enfatizando los modelos más relevantes para el contexto intraurbano de la presente memoria.

3.3.1. Modelo de oportunidades ponderadas por población

Yan *et al.* [Yan *et al.*, 2014] identificaron en sus experimentos que el modelo de radiación falla sistemáticamente al predecir flujos dentro de una ciudad: sobreestima los flujos de corto alcance y subestima los de largo alcance intraurbano. Los autores argumentaron que el supuesto de selección secuencial por proximidad no refleja la realidad del viajero urbano, quien considera simultáneamente el conjunto completo de destinos disponibles en la ciudad.

Para corregir esto, Yan *et al.* [Yan *et al.*, 2014] propusieron el *Modelo de Oportunidades Ponderadas por Población* (Population-Weighted Opportunity, PWO), en el que la probabilidad

de elegir el destino j desde el origen i es proporcional a las oportunidades del destino e inversamente proporcional a las oportunidades totales dentro de un círculo centrado en el destino j con radio d_{ij} :

$$P_{ij} = \frac{m_j}{S_{ji}} \quad (18)$$

donde m_j es la cantidad de oportunidades (población) del destino j , y $S_{ji} = m_j + s_{ji} + m_i$ es el total de oportunidades dentro del círculo de radio d_{ij} centrado en j , incluyendo origen y destino. El cambio conceptual respecto al modelo de radiación es fundamental: en lugar de evaluar la competencia desde el origen, el modelo PWO evalúa la competencia desde el destino, capturando la lógica de atracción de un lugar sobre su entorno geográfico inmediato.

Al igual que el modelo de radiación, el modelo PWO es libre de parámetros: requiere únicamente la distribución de población de las zonas para generar predicciones, sin necesidad de calibración con datos históricos. Validado sobre datos de transporte público en múltiples ciudades chinas, el modelo PWO supera consistentemente al modelo de radiación en la predicción de viajes intraurbanos [Yan *et al.*, 2014]. Yan *et al.* [Yan *et al.*, 2017] extendieron posteriormente este modelo combinándolo con un proceso de caminata aleatoria con memoria, logrando reproducir simultáneamente los patrones de movilidad a nivel individual y los flujos agregados a nivel poblacional.

3.3.2. Modelos exploratorios: más allá de la selección secuencial

Tanto el modelo de radiación como el modelo PWO comparten un supuesto implícito sobre el comportamiento del viajero. Según la terminología introducida retrospectivamente por Liu y Yan [Liu y Yan, 2020] para clasificar los mecanismos de selección de destino, el modelo de radiación asume una *tendencia cautelosa*: el individuo elige el destino más cercano que supera el beneficio del origen. El modelo PWO también incorpora una lógica de competencia local. En ambos casos, la distancia juega un papel restrictivo en la selección.

Investigaciones posteriores mostraron que este supuesto no aplica universalmente. En el ámbito de los procesos de evaluación y selección social, Sim *et al.* [Sim *et al.*, 2015] identificaron un mecanismo alternativo al que denominaron *tendencia exploratoria*: los individuos que buscan el mejor resultado posible no se restringen a las opciones más cercanas, sino que aceptan recorrer distancias mayores si el destino ofrece un beneficio suficientemente alto. Liu y Yan [Liu y Yan, 2019] trasladaron formalmente este concepto al dominio de la movilidad espacial y propusieron el *Modelo de Selección Prioritaria de Oportunidades* (Opportunity Priority Selection), en el que un individuo en i elige el destino j si su beneficio supera tanto al del origen como al de todas las oportunidades intervinientes:

$$P_{ij} = \frac{m_j}{S_{ij}} = \frac{m_j}{m_i + s_{ij} + m_j} \quad (19)$$

donde $S_{ij} = m_i + s_{ij} + m_j$ es el total de oportunidades en el círculo de radio d_{ij} centrado en el origen i . Este modelo, al igual que el PWO, es libre de parámetros y fue validado con buenos resultados tanto para viajes intraurbanos como interurbanos.

3.3.3. Modelo Unificado de Oportunidades

La existencia de modelos con supuestos comportamentales tan distintos, el cauteloso modelo de radiación y el exploratorio modelo de selección prioritaria, planteó una pregunta natural: ¿qué modelo aplicar en cada contexto? Liu y Yan [Liu y Yan, 2020] respondieron esta pregunta proponiendo el *Modelo Unificado de Oportunidades* (Universal Opportunity Model), un marco general con dos parámetros que engloba a los modelos anteriores como casos especiales. La probabilidad de que un individuo en i elija el destino j se formula como:

$$P_{ij} = \frac{(m_i + \alpha s_{ij}) m_j}{[m_i + (\alpha + \beta) s_{ij}] [m_i + (\alpha + \beta) s_{ij} + m_j]} \quad (20)$$

donde $\alpha \geq 0$ es el parámetro de *tendencia exploratoria* (cuán dispuesto está el individuo a alejarse buscando mayor beneficio) y $\beta \geq 0$ es el parámetro de *tendencia cautelosa* (preferencia por destinos cercanos), sujetos a $\alpha + \beta \leq 1$. Los modelos previos emergen como casos particulares de esta formulación:

- Si $\alpha = 0, \beta = 1$: la ecuación (20) se reduce a la ecuación (7) del modelo de radiación (comportamiento puramente cauteloso).
- Si $\alpha = 1, \beta = 0$: la ecuación (20) se reduce a la ecuación (19) del modelo de selección prioritaria (comportamiento puramente exploratorio).

Liu y Yan [Liu y Yan, 2020] validaron el modelo sobre 14 conjuntos de datos de movilidad a distintas escalas: carga de mercancías, *commuting* interurbano (EE.UU., Italia, Hungría), búsqueda de empleo, migración, viajes entre ciudades y viajes intraurbanos (Berlín, Londres, Beijing, Shenzhen, Suzhou). Sus resultados revelan un patrón sistemático: los flujos de *commuting* y carga exhiben alta tendencia cautelosa (los individuos priorizan destinos cercanos de alto beneficio), mientras que los desplazamientos intraurbanos presentan valores bajos de ambos parámetros, indicando que la masa poblacional por sí sola es insuficiente para capturar la complejidad de la elección de destino en la ciudad. Este hallazgo es particularmente relevante para la presente memoria: sugiere que las variables de oportunidad basadas en población deben complementarse con atributos del tejido urbano para modelar adecuadamente los flujos en Santiago de Chile.

Aplicaciones colaterales. Más allá de la movilidad de transporte, esta familia de modelos ha demostrado versatilidad en otros dominios. En el campo de la epidemiología, modelos como el de radiación y el PWO han sido utilizados para estimar probabilidades de contacto entre poblaciones y parametrizar la difusión espacial de enfermedades infecciosas, incluyendo estudios sobre la propagación de COVID-19 [Liu y Yan, 2020]. Esta amplitud de aplicación evidencia la robustez conceptual del marco de oportunidades intervinientes.

3.4. Deep Learning y modelos espacio-temporales en movilidad

Para superar las limitaciones lineales y la dependencia exclusiva de la densidad poblacional, la literatura reciente ha migrado hacia el aprendizaje automático (*Machine Learning*) y el aprendizaje profundo (*Deep Learning*) [Rong et al., 2024]. Las arquitecturas neuronales han demostrado una capacidad superior para capturar la no linealidad del entorno urbano.

Un avance significativo en esta línea es la incorporación explícita de Puntos de Interés (POIs) y características del entorno construido como variables condicionantes. Por ejemplo, Luca et al. [Luca et al., 2024] propusieron el *framework* TS-Mob, que combina modelos fundacionales de series de tiempo (*TimesFM*) con un módulo de atractividad gravitacional basado en perceptrones multicapa (MLP). Este modelo integra 16 categorías de POIs extraídas de bases de datos abiertas. Ello permite modular la probabilidad de atracción estructural de un destino en función de la oferta real de servicios comerciales, educativos o de salud, y no únicamente de su población. Es importante distinguir este enfoque del de *Deep Gravity*: mientras TS-Mob integra estas categorías en un módulo de atractividad temporal, la adaptación de *Deep Gravity* de esta memoria utiliza un vector estático de atributos territoriales y distancia. Su composición y preprocesamiento se describen en la Sección 4.5.

No obstante, la transición hacia arquitecturas profundas introdujo nuevos desafíos. Las redes neuronales profundas y espaciales requieren enormes volúmenes de datos para evitar el sobreajuste y, más críticamente, operan como *cajas negras* [Rong et al., 2024]. Estos modelos reducen drásticamente el error absoluto medio (MAE) y mejoran la similitud estructural de flujos (CPC) respecto a los modelos clásicos. Sin embargo, la incapacidad de explicar por qué el modelo predice un flujo determinado limita su adopción institucional. Este aspecto es crítico en la planificación urbana pública.

3.5. Generación de flujos mediante datos no convencionales

En el estado del arte más reciente (2024-2025), la investigación ha explorado métodos para mitigar la dependencia de datos socioeconómicos hiperlocales o de costosas encuestas de transporte. Destaca el paradigma de inferencia mediante imágenes satelitales y modelos generativos de grafos.

Un estudio fundacional en esta línea metodológica es el de Xu et al. [Xu et al., 2025], quienes desarrollaron *Imagery2Flow*, un modelo que emplea aprendizaje contrastivo y Redes de Atención en Grafos (GAT) para predecir flujos a partir de imágenes satelitales. Su investigación utiliza a *Deep Gravity* como arquitectura de referencia en la literatura. Los autores demuestran que la versión con atributos espaciales (*Deep Gravity-V*) supera con claridad a la versión puramente poblacional (*Deep Gravity-P*). Este resultado respalda la utilidad predictiva de esos atributos en las condiciones evaluadas por los autores.

Posteriormente, Rong et al. [Rong et al., 2026] extendieron este paradigma de inferencia sa-

telital mediante *GLODGen*, un generador global de flujos OD basado en modelos de difusión (*Denoising Diffusion Networks*). Este *framework* utiliza un codificador visual multimodal (*RemoteCLIP*) para extraer un *embedding* semántico de 1.024 dimensiones directamente desde imágenes satelitales de alta resolución. Los autores reportan que el aspecto visual del entorno urbano y un mapa global de población poseen una expresividad superior al 98 % respecto al uso de datos multisectoriales complejos (catastros, POIs, atributos socioeconómicos). Su modelo, entrenado en Estados Unidos, demostró transferibilidad a ciudades de Europa, China, Brasil y África.

Estos modelos presentan barreras prácticas para su aplicación. Pueden conservar sesgos geográficos de los contextos donde fueron entrenados y su desempeño es, además, sensible a la calidad de las imágenes satelitales. La representación del territorio mediante *embeddings* puede dificultar la asociación directa entre los componentes aprendidos y categorías urbanas explícitas. Relacionar una predicción con equipamientos concretos requiere procedimientos de interpretación adicionales y validación; esa dificultad depende de la arquitectura, los datos y el método de explicación utilizado. El uso de estas representaciones para analizar intervenciones urbanas exigiría validación adicional; las atribuciones de una predicción no establecen por sí solas el efecto de una intervención.

En el contexto latinoamericano, los antecedentes de aplicación de modelos computacionales para la generación de flujos son escasos. Spadon et al. [Spadon et al., 2019] reconstruyeron redes de *commuting* en la región metropolitana de São Paulo utilizando *random forests* e indicadores urbanos municipales, demostrando la viabilidad de enfoques basados en aprendizaje automático para ciudades de la región. Sin embargo, su trabajo emplea arquitecturas de baja complejidad, no incorpora *amenities* de OpenStreetMap como variables explicativas y no incluye técnicas de explicabilidad. Las fuentes revisadas no permiten anticipar el desempeño de la adaptación de *Deep Gravity* al transporte público de Santiago ni permiten suponer que las atribuciones serán estables; la viabilidad de ese análisis se examina específicamente en esta memoria.

3.6. En Resumen

La revisión permite comparar los supuestos, las necesidades de datos y las posibilidades de interpretación de los modelos:

- Los modelos físicos y estadísticos clásicos (Secciones 3.1 y 3.2) ofrecen formulaciones explícitas; algunos marcos continuos incorporan propiedades de aditividad [Simini et al., 2013]. Las versiones basadas en población y distancia restringen de antemano la relación entre esas variables y el flujo, mientras que otras formulaciones amplían sus atributos y supuestos.
- Los modelos de oportunidades intervinientes (Sección 3.3) han dado lugar a formulaciones con distintos supuestos de selección de destino y requisitos de calibración. En

las variantes revisadas, la población suele utilizarse como aproximación de las oportunidades, lo que limita la descripción de actividades urbanas específicas.

- Los modelos basados en aprendizaje profundo, series de tiempo e imágenes satelitales (Secciones 3.4 y 3.5) han mostrado capacidad predictiva en los contextos y protocolos evaluados por los estudios citados. Sus necesidades de cómputo y la interpretación de sus salidas dependen de la arquitectura, de los atributos y del método de explicación.

En este contexto metodológico, el uso del modelo *Deep Gravity* [Simini *et al.*, 2021], alimentado con datos de OpenStreetMap (OSM), motiva una evaluación conjunta de capacidad predictiva y representación espacial en Santiago de Chile. La memoria también evaluó, como componente complementario, la viabilidad de atribuir predicciones mediante métodos inspirados en SHAP [Lundberg y Lee, 2017] y gradientes integrados.

Por un lado, *Deep Gravity* reemplaza la rigidez heurística de los exponentes gravitacionales por una red neuronal profunda capaz de capturar relaciones no lineales entre el territorio y los flujos. A diferencia de los *embeddings* satelitales, utiliza variables explícitas y semánticamente interpretables provistas por OSM: centros de salud, red vial, escuelas y comercio. Por otro lado, su arquitectura permite aplicar métodos de explicabilidad como SHAP. Esta combinación permite formular un análisis de las predicciones y de sus atributos de entrada, pero no garantiza que sus atribuciones sean estables. La evaluación predictiva y el resultado no validado del análisis de atribuciones se establecen en los capítulos siguientes.

CAPÍTULO 4

PROPUESTA DE SOLUCIÓN

Este capítulo especifica el procedimiento reproducible para estudiar la sensibilidad de *Deep Gravity* frente a la discretización espacial en Santiago. La comparación no presupone que una representación supere a otra: construye las ramas Zona 777, H3-r7 y H3-r8 a partir de una cohorte común, con atributos, particiones y protocolo de evaluación explícitos. Se distinguen un piloto de un día, destinado a comprobar la factibilidad del recorrido, y un experimento mensual agregado, destinado a la evaluación principal. Ambos comparten decisiones estructurales, pero difieren en su escenario, normalización, presupuesto y regla de liberación de prueba.

4.1. Diseño general y trazabilidad

La solución parte de registros DTPM de viajes y etapas, reconstruye extremos válidos a nivel de viaje y aplica una delimitación territorial común. A continuación, dos adaptadores espaciales asignan esos mismos viajes a zonas operativas DTPM o a celdas H3. Cada rama recibe atributos externos, forma pares origen-destino y utiliza la misma familia de modelos y reglas de evaluación. La Figura 2 resume esta separación entre núcleo común y adaptadores.




Figura 2: Procedimiento de Santiago: un núcleo común de viajes precede a los adaptadores espaciales y a la evaluación. Fuente: elaboración propia.

La variable de respuesta es el flujo observado agregado entre una unidad de origen i y una unidad de destino j . La población censal, el flujo saliente observado, el factor de expansión y los atributos de OSM son magnitudes distintas: el flujo saliente permite reconstruir la masa predicha condicionada al origen, pero no se incorpora como sustituto de población ni como predictor científico.

4.2. Datos de movilidad y reconstrucción del viaje

La entrega DTPM disponible comprende 29 fechas, desde el 1 al 29 de noviembre de 2024. Los archivos del día 30 llegaron con errores y se excluyen sin imputación. La unidad observacional utilizada en la comparación es un viaje canónico, no una validación aislada. La unión diaria validada vincula viajes.(id_tarjeta, id_viaje) con etapas.(id_etapa, correlativo_viajes). El origen se reconstruye desde la primera etapa y el destino desde una bajada válida de la etapa final; las coordenadas UTM de ambos extremos residen en etapas, no en viajes.

La cohorte primaria exige una secuencia completa y sin duplicados de etapas, numeradas desde uno hasta el número declarado para el viaje. El origen corresponde a la primera etapa y el destino a la bajada de la última; esta debe tener tiene_bajada=1 y el viaje debe indicar ultimaetapaconbajada=1. Se requieren zonas de origen y destino disponibles y factor_expansion no negativo. Como control técnico previo al recorte territorial, las coordenadas de ambos extremos deben satisfacer $100,000 \leq X \leq 900,000$ y $5,000,000 \leq Y \leq 10,000,000$, en metros. Estos rangos no definen el área de estudio.

El factor de expansión de viajes es el peso principal para los flujos expandidos; el conteo sin expansión se conserva para el análisis de sensibilidad. La Tabla 2 distingue procedencia y función de los insumos para evitar confundir pesos, coordenadas y variables explicativas.

Tabla 2: Fuentes de datos y función de las variables usadas por el procedimiento. Fuente: elaboración propia.

Insumo	Contenido o unidad	Uso y regla de trazabilidad
viajes DTPM	Identificadores del viaje, zonas consolidadas, secuencia y factor_expansion.	Aporta la identidad del viaje, las zonas de la rama zonal y la masa expandida. No aporta coordenadas UTM de los extremos.
etapas DTPM	Identificadores de etapa y viaje; coordenadas UTM de subida y bajada.	Permite reconstruir origen y destino válidos y asignar H3 tras transformar EPSG:32719 a WGS84.
ShapeZona 777 DTPM	Geometría oficial de zonas y sus identificadores.	Sustenta área, centroides y atributos de las zonas; no se fabrican polígonos para IDs sin geometría verificable.
Censo 2024 (INE)	Población de manzanas y entidades de la Región Metropolitana.	Se interpola por fracción de área en EPSG:32719 y se expresa por unidad espacial. No equivale a generación observada.
OSM Chile 2024-01-01	Polígonos, vías y puntos del extracto histórico.	Aporta coberturas y densidades utilizadas como atributos territoriales; un cero representa ausencia cartografiada, no prueba de ausencia real.

Para un escenario temporal dado, el flujo expandido se agrega como

$$T_{ij} = \sum_{v \in \mathcal{V}_{ij}} w_v, \quad (21)$$

donde $\mathcal{V}_{ij}$ reúne los viajes canónicos entre i y j , y w_v es el peso expandido del viaje v . Las tablas OD operativas conservan, por separado, `trip_count` y `expanded_mass`; no incluyen identificadores personales.

4.3. Delimitación territorial y cohorte común

El dominio de estudio es el núcleo urbano referencial de 34 comunas. Cada extremo UTM debe estar estrictamente contenido en una de las geometrías comunales DPA 2023 proyectadas a EPSG:32719; los puntos ubicados en un límite se excluyen por la regla `contains`. El filtro territorial retiene 60.513.881 viajes de la cohorte primaria y 85.777.662,9386 de masa expandida. La Figura 3 documenta esa decisión territorial.




Figura 3: Delimitación del área de estudio: núcleo urbano referencial de 34 comunas dentro de la Región Metropolitana. Las cifras de la figura corresponden al filtro territorial previo a la exclusión común posterior de tres zonas sin polígono oficial verificable. Fuente: elaboración propia. Los datos territoriales y el procedimiento se describen en esta sección.

Después del recorte territorial se excluyen, en las tres ramas, los 1.904 viajes que tienen al menos un extremo en las zonas 848, 849 o 852, ya que no disponen de polígono oficial verificable para construir atributos. La cohorte comparativa resultante contiene 60.511.977

viajes y 85.774.522,4070 de masa expandida. Esta exclusión se aplica antes de agregar OD y no se reemplaza mediante geometrías de otra codificación.

4.4. Adaptadores espaciales, unidades y *tiles*

La rama Zona 777 usa las zonas de origen y destino auditadas en el viaje canónico y la geometría oficial publicada por DTPM. La rama H3 transforma las coordenadas válidas desde EPSG:32719 a WGS84 con `always_xy=True` y asigna cada extremo mediante `latlng_to_cell`. La política de borde conserva la celda H3 completa observada: los viajes se recortan por el dominio de estudio, pero las huellas de las celdas no se recortan ni se reparte flujo por superficie.

H3 es un sistema jerárquico de índices geoespaciales. Sus áreas y distancias varían geográficamente, existen pentágonos y la vecindad no puede resumirse como seis vecinos para toda celda. Por ello, H3 no elimina el problema de la unidad espacial modificable (MAUP, por sus siglas en inglés): la comparación trata la discretización espacial como una fuente de sensibilidad empírica. El análisis de factibilidad consideró H3-r3 a H3-r8; H3-r7 y H3-r8 pasaron al piloto junto con Zona 777. La Tabla 3 presenta las representaciones operativas de la cohorte común, sin inferir superioridad entre ellas.

Tabla 3: Representaciones espaciales operativas después de la exclusión común. Fuente: elaboración propia.

Rama	Unidades	Rol	Regla de asignación y alcance
Zona 777	793 zonas	Referencia zonal	Zonas de origen y destino del viaje canónico; atributos calculados desde la geometría oficial verificable.
H3-r7	223 celdas	Candidata de escala más agregada	Ambos extremos válidos se asignan directamente a celdas H3; mantiene celdas completas en el borde.
H3-r8	1.210 celdas	Candidata de mayor detalle	Misma regla de asignación H3 y misma cohorte fuente; su mayor desagregación modifica el soporte OD.

Una zona o celda es una unidad OD. Un *tile* es un bloque mayor, de 15.000 m de lado en EPSG:32719, indexado por $\text{floor}(x/15000)$ y $\text{floor}(y/15000)$. Se fijaron diez *tiles* comunes y una agenda determinista con semilla 20260909: siete para entrenamiento, dos para validación y uno para prueba. La partición se aplica al origen; todos los destinos del dominio de estudio, incluidos los de otros *tiles* o particiones, permanecen candidatos y los flujos cruzados se conservan. La Figura 4 distingue estos objetos y evita equiparar un *tile* con una unidad OD.



Figura 4: Escalas espaciales del procedimiento. Cada rama representa el mismo dominio mediante sus propias unidades OD; el *tile* es un bloque de partición mayor y no reemplaza a una zona o celda. Esquema no a escala. Fuente: elaboración propia.

4.5. Construcción de atributos y vector de entrada

La configuración principal utiliza 19 variables por ubicación y, para un par OD, forma un vector de 39 entradas: 19 del origen, 19 del destino y una distancia. Incluye densidad de población censal, cinco coberturas de uso de suelo, tres densidades de longitud vial y cinco familias de servicios, cada una medida mediante densidad de puntos y cobertura de áreas. Se conserva una configuración alternativa para diagnóstico, con 20 variables por ubicación y 41 entradas por par, que no reemplaza la configuración principal del piloto.

$$\mathbf{x}_{ij} = [\mathbf{a}_i^{(19)}, \mathbf{a}_j^{(19)}, d_{ij}], \quad (22)$$

donde $\mathbf{a}_i$ y $\mathbf{a}_j$ contienen los atributos externos de origen y destino, respectivamente, y d_{ij} es la distancia geodésica calculada desde representantes espaciales en WGS84. La población se interpola desde Censo 2024 a las unidades y se divide por su área para construir la densidad de entrada a la red; no se reemplaza por el flujo saliente observado.

Los polígonos y las vías se recortan y unen dentro de cada categoría antes de calcular cobertura o longitud. Los puntos requieren pertenencia estricta a la unidad. Para densidades y tasas se aplica $\log_{1p}$; las coberturas mantienen su escala física antes de estandarizar. Media y desviación estándar se estiman solo con orígenes activos de entrenamiento de cada rama y escenario, y luego se aplican a validación y prueba. Esta regla impide que el conjunto de prueba intervenga en la normalización.

El piloto ajustó esta transformación con los orígenes activos del 5 de noviembre de 2024. En contraste, el experimento principal recalculó y verificó independientemente la normalización mensual a partir de los atributos sin normalizar y de sus propios orígenes de entrenamiento; no reutilizó los parámetros del piloto. Las variables constantes reciben escala uno. Por tanto, una coincidencia de diccionario de atributos no supone que las transformaciones numéricas de ambos escenarios sean intercambiables.

4.6. Modelo, muestreo y evaluación

4.6.1. Relación con el modelo gravitatorio

El *softmax* de una utilidad sistemática V_{ij} define la probabilidad de destino

$$p_{ij} = \frac{\exp(V_{ij})}{\sum_{k \in \mathcal{D}_i} \exp(V_{ik})}, \quad (23)$$

donde $\mathcal{D}_i$ es el soporte de destinos permitido para el origen i . Si $V_{ij} = \beta_1 \ln(P_j) + \beta_2 \ln(d_{ij})$, el *softmax* induce una forma de potencia $P_j^{\beta_1} d_{ij}^{\beta_2}$; no induce una disuasión exponencial. Una forma gravitatoria exponencial requiere, por ejemplo, una utilidad coherente $V_{ij} = \alpha \ln(P_j) - \beta d_{ij}$ [McFadden, 1974, Ortúzar y Willumsen, 2011].

Deep Gravity reemplaza la utilidad lineal por una función no lineal aprendida $f_\theta(\mathbf{x}_{ij})$. El teorema de aproximación universal respalda una capacidad de representación bajo sus supuestos, pero no garantiza que una arquitectura concreta se optimice, generalice o supere a un *baseline* con datos finitos [Hornik, 1991].

4.6.2. Arquitectura, soporte y pérdida

La implementación efectiva conserva 15 capas ocultas: cinco de ancho 256 y diez de ancho 128, con activaciones LeakyReLU. No usa BatchNorm y el *dropout* efectivo es 0,0 en la ruta vigente. La capa final produce un *score* por destino candidato. La arquitectura heredada y la corrida técnica de Nueva York se mantienen como antecedentes de compatibilidad, no como demostración de desempeño científico para Santiago.

El muestreador general permite limitar el número de destinos por origen, sin reposición, y reservar una fracción de candidatos con flujo positivo. Los candidatos restantes se eligen uniformemente entre los disponibles, por lo que pueden incluir otros destinos con flujo positivo. Esa opción no se utilizó en el piloto ni en el experimento mensual: tanto el entrenamiento como la evaluación usaron el soporte completo de destinos de cada representación. Los destinos de todo el dominio metropolitano permanecieron disponibles aunque correspondieran a otro *tile* o partición.

La pérdida es la log-verosimilitud multinomial negativa ponderada por la masa elegida:

$$\mathcal{L} = - \sum_i \sum_{j \in \mathcal{D}_i} y_{ij} \log p_{ij}. \quad (24)$$

Para conteos enteros, minimizar esta expresión equivale a maximizar la log-verosimilitud multinomial, salvo constantes independientes del modelo. Con masa expandida fraccionaria, se interpreta como una pérdida multinomial ponderada, con el soporte de destinos y

los pesos definidos para el análisis. Su relación con la formulación de entropía de Wilson es conceptual y requiere restricciones adicionales; no se identifica automáticamente con maximizar la entropía de Wilson [Wilson, 1970].

4.6.3. Modelos de referencia, particiones y métricas

Las tres referencias se ajustan solamente con los flujos cuyos orígenes pertenecen a entrenamiento y se evalúan sobre los mismos orígenes, destinos y masa que la red dentro de cada rama. La referencia uniforme asigna $1/|\mathcal{D}|$ a cada destino del soporte. La referencia de atracción usa la masa expandida recibida durante entrenamiento:

$$\hat{y}_{ij} = O_i \frac{A_j^{\text{train}} + \lambda}{\sum_{k \in \mathcal{D}} A_k^{\text{train}} + \lambda |\mathcal{D}|}, \quad \lambda = 1. \quad (25)$$

donde A_j^{train} es la masa que llega a j desde los orígenes de entrenamiento, $\mathcal{D}$ es el soporte completo de destinos de la rama y O_i es el flujo saliente observado del origen que se evalúa. El pseudoconteo λ corresponde a una unidad de masa por destino. Esta referencia distribuye una salida observada; no es población, ni un atributo de la red, ni una estimación de la generación de viajes.

En el modelo gravitatorio exponencial, la utilidad se calcula como

$$V_{ij} = \alpha \ln(1 + P_j) + \beta d_{ij}, \quad \alpha \geq 0, \quad \beta \leq 0, \quad (26)$$

donde P_j es la población total interpolada, recuperada multiplicando la densidad censal por el área de la unidad, y d_{ij} es la distancia esférica en kilómetros. Los parámetros se ajustan exclusivamente con los flujos de entrenamiento mediante una pérdida multinomial ponderada y L-BFGS-B, inicializado en $(1, -0.1)$, con un máximo de 500 iteraciones, $ftol = 10^{-12}$ y $gtol = 10^{-8}$; se imponen $\alpha \geq 0$ y $\beta \leq 0$. Esta variable del modelo de referencia se distingue de la densidad de población transformada y estandarizada que recibe la red. La distancia intrazonal o intracelda es cero, valor admisible en la disuasión exponencial.

El piloto verificó la comparación contra estas tres referencias en el mismo soporte de cada rama. El *checkpoint* se selecciona por CPC de validación; la prueba se ejecuta después y no ajusta parámetros. La configuración del piloto usa RMSprop, tasa de aprendizaje 5×10^{-6} , momento 0.9, lotes de ocho orígenes y 15 épocas. Estos valores son una configuración de piloto registrada, no una selección definitiva de hiperparámetros para el experimento mensual.

La métrica principal es

$$\text{CPC} = \frac{2 \sum_{ij} \min(T_{ij}, \hat{T}_{ij})}{\sum_{ij} T_{ij} + \sum_{ij} \hat{T}_{ij}}. \quad (27)$$

Se guardan numerador y ambas masas por origen para agregar CPC global y por *tile* sobre el mismo soporte. Las medias por origen, por todos los *tiles* y condicionadas a CPC positivo

se reportan separadamente. El piloto de Santiago confirma que el procedimiento se puede ejecutar y repetir con tres semillas, pero una comparación directa de CPC entre resoluciones no demuestra por sí sola superioridad de H3: cambian la agregación, los representantes espaciales y la masa de prueba entre ramas.

4.6.4. Piloto y experimento mensual

El piloto utilizó el martes 5 de noviembre de 2024. Incluyó diagnósticos en una muestra, en el día completo y en tres ventanas horarias, y nueve corridas estables del día completo: tres ramas y las semillas 20260909, 20260910 y 20260911. Cada corrida estable se entrenó durante 15 épocas; el mejor *checkpoint* de validación se conservó y se evaluó posteriormente en prueba. Las ventanas y el número de épocas sirvieron para comprobar la factibilidad y estabilidad iniciales, no para establecer convergencia, ajustar hiperparámetros ni generalizar el comportamiento de un día al período mensual.

El experimento principal agrega las 29 fechas disponibles entre el 1 y el 29 de noviembre de 2024; el día 30 se excluye por problemas en los archivos y no se imputa. Se entrenaron nueve modelos desde inicializaciones nuevas: las tres ramas y las mismas tres semillas. La red, el soporte completo y la pérdida fueron los descritos antes. El optimizador fue RMS-prop con tasa 5×10^{-6} , momento 0,9, $\alpha = 0,99$, $\epsilon = 10^{-8}$, sin decaimiento de pesos ni centrado; se usaron lotes de ocho orígenes en orden estable y sin barajado. Las corridas se ejecutaron secuencialmente en CPU con cuatro hilos. Cada época evaluó todos los orígenes de validación.

La selección del *checkpoint* y la parada anticipada obedecieron a reglas diferentes. Se conservó el *checkpoint* con el mayor CPC global de validación entre todas las épocas ejecutadas y, ante un empate exacto, el primero. Para la parada, la primera época de validación inicializó una referencia significativa; esta se actualizó solo si el CPC posterior era estrictamente mayor que la referencia más 0,0001. Tras un mínimo de 50 épocas, la corrida se detenía cuando acumulaba 30 épocas sin esa mejora significativa. El límite inicial fue 200 épocas: alcanzarlo sin meseta no se interpretaba como convergencia ni autorizaba una extensión automática.

Dos corridas alcanzaron dicho límite y recibieron una autorización previa a la prueba para continuar, sin reinicializar ni alterar datos, particiones, arquitectura, optimizador, métrica o regla de selección. La continuación elevó el máximo a 300 épocas para Zona 777 con semilla 20260909 y H3-r8 con semilla 20260910. Ambas cerraron posteriormente por la misma regla de meseta, en las épocas 226 y 218, respectivamente; sus *checkpoints* seleccionados permanecieron en las épocas 196 y 188. Las demás corridas cerraron con la configuración inicial. La prueba se liberó una sola vez después de congelar las fuentes, las decisiones de validación y los *checkpoints* seleccionados; no intervino en la elección de época, semilla, parámetros o representación.

Como análisis de sensibilidad de la evaluación, las probabilidades ya congeladas se aplicaron

también a los conteos OD sin expansión y se reescalaron por el flujo saliente no expandido de cada origen. El CPC resultante es secundario: no implica reentrenamiento sin pesos, nueva selección ni un nuevo ajuste de los modelos de referencia, cuyos parámetros se obtuvieron con la masa expandida.

4.7. Análisis complementario de atribuciones predictivas

Después de congelar los modelos mensuales se evaluó la viabilidad de explicar la log-probabilidad condicional de un destino dentro del soporte completo de cada origen. Los representantes se escogieron por la mediana del CPC de validación de cada rama, sin usar el CPC de prueba ni la apariencia de una atribución. Las referencias se construyeron exclusivamente con orígenes de entrenamiento de la rama correspondiente; la función explicada, la muestra y los controles se fijaron antes de cada ejecución. Se ensayaron gradientes integrados con cuadratura Gauss-Legendre [Sundararajan *et al.*, 2017], SHAP por permutaciones agrupadas y valores de Shapley exactos para grupos jerárquicos [Lundberg y Lee, 2017]. En todos los casos las atribuciones se definieron como sensibilidad predictiva dependiente de la referencia, no como efectos causales.

Las tres aproximaciones se evaluaron contra controles de integridad, coincidencia entre el adaptador y la salida del modelo, finitud, convergencia o eficiencia según el método, repetibilidad y estabilidad frente a fondos independientes. Los gradientes integrados no acreditaron completitud para una consulta crítica aun con 4.096 nodos. El método por permutaciones no acreditó estabilidad entre fondos en dos de tres semillas de su primera consulta obligatoria. El método exacto jerárquico acreditó una primera consulta a 24 fondos, pero otra consulta crítica no acreditó la estabilidad de los tres supergrupos a 24 ni a 48 fondos. En consecuencia, ninguna aproximación superó todos los controles requeridos para publicar atribuciones. No se presentan rankings, atribuciones, figuras SHAP ni casos locales; los registros técnicos se conservan como respaldo reproducible y el desenlace se desarrolla en el Capítulo 5.

4.8. Reproducibilidad, alcances y limitaciones

Cada ejecución conserva configuración efectiva, semillas, versiones, hashes de entradas y código, particiones, métricas y *checkpoint* en un directorio exclusivo. Los productos de datos, las especificaciones de procesamiento y los registros de ejecución permiten verificar la conservación de masa y reconstruir la procedencia de cada corrida. La prueba espacial se mantiene reservada durante la selección; el conjunto de prueba no participa en la normalización ni en el ajuste de hiperparámetros.

El alcance se limita a la movilidad observable en DTPM durante las 29 fechas disponibles de noviembre de 2024 y al dominio de estudio de 34 comunas. No representa todos los mo-

dos urbanos, no predice la generación total de viajes por origen ni fechas futuras. El piloto no acredita por sí mismo generalización temporal al período mensual. A su vez, el agregado mensual incluye el 5 de noviembre y reutiliza la misma geografía de prueba, por lo que no constituye una prueba enteramente nueva e independiente del piloto. Las tres semillas caracterizan variación de inicialización bajo una sola partición espacial, no incertidumbre espacial o poblacional. La instantánea OSM antecede a los viajes y su cobertura no equivale a presencia real de servicios; la interpolación areal del Censo 2024 supone distribución uniforme dentro de cada geometría censal. Además, la exclusión de las zonas sin polígono, la decisión de discretización y las diferencias de agregación espacial condicionan toda interpretación comparativa.

El resultado del análisis complementario de explicabilidad limita la interpretación de las características territoriales: bajo las configuraciones ensayadas no fue posible obtener atribuciones suficientemente estables para una interpretación sustantiva. Esta limitación no altera las métricas predictivas ni las comparaciones con referencias, que se fundamentan en su propio protocolo de evaluación.

CAPÍTULO 5

VALIDACIÓN DE LA SOLUCIÓN

CAPÍTULO 6

CONCLUSIONES

Las Conclusiones son, según algunos especialistas, el aspecto principal de una memoria, ya que reflejan el aprendizaje final del autor del documento. En ellas se tiende a considerar los alcances y limitaciones de la propuesta de solución, establecer de forma simple y directa los resultados, discutir respecto a la validez de los objetivos formulados, identificar las principales contribuciones y aplicaciones del trabajo realizado, así como su impacto o aporte a la organización o a los actores involucrados. Otro aspecto que tiende a incluirse son recomendaciones para quienes se sientan motivados por el tema y deseen profundizarlo, o lineamientos de una futura ampliación del trabajo.

Todo esto debe sintetizarse en al menos 5 páginas.

ANEXOS

En los Anexos se incluye todo aquel material complementario que no es parte del contenido de los capítulos de la memoria, pero que permiten a un lector contar con un contenido adjunto relacionado con el tema.

REFERENCIAS BIBLIOGRÁFICAS

- [Barrington-Leigh y Millard-Ball, 2017] Barrington-Leigh, C. y Millard-Ball, A. (2017). The world's user-generated road map is more than 80 % complete. *PLOS ONE*, 12(8):e0180698.
- [Brockmann *et al.*, 2006] Brockmann, D., Hufnagel, L., y Geisel, T. (2006). The scaling laws of human travel. *Nature*, 439(7075):462–465.
- [Directorio de Transporte Público Metropolitano, 2025] Directorio de Transporte Público Metropolitano (2025). Informe de gestión 2024. Informe institucional sobre el año 2024, Ministerio de Transportes y Telecomunicaciones, Gobierno de Chile. Sección 2.2, p. 33. Consultado el 19 de septiembre de 2026.
- [González *et al.*, 2008] González, M. C., Hidalgo, C. A., y Barabási, A.-L. (2008). Understanding individual human mobility patterns. *Nature*, 453(7196):779–782.
- [Haklay y Weber, 2008] Haklay, M. y Weber, P. (2008). OpenStreetMap: User-generated street maps. *IEEE Pervasive Computing*, 7(4):12–18.
- [Herfort *et al.*, 2023] Herfort, B., Lautenbach, S., Porto de Albuquerque, J., Anderson, J., y Zipf, A. (2023). A spatio-temporal analysis investigating completeness and inequalities of global urban building data in OpenStreetMap. *Nature Communications*, 14(1):3985.
- [Hornik, 1991] Hornik, K. (1991). Approximation capabilities of multilayer feedforward networks. *Neural Networks*, 4(2):251–257.
- [Kang *et al.*, 2015] Kang, C., Liu, Y., Guo, D., y Qin, K. (2015). Generalized radiation model for human mobility: spatial scale, searching direction and trip constraint. *PLOS ONE*, 10(11):e0143500.
- [Liu y Yan, 2019] Liu, E.-J. y Yan, X.-Y. (2019). Opportunity priority selection model for human mobility. *Physica A: Statistical Mechanics and its Applications*, 526:121023.
- [Liu y Yan, 2020] Liu, E.-J. y Yan, X.-Y. (2020). Research advances in intervening opportunity class models for predicting human mobility. *Acta Physica Sinica*, 69(24):248901.
- [Luca *et al.*, 2024] Luca, M., Beneduce, C., y Lepri, B. (2024). TS-Mob: Social and geographical-aware time series foundation-model framework for human mobility prediction. *arXiv preprint arXiv:2412.09180*.
- [Lundberg y Lee, 2017] Lundberg, S. M. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems*, volumen 30. Curran Associates, Inc.
- [Marín-Flores *et al.*, 2026] Marín-Flores, C., Ferres, L., y Tenkanen, H. (2026). When proximity falls short: Inequalities in commuting and accessibility by public transport in Santiago, Chile. *Geographical Analysis*, 58(2):e70039.

- [McFadden, 1974] McFadden, D. (1974). Conditional logit analysis of qualitative choice behavior. En Zarembka, P., editor, *Frontiers in Econometrics*, pp. 105–142. Academic Press, New York.
- [Ortúzar y Willumsen, 2011] Ortúzar, J. d. D. y Willumsen, L. G. (2011). *Modelling Transport*. John Wiley & Sons, Chichester, 4 edici n.
- [Pappalardo et al., 2023] Pappalardo, L., Simini, F., Barlacchi, G., y Pellungrini, R. (2023). scikit-mobility: a python library for the analysis, generation and risk assessment of mobility data. *Journal of Statistical Software*, 103(4):1–38.
- [Ren et al., 2014] Ren, Y., Ercsey-Ravasz, M., Wang, P., González, M. C., y Toroczkai, Z. (2014). Predicting commuter flows in spatial networks using a radiation model based on temporal ranges. *Nature Communications*, 5(1):5347.
- [Rong et al., 2024] Rong, C., Ding, J., y Li, Y. (2024). An interdisciplinary survey on origin-destination flows modeling: Theory and techniques. *ACM Computing Surveys*, 57(1):1–38.
- [Rong et al., 2026] Rong, C., Zhang, X., Xi, Y., SUI, H., Ding, J., y Li, Y. (2026). Satellites reveal mobility: A commuting origin-destination flow generator for global cities. En *The Thirty-ninth Annual Conference on Neural Information Processing Systems Datasets and Benchmarks Track*.
- [Sim et al., 2015] Sim, A., Yaliraki, S. N., Barahona, M., y Stumpf, M. P. (2015). Modelling the effects of subjective and objective decision making in scientific peer review. *Journal of The Royal Society Interface*, 12(107):20150315.
- [Simini et al., 2021] Simini, F., Barlacchi, G., Luca, M., y Pappalardo, L. (2021). A deep gravity model for mobility flows generation. *Nature Communications*, 12(1):6576.
- [Simini et al., 2012] Simini, F., González, M. C., Maritan, A., y Barabási, A.-L. (2012). A universal model for mobility and migration patterns. *Nature*, 484(7392):96–100.
- [Simini et al., 2013] Simini, F., Maritan, A., y Néda, Z. (2013). Human mobility in a continuum approach. *PloS one*, 8(3):e60069.
- [Spadon et al., 2019] Spadon, G., de Carvalho, A. C. P. L. F., Rodrigues-Jr, J. F., y Alves, L. G. A. (2019). Reconstructing commuters network using machine learning and urban indicators. *Scientific Reports*, 9:11801.
- [Stouffer, 1940] Stouffer, S. A. (1940). Intervening opportunities: a theory relating mobility and distance. *American Sociological Review*, 5(6):845–867.
- [Sundararajan et al., 2017] Sundararajan, M., Taly, A., y Yan, Q. (2017). Axiomatic attribution for deep networks. En *Proceedings of the 34th International Conference on Machine Learning*, volumen 70, pp. 3319–3328. PMLR.

- [Vecchio *et al.*, 2020] Vecchio, G., Tiznado-Aitken, I., y Hurtubia, R. (2020). Transport and equity in Latin America: a critical review of socially oriented accessibility assessments. *Transport Reviews*, 40(3):354–381.
- [Wilson, 1970] Wilson, A. G. (1970). *Entropy in Urban and Regional Modelling*. Pion, London.
- [Xu *et al.*, 2025] Xu, Y., Gao, S., Huang, Q., Göçmen, A., Zhu, Q., y Zhang, F. (2025). Predicting human mobility flows in cities using deep learning on satellite imagery. *Nature Communications*, 16:10372.
- [Yan *et al.*, 2017] Yan, X.-Y., Wang, W.-X., Gao, Z.-Y., y Lai, Y.-C. (2017). Universal model of individual and population mobility on diverse spatial scales. *Nature Communications*, 8(1):1639.
- [Yan *et al.*, 2014] Yan, X.-Y., Zhao, C., Fan, Y., Di, Z., y Wang, W.-X. (2014). Universal predictability of mobility patterns in cities. *Journal of The Royal Society Interface*, 11(100):20140834.
- [Yang *et al.*, 2014] Yang, Y.-X., Herrera, C., Eagle, N., y González, M. C. (2014). Limits of predictability in human mobility. *Scientific Reports*, 4(1):5662.
- [Zipf, 1946] Zipf, G. K. (1946). The P1 P2/D hypothesis: on the intercity movement of persons. *American Sociological Review*, 11(6):677–686.