

UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA
DEPARTAMENTO DE INFORMÁTICA
SANTIAGO - CHILE



“GENERACIÓN DE FLUJOS DE MOVILIDAD EN
SANTIAGO DE CHILE MEDIANTE DEEP GRAVITY:
EVALUACIÓN DEL IMPACTO DE LAS AMENITIES DE
OPENSTREETMAP Y ANÁLISIS MEDIANTE XAI”

PABLO ALBERTO CAMPOS ÁVILA

MEMORIA PARA OPTAR AL TÍTULO DE
INGENIERO CIVIL EN INFORMÁTICA

Profesor Guía: Daniela Opitz
Profesor Correferente: Nombre del correferente NN2

Julio - 2026

DEDICATORIA

Considerando la importancia de este trabajo para los alumnos, este apartado es para que el autor entregue palabras personales para dedicar este documento. La extensión puede ser de máximo una hoja y se deben mantener este formato, tipo y tamaño de letra.

AGRADECIMIENTOS

Considerando la importancia de este trabajo para los alumnos, este apartado se podrá incluir en el caso de que el autor desee agradecer a las personas que facilitaron alguna ayuda relevante en su trabajo para la realización de este documento. La extensión puede ser de máximo una hoja y se deben mantener este formato, tipo y tamaño de letra.

RESUMEN

Resumen— El resumen y las palabras clave no deben superar la mitad de la página, donde debe precisarse brevemente: 1) lo que el autor ha hecho, 2) cómo lo hizo (sólo si es importante detallarlo), 3) los resultados principales, 4) la relevancia de los resultados. El resumen es una representación abreviada, pero comprensiva de la memoria y debe informar sobre el objetivo, la metodología y los resultados del trabajo realizado.

Palabras Clave— Cinco es el máximo de palabras clave para describir los temas tratados en la memoria, ponerlas separadas por punto y comas.

ABSTRACT

Abstract— Corresponde a la traducción al idioma inglés del Resumen anterior. Sujeto a la misma regla de extensión del Resumen.

Keywords— Corresponde a la traducción al idioma inglés de Palabras Clave anteriores.

GLOSARIO

Aquí se deben colocar las siglas mencionadas en el trabajo y su explicación, por orden alfabético. Por ejemplo:

DI: Departamento de Informática.

UTFSM: Universidad Técnica Federico Santa María.

ÍNDICE DE CONTENIDOS

RESUMEN	IV
ABSTRACT	IV
GLOSARIO	V
ÍNDICE DE FIGURAS	VIII
ÍNDICE DE TABLAS	VIII
INTRODUCCIÓN	1
CAPÍTULO 1: DEFINICIÓN DEL PROBLEMA	2
1.1 Fuentes de datos actuales y sus limitaciones	2
1.2 Limitaciones de los modelos vigentes	3
1.3 Especificidad del contexto latinoamericano	3
1.4 Síntesis del problema	3
1.5 Árbol del problema	4
1.6 Objetivo General	5
1.7 Objetivos Específicos	5
CAPÍTULO 2: MARCO CONCEPTUAL	6
2.1 Movilidad urbana y flujos origen-destino	6
2.2 Modelos clásicos de generación de flujos	7
2.2.1 Modelo gravitatorio	7
2.2.2 Modelo de oportunidades intervinientes	8
2.2.3 Modelo de radiación	9
2.3 Aprendizaje profundo aplicado a la movilidad	10
2.4 Deep Gravity	11
2.4.1 Formulación matemática	11
2.4.2 Arquitectura de la red neuronal	12
2.4.3 Vector de características geoespaciales	12
2.4.4 Resultados y desempeño	12
2.5 Explicabilidad en modelos de inteligencia artificial (XAI)	13
2.5.1 Valores SHAP	13
2.5.2 Gradientes integrados	14
2.6 OpenStreetMap como fuente de datos geoespaciales	14
2.7 Contexto de la movilidad en Santiago de Chile	15
CAPÍTULO 3: TRABAJO RELACIONADO	16
3.1 Descubrimiento de patrones en la movilidad individual	16
3.2 Unificación de modelos clásicos y enfoques continuos	16
3.3 Evolución de los modelos de oportunidades intervinientes	17

3.3.1	Modelo de oportunidades ponderadas por población	17
3.3.2	Modelos exploratorios: más allá de la selección secuencial	18
3.3.3	Modelo Unificado de Oportunidades	19
3.4	Deep Learning y modelos espacio-temporales en movilidad	20
3.5	Generación de flujos mediante datos no convencionales	20
3.6	En Resumen	21
CAPÍTULO 4: PROPUESTA DE SOLUCIÓN		23
4.1	EJEMPLO DE COMO CITAR FIGURAS E ILUSTRACIONES	23
CAPÍTULO 5: VALIDACIÓN DE LA SOLUCIÓN		24
5.1	EJEMPLO DE COMO CITAR TABLAS	24
CAPÍTULO 6: CONCLUSIONES		25
ANEXOS		26
REFERENCIAS BIBLIOGRÁFICAS		27

ÍNDICE DE FIGURAS

1	Diagrama del árbol del problema. Fuente: Elaboración propia.	4
2	Malla Curricular Ingeniería Civil Informática.	23

ÍNDICE DE TABLAS

1	Coloquios del Ciclo de Charlas Informática.	24
---	---	----

INTRODUCCIÓN

Los flujos de movilidad origen-destino (OD) cuantifican el número de personas que se desplazan entre dos ubicaciones geográficas en un período de tiempo definido. Constituyen un insumo central para la planificación del transporte, la gestión de emergencias y el diseño de políticas urbanas [Rong *et al.*, 2024a]. Obtener estos datos mediante observación directa es costoso y poco frecuente. Esta limitación ha motivado el desarrollo de modelos generativos capaces de estimar flujos OD a partir de características observables del territorio, permitiendo extrapolar predicciones a contextos donde no existen datos de encuesta.

La estimación de flujos OD cuenta con una tradición extensa en la geografía cuantitativa. Modelos clásicos como el gravitacional [Zipf, 1946], el de oportunidades intermedias [Stouffer, 1940] y el de radiación [Simini *et al.*, 2012] han dominado históricamente esta área. Estos modelos comparten limitaciones conocidas: dependen de un conjunto reducido de variables explicativas y no capturan relaciones no lineales entre el tejido urbano y los flujos observados. El Marco Conceptual de esta memoria detalla la formulación de estos modelos y sus restricciones. Más recientemente, la incorporación de redes neuronales profundas ha permitido superar parte de estas limitaciones, dando origen a modelos como Deep Gravity [Simini *et al.*, 2021], cuya arquitectura y validación también se describen en el Marco Conceptual.

Deep Gravity ha sido validado sobre ciudades del Norte Global, pero no existe evidencia de su aplicación en una metrópolis latinoamericana. Tampoco ha sido evaluado sobre datos posteriores a la pandemia de COVID-19. Esta memoria aplica Deep Gravity para generar flujos de movilidad en Santiago de Chile a partir de datos abiertos de OpenStreetMap, implementándolo sobre la biblioteca *scikit-mobility* [Pappalardo *et al.*, 2023]. El trabajo evalúa el impacto de las categorías de *amenities* de OpenStreetMap sobre la precisión de las predicciones. Además, aplica la técnica SHAP (*SHapley Additive exPlanations*) [Lundberg y Lee, 2017] para interpretar la contribución de las características urbanas a los flujos estimados. Con ello, la memoria aporta la primera aplicación conocida de Deep Gravity a una ciudad latinoamericana, junto con un análisis de explicabilidad de sus predicciones sobre el tejido urbano de Santiago.

El resto del documento se organiza en cinco capítulos. El Capítulo 1 (Definición del Problema) diagnostica las brechas actuales en la estimación de flujos de movilidad en Santiago y establece los objetivos de la memoria. El Capítulo 2 (Marco Conceptual) presenta los fundamentos teóricos de los modelos de movilidad y detalla la arquitectura de Deep Gravity. El Capítulo 3 (Propuesta de Solución) describe la construcción del dataset, la adaptación del modelo y el diseño experimental. El Capítulo 4 (Validación de la Solución) presenta los resultados obtenidos y su comparación con los modelos baseline. Finalmente, el Capítulo 5 (Conclusiones) discute los hallazgos y propone líneas de trabajo futuro.

CAPÍTULO 1

DEFINICIÓN DEL PROBLEMA

Santiago posee uno de los sistemas de transporte público más avanzados de América Latina. Se caracteriza por la integración de buses, metro y tren suburbano. Este sistema registra más de tres millones de transacciones diarias solo en el modo bus [DPTM, 2025]. La red de movilidad de la ciudad conecta a una población metropolitana que supera los siete millones de habitantes, distribuida en más de cuarenta comunas.

Comprender la distribución espacial de los desplazamientos en esta red, representada mediante flujos origen-destino (OD), es un insumo esencial para la planificación del transporte. También lo es para el diseño de infraestructura vial y la formulación de políticas urbanas basadas en evidencia [Rong *et al.*, 2024a].

1.1. Fuentes de datos actuales y sus limitaciones

La planificación del transporte en Santiago se apoya actualmente en dos fuentes principales de datos de movilidad. La primera es la *Encuesta Origen-Destino* (EOD) de SECTRA¹. Su última versión fue levantada en 2012, con actualizaciones parciales en 2017. Esta encuesta constituye la referencia canónica de flujos de movilidad en la ciudad. Sin embargo, su periodicidad de siete a diez años implica que los datos disponibles pueden no reflejar la movilidad actual. Esto es especialmente relevante tras la reconfiguración de patrones de desplazamiento producida por la pandemia de COVID-19. Su elevado costo de levantamiento agrava además esta desactualización.

La segunda fuente son los datos anonimizados de validación de la *tarjeta bip*², administrados por el DTPM³. Estos datos registran validaciones en Metro y buses con alta resolución temporal. No obstante, no cubren etapas caminadas. Tampoco cubren viajes en taxi o colectivo pagados en efectivo, ni modos no motorizados.

Esta brecha entre la necesidad de datos actualizados y su disponibilidad real motiva el desarrollo de modelos generativos. Dichos modelos deben ser capaces de estimar flujos OD a partir de características observables del territorio, sin depender exclusivamente de encuestas o registros transaccionales.

¹Secretaría de Planificación del Transporte, organismo dependiente del Ministerio de Transportes y Telecomunicaciones de Chile.

²Nombre oficial del sistema de tarificación electrónica del transporte público de Santiago.

³Directorio de Transporte Público Metropolitano.

1.2. Limitaciones de los modelos vigentes

Los modelos utilizados en la práctica para la estimación de flujos en Santiago corresponden a modelos de gravedad clásicos. Estos modelos presentan limitaciones ampliamente documentadas en la literatura [Zipf, 1946, Simini *et al.*, 2012, Rong *et al.*, 2024a]. Imponen relaciones paramétricas monótonas entre población, distancia y flujo, lo que genera un ajuste deficiente ante fenómenos no lineales, como la existencia de subcentros de empleo o corredores de transporte masivo. Requieren además calibración manual para cada contexto geográfico, lo que limita su transferibilidad. Finalmente, no incorporan como variables explicativas el tejido urbano: puntos de interés, uso de suelo ni infraestructura de transporte.

Modelos basados en aprendizaje profundo, como Deep Gravity [Simini *et al.*, 2021], han demostrado superar estas limitaciones incorporando variables geoespaciales de OpenStreetMap. Su arquitectura y su desempeño reportado se detallan en el Marco Conceptual de esta memoria. Sin embargo, su aplicación en ciudades latinoamericanas no ha sido explorada.

1.3. Especificidad del contexto latinoamericano

Esta ausencia de validación es relevante porque las ciudades latinoamericanas presentan características estructurales que las diferencian de los contextos donde estos modelos han sido desarrollados y evaluados. Entre ellas se cuentan la segregación socioeconómica, la coexistencia de sistemas de transporte formales e informales y diferencias en la completitud de los datos geoespaciales de OpenStreetMap entre regiones del mundo [Barrington-Leigh y Millard-Ball, 2017]. Estas diferencias impiden anticipar si un modelo como Deep Gravity mantendría su desempeño al ser aplicado sobre Santiago.

Más allá del contexto geográfico, el modelo carece de una capa de explicabilidad que permita a los planificadores comprender qué factores del tejido urbano impulsan cada predicción.

1.4. Síntesis del problema

En síntesis, el problema que aborda esta memoria se formula de la siguiente manera:

La planificación del transporte en Santiago de Chile opera con estimaciones de flujos OD basadas en datos desactualizados y modelos paramétricos que no capturan la complejidad del tejido urbano. Modelos basados en aprendizaje profundo, como Deep Gravity, han demostrado superar estas limitaciones, pero su aplicación en ciudades latinoamericanas no ha sido explorada. Se desconoce tanto su capacidad predictiva en este contexto como la contribución de las amenities

urbanas a la generación de flujos. Asimismo, la ausencia de técnicas de explicabilidad sobre estos modelos impide que los planificadores comprendan los factores que determinan las predicciones.

1.5. Árbol del problema

A continuación se presenta el diagrama del árbol del problema (Figura 1):




Figura 1: Diagrama del árbol del problema. Fuente: Elaboración propia.

La Figura 1 presenta el árbol del problema que resume los principales desafíos asociados a la estimación de movilidad en el Gran Santiago. En el centro se sitúa el problema fundamental: la inexactitud y obsolescencia en la estimación de flujos de movilidad urbana.

Este problema se origina por cuatro causas principales: la desactualización y cobertura incompleta de fuentes de datos tradicionales (EOD y bip!), la rigidez de los modelos gravitacionales clásicos al omitir variables del tejido urbano, los supuestos teóricos simplistas basados únicamente en distancia y masa poblacional, y la falta de validación y explicabilidad de modelos de Deep Learning en el contexto regional.

Como consecuencia, se generan cuatro efectos críticos: decisiones de inversión en infraestructura basadas en datos obsoletos, la incapacidad de anticipar el impacto de intervenciones territoriales, la opacidad en la decisión pública junto a la subutilización de datos masivos

y abiertos, y una asignación ineficiente de recursos públicos con políticas desalineadas de la dinámica urbana real.

1.6. Objetivo General

Generar flujos de movilidad origen-destino en Santiago de Chile mediante el modelo Deep Gravity, evaluando el impacto de las *amenities* de OpenStreetMap sobre la precisión de las predicciones y analizando la contribución de las variables geoespaciales mediante técnicas de Inteligencia Artificial Explicable (XAI).

1.7. Objetivos Específicos

1. Reproducir y adaptar el modelo Deep Gravity sobre el dataset de referencia del repositorio original, validando el pipeline y las métricas reportadas, para garantizar la trazabilidad y reproducibilidad del proceso.
2. Caracterizar el dataset de viajes y etapas de noviembre de 2024 del DTPM y construir una tessellation cuadrada para el Gran Santiago, evaluando la sensibilidad de los resultados ante distintas resoluciones de grilla (**500 m, 1 km, 2 km y 5 km**).
3. Extraer las *amenities* de OpenStreetMap para el área de estudio, utilizando el conjunto de categorías del paper original y evaluando la pertinencia de un conjunto extendido adaptado a las características del tejido urbano latinoamericano.
4. Entrenar y evaluar el modelo Deep Gravity sobre Santiago, comparando cuantitativamente su desempeño con el de los modelos de gravedad clásico y de radiación mediante la métrica CPC (*Common Part of Commuters*) y su descomposición espacial por *tile*.
5. Cuantificar el impacto de las *amenities* de OSM sobre el desempeño del modelo mediante la técnica SHAP (*SHapley Additive exPlanations*), determinando la importancia global y local de cada categoría de *amenity* en la generación de flujos.
6. *Analizar la sensibilidad de las explicaciones obtenidas (valores SHAP) frente a la escala de agregación espacial de la grilla y a las distintas temporalidades del flujo (períodos punta y fuera de punta), discutiendo la coherencia de las amenities identificadas con las dinámicas socioespaciales de Santiago.*

CAPÍTULO 2

MARCO CONCEPTUAL

Este capítulo presenta los fundamentos teóricos y técnicos en que se apoya esta memoria. Se introducen, en primer lugar, los conceptos centrales de movilidad urbana y flujos origen-destino. Luego se describen los modelos clásicos de generación de flujos, que constituyen la base histórica del problema y los *baselines* de esta investigación. A continuación se expone cómo el aprendizaje profundo ha permitido superar las limitaciones de esos modelos, culminando en la arquitectura *Deep Gravity*. El capítulo continúa con los fundamentos de la explicabilidad de modelos de inteligencia artificial mediante SHAP, la descripción de OpenStreetMap como fuente de datos geospaciales, y concluye con el contexto de la movilidad en Santiago de Chile.

2.1. Movilidad urbana y flujos origen-destino

La movilidad urbana comprende el conjunto de desplazamientos que realizan las personas entre distintas ubicaciones de la ciudad en un período de tiempo determinado [Rong *et al.*, 2024a]. Comprender estos desplazamientos es un insumo fundamental para la planificación del transporte, el diseño de infraestructura vial y la formulación de políticas públicas basadas en evidencia.

Una representación sintética y cuantitativa de la movilidad urbana es la matriz origen-destino (matriz OD). Formalmente, dado un conjunto de n zonas geográficas $\mathcal{Z} = \{z_1, z_2, \dots, z_n\}$ que particionan el área de estudio, el flujo T_{ij} representa el número de viajes que se realizan desde la zona de origen z_i hasta la zona de destino z_j en un intervalo de tiempo fijo:

$$\mathbf{T} \in \mathbb{R}^{n \times n}, \quad T_{ij} \geq 0 \quad \forall i, j \in \{1, \dots, n\} \quad (1)$$

La colección de todos los flujos posibles entre pares de zonas conforma la matriz OD. Cada fila i representa los flujos salientes desde una zona de origen, y cada columna j los flujos entrantes hacia una zona de destino.

Obtener la matriz OD mediante observación directa, a través de encuestas domiciliarias, aforos de tráfico o registros de tarjetas de pago, es costoso y poco frecuente. Esta limitación ha motivado el desarrollo de modelos generativos de flujos, capaces de estimar $\mathbf{T}$ a partir de características observables del territorio, como la distribución de la población o la presencia de equipamientos urbanos, sin depender exclusivamente de mediciones directas [Simini *et al.*, 2021].

El problema de generación de flujos se formula de la siguiente manera: dado un conjunto de zonas $\mathcal{Z}$, sus características geospaciales y los flujos totales salientes por zona $O_i = \sum_j T_{ij}$, estimar los flujos por par origen-destino $\hat{T}_{ij}$ para todos los pares (i, j) .

2.2. Modelos clásicos de generación de flujos

La estimación de flujos origen-destino cuenta con una tradición extensa en la geografía cuantitativa. Los modelos que se describen a continuación han dominado históricamente esta área y constituyen los *baselines* de referencia en esta memoria.

2.2.1. Modelo gravitatorio

El modelo gravitatorio de movilidad establece una analogía con la ley de gravitación universal de Newton. La aplicación de este principio a los fenómenos sociales cuenta con antecedentes desde el siglo XIX. Posteriormente, Zipf [Zipf, 1946] lo formalizó en 1946 para la predicción de flujos. Su formulación postula que el volumen de desplazamientos entre dos zonas es directamente proporcional al producto de sus masas (habitualmente la población) e inversamente proporcional a la distancia que las separa:

$$T_{ij} = k \cdot \frac{P_i^\alpha \cdot P_j^\beta}{d_{ij}^\gamma} \quad (2)$$

donde P_i y P_j son las poblaciones de las zonas de origen y destino, d_{ij} es la distancia entre sus centroides, k es una constante de proporcionalidad, y α, β, γ son parámetros que deben calibrarse con datos observados. Zipf verificó empíricamente esta relación mediante datos de tráfico de buses, ferrocarriles y llamadas telefónicas entre ciudades de Estados Unidos. Los coeficientes obtenidos se aproximan a la unidad en todos los casos.

La formulación de la ecuación (2) recibe el nombre de *modelo de gravedad no restringido*. En la práctica, para garantizar que los flujos generados sean consistentes con los totales salientes observados, se utiliza la versión *restringida en origen* (*singly-constrained*), que normaliza los flujos de cada origen sobre todos sus destinos posibles:

$$\hat{T}_{ij} = O_i \cdot \frac{P_j^\beta f(d_{ij})}{\sum_k P_k^\beta f(d_{ik})} \quad (3)$$

donde $O_i = \sum_j T_{ij}$ es el flujo total saliente de la zona i y $f(d_{ij})$ es una función de disuasión por distancia, que puede adoptar forma exponencial ($e^{\beta_2 d}$) o de ley de potencia (d^{β_2}).

El modelo gravitatorio presenta limitaciones ampliamente documentadas [Rong et al., 2024a]. Su formulación impone una relación paramétrica monótona entre población, distancia y flujo, lo que restringe su capacidad de representar fenómenos no lineales. No incorpora variables del tejido urbano como puntos de interés, uso de suelo o infraestructura de transporte. Requiere además calibración manual para cada contexto geográfico, lo que limita su transferibilidad. La implicancia concreta de estas restricciones para el caso de Santiago se detalla en la Sección de Definición del Problema de esta memoria.

2.2.2. Modelo de oportunidades intervinientes

Stouffer [Stouffer, 1940] propuso en 1940 una perspectiva alternativa al modelo gravitatorio, argumentando que la distancia no es en sí misma el factor determinante de la movilidad, sino que actúa como un contenedor espacial de oportunidades. Su hipótesis central es que el número de personas que se desplazan a una zona de destino es directamente proporcional al número de oportunidades en ese destino e inversamente proporcional al número de oportunidades intervinientes entre el origen y el destino.

Formalmente, sea y el número de personas que se desplazan desde un origen hasta una banda circular de anchura Δs , y sea x el número acumulado de oportunidades entre el origen y la distancia s . Stouffer postula:

$$\Delta y = a \cdot \frac{\Delta x}{x} \quad (4)$$

Integrando esta expresión diferencial, el número total de personas que se detienen dentro de un círculo de radio s desde el origen es:

$$y = a \cdot \ln f(s) + c \quad (5)$$

donde $f(s)$ es el número acumulado de oportunidades dentro de ese radio y c es una constante de integración. Stouffer verificó empíricamente esta formulación con datos de movilidad residencial en Cleveland, Ohio (1933-1935). Los resultados muestran una buena correspondencia entre los flujos observados y los predichos por el modelo.

Liu y Yan [Liu y Yan, 2020] formalizaron y extendieron esta familia de modelos de manera rigurosa. Para describir su funcionamiento, es necesario precisar tres conceptos fundamentales:

- **Oportunidades de un lugar (m_l):** cantidad de oportunidades que ofrece el lugar l para satisfacer el propósito del desplazamiento. En la práctica se asume que m_l es proporcional a la población del lugar.
- **Oportunidades intervinientes (s_{ij}):** suma de oportunidades de todos los lugares cuya distancia al origen i es menor que d_{ij} , excluyendo el propio origen i y el destino j . Si se incluyen origen y destino se utiliza la notación $S_{ij} = m_i + s_{ij} + m_j$.
- **Valor de beneficio de una oportunidad (z):** utilidad o recompensa que una oportunidad reporta al viajero. Se modela como variable aleatoria continua con distribución $p(z)$.

El modelo de Stouffer establece que cada individuo que parte del origen i ordena todos los destinos potenciales por distancia creciente y se detiene en cada lugar con una probabilidad

fija proporcional al parámetro α . Bajo este mecanismo, la probabilidad de que un individuo en i elija el destino j adopta la forma [Stouffer, 1940, Liu y Yan, 2020]:

$$P_{ij} = \frac{e^{-\alpha(S_{ij}-m_j)} - e^{-\alpha S_{ij}}}{1 - e^{-\alpha M}} \quad (6)$$

donde m_j es la cantidad de oportunidades del destino j , S_{ij} es el total de oportunidades en el círculo de radio d_{ij} centrado en i (incluyendo origen y destino), α es el parámetro de absorción a calibrar con datos históricos, y $M = \sum_k m_k$ es el total de oportunidades del sistema. La ecuación (6) muestra que la probabilidad de elegir j crece con las oportunidades del destino m_j y decrece con el número de oportunidades intervinientes s_{ij} : cuanto mayor es la competencia en el camino, menor la probabilidad de alcanzar el destino.

La principal limitación del modelo original de Stouffer es que contiene el parámetro α , que debe calibrarse mediante datos históricos de flujo observado. Esta dependencia paramétrica restringe su aplicabilidad cuando no se dispone de matrices OD previas, y motivó el desarrollo de modelos libres de parámetros basados en el mismo concepto de oportunidades intervinientes.

2.2.3. Modelo de radiación

Simini et al. [Simini et al., 2012] propusieron en 2012 el modelo de radiación como una alternativa libre de parámetros al modelo gravitatorio. El modelo establece una analogía con los procesos de radiación y absorción en física de partículas. Su mecanismo se basa en un proceso estocástico de toma de decisiones locales: cada individuo en un origen busca la mejor oportunidad disponible dentro de radios geográficos crecientes y se desplaza hacia el destino donde la encuentra.

El mecanismo es el siguiente. Se asigna a cada oportunidad un valor de beneficio z extraído de una distribución de probabilidad $p(z)$. La probabilidad de que un individuo en la zona i elija la zona j como destino es la probabilidad de que el mejor beneficio dentro de j supere al mejor beneficio disponible dentro del círculo de radio d_{ij} centrado en i (excluyendo i y j). Esta probabilidad es:

$$p(n_j | m_i, s_{ij}) = \frac{m_i n_j}{(m_i + s_{ij})(m_i + n_j + s_{ij})} \quad (7)$$

donde m_i es la población de la zona de origen i , n_j es la población de la zona de destino j , y s_{ij} es la población total dentro de un círculo de radio d_{ij} centrado en i , excluyendo las poblaciones de i y de j . El flujo esperado entre i y j es entonces:

$$\langle T_{ij} \rangle = T_i \cdot \frac{m_i n_j}{(m_i + s_{ij})(m_i + n_j + s_{ij})} \quad (8)$$

donde $T_i = \sum_j T_{ij}$ es el flujo total saliente de la zona i . Una propiedad destacable del modelo de radiación es que satisface automáticamente la restricción de conservación de flujos: $\sum_j \langle T_{ij} \rangle = T_i$, sin necesidad de calibración de parámetros adicionales.

Simini et al. [Simini et al., 2012] validaron el modelo sobre datos de commuting del censo de Estados Unidos (2000). Los resultados muestran que el modelo de radiación supera al modelo gravitatorio en la reproducción de flujos observados, especialmente en viajes de corta distancia, que el modelo gravitatorio tiende a sobreestimar.

Variantes del modelo de radiación. La solidez del modelo original motivó diversas extensiones para adaptar su mecanismo a diferentes contextos. Ren et al. [Ren et al., 2014] propusieron una versión basada en tiempo de viaje en lugar de distancia euclidiana, incorporando así la resistencia real de la red de transporte. Kang et al. [Kang et al., 2015] formularon un modelo de radiación generalizado que introduce parámetros de escala y restricciones explícitas de producción y atracción, mejorando la precisión en contextos con heterogeneidad espacial marcada. Yang et al. [Yang et al., 2014] extendieron el modelo para incorporar la distribución no homogénea de oportunidades en el espacio, relevante en regiones con alta segregación funcional del suelo.

Limitación del modelo de radiación a escala intraurbana. A pesar de su éxito en la predicción de commuting interurbano, el modelo de radiación presenta una limitación estructural cuando se aplica a la escala intraurbana [Yan et al., 2014, Liu y Yan, 2020]. Su supuesto central —que cada individuo elige el destino más cercano cuyo beneficio supera al del origen— refleja adecuadamente el comportamiento en la búsqueda de empleo a larga distancia (donde la proximidad es costosa), pero no captura la lógica real de los desplazamientos dentro de una ciudad. En entornos urbanos, las personas consideran simultáneamente el conjunto de destinos disponibles en toda la ciudad, sin restringirse a los más cercanos. Estudios empíricos sobre datos de transporte público en diversas ciudades confirman que el modelo de radiación subestima sistemáticamente los flujos intraurbanos de largo alcance [Yan et al., 2014]. Esta limitación fue el punto de partida para el desarrollo del modelo de oportunidades ponderadas por población, descrito en la Sección 3.3, y justifica el uso de modelos capaces de representar el tejido urbano más allá de la simple distribución poblacional, como *Deep Gravity*.

A pesar de sus ventajas, el modelo de radiación utiliza exclusivamente la población como *proxy*⁴ de oportunidades, sin incorporar características del tejido urbano como el uso de suelo o la distribución de actividades económicas. Esta limitación fue el punto de partida para el desarrollo de modelos basados en aprendizaje profundo.

⁴Una variable proxy es una medida indirecta que se emplea en sustitución de una variable inobservable, asumiendo que existe una fuerte correlación estadística entre ambas.

2.3. Aprendizaje profundo aplicado a la movilidad

El aprendizaje profundo (*deep learning*) es un subcampo del aprendizaje automático que utiliza redes neuronales con múltiples capas de transformaciones no lineales para aprender representaciones jerárquicas de los datos [Rong et al., 2024a]. Su aplicación a la predicción de flujos de movilidad ha permitido incorporar un conjunto amplio de variables geoespaciales y capturar relaciones no lineales que los modelos clásicos no pueden representar.

Una red neuronal *feedforward* (de propagación hacia adelante) con L capas ocultas transforma un vector de entrada $\mathbf{x} \in \mathbb{R}^d$ mediante una secuencia de transformaciones afines seguidas de funciones de activación no lineales:

$$\mathbf{z}^{(0)} = \sigma(W^{(0)} \mathbf{x}), \quad \mathbf{z}^{(\ell)} = \sigma(W^{(\ell)} \mathbf{z}^{(\ell-1)}), \quad \ell = 1, \dots, L-1 \quad (9)$$

donde $W^{(\ell)}$ es la matriz de pesos de la capa ℓ y $\sigma(\cdot)$ es la función de activación, comúnmente ReLU ($\max(0, x)$) o su variante LeakyReLU ($\max(\alpha x, x)$ con α pequeño), que mitiga el problema del gradiente desvanecido en redes profundas.

En el contexto de la generación de flujos, el aprendizaje profundo ha sido aplicado de múltiples formas: como extensión no lineal del modelo gravitatorio [Simini et al., 2021], mediante redes neuronales de grafos que modelan la estructura espacial de las zonas, y mediante modelos de series de tiempo que capturan la evolución temporal de los flujos [Luca et al., 2024]. Esta memoria se enfoca en el primero de estos enfoques, implementado a través del modelo *Deep Gravity*.

2.4. Deep Gravity

Deep Gravity es un modelo de generación de flujos de movilidad propuesto por Simini et al. [Simini et al., 2021] en 2021. Su contribución central es demostrar que el modelo gravitatorio clásico restringido en origen (ecuación 3) es formalmente equivalente a una red neuronal lineal de una sola capa con salida *softmax*, y que reemplazar esa capa lineal por una red neuronal profunda permite capturar relaciones no lineales entre las características del territorio y los flujos observados.

2.4.1. Formulación matemática

El modelo gravitatorio restringido en origen puede reescribirse como un modelo lineal generalizado con distribución multinomial. Para un origen i , la probabilidad de que un viaje se dirija al destino j es:

$$p_{ij} = \frac{\exp(\beta^\top \mathbf{x}(l_i, l_j))}{\sum_k \exp(\beta^\top \mathbf{x}(l_i, l_k))} \quad (10)$$

donde $\mathbf{x}(l_i, l_j) = [\ln P_j, d_{ij}]$ es el vector de características del par (i, j) , y $\beta = [\beta_1, \beta_2]$ son los parámetros del modelo. Esta formulación es entrenada maximizando la log-verosimilitud multinomial, cuya función de pérdida es equivalente a la entropía cruzada:

$$H = - \sum_i \sum_j \frac{T_{ij}}{O_i} \ln p_{ij} \quad (11)$$

Deep Gravity reemplaza el producto interno lineal $\beta^\top \mathbf{x}(l_i, l_j)$ por una red neuronal profunda $f_\theta(\mathbf{x}(l_i, l_j))$ que produce un score escalar. Las probabilidades de destino se obtienen mediante *softmax* sobre los scores de todos los destinos candidatos desde el origen i :

$$p_{ij} = \frac{\exp(f_\theta(\mathbf{x}(l_i, l_j)))}{\sum_k \exp(f_\theta(\mathbf{x}(l_i, l_k)))} \quad (12)$$

El flujo estimado desde i hacia j es entonces $\hat{T}_{ij} = O_i \cdot p_{ij}$.

2.4.2. Arquitectura de la red neuronal

La función f_θ es implementada como una red neuronal *feedforward* de 15 capas ocultas con activación LeakyReLU. Las primeras 6 capas tienen dimensión 256 y las 9 restantes dimensión 128. La capa de salida produce un escalar:

$$\begin{aligned} \mathbf{z}^{(0)} &= \text{LeakyReLU}(W^{(0)} \mathbf{x}(l_i, l_j)) \\ \mathbf{z}^{(\ell)} &= \text{LeakyReLU}(W^{(\ell)} \mathbf{z}^{(\ell-1)}), \quad \ell = 1, \dots, 14 \\ f_\theta(\mathbf{x}(l_i, l_j)) &= \mathbf{w}^\top \mathbf{z}^{(14)} \end{aligned} \quad (13)$$

El modelo se entrena con el optimizador RMSprop (momentum = 0,9; tasa de aprendizaje = 5×10^{-6}), con *batches* de 64 zonas de origen. Para cada origen, se aplica *negative sampling*: se seleccionan hasta 512 destinos candidatos por origen, combinando destinos con flujos observados y destinos aleatorios sin flujos observados, lo que hace computacionalmente tratable la normalización del *softmax* sobre todas las zonas.

2.4.3. Vector de características geoespaciales

El vector de entrada $\mathbf{x}(l_i, l_j) \in \mathbb{R}^{39}$ concatena las características del origen, el destino y la distancia entre ellos:

$$\mathbf{x}(l_i, l_j) = [\mathbf{f}(l_i), \mathbf{f}(l_j), \ln P_i, \ln P_j, d_{ij}] \quad (14)$$

donde $\mathbf{f}(l) \in \mathbb{R}^{18}$ es el vector de 18 características geoespaciales extraídas de OpenStreetMap para la zona l , P_i y P_j son las poblaciones de origen y destino, y d_{ij} es la distancia geodésica entre sus centroides (en kilómetros). Las 18 características se organizan en 7 categorías:

uso del suelo (5 features), red vial (3 features), instalaciones de transporte (2 features), alimentación (2 features), salud (2 features), educación (2 features) y comercio (2 features). Todas ellas se normalizan dividiendo por el área de la zona, expresando su valor por kilómetro cuadrado.

2.4.4. Resultados y desempeño

Simini et al. [Simini et al., 2021] evaluaron *Deep Gravity* sobre datos de commuting de Inglaterra, Italia y el estado de Nueva York, utilizando la métrica *Common Part of Commuters* (CPC), definida como:

$$\text{CPC}(\hat{\mathbf{T}}, \mathbf{T}) = \frac{2 \sum_{i,j} \min(\hat{T}_{ij}, T_{ij})}{\sum_{i,j} \hat{T}_{ij} + \sum_{i,j} T_{ij}} \quad (15)$$

La métrica CPC toma valores en $[0, 1]$, donde 1 indica coincidencia exacta entre flujos generados y reales. Es equivalente al índice de Sørensen-Dice aplicado a flujos. Los resultados muestran que *Deep Gravity* supera al modelo gravitatorio clásico en todos los contextos evaluados. Las mejoras en CPC global alcanzan hasta un 190 % en Inglaterra y un 1.066 % en el estado de Nueva York. El modelo también demostró transferibilidad geográfica. Entrenado en algunas ciudades del Reino Unido, mantiene un desempeño similar al evaluarse en ciudades no vistas durante el entrenamiento.

2.5. Explicabilidad en modelos de inteligencia artificial (XAI)

La explicabilidad de la inteligencia artificial (*eXplainable Artificial Intelligence*, XAI) se refiere al conjunto de técnicas que permiten comprender e interpretar las predicciones de modelos de aprendizaje automático complejos [Lundberg y Lee, 2017]. En el contexto de la planificación del transporte, la explicabilidad es relevante no solo desde el punto de vista académico, para entender qué variables del territorio impulsan los flujos, sino también desde el punto de vista institucional, ya que permite a los planificadores auditar las predicciones del modelo.

2.5.1. Valores SHAP

SHAP (*SHapley Additive exPlanations*), propuesto por Lundberg y Lee [Lundberg y Lee, 2017], es un método de explicabilidad que fundamenta la importancia de cada variable en la teoría de juegos cooperativos de Shapley. La contribución de la característica i a la predicción del

modelo para una instancia $\mathbf{x}$ se define como:

$$\phi_i(f, \mathbf{x}) = \sum_{S \subseteq \mathcal{F} \setminus \{i\}} \frac{|S|! (|\mathcal{F}| - |S| - 1)!}{|\mathcal{F}|!} [f(S \cup \{i\}) - f(S)] \quad (16)$$

donde $\mathcal{F}$ es el conjunto de todas las características, S es una coalición de características que no incluye a i , y $f(S)$ es la predicción del modelo usando solo las características en S . El valor ϕ_i representa la contribución marginal promedio de la característica i sobre todas las posibles coaliciones de características.

Los valores SHAP satisfacen tres propiedades deseables: *eficiencia* (la suma de todos los valores SHAP es igual a la diferencia entre la predicción y el valor base), *simetría* (características con igual contribución marginal reciben igual valor SHAP) y *dummy* (características sin influencia reciben valor cero). En conjunto, estas propiedades garantizan una atribución justa y consistente de importancias.

En esta memoria se utilizan los valores SHAP para cuantificar el impacto de cada categoría de *amenity* de OpenStreetMap sobre la predicción de flujos del modelo *Deep Gravity*. El análisis SHAP permite determinar qué tipos de equipamiento urbano —educación, salud, comercio, transporte, entre otros— son los más determinantes en la generación de flujos para el contexto de Santiago de Chile.

2.5.2. Gradientes integrados

Los *Integrated Gradients* [Sundararajan et al., 2017] son un método de atribución basado en el gradiente de la función del modelo con respecto a las variables de entrada. Para una predicción $f(\mathbf{x})$ y una entrada de referencia $\mathbf{x}'$ (típicamente el vector nulo), la atribución de la característica i se define como:

$$\text{IG}_i(\mathbf{x}) = (x_i - x'_i) \cdot \int_0^1 \frac{\partial f(\mathbf{x}' + \alpha(\mathbf{x} - \mathbf{x}'))}{\partial x_i} d\alpha \quad (17)$$

En esta memoria, los *Integrated Gradients* se utilizan como técnica complementaria a SHAP para obtener atribuciones a nivel de par origen-destino específico, permitiendo identificar qué características son más relevantes para flujos particulares.

2.6. OpenStreetMap como fuente de datos geoespaciales

OpenStreetMap (OSM) es una base de datos geoespacial colaborativa y de libre acceso, construida y mantenida por una comunidad global de voluntarios desde su creación en 2004 [Haklay y Weber, 2008]. Su modelo de datos se articula en tres tipos de objetos geométricos: *nodos* (puntos), *vías* (secuencias de nodos que representan líneas o polígonos) y *relaciones*

(agrupaciones de nodos y vías con un significado semántico compartido). Cada objeto puede llevar asociados pares clave-valor denominados *etiquetas* (*tags*), que codifican su naturaleza (por ejemplo, *amenity=hospital* o *landuse=residential*).

Para el modelado de flujos de movilidad, OSM provee información sobre la distribución espacial de equipamientos y servicios urbanos, comúnmente denominados *amenities*, que el modelo *Deep Gravity* utiliza como variables explicativas. Estas incluyen establecimientos de salud, educación, comercio, alimentación, transporte, y áreas de uso de suelo residencial, comercial e industrial, entre otras categorías.

Una limitación reconocida de OSM en el contexto latinoamericano es la heterogeneidad espacial de su cobertura. Estudios previos [Barrington-Leigh y Millard-Ball, 2017] han documentado que la densidad y completitud de los datos OSM varía significativamente según el nivel socioeconómico y la accesibilidad de las distintas áreas de una ciudad. En Santiago, esto se manifiesta en una mayor completitud en comunas de ingresos medios y altos, como Providencia, Las Condes y Vitacura, y menor cobertura en comunas periféricas de menores ingresos. Esta heterogeneidad es un factor metodológico relevante para esta memoria. Puede sesgar la estimación de las características geoespaciales de entrada al modelo en las zonas con menor presencia de datos voluntarios. Este aspecto se aborda en el análisis de resultados.

2.7. Contexto de la movilidad en Santiago de Chile

Santiago de Chile es la capital de la Región Metropolitana y alberga aproximadamente siete millones de habitantes, distribuidos en más de cuarenta comunas. Es una de las ciudades de América Latina con mayor complejidad en su sistema de transporte público, que integra buses (*Red Metropolitana de Movilidad*), Metro, tren suburbano (Metrotren Nos) y sistemas de transporte activo [DPTM, 2025].

La principal fuente histórica de datos de movilidad en Santiago es la Encuesta Origen-Destino (EOD) del SECTRA⁵. Su última versión fue levantada en 2012, con actualizaciones parciales en 2017. Esta encuesta constituye la referencia canónica de flujos de movilidad en la ciudad. Sin embargo, su periodicidad de siete a diez años, combinada con el elevado costo de levantamiento, implica que los datos disponibles pueden no reflejar la movilidad actual, especialmente tras la reconfiguración de los patrones de desplazamiento producida por la pandemia de COVID-19.

Una fuente complementaria, de mayor resolución temporal, son los registros de validación de la tarjeta bip!, administrados por el DTPM⁶. Estos datos registran cada validación en Metro y buses con información de paradero, zona y hora, lo que permite construir matrices OD a

⁵Secretaría de Planificación del Transporte, organismo dependiente del Ministerio de Transportes y Telecomunicaciones de Chile.

⁶Directorio de Transporte Público Metropolitano.

nivel de viaje individual. No obstante, no cubren etapas caminadas, viajes en taxi o colectivo pagados en efectivo, ni modos no motorizados.

Esta memoria utiliza el dataset de viajes y etapas de noviembre de 2024 del DTPM, que comprende aproximadamente 3,6 millones de viajes en un mes completo, con información de zona de inicio, zona de fin, modo de transporte, hora, factor de expansión y coordenadas estimadas de subida y bajada. Este dataset, de mayor resolución temporal y amplitud que la EOD, permite construir matrices OD a escala diaria o por período horario (punta mañana, punta tarde, fuera de punta). Constituye la principal fuente de flujos observados para el entrenamiento y evaluación del modelo *Deep Gravity* en Santiago.

CAPÍTULO 3

TRABAJO RELACIONADO

El estudio de la movilidad humana y la predicción de flujos origen-destino (OD) ha experimentado una evolución metodológica fundamental en las últimas décadas. Este capítulo no busca enumerar exhaustivamente todas las investigaciones previas, sino trazar una línea evolutiva que contraste las fortalezas y debilidades de los distintos enfoques adoptados en la literatura científica. A través de este análisis se fundamentan las decisiones metodológicas que sustentan la presente memoria. Se demuestra por qué la integración de modelos de aprendizaje profundo con datos geospaciales abiertos constituye la alternativa más adecuada para el contexto actual.

3.1. Descubrimiento de patrones en la movilidad individual

Durante mucho tiempo, la falta de datos de trayectoria masivos obligó a los investigadores a extrapolar los patrones de movilidad humana a partir de la dispersión de billetes de banco, asumiendo que los desplazamientos individuales seguían trayectorias puramente aleatorias y no acotadas, similares a los vuelos de Lévy (*Lévy flights*).

Este paradigma fue refutado por González et al. [González et al., 2008], quienes utilizaron registros masivos de telefonía móvil (CDR, por sus siglas en inglés) de 100.000 usuarios durante seis meses para analizar la movilidad humana a nivel microscópico. Su trabajo demostró que, a diferencia del movimiento browniano o de los vuelos de Lévy, las trayectorias humanas son altamente predecibles, regulares y están fuertemente confinadas espacialmente. Los autores introdujeron el concepto de *radio de giro* para cuantificar la distancia típica recorrida por un individuo. Su análisis demostró que la aparente distribución pesada de saltos poblacionales es, en realidad, el resultado de agregar trayectorias individuales acotadas con una gran heterogeneidad en los radios de giro.

Esta contribución fue clave porque estableció que la movilidad urbana no es un fenómeno caótico, sino un sistema gobernado por rutinas (hogar-trabajo) y patrones espaciales predecibles. Esta previsibilidad estadística es la premisa fundamental que justifica el desarrollo de modelos matemáticos y algorítmicos para la predicción de flujos agregados.

3.2. Unificación de modelos clásicos y enfoques continuos

Con la confirmación de la regularidad en la movilidad humana, los esfuerzos se centraron en predecir los volúmenes de viaje entre distintas zonas de una ciudad o país. Tradicionalmente, este problema se abordó mediante el modelo gravitatorio [Zipf, 1946] y el mo-

delo de oportunidades intervinientes [Stouffer, 1940]. Más tarde, el modelo de radiación [Simini *et al.*, 2012] ofreció una solución libre de parámetros que superaba varias limitaciones empíricas de la formulación gravitatoria.

Sin embargo, estos modelos presentaban un problema matemático estructural: dependían fuertemente de la partición espacial utilizada (comunas, distritos, censos), lo que generaba inconsistencias espaciales. Además, salvo casos triviales, las formulaciones discretas como el modelo gravitatorio violaban la propiedad de *aditividad* (el flujo hacia una región compuesta no siempre equivalía a la suma de los flujos hacia sus subregiones).

Para resolver esto, Simini, Maritan y Néda [Simini *et al.*, 2013] propusieron un marco unificado en el continuo. Los autores formularon un principio estocástico general de selección de beneficios laborales que preserva estrictamente la aditividad de los flujos. Además, demostraron que la gravedad, las oportunidades intervinientes y la radiación son, matemáticamente, casos particulares de una misma familia de procesos de selección espacial continua. Asimismo, introdujeron un parámetro de selección (λ) que flexibilizó el modelo de radiación para adaptarlo a diferentes escalas geográficas.

A pesar de su solidez teórica y elegancia matemática, este paradigma continuo arrastra una limitación fundamental de representación: asume que la cantidad de oportunidades en una región es estrictamente proporcional a su masa poblacional. En la realidad urbana, existe una profunda segregación funcional del suelo (zonas industriales, distritos financieros, áreas puramente residenciales) que rompe esta proporcionalidad lineal, exigiendo modelos capaces de entender el tejido urbano más allá de la simple aglomeración de personas.

3.3. Evolución de los modelos de oportunidades intervinientes

El concepto de oportunidades intervinientes de Stouffer [Stouffer, 1940] inspiró, a lo largo de las décadas siguientes, una familia de modelos cada vez más sofisticados que buscaron superar las limitaciones paramétricas y escalares del modelo original. Liu y Yan [Liu y Yan, 2020] ofrecen una revisión sistemática de esta evolución, identificando una línea de progresión que va desde el modelo de radiación hasta un marco unificado de comportamiento de destino. Esta sección sigue esa trayectoria, enfatizando los modelos más relevantes para el contexto intraurbano de la presente memoria.

3.3.1. Modelo de oportunidades ponderadas por población

Yan *et al.* [Yan *et al.*, 2014] identificaron en sus experimentos que el modelo de radiación falla sistemáticamente al predecir flujos dentro de una ciudad: sobreestima los flujos de corto alcance y subestima los de largo alcance intraurbano. Los autores argumentaron que el supuesto de selección secuencial por proximidad no refleja la realidad del viajero urbano, quien

considera simultáneamente el conjunto completo de destinos disponibles en la ciudad.

Para corregir esto, Yan et al. [Yan et al., 2014] propusieron el *Modelo de Oportunidades Ponderadas por Población* (Population-Weighted Opportunity, PWO), en el que la probabilidad de elegir el destino j desde el origen i es proporcional a las oportunidades del destino e inversamente proporcional a las oportunidades totales dentro de un círculo centrado en el destino j con radio d_{ij} :

$$P_{ij} = \frac{m_j}{S_{ji}} \quad (18)$$

donde m_j es la cantidad de oportunidades (población) del destino j , y $S_{ji} = m_j + s_{ji} + m_i$ es el total de oportunidades dentro del círculo de radio d_{ij} centrado en j , incluyendo origen y destino. El cambio conceptual respecto al modelo de radiación es fundamental: en lugar de evaluar la competencia desde el origen, el modelo PWO evalúa la competencia desde el destino, capturando la lógica de atracción de un lugar sobre su entorno geográfico inmediato.

Al igual que el modelo de radiación, el modelo PWO es libre de parámetros: requiere únicamente la distribución de población de las zonas para generar predicciones, sin necesidad de calibración con datos históricos. Validado sobre datos de transporte público en múltiples ciudades chinas, el modelo PWO supera consistentemente al modelo de radiación en la predicción de viajes intraurbanos [Yan et al., 2014]. Yan et al. [Yan et al., 2017] extendieron posteriormente este modelo combinándolo con un proceso de caminata aleatoria con memoria, logrando reproducir simultáneamente los patrones de movilidad a nivel individual y los flujos agregados a nivel poblacional.

3.3.2. Modelos exploratorios: más allá de la selección secuencial

Tanto el modelo de radiación como el modelo PWO comparten un supuesto implícito sobre el comportamiento del viajero. El modelo de radiación asume una *tendencia cautelosa*: el individuo elige el destino más cercano que supera el beneficio del origen. El modelo PWO también incorpora una lógica de competencia local. En ambos casos, la distancia juega un papel restrictivo en la selección.

Investigaciones posteriores mostraron que este supuesto no aplica universalmente. Sim et al. [Sim et al., 2015] identificaron, en el contexto de la selección de contactos sociales, una *tendencia exploratoria*: los individuos que buscan el mejor resultado posible no se restringen a las opciones más cercanas, sino que aceptan recorrer distancias mayores si el destino ofrece un beneficio suficientemente alto. Trasladando esta lógica a la movilidad espacial, Liu y Yan [Liu y Yan, 2019] propusieron el *Modelo de Selección Prioritaria de Oportunidades* (Opportunity Priority Selection), en el que un individuo en i elige el destino j si su beneficio supera tanto al del origen como al de todas las oportunidades intervinientes:

$$P_{ij} = \frac{m_j}{S_{ij}} = \frac{m_j}{m_i + s_{ij} + m_j} \quad (19)$$

donde $S_{ij} = m_i + s_{ij} + m_j$ es el total de oportunidades en el círculo de radio d_{ij} centrado en el origen i . Este modelo, al igual que el PWO, es libre de parámetros y fue validado con buenos resultados tanto para viajes intraurbanos como interurbanos.

3.3.3. Modelo Unificado de Oportunidades

La existencia de modelos con supuestos comportamentales tan distintos —el cauteloso modelo de radiación y el exploratorio modelo de selección prioritaria— planteó una pregunta natural: ¿qué modelo aplicar en cada contexto? Liu y Yan [Liu y Yan, 2020] respondieron esta pregunta proponiendo el *Modelo Unificado de Oportunidades* (Universal Opportunity Model), un marco general con dos parámetros que engloba a los modelos anteriores como casos especiales. La probabilidad de que un individuo en i elija el destino j se formula como:

$$P_{ij} = \frac{(m_i + \alpha s_{ij}) m_j}{[m_i + (\alpha + \beta) s_{ij}] [m_i + (\alpha + \beta) s_{ij} + m_j]} \quad (20)$$

donde $\alpha \geq 0$ es el parámetro de *tendencia exploratoria* (cuán dispuesto está el individuo a alejarse buscando mayor beneficio) y $\beta \geq 0$ es el parámetro de *tendencia cautelosa* (preferencia por destinos cercanos), sujetos a $\alpha + \beta \leq 1$. Los modelos previos emergen como casos particulares de esta formulación:

- Si $\alpha = 0, \beta = 1$: la ecuación (20) se reduce a la ecuación (7) del modelo de radiación (comportamiento puramente cauteloso).
- Si $\alpha = 1, \beta = 0$: la ecuación (20) se reduce a la ecuación (19) del modelo de selección prioritaria (comportamiento puramente exploratorio).

Liu y Yan [Liu y Yan, 2020] validaron el modelo sobre 14 conjuntos de datos de movilidad a distintas escalas: carga de mercancías, commuting interurbano (EE.UU., Italia, Hungría), búsqueda de empleo, migración, viajes entre ciudades y viajes intraurbanos (Berlín, Londres, Beijing, Shenzhen, Suzhou). Sus resultados revelan un patrón sistemático: los flujos de commuting y carga exhiben alta tendencia cautelosa (los individuos priorizan destinos cercanos de alto beneficio), mientras que los desplazamientos intraurbanos presentan valores bajos de ambos parámetros, indicando que la masa poblacional por sí sola es insuficiente para capturar la complejidad de la elección de destino en la ciudad. Este hallazgo es particularmente relevante para la presente memoria: sugiere que las variables de oportunidad basadas en población deben complementarse con atributos del tejido urbano para modelar adecuadamente los flujos en Santiago de Chile.

Vale mencionar que esta familia de modelos ha demostrado una versatilidad que trasciende la movilidad de transporte. En el campo de la epidemiología, modelos como el de radiación y el PWO han sido utilizados para estimar probabilidades de contacto entre poblaciones y

parametrizar la difusión espacial de enfermedades infecciosas, incluyendo estudios sobre la propagación de COVID-19 [Liu y Yan, 2020]. Esta amplitud de aplicación evidencia la robustez conceptual del marco de oportunidades intervinientes.

3.4. Deep Learning y modelos espacio-temporales en movilidad

Para superar las limitaciones lineales y la dependencia exclusiva de la densidad poblacional, la literatura reciente ha migrado hacia el aprendizaje automático (*Machine Learning*) y el aprendizaje profundo (*Deep Learning*) [Rong et al., 2024a]. Las arquitecturas neuronales han demostrado una capacidad superior para capturar la no linealidad del entorno urbano.

Un avance significativo en esta línea es la incorporación explícita de Puntos de Interés (POIs) y características del entorno construido como variables condicionantes. Por ejemplo, Luca et al. [Luca et al., 2024] propusieron el *framework* TS-Mob, que combina modelos fundacionales de series de tiempo (*TimesFM*) con un módulo de atractividad gravitacional basado en perceptrones multicapa (MLP). Este modelo integra 16 categorías de POIs extraídas de bases de datos abiertas. Ello permite modular la probabilidad de atracción estructural de un destino en función de la oferta real de servicios comerciales, educativos o de salud, y no únicamente de su población.

No obstante, la transición hacia arquitecturas profundas introdujo nuevos desafíos. Las redes neuronales profundas y espaciales requieren enormes volúmenes de datos para evitar el sobreajuste y, más críticamente, operan como *cajas negras* [Rong et al., 2024a]. Estos modelos reducen drásticamente el error absoluto medio (MAE) y mejoran la similitud estructural de flujos (CPC) respecto a los modelos clásicos. Sin embargo, la incapacidad de explicar por qué el modelo predice un flujo determinado limita su adopción institucional. Este aspecto es crítico en la planificación urbana pública.

3.5. Generación de flujos mediante datos no convencionales

En el estado del arte más reciente (2024-2025), la investigación ha explorado métodos para mitigar la dependencia de datos socioeconómicos hiperlocales o de costosas encuestas de transporte. Destaca el paradigma de inferencia mediante imágenes satelitales y modelos generativos de grafos.

Un estudio fundacional en esta línea metodológica es el de Xu et al. [Xu et al., 2025], quienes desarrollaron *Imagery2Flow*, un modelo que emplea aprendizaje contrastivo y Redes de Atención en Grafos (GAT) para predecir flujos a partir de imágenes satelitales. Su investigación valida empíricamente a *Deep Gravity* como arquitectura de referencia en la literatura. Los autores demuestran que la versión con atributos espaciales (*Deep Gravity-V*) supera con claridad a la versión puramente poblacional (*Deep Gravity-P*). Este resultado confirma que

las características del entorno construido son determinantes para el aprendizaje profundo aplicado a la movilidad.

Posteriormente, Rong et al. [Rong et al., 2024b] extendieron este paradigma de inferencia satelital mediante *GLODGen*, un generador global de flujos OD basado en modelos de difusión (*Denoising Diffusion Networks*). Este *framework* utiliza un codificador visual multimodal (*RemoteCLIP*) para extraer un *embedding* semántico de 1.024 dimensiones directamente desde imágenes satelitales de alta resolución. Los autores reportan que el aspecto visual del entorno urbano y un mapa global de población poseen una expresividad superior al 98 % respecto al uso de datos multisectoriales complejos (catastros, POIs, atributos socioeconómicos). Su modelo, entrenado en Estados Unidos, demostró transferibilidad a ciudades de Europa, China, Brasil y África.

A pesar del salto tecnológico que representan estos modelos, presentan barreras prácticas relevantes. Suelen estar condicionados por sesgos geográficos propios de los contextos donde fueron entrenados. Su desempeño es además sensible a la calidad, iluminación y nubosidad de las imágenes satelitales. La limitación más crítica es de naturaleza interpretativa: la compresión del entorno urbano en *embeddings* altamente dimensionales sacrifica completamente la interpretabilidad semántica. Resulta imposible aislar el impacto de variables específicas como “presencia de escuelas” o “red de hospitales” sobre la predicción del flujo. Estas variables son, sin embargo, fundamentales para simular escenarios de impacto urbano y fundamentar políticas públicas.

3.6. En Resumen

La revisión de la literatura evidencia un claro *trade-off* en la evolución de los modelos de movilidad:

- Los modelos físicos y estadísticos clásicos (Secciones 3.1 y 3.2) ofrecen transparencia matemática, rigor explicativo y garantías de aditividad. Sin embargo, dependen exclusivamente de la distancia y la masa poblacional como variables *proxy* de oportunidad, lo que les impide modelar las no linealidades del uso de suelo urbano contemporáneo.
- Los modelos de la familia de oportunidades intervinientes (Sección 3.3) avanzaron hacia marcos libres de parámetros y comportamentalmente ricos, revelando que los desplazamientos intraurbanos requieren variables del tejido urbano para ser bien predichos. Sin embargo, continúan dependiendo de la población como único *proxy* de oportunidades.
- Los modelos avanzados basados en aprendizaje profundo, series de tiempo e imágenes satelitales (Secciones 3.4 y 3.5) alcanzan alta precisión predictiva y transferibilidad global. No obstante, operan como *cajas negras* opacas y computacionalmente costosas, lo que limita su utilidad para fundamentar políticas públicas explicables.

En este contexto metodológico, el uso del modelo *Deep Gravity* [Simini *et al.*, 2021] alimentado con datos de OpenStreetMap (OSM) y analizado mediante técnicas de explicabilidad SHAP [Lundberg y Lee, 2017] se posiciona como una solución de equilibrio o *sweet spot* para el caso de Santiago de Chile.

Por un lado, *Deep Gravity* reemplaza la rigidez heurística de los exponentes gravitacionales por una red neuronal profunda capaz de capturar relaciones no lineales entre el territorio y los flujos. A diferencia de los *embeddings* satelitales, utiliza variables explícitas y semánticamente interpretables provistas por OSM: centros de salud, red vial, escuelas y comercio. Por otro lado, su arquitectura relativamente simple facilita la aplicación de métodos de explicabilidad como SHAP. Ello permite no solo estimar los flujos con alta precisión, sino también auditar *por qué* ocurren, proveyendo evidencia interpretable para la planificación territorial en el Gran Santiago.

CAPÍTULO 4

PROPUESTA DE SOLUCIÓN

Se debe desarrollar la solución propuesta. Los subcapítulos por poner aquí son propios del autor. Se sugiere mencionar metodología usada. Es conveniente incorporar figuras y tablas para aclarar la solución, que deben indicar el número de la figura, su nombre y su autor o fuente (si las diseñas tú, la fuente es “Elaboración propia”). Ver ejemplos en esta página y en la siguiente.

Cabe mencionar que aquí está la esencia del trabajo en lo que se refiere al aporte creativo del memorista, es el momento de demostrar que usted es un destacado profesional que creó, diseñó y/o llevó a cabo la solución propuesta.

4.1. EJEMPLO DE COMO CITAR FIGURAS E ILUSTRACIONES

Se colocó una imagen que se puede referenciar también desde el texto (Ver figura 2).

Malla Curricular Ingeniería Civil Informática																							
AÑO 1				AÑO 2				AÑO 3				AÑO 4				AÑO 5		AÑO 5 1/2					
SEMESTRE I		SEMESTRE II		SEMESTRE III		SEMESTRE IV		SEMESTRE V		SEMESTRE VI		SEMESTRE VII		SEMESTRE VIII		SEMESTRE IX		SEMESTRE X		SEMESTRE XI			
IVI-131	QUI-010	INF-134	INF-253	INF-239	INF-236	INF-225	INF-322	INF-302															
Programación	Química y Sociedad	Estructuras de Datos	Lenguajes de Programación	Bases de Datos	Análisis y Diseño de Software	Ingeniería de Software	Diseño Interfaces Usuarios	Electivo Informática II															
3 5	3 5	3 5	12 3 5	12 3 5	12 3 5	12 3 5	12 3 5	3 5															
MAT-021	MAT-022	MAT-023	MAT-024	INF-245	INF-246	INF-256	INF-343	INF-303	INF-304														
Matemáticas I	Matemáticas II	Matemáticas III	Matemáticas IV	Arquitectura y Organización de Computadores	Sistemas Operativos	Redes de Computadores	Sistemas Distribuidos	Electivo Informática III	Electivo Informática IV														
5 8	5 7	4 7	4 6	12 3 5	12 3 5	12 3 5	12 3 5	3 5	3 5														
FIS-100	FIS-110	FIS-130	FIS-120	FIS-140	INF-276	ICN-270	INF-301	INF-311	INF-313														
Introducción a la Física	Física General I	Física General III	Física General II	Física General IV	Ingeniería, Informática y Sociedad	Información y Matemáticas Financieras	Electivo Informática I	Electivo I	Electivo III														
3 6	3 6	7 8	7 8	4 8	12 3 5	12 3 5	3 5	3 5	3 5														
	ING-101	INF-152	INF-155	INF-280	INF-221	INF-285	INF-295	INF-312	INF-314														
	Introducción a la Ingeniería	Estructuras Discretas	Informática Teórica	Estadística Computacional	Algoritmos y Complejidad	Computación Científica	Inteligencia Artificial	Electivo II	Electivo IV														
	2 3	1 2 3 5	12 16 3 5	1 16 3 5	1 16 3 5	1 16 3 5	1 16 3 5	3 5	6 10														
HRW-132	HRW-133	INF-260	INF-170	INF-270	INF-292	INF-293	INF-266	INF-360	INF-228														
Humanístico I	Humanístico II	Teoría de Sistemas	Economía IA	Organizaciones y Sistemas de Información	Optimización	Investigación de Operaciones	Sistemas de Gestión	Gestión de Proyectos de Ingeniería	Taller de Desarrollo de Proyecto de Ingeniería														
2 3	2 3	1 2 3 5	1 2 3 5	1 2 3 5	1 2 3 5	1 2 3 6	1 2 3 5	1 2 3 5	1 2 3 5														
DEW-100	DEW-101	INF-1	INF-2	INF-3	INF-4	INF-5	INF-6	INF-7	INF-309	INF-310													
Educación Física I	Educación Física II	Libre1/ Actividad co-curricular	Libre2/ Actividad co-curricular	Libre3/ Actividad co-curricular	Libre4/ Actividad co-curricular	Libre5/ Actividad co-curricular	Libre6/ Actividad co-curricular	Libre7/ Actividad co-curricular	Trabajo de Título 1	Trabajo de Título 2													
1 2	1 2	1 2	1 2	1 2	1 2	1 2	1 2	1 2	1 2	12 20													
14 24	18 28	18 32	18 31	17 30	16 27	16 28	16 27	16 27	16 27	12 20													
BACHILLER EN CIENCIAS DE LA INGENIERÍA				LICENCIADO EN CIENCIAS DE LA INGENIERÍA																			
Código asignatura: FIS-110 Número asignatura: 110 Nombre asignatura: Física General I Pre Requisito: QUI-010 Créditos USM SCT: 5				Matemáticas, Física y Química Transversal e Integración Humanidades, Educación Física y Libres Industrial y Comercial								Fundamentos de Informática Sistemas de Información y de Decisión Ingeniería de Software y Datos Infraestructura TIC								Computación Aplicada en Ciencia e Ingeniería Electivos Informática y Electivos			
												Al reverso perfil de egreso, inglés, prácticas, titulación, otros											
												Departamento de Informática											

Figura 2: Malla Curricular Ingeniería Civil Informática.

Fuente: Departamento de Informática.

CAPÍTULO 5

VALIDACIÓN DE LA SOLUCIÓN

Se debe validar la solución propuesta. Esto significa probar o demostrar que la solución propuesta es válida para el entorno donde fue planteada.

Tradicionalmente es una etapa crítica, pues debe comprobarse por algún medio que vuestra propuesta es básicamente válida. En el caso de un desarrollo de software es la construcción y sus pruebas; en el caso de propuestas de modelos, guías o metodologías podrían ser desde la aplicación a un caso real hasta encuestas o entrevistas con especialistas; en el caso de mejoras de procesos u optimizaciones, podría ser comparar la situación actual (previa a la memoria) con la situación final (cuando la memoria está ya implementada) en base a un conjunto cuantitativo de indicadores o criterios.

5.1. EJEMPLO DE COMO CITAR TABLAS

Se colocó una tabla que se puede referenciar también desde el texto (Ver tabla 1).

Tabla 1: Coloquios del Ciclo de Charlas Informática.
Fuente: Elaboración Propia.

Título Coloquio	Presentador, País
"Sensible, invisible, sometimes tolerant, heterogeneous, decentralized and interoperable... and we still need to assure its quality..."	Guilherme Horta Travassos, Brasil.
"Dispersed Multiphase Flow Modeling: From Environmental to Industrial Applications"	Orlando Ayala, EE.UU.
"Líneas de Producto Software Dinámicas para Sistemas atentos el Contexto"	Rafael Capilla, España.
...	...

CAPÍTULO 6

CONCLUSIONES

Las Conclusiones son, según algunos especialistas, el aspecto principal de una memoria, ya que reflejan el aprendizaje final del autor del documento. En ellas se tiende a considerar los alcances y limitaciones de la propuesta de solución, establecer de forma simple y directa los resultados, discutir respecto a la validez de los objetivos formulados, identificar las principales contribuciones y aplicaciones del trabajo realizado, así como su impacto o aporte a la organización o a los actores involucrados. Otro aspecto que tiende a incluirse son recomendaciones para quienes se sientan motivados por el tema y deseen profundizarlo, o lineamientos de una futura ampliación del trabajo.

Todo esto debe sintetizarse en al menos 5 páginas.

ANEXOS

En los Anexos se incluye todo aquel material complementario que no es parte del contenido de los capítulos de la memoria, pero que permiten a un lector contar con un contenido adjunto relacionado con el tema.

REFERENCIAS BIBLIOGRÁFICAS

- [Barrington-Leigh y Millard-Ball, 2017] Barrington-Leigh, C. y Millard-Ball, A. (2017). The world's user-generated road map is more than 80 % complete. *PLOS ONE*, 12(8):e0180698.
- [DPTM, 2025] DPTM (2025). Sistema de transporte público de santiago. <https://www.dtpm.cl/index.php/sistema-de-transporte-publico-de-santiago>. Consultado el 4 de octubre de 2025.
- [González *et al.*, 2008] González, M. C., Hidalgo, C. A., y Barabási, A.-L. (2008). Understanding individual human mobility patterns. *nature*, 453(7196):779–782.
- [Haklay y Weber, 2008] Haklay, M. y Weber, P. (2008). OpenStreetMap: User-generated street maps. *IEEE Pervasive Computing*, 7(4):12–18.
- [Kang *et al.*, 2015] Kang, C., Liu, Y., Guo, D., y Qin, K. (2015). Generalized radiation model for human mobility: spatial scale, searching direction and trip constraint. *PLOS ONE*, 10(11):e0143500.
- [Liu y Yan, 2019] Liu, E.-J. y Yan, X.-Y. (2019). Opportunity priority selection model for human mobility. *Physica A: Statistical Mechanics and its Applications*, 526:121023.
- [Liu y Yan, 2020] Liu, E.-J. y Yan, X.-Y. (2020). Research advances in intervening opportunity class models for predicting human mobility. *Acta Physica Sinica*, 69(24):248901.
- [Luca *et al.*, 2024] Luca, M., Beneduce, C., y Lepri, B. (2024). TS-Mob: Social and geographical-aware time series foundation-model framework for human mobility prediction. *arXiv preprint arXiv:2412.09180*.
- [Lundberg y Lee, 2017] Lundberg, S. M. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems*, volumen 30. Curran Associates, Inc.
- [Pappalardo *et al.*, 2023] Pappalardo, L., Simini, F., Barlacchi, G., y Pellungrini, R. (2023). scikit-mobility: a python library for the analysis, generation and risk assessment of mobility data. *Journal of Statistical Software*, 103(4):1–38.
- [Ren *et al.*, 2014] Ren, Y., Ercsey-Ravasz, M., Wang, P., González, M. C., y Toroczkai, Z. (2014). Predicting commuter flows in spatial networks using a radiation model based on temporal ranges. *Nature Communications*, 5(1):5347.
- [Rong *et al.*, 2024a] Rong, C., Ding, J., y Li, Y. (2024a). An interdisciplinary survey on origin-destination flows modeling: Theory and techniques. *ACM Computing Surveys*, 57(1):1–38.
- [Rong *et al.*, 2024b] Rong, C., Zhang, X., Xi, Y., Sui, H., Ding, J., y Li, Y. (2024b). Satellites reveal mobility: A commuting origin-destination flow generator for global cities. *arXiv preprint arXiv:2407.15392*.

- [Sim *et al.*, 2015] Sim, A., Yaliraki, S. N., Barahona, M., y Stumpf, M. P. (2015). Modelling the effects of subjective and objective decision making in scientific peer review. *Journal of The Royal Society Interface*, 12(107):20150315.
- [Simini *et al.*, 2021] Simini, F., Barlacchi, G., Luca, M., y Pappalardo, L. (2021). A deep gravity model for mobility flows generation. *Nature Communications*, 12(1):6576.
- [Simini *et al.*, 2012] Simini, F., González, M. C., Maritan, A., y Barabási, A.-L. (2012). A universal model for mobility and migration patterns. *Nature*, 484(7392):96–100.
- [Simini *et al.*, 2013] Simini, F., Maritan, A., y Nédá, Z. (2013). Human mobility in a continuum approach. *PloS one*, 8(3):e60069.
- [Stouffer, 1940] Stouffer, S. A. (1940). Intervening opportunities: a theory relating mobility and distance. *American Sociological Review*, 5(6):845–867.
- [Sundararajan *et al.*, 2017] Sundararajan, M., Taly, A., y Yan, Q. (2017). Axiomatic attribution for deep networks. En *Proceedings of the 34th International Conference on Machine Learning*, volumen 70, pp. 3319–3328. PMLR.
- [Xu *et al.*, 2025] Xu, Y., Gao, S., Huang, Q., Göçmen, A., Zhu, Q., y Zhang, F. (2025). Predicting human mobility flows in cities using deep learning on satellite imagery. *Nature Communications*, 16:10372.
- [Yan *et al.*, 2017] Yan, X.-Y., Wang, W.-X., Gao, Z.-Y., y Lai, Y.-C. (2017). Universal model of individual and population mobility on diverse spatial scales. *Nature Communications*, 8(1):1639.
- [Yan *et al.*, 2014] Yan, X.-Y., Zhao, C., Fan, Y., Di, Z., y Wang, W.-X. (2014). Universal predictability of mobility patterns in cities. *Journal of The Royal Society Interface*, 11(100):20140834.
- [Yang *et al.*, 2014] Yang, Y.-X., Herrera, C., Eagle, N., y González, M. C. (2014). Limits of predictability in human mobility. *Scientific Reports*, 4(1):5662.
- [Zipf, 1946] Zipf, G. K. (1946). The P1 P2/D hypothesis: on the intercity movement of persons. *American Sociological Review*, 11(6):677–686.